Előszó a Classics kiadáshoz

Megtiszteltetés számomra, hogy a SIAM a Classics sorozatában jelenteti meg a könyvemet. Ennek az új kiadásnak az előkészítése során jelentősen átdolgoztam a könyv leginkább frissítésre szoruló részeit, elsősorban a rendelkezésre álló szoftverekre vonatkozó hivatkozásokat és az irodalomjegyzéket. A könyv tartalmának nagyobbik része azonban időtállónak bizonyult, és nagyrészt érintetlen maradt. Szeretném azt hinni, hogy ez a könyv korszerű szemléletének köszönhető, de valószínűbb, hogy inkább az alapozó jellegéből adódik: a numerikus analízis és a tudományos számítások legalapvetőbb fogalmait és módszereit tárgyalja, amelyek viszonylag lassan változnak (Newton, Euler és Gauss nem publikált sokat az utóbbi időben!). A legjelentősebb technikai változás talán az, hogy a Lagrange-interpoláció baricentrikus alakját beépítettem a törzsanyagba – korábban ez csak egy feladatban szerepelt.

A könyv eredeti megjelenése óta számos új irányzat bontakozott ki, amelyek közül néhányra ez az új kiadás utal is, míg mások túlmutatnak a könyv keretein. Pedagógiai szempontból talán a legfontosabb trend a Python mint programozási nyelv és számítási környezet térnyerése, amely az oktatásban és a szakmai gyakorlatban egyaránt jelentős hatást gyakorolt. Ennek megfelelően a könyv szoftverhivatkozásait kiegészítettem a vonatkozó Python-csomagokkal. A szoftverek területén egy másik figyelemre méltó újdonság a Chebfun, amely több hagyományos megközelítést ötvöz innovatív módon, és ezáltal új, mélyreható számítási lehetőségeket kínál. A nagyléptékű tudományos számításokban a párhuzamosság egyre erőteljesebb kihasználásának tendenciája töretlenül folytatódott, ám a párhuzamos algoritmusok komoly tárgyalása már egy egész újabb könyvet igényelne.

Egy másik trend a sztochasztikus módszerek növekvő alkalmazása – például a lineáris algebrában és az optimalizálásban –, amelyet gyakran a gyorsan fejlődő területek, mint a gépi tanulás és az adattudomány alkalmazásai motiválnak. A könyv már eredetileg is tartalmazott egy rövid fejezetet a sztochasztikus módszerekről, amely jó alapot nyújt a további, más forrásokra támaszkodó tanulmányokhoz. A bizonytalanság-számszerűsítés (UQ) iránti érdeklődés is ugrásszerűen megnőtt az utóbbi években. A létezés, egyértelműség, kondicionáltság és stabilitás következetes hangsúlyozásával a könyv szilárd fogalmi alapot nyújt a számítási eredmények megbízhatóságának megítéléséhez, de a legújabb UQ-technikák részletes tárgyalása ismét csak meghaladja a kereteinket.

A korábbi kiadás megjelenése óta eltelt időszak fontos újdonsága, hogy elérhetővé vált mintegy 100 oktatási modul, amelyeket több diákkal együttműködve készítettem. Ezek a Java-appletek dinamikusan szemléltetik a tudományos számítások számos fogalmát és módszerét, és a könyvet kísérő interaktív példákként szolgálnak. Alkalmasak tantermi demonstrációkra, illetve a diákok önálló tanulásához is. A modulok elérhetők webböngészőn keresztül, illetve letölthetők egy önálló változatban, amely a felhasználó saját számítógépén futtatható. A modulok szabadon beszerezhetők a www.siam.org/books/cl80 címen.

Az eredeti előszóban megköszönt két mentorom (Alston Householder és Gene Golub) mellett szeretném ezt az alkalmat arra is használni, hogy elismerésemet fejezzem ki több szerzőnek, akiknek világos és elegáns stílusát következetesen inspirálónak és követendőnek találtam: Nick Higham, Pete Stewart, Gil Strang, Nick Trefethen és Charlie Van Loan. Végül ismét köszönetet szeretnék mondani feleségem, Mona türelméért és megértéséért, aki mellett „nyugdíjazásom” ellenére továbbra is dolgozom – illő, hogy ezzel az új kiadással végre ő is saját ajánlóoldalt kapjon!

Michael T. Heath

Előszó

Ez a könyv átfogó áttekintést nyújt a numerikus módszerekről olyan hallgatók és a gyakorlatban dolgozó szakemberek számára, akiknek matematikai feladatokat kell megoldaniuk a számításigényes tudományterületeken. A hagyományos numerikus analízis könyvektől abban különbözik, hogy a bemutatott algoritmusok mögött rejlő motivációra és gondolatokra helyezi a hangsúlyt, nem pedig azok részletes elemzésére. Igyekszem általános képet adni azokról a technikákról, amelyek az egyes nagyobb problémakategóriákban rendelkezésre állnak, ideértve a helyes feladatmegfogalmazást és az eredmények értelmezését, ugyanakkor ahol csak lehetséges, a professzionális matematikai szoftverek használatát szorgalmazom a feladatok megoldására. A könyv inkább a matematikai szoftverek potenciális felhasználóinak szól, mint az ilyen szoftverek lehetséges készítőinek. Remélem, hogy felhívhatom az olvasó figyelmét arra, hogy milyen kérdések lényegesek a megfelelő módszerek és szoftverek kiválasztásánál és körültekintő alkalmazásánál.

A University of Illinois-on ez a könyv egy átfogó, egyféléves numerikus módszerek kurzus tankönyveként szolgál, és több célt is betölt:

- Zárókurzusként végzős alapképzéses hallgatóknak, főként informatika, matematika és mérnöki szakokon
- Alapozó kurzusként olyan mesterképzéses hallgatóknak informatika és matematika szakon, akik tudományos számításokra kívánnak szakosodni
- Átfogó kurzusként olyan informatika mesterképzéses hallgatóknak, akik nem kívánnak tudományos számításokra szakosodni
- Gyakorlati képzésként olyan természettudományos és mérnöki mesterképzéses hallgatóknak, akiknek numerikus módszereket és szoftvereket kell használniuk a kutatásukban. Ez egy kötelező alapkurzus a Mérnöki Kar által támogatott interdiszciplináris Computational Science and Engineering mesterképzési programban.

Hogy ezt a sokszínű hallgatói kört kiszolgáljam, a kurzus és a könyv előkövetelményeit a lehető legalacsonyabb szintre szorítottam: alapvető jártasság a lineáris algebrában, a többváltozós analízisben és némi ismeret a differenciálegyenletekről. Numerikus módszerekben való előzetes jártasságot nem feltételezek. A könyv ugyanakkor meglehetősen kifinomult szemléletet alkalmaz, ezért a hallgatónál (vagy olvasónál) bizonyos fokú matematikai érettség ajánlott. Az akadémiai környezeten túl remélem, hogy a könyv kézikönyvként is hasznos lesz a gyakorló mérnökök és tudósok számára, akiknek gyors áttekintésre lehet szükségük egy adott számítási feladatról, valamint a megoldásához rendelkezésre álló módszerekről és szoftverekről.

Noha a könyv hangsúlyozza a matematikai szoftverek használatát, néhány más szoftverközpontú munkával ellentétben a kötet önmagában nem mellékel szoftvert, és nem összpontosít konkrét szoftvercsomagokra, könyvtárakra vagy környezetekre. Ehelyett minden problémakategóriához hivatkozásokat ad olyan konkrét rutinokra, amelyek nyilvánosan elérhető tárolókból, valamint a jelentősebb kereskedelmi könyvtárakból és csomagokból szerezhetők be. Sok akadémiai és ipari számítási környezetben az ilyen szoftverek már telepítve vannak, mindenesetre hivatkozások szerepelnek a nyilvánosan hozzáférhető, az interneten keresztül szabadon elérhető szoftverekre is. A könyvben szereplő számítógépes feladatok nem függenek egy konkrét szoftver vagy programozási nyelv megválasztásától.

A könyv felépítésének főbb elemei a következők:

Fejezetek: A könyv minden fejezete egy-egy jelentős számítási problémakört tárgyal. A könyv első fele főként algebrai feladatokkal, míg a második fele a deriváltakat és integrálokat érintő analitikus

feladatokkal foglalkozik. Az első két fejezet alapvető a könyv többi részéhez, a további fejezetek azonban az oktató preferenciája szerint különféle sorrendben tárgyalhatók. Pontosabban, a fejezetek közötti főbb függőségek nagyjából a következők:

Fejezet	Függ ettől	Fejezet	Függ ettől	Fejezet	Függ ettől
2	1	6	1, 2, 3, 5	10	1, 2, 5, 7, 9
3	1, 2	7	1, 2	11	1, 2, 7, 9, 10
4	1, 2, 3	8	1, 2, 7	12	1, 2, 7
5	1, 2	9	1, 2, 5, 7	13	1

Így a 7., 8., 12. és 13. fejezet sokkal korábban, míg a 3., 4. és 6. fejezet sokkal később is tárgyalhatók, mint ahogy a könyvben szerepelnek. Például a 3., 7. és 12. fejezet mindegyike valamilyen adatillesztést tartalmaz, így kívánatos lehet egy egységként tárgyalni őket. Egy másik példa: a lineáris egyenletrendszerek iterációs módszerei a parciális differenciálegyenletekről szóló 11. fejezetben találhatók, mert innen származnak a legfontosabb motivációs példák, de ennek az anyagnak nagy része közvetlenül a 2. fejezet lineáris egyenletrendszerekre vonatkozó direkt módszerei után is tárgyalható. Megjegyezzük, hogy a sajátértékek fogalmára a könyv többi részében széles körben építünk, így célszerű a 4. fejezetet viszonylag korán feldolgozni, hacsak a hallgatók már nem ismerik e téma alapjait.

A könyvben több mint elegendő anyag van egy teljes egyféléves kurzushoz, így egy egyféléves kurzusban körültekintő válogatásra lehet szükség. Például a véletlen számokról és a sztochasztikus szimulációról szóló 13. fejezet csak érintőlegesen kapcsolódik a könyv többi részéhez, és nyilvánvaló jelölt az elhagyásra (véletlenszám-generátorokat azonban a könyv számos feladatában használunk). A teljes könyv két negyedéves (quarter) vagy kétféléves kurzus alatt dolgozható fel.

Példák: Szinte minden bevezetett fogalmat és módszert egy vagy több példa illusztrál. Ezek a példák a viszonylag tömör általános tárgyalás kiegészítését szolgálják, és a szöveg lényeges részeként olvasandók. A példákat a lehető legegyszerűbben tartottam (akár a túlzott leegyszerűsítés kockázatát is vállalva), hogy az olvasó könnyen követhesse őket. Tapasztalatom szerint egy alaposan megértett egyszerű példa rendszerint többet segít, mint egy realisztikusabb, de nehezebben követhető.

Szoftverek: Az egyes problémakategóriákhoz tartozó, rendelkezésre álló szoftverek listája igyekszik kellően átfogó lenni. Nem kíséreltem meg kiemelni a „legjobb” szoftvert egy-egy adott feladathoz, részben azért, mert rendszerint egyetlen csomag sem múlja felül a többit minden tekintetben, részben pedig azért, hogy figyelembe vegyem a különböző olvasóknál fennálló eltérő szoftverelérhetőséget és programozásinyelv-választást. Minden idézett szoftver legalábbis professzionálisan fejlesztett, némelyikük pedig egészen kiváló.

Feladatok: A könyv sok feladatot tartalmaz, amelyek három kategóriába sorolhatók:

- Áttekintő kérdések, amelyek rövid választ igényelnek, és az alapvető fogalmi megértés ellenőrzésére szolgálnak
- Gyakorló feladatok, amelyek valamivel több gondolkodást, hosszabb válaszokat és esetleg kézi számításokat igényelnek
- Számítógépes feladatok, amelyek némi programozást igényelnek, és gyakran meglévő szoftverek használatát is magukban foglalják.

Az áttekintő kérdések az olvasó öntesztelését szolgálják. Szándékosan tartalmaznak némi ismétlést, hogy rögzítsék a kulcsfontosságú gondolatokat, és megerősítsék a hallgatók magabiztosságát az anyag elsajátításában. A hosszabb feladatok írásbeli házi feladatok céljára alkalmasak. Némelyikük egyszerű példákkal való kézi számítást igényel, míg másokat úgy terveztem, hogy pótolják a törzsanyagból kimaradt levezetések és bizonyítások részleteit. Ez utóbbiak különösen hasznosak lehetnek, ha a könyvet elméletibb jellegű kurzushoz használjuk. A számítógépes feladatok lehetőséget biztosítanak a gyakorlati tapasztalatszerzésre az ajánlott szoftverek használatában, az egyes kategóriákhoz tartozó tipikus feladatok megoldására. Egyes feladatok általánosak, mások viszont közvetlenül kapcsolódnak a különböző tudományos és mérnöki diszciplínák konkrét alkalmazásaihoz.

Változások a második kiadásban. Minden fejezet most motiváló bevezetővel és egy vagy több szemléltető példával kezdődik, amelyet az adott típusú feladat megoldásainak létezését, egyértelműségét és kondicionáltságát vizsgáló rész követ. A cél az, hogy a hallgató jobban megértse, miért fontos az adott feladat, és hogyan ismerheti fel a „jó” vagy „rossz” feladatmegfogalmazást, mielőtt a megoldó algoritmusokat tárgyalnánk. A legfontosabb algoritmusokat formálisan is megadtam, és a könnyebb hivatkozhatóság érdekében sorszámmal láttam el. Az irodalomjegyzéket naprakésszé tettem, a történeti jegyzeteket pedig némileg kibővítettem. Az 1. fejezetben az előreható és hátraható hibákról, valamint azok kapcsolatáról szóló részt kibővítettem és pontosítottam. A szingulárisérték-felbontásról szóló anyag nagy részét a 4. fejezetből a 3. fejezetbe helyeztem át, ahol alkalmazásai jobban illeszkednek. A 4. fejezetben a sajátérték-algoritmusok tárgyalását kibővítettem, több motivációval és részlettel – különösen a QR-iterációról –, valamint néhány további módszerrel. A 6. fejezet feltételes optimalizálásról szóló elemzését lényegesen kibővítettem. A differenciálegyenletekről szóló fejezeteket némileg átszerveztem, a spektrális módszerek bemutatását pedig kiegészítettem. A gyors Fourier-transzformációról szóló 12. fejezetet átalakítottam, és letisztultabbá tettem néhány felesleges rész elhagyásával.

Szeretném megköszönni mentoraim hatását, akik először bevezettek a numerikus számítás szépségeibe: Alston Householdernek és Gene Golubnak. Hálás vagyok azért a bőséges visszajelzésért, amelyet a könyv első kiadását használó hallgatóktól és oktatóktól kaptam. Az első kiadás előzetes lektorai a következők voltak: Alan George, University of Waterloo; Dianne O'Leary, University of Maryland; James Ortega, University of Virginia; John Strikwerda, University of Wisconsin; és Lloyd N. Trefethen, Oxford University. A második kiadás előkészítésében segédkező lektorok a következők voltak: Thomas Coleman, Cornell University; Robert Funderlic, North Carolina State University; Thomas Hagstrom, University of New Mexico; Ramon Moore, Ohio State University; Mark Pernarowski, Montana State University; Linda Petzold, University of California at Santa Barbara; és Brian Suchomel, University of Minnesota. Köszönöm valamennyi lektor felbecsülhetetlen értékű javaslatait. Ezen felül külön köszönetet szeretnék mondani kollégáimnak – Joerg Liesennek, Paul Saylornak és Eric de Sturlernek, mindhármuknak a University of Illinois-ról –, akik mindegyike elolvasta az átdolgozott kézirat egy részét vagy egészét, és rendkívül értékes visszajelzést adott. Köszönöm Melchior Franznak és Justin Winklernek a tördeléssel kapcsolatos hasznos tanácsait, amelyek elengedhetetlenek voltak a nyomdakész példány előkészítéséhez. Végül végtelenül hálás vagyok feleségemnek, Monának a türelméért és megértéséért e könyv megírásának és átdolgozásának számtalan órája alatt. Nagy örömmel és hálával ajánlom neki ezt a könyvet.

Michael T. Heath

A könyv honlapja: www.siam.org/books/cl80 A szerző honlapja: heath.cs.illinois.edu

Jelölések

A könyvben használt jelölésrendszer meglehetősen szabványos, és kevés magyarázatra szorul. Szabadon használunk vektor- és mátrixjelölést: mátrixokat általában nagybetűs félkövér szedéssel, vektorokat kisbetűs félkövér szedéssel, skalárokat pedig normál szedéssel jelölünk. Az iterációs és komponensindexeket alsó indexszel jelöljük, általában i-től n-ig. Például egy x vektornak és egy A mátrixnak rendre x_i és a_{ij} elemei vannak. Azokban a ritkább esetekben, amikor iterációs index és komponensindex egyaránt szükséges, az iterációt zárójeles felső index jelzi, például $x_i^{(k)}$ egy sorozat k-adik vektorának i-edik komponensét jelenti. Egyébként x_i az x vektor i-edik komponensét jelöli, míg x_k egy sorozat k-adik vektorát.

Az egyszerűség kedvéért elsősorban valós vektorokkal és mátrixokkal foglalkozunk, noha az általunk tárgyalt elmélet és algoritmusok nagy része kevés változtatással (vagy akár változtatás nélkül) átvihető a komplex esetre. A valós számok halmazát $\mathbb{R}$ jelöli, az n-dimenziós valós euklideszi teret $\mathbb{R}^n$, a valós $m \times n$ mátrixok halmazát pedig $\mathbb{R}^{m\times n}$. A komplex eset megfelelő jelölései rendre $\mathbb{C}$, $\mathbb{C}^n$ és $\mathbb{C}^{m\times n}$.

Egy vektor vagy mátrix transzponáltját felső T index jelzi, konjugált transzponáltját pedig felső H index (a Hermitian transpose rövidítése). Hacsak másként nem jelezzük, minden vektort oszlopvektornak tekintünk; egy sorvektort egy oszlopvektor explicit transzponálásával adunk meg. A tördelési kényelem kedvéért egy oszlopvektor komponenseit néha a megfelelő sorvektor transzponáltjaként jelöljük, például $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^T$. Két n-dimenziós $\mathbf{x}$ és $\mathbf{y}$ vektor belső szorzata (más néven skaláris szorzat) a mátrixszorzás speciális eseteként áll elő, ezért $\mathbf{x}^T\mathbf{y}$-nal jelöljük (vagy $\mathbf{x}^H\mathbf{y}$-nal a komplex esetben). Hasonlóképpen két n-dimenziós $\mathbf{x}$ és $\mathbf{y}$ vektor külső szorzata, amely egy $n \times n$-es mátrix, $\mathbf{x}\mathbf{y}^T$ alakban írható. Az n-edrendű egységmátrixot $\mathbf{I}_n$ jelöli (vagy csak $\mathbf{I}$, ha az n dimenzió a szövegkörnyezetből egyértelmű), i-edik oszlopát pedig $\mathbf{e}_i$. A zérusmátrixot $\mathbf{O}$, a zérusvektort $\mathbf{0}$, a zérusskalárt pedig 0 jelöli. A $d_1, \dots, d_n$ átlóbeli elemekkel rendelkező diagonális mátrixot $\operatorname{diag}(d_1, \dots, d_n)$ jelöli. Vektorok vagy mátrixok közötti egyenlőtlenségek elemenként értelmezendők. Az $m \times n$-es $\mathbf{A}$ mátrix oszlopai által kifeszített alteret $\mathbb{R}^m$-ben, azaz $\{\mathbf{A}\mathbf{x} : \mathbf{x} \in \mathbb{R}^n\}$-t, $\operatorname{span}(\mathbf{A})$ jelöli.

Egyváltozós $f(t)$ függvény közönséges deriváltját df/dt vagy $f'(t)$ jelöli. Többváltozós függvények – például $u(x, y)$ – parciális deriváltjait $\partial u/\partial x$ alakban, vagy egyes szövegkörnyezetekben alsó indexszel, például u_x alakban jelöljük. A gradiensvektorok, a Jacobi-mátrixok és a Hesse-mátrixok jelölését szükség szerint vezetjük be. Minden logaritmus természetes alapú (az alap $e \approx 2{,}718$), hacsak más alapot kifejezetten nem jelölünk. A $\approx$ szimbólumot hagyományos értelemben vett közelítő egyenlőségre, a $\cong$ szimbólumot pedig kifejezetten legkisebb négyzetes közelítésekre tartjuk fenn.

A numerikus algoritmusok számítási költségét, avagy számítási komplexitását általában a szükséges aritmetikai műveletek számával mérjük. Hagyományosan a numerikus analízisben csak a szorzásokat számolták (esetleg az osztásokat és négyzetgyökvonásokat is), mert a szorzás általában lényegesen drágább volt az összeadásnál vagy kivonásnál, és mert a legtöbb algoritmusban a szorzások jellemzően hasonló számú összeadással párosulnak (például két vektor belső szorzatának számításánál). Újabban az összeadás és a szorzás közötti költségkülönbség nagyrészt eltűnt (sőt, sok modern mikroprocesszor egyetlen szorzás-összeadás utasítással el tudja végezni az összevont szorzást és összeadást). A számítógépgyártók és -felhasználók szeretik a legmagasabb lehetséges teljesítményt hirdetni, ezért egyre gyakoribb, hogy minden egyes aritmetikai műveletet számolnak. Mivel azonban egyes műveletszámok nagyon jól ismertek a hagyományos gyakorlat szerint, ebben

a könyvben rendszerint csak a szorzásokat számoljuk. Az egyértelműség kedvéért hozzátesszük a „és hasonló számú összeadás” fordulatot, vagy külön jelezzük, ha mindkét műveletet számoljuk.

A műveletszám és a közelítések pontosságának számszerűsítéséhez gyakran a „nagy O” jelölést használjuk egy függvény nagyságrendjének, illetve domináns tagjának megadására. Műveletszám esetén arra vagyunk kíváncsiak, hogyan viselkedik a függvény, ha a feladat mérete – mondjuk n – nagy lesz. Azt mondjuk, hogy

$$f(n) = \mathcal{O}(g(n))$$

(„f nagy O-ja g-nek”, vagy „f g nagyságrendű”), ha létezik olyan C pozitív állandó, amelyre

$$|f(n)| \leq C|g(n)|$$

minden elég nagy n-re teljesül. Például

$$2n^3 + 3n^2 + n = \mathcal{O}(n^3),$$

mert ahogy n nagy lesz, az n^3-nál kisebb rendű tagok relatíve jelentéktelenné válnak. Pontossági becslésnél egy olyan h mennyiség (például egy lépésköz vagy rácstávolság) kicsivé válását vizsgáljuk. Azt mondjuk, hogy

$$f(h) = \mathcal{O}(g(h)),$$

ha létezik olyan C pozitív állandó, amelyre

$$|f(h)| \leq C|g(h)|$$

minden elég kicsi h-ra teljesül. Például

$$\frac{1}{1-h} = 1 + h + h^2 + h^3 + \cdots = 1 + h + \mathcal{O}(h^2),$$

mert ahogy h kicsivé válik, a h^2-nél magasabb rendű elhagyott tagok relatíve jelentéktelenné válnak. Vegyük észre, hogy a két definíció ekvivalens, ha $h = 1/n$.

Tudományos számítások

1.1 Bevezetés

Ennek a könyvnek a tárgyát hagyományosan numerikus analízisnek nevezik. A numerikus analízis olyan algoritmusok tervezésével és elemzésével foglalkozik, amelyek számos területen – különösen a természettudományokban és a mérnöki tudományokban – felmerülő matematikai feladatokat oldanak meg. Ezért a numerikus analízist az utóbbi időben tudományos számításoknak is nevezik. A tudományos számításokat a számítástudomány legtöbb más ágától az különbözteti meg, hogy folytonos, nem pedig diszkrét mennyiségekkel foglalkozik. Olyan függvényekkel és egyenletekkel

dolgozik, amelyek alapul szolgáló változói – idő, távolság, sebesség, hőmérséklet, sűrűség, nyomás, feszültség és hasonlók – természetüknél fogva folytonosak.

A folytonos matematika legtöbb feladata (például szinte bármely feladat, amely deriváltakat, integrálokat vagy nemlinearitást tartalmaz) még elvben sem oldható meg véges számú lépésben egzaktul, ezért ezeket egy (elméletileg végtelen) iteratív eljárással kell megoldani, amely végül a megoldáshoz konvergál. A gyakorlatban természetesen nem iterálunk örökké, hanem csak addig, amíg a válasz megközelítőleg helyes, azaz gyakorlati célokra „elég közel" van a kívánt eredményhez. Így a tudományos számítások egyik legfontosabb aspektusa a gyorsan konvergáló iteratív algoritmusok megtalálása és a kapott közelítés pontosságának felmérése. Ha a konvergencia kellően gyors, akkor még néhány olyan feladat is, amely véges algoritmussal megoldható – mint például a lineáris algebrai egyenletrendszerek –, bizonyos esetekben előnyösebben oldható meg iterációs módszerekkel, amint azt látni fogjuk.

Ebből kifolyólag a tudományos számítások egy másik megkülönböztető jellemzője, hogy foglalkozik a közelítések hatásaival. Sok megoldási technika különféle típusú közelítések egész sorozatát foglalja magában. Még a használt aritmetika is csak közelítő, hiszen a digitális számítógépek nem tudnak minden valós számot egzaktul ábrázolni. A jó algoritmusok szokásos tulajdonságain – például a hatékonyságon – túl a numerikus algoritmusoknak a lehető legmegbízhatóbbnak és legpontosabbnak kell lenniük az útközben alkalmazott különféle közelítések ellenére.

1.1.1 Számítási feladatok

Ahogy a név is sugallja, a tudományos számításokban felmerülő sok feladat a természettudományokból és a mérnöki tudományokból származik, ahol a végső cél valamely természeti jelenség megértése vagy egy eszköz tervezése. A számítógépes szimuláció egy fizikai rendszer vagy folyamat számítógépes ábrázolása és utánzása. A számítógépes szimuláció nagymértékben elmélyítheti a tudományos megértést, mert lehetővé teszi olyan helyzetek vizsgálatát, amelyeket kizárólag elméleti, megfigyelési vagy kísérleti úton nehéz vagy lehetetlen volna vizsgálni. Az asztrofizikában például két ütköző fekete lyuk részletes viselkedése túl bonyolult ahhoz, hogy elméletileg meghatározzuk, és lehetetlen közvetlenül megfigyelni vagy laboratóriumban reprodukálni. Számítógépes szimulációjához mindössze egy megfelelő matematikai leírásra (ebben az esetben Einstein általános relativitáselméleti egyenleteire), az egyenletek numerikus megoldására szolgáló algoritmusra és egy elegendően nagy számítógépre van szükség, amelyen az algoritmus implementálható.

A számítógépes szimuláció nemcsak egzotikus vagy egyébként hozzáférhetetlen helyzetek feltárására hasznos, hanem a „normális" forgatókönyvek szélesebb körének vizsgálatát is lehetővé teszi, mint amennyit ésszerű költséggel és idővel egyébként vizsgálni lehetne. A mérnöki tervezésben a számítógépes szimuláció lehetővé teszi, hogy sok tervezési alternatívát sokkal gyorsabban, olcsóbban és biztonságosabban próbáljunk ki, mint a fizikai prototípusokat használó hagyományos „építsd meg és teszteld" módszerekkel. Ebben az értelemben a számítógépes szimuláció virtuális prototípus-készítés néven is ismertté vált. A gépjárműbiztonság javításánál például a töréstesztszámítógépen sokkal olcsóbb és veszélytelenebb, mint a valóságban, így a lehetséges tervezési paraméterek tere sokkal alaposabban feltárható egy optimális terv kidolgozásához.

A számítógépes szimuláció átfogó problémamegoldási folyamata általában a következő lépéseket tartalmazza:

- 1. Az érdeklődési körbe tartozó fizikai jelenség vagy rendszer matematikai modelljének kidolgozása – általában valamilyen típusú egyenletekkel megfogalmazva.
- 2. Algoritmusok kidolgozása az egyenletek numerikus megoldására.

- 3. Az algoritmusok implementálása számítógépes szoftverben.
- 4. A szoftver futtatása számítógépen, a fizikai folyamat numerikus szimulálására.
- 5. A számított eredmények valamilyen érthető formában – például grafikus megjelenítéssel – való bemutatása.
- 6. A számított eredmények értelmezése és validálása, szükség esetén az előző lépések bármelyikének megismétlésével.

Az 1. lépést gyakran matematikai modellezésnek nevezik. Ehhez az érintett tudományos vagy mérnöki terület speciális ismerete, valamint az alkalmazott matematikában való jártasság szükséges. A 2. és 3. lépés – numerikus algoritmusok és szoftverek tervezése, elemzése, implementálása és használata – a tudományos számítások fő témája, így e könyvé is. Noha a 2. és 3. lépésre összpontosítunk, lényeges, hogy mindezek a lépések – a probléma megfogalmazásától egészen az eredmények értelmezéséig és validálásáig – megfelelően történjenek, hogy az eredmények értelmesek és hasznosak legyenek. A tudományos számítások elveit és módszereit meglehetősen általános szinten lehet tanulmányozni, amint azt látni fogjuk, de a konkrét feladat konkrét forrását és az eredmények felhasználási módját mindig szem előtt kell tartani, mivel mindegyik szempont hat a többire és fordítva. Például az eredeti feladatmegfogalmazás erősen befolyásolhatja a numerikus eredmények pontosságát, ami viszont kihat az eredmények értelmezésére és validálására.

Egy matematikai feladatot jól kitűzöttnek mondunk, ha létezik megoldása, az egyértelmű, és folytonosan függ a feladat adataitól. Az utóbbi feltétel azt jelenti, hogy a feladat adatainak kis megváltozása nem okoz hirtelen, aránytalan változást a megoldásban; ez a tulajdonság különösen fontos a numerikus számításokban, ahol – amint hamarosan látni fogjuk – az ilyen perturbációk általában elkerülhetetlenek. A jól kitűzöttség erősen kívánatos a fizikai rendszerek matematikai modelljeiben, de ez nem mindig érhető el. Például egy fizikai rendszer belső szerkezetére csak külső megfigyelésekből való következtetés – mint a tomográfiában vagy a szeizmológiában – gyakran eredendően rosszul kitűzött matematikai feladatokra vezet, amelyekben egymástól jelentősen eltérő belső konfigurációk megkülönböztethetetlen külső megjelenéssel rendelkeznek.

Még ha egy feladat jól kitűzött is, a megoldás akkor is nagyon érzékenyen (bár folytonosan) reagálhat a feladat adataiban bekövetkező perturbációkra. Ahhoz, hogy felmérjük az ilyen perturbációk hatásait, a folytonosság kvalitatív fogalmán túl kell lépnünk, és meg kell határoznunk a feladat érzékenységének mennyiségi mértékét. Ezenfelül ügyelnünk kell arra is, hogy az adott feladat numerikus megoldására használt algoritmus ne tegye az eredményeket érzékenyebbé annál, mint ami az alapul szolgáló feladatban eleve benne rejlik (a „ne árts!” hippokratészi eskü a numerikus matematikusokra éppúgy vonatkozik, mint az orvosokra). Ez a követelmény vezet el a stabil algoritmus fogalmához. Ezeket az általános fogalmakat és kérdéseket ebben a fejezetben vezetjük be, majd a későbbi fejezetekben részletesen is tárgyaljuk őket a konkrét típusú számítási feladatok kapcsán.

1.1.2 Általános stratégia

Egy adott számítási feladat megoldása során – és ez a könyvön végigvonuló alapvető stratégia – az a célunk, hogy egy nehéz feladatot egy könnyebbre cseréljünk, amelynek ugyanaz a megoldása, vagy legalábbis nagyon közel áll ahhoz. Ennek a megközelítésnek a példái:

- Végtelendimenziós terek helyettesítése végesdimenziós terekkel
- Végtelen folyamatok helyettesítése véges folyamatokkal, például integrálok vagy végtelen sorok helyettesítése véges összegekkel, illetve a deriváltak helyettesítése véges differenciákkal
- Differenciálegyenletek helyettesítése algebrai egyenletekkel

- Nemlineáris feladatok helyettesítése lineáris feladatokkal
- Magasabb rendű rendszerek helyettesítése alacsonyabb rendű rendszerekkel
- Bonyolult függvények helyettesítése egyszerű függvényekkel, például polinomokkal
- Általános mátrixok helyettesítése egyszerűbb alakú mátrixokkal

Például egy nemlineáris differenciálegyenlet-rendszert először egy nemlineáris algebrai egyenletrendszerrel helyettesíthetünk, majd a nemlineáris algebrai rendszert egy lineáris algebrai rendszerrel, végül pedig a lineáris rendszer mátrixát olyan speciális alakú mátrixra cserélhetjük, amellyel a megoldás már könnyen kiszámítható. E folyamat minden lépésében meg kell győződnünk arról, hogy a megoldás nem változott meg, vagy legalábbis a valódi megoldáshoz képest egy előírt tűréshatáron belül marad.

Ahhoz, hogy ez az általános stratégia egy adott feladatra működjön, a következők megléte szükséges:

- Egy olyan alternatív feladat vagy feladatosztály, amely könnyebben megoldható
- Az eredeti feladatnak egy olyan transzformációja ebbe az alternatív típusba, amely valamilyen értelemben megőrzi a megoldást

Így erőfeszítéseink nagy része olyan megfelelő feladatosztályok azonosítására irányul, amelyeknek egyszerű megoldásuk van, valamint az ilyen osztályokba vezető, megoldástartó transzformációk megtalálására.

Ideális esetben a transzformált feladat megoldása azonos az eredeti feladat megoldásával, de ez nem mindig lehetséges. Az utóbbi esetben a megoldás csak közelíti az eredeti feladatét, de a pontosság általában tetszőlegesen javítható további számítási munka és tárhely árán. Ezért elsődleges feladatunk az ilyen közelítő megoldás pontosságának becslése és annak igazolása, hogy határértékben a valódi megoldáshoz konvergál.

1.2 Közelítések a tudományos számításokban

1.2.1 A közelítés forrásai

A tudományos számításokban a közelítésnek, illetve a pontatlanságnak számos forrása van. Néhány közelítés már a számítás megkezdése előtt felléphet:

- Modellezés: A vizsgált feladat vagy rendszer bizonyos fizikai jellemzőit leegyszerűsíthetjük vagy elhagyhatjuk (pl. súrlódás, viszkozitás, légellenállás).
- Empirikus mérések: A laboratóriumi műszereknek véges a pontossága. Pontosságukat tovább korlátozhatja a kis mintaelemszám, vagy a leolvasott értékeket véletlen zaj, illetve szisztematikus torzítás is terhelheti. Például még a fontos fizikai állandók – mint a Newton-féle gravitációs állandó vagy a Planck-állandó – legalaposabb méréseiből is jellemzően legfeljebb nyolc vagy kilenc értékes jegyet kapunk, a legtöbb laboratóriumi mérés pedig ennél jóval pontatlanabb.
- Korábbi számítások: A bemenő adatok egy korábbi számítási lépésből származhatnak, amelynek eredményei csak közelítők voltak.

Az imént felsorolt közelítésekre általában nincs ráhatásunk, de fontos szerepet játszanak annak meghatározásában, hogy egy számítástól milyen pontosság várható. Figyelmünket elsősorban azokra a közelítésekre fordítjuk, amelyeket képesek vagyunk befolyásolni. Ezek a számítás közben fellépő szisztematikus közelítések a következők:

• Csonkítás vagy diszkretizáció: egy matematikai modell bizonyos jellemzőit elhagyhatjuk vagy leegyszerűsíthetjük (pl. deriváltakat véges differenciákkal helyettesítünk, vagy egy végtelen sornak

csak véges sok tagját használjuk).

• Kerekítés: legyen szó kézi számításról, zsebszámológépről vagy digitális számítógépről, a valós számok és a rajtuk végzett aritmetikai műveletek ábrázolása végső soron véges pontosságra korlátozódik, így általában nem egzakt.

Egy számítás végeredményének pontossága ezen közelítések bármelyikéből, vagy akár mindegyikének együttes hatásából is fakadhat, a fellépő perturbációkat pedig a megoldandó feladat természete vagy a használt algoritmus – netán mindkettő – fel is erősítheti. Az ilyen közelítéseknek a numerikus algoritmusok pontosságára és stabilitására gyakorolt hatásának vizsgálatát hagyományosan hibaelemzésnek nevezik.

1.1. Példa. Közelítések. A Föld felszínét egy r sugarú gömb felszínképletével, az

$$A = 4\pi r^2$$

összefüggéssel számíthatjuk ki. Ennek a képletnek a használata a számításban számos közelítést foglal magában:

- A Földet gömbként modellezzük, ami a tényleges alakjának idealizálása.
- Az $r \approx 6370$ km sugárérték empirikus mérések és korábbi számítások kombinációján alapul.
- A π értékét egy végtelen határérték-folyamat adja meg, amelyet valahol csonkolni kell.
- A bemenő adatok numerikus értékei, valamint a rajtuk végzett aritmetikai műveletek eredményei egy számítógépen vagy számológépen kerekítéssel állnak elő.

A számított eredmény pontossága mindezektől a közelítésektől függ.

1.2.2 Abszolút hiba és relatív hiba

Egy hiba jelentősége nyilvánvalóan összefügg a mért vagy számított mennyiség nagyságával. Például egy egységnyi hiba sokkal kisebb jelentőségű a Föld népességének számolásánál, mint egy telefonfülke lakóinak számolásánál. Ez motiválja az *abszolút hiba* és a *relatív hiba* fogalmait, amelyeket a következőképpen definiálunk:

$$\text{abszolút hiba} = \text{közelítő érték} - \text{valódi érték},$$

$$\text{relatív hiba} = \frac{\text{abszolút hiba}}{\text{valódi érték}}.$$

Egyes szerzők az abszolút hibát a fenti különbség abszolút értékeként definiálják, de mi az abszolút értéket (vagy vektorok és mátrixok esetén a normát) csak akkor alkalmazzuk, amikor kifejezetten a hiba nagyságára van szükségünk. Megjegyezzük, hogy a relatív hiba nincs definiálva, ha a valódi érték nulla.

A relatív hiba százalékban is kifejezhető, ami egyszerűen a relatív hiba 100-szorosa. Így például egy 0,1-es abszolút hiba a 10-es valódi értékhez viszonyítva 0,01, azaz 1 százalékos relatív hibának felel meg. Egy teljesen hibás közelítés legalább 1, azaz legalább 100 százalékos relatív hibának felelne meg, ami azt jelenti, hogy az abszolút hiba akkora, mint maga a valódi érték.

A relatív hiba egy másik értelmezése: ha egy közelítő érték relatív hibája körülbelül 10^{-p}, akkor tizedestört alakja körülbelül p helyes értékes jegyet tartalmaz (az értékes jegyek az első nem nulla

számjegytől kezdve az azt követő összes jegyet jelentik). Ezzel kapcsolatban érdemes különbséget tenni a *precízió* és a *pontosság* között: a precízió azon jegyek számára utal, amelyekkel a számot kifejezzük, a pontosság pedig a kívánt mennyiség közelítésében helyes értékes jegyek számára (azaz a relatív hibára). Például a 3,252603764690804 egy nagyon precíz szám, de a π közelítéseként nem túl pontos. Amint hamarosan látni fogjuk, az, hogy egy mennyiséget adott precízióval számítunk, önmagában nem jelenti, hogy az eredmény ugyanilyen mértékben lesz pontos.

Az abszolút és relatív hiba közötti összefüggés egy hasznos alakja a következő:

$$\text{közelítő érték} = (\text{valódi érték}) \times (1 + \text{relatív hiba}).$$

Természetesen általában nem ismerjük a valódi értéket; ha ismernénk, nem kellene bajlódnunk a közelítésével. Ezért a hibát rendszerint csak becsüljük vagy felső korlátot adunk rá, nem pedig egzaktul kiszámítjuk, hiszen a valódi érték ismeretlen. Ugyanezen okból a relatív hibát gyakran a közelítő értékhez, nem pedig a valódi értékhez viszonyítva számítják, eltérően a fenti definíciótól.

1.2.3 Adathiba és számítási hiba

Amint láttuk, egyes hibák a bemenő adatoknak tulajdoníthatók, míg mások a későbbi számítási folyamatok során keletkeznek. Bár ez a megkülönböztetés nem mindig egyértelmű (a kerekítés például érintheti a bemenő adatokat és a későbbi számítási eredményeket is), mégis segít megérteni a közelítéseknek a numerikus számításokra gyakorolt összhatását.

A legtöbb realisztikus feladat többdimenziós, de az egyszerűség kedvéért ebben a fejezetben csak egydimenziós feladatokat vizsgálunk; a definíciók és eredmények magasabb dimenziókra való kiterjesztése egyértelmű, általában csak az abszolút értékek megfelelő normákra cserélését igényli (lásd a 2.3.1. szakaszt). Egy tipikus egydimenziós feladat felfogható egy függvény – mondjuk $f : \mathbb{R} \to \mathbb{R}$ – értékének számításaként, amely egy adott bemenő értéket egy kimenő eredményhez rendel. Jelölje a bemenet valódi értékét x, így a kívánt valódi eredmény $f(x)$. Tegyük fel, hogy pontatlan bemenettel, mondjuk $\hat{x}$-szel kell dolgoznunk, és csak egy közelítést – mondjuk $\hat{f}$-et – tudunk számítani a függvényértékre. Ekkor azzal a jól ismert matematikai trükkel, hogy ugyanazt a mennyiséget hozzáadjuk és kivonjuk úgy, hogy az összeg változatlan maradjon, a következőt kapjuk:

$$\begin{aligned}
\text{teljes hiba} &= \hat{f}(\hat{x}) - f(x) \\
&= (\hat{f}(\hat{x}) - f(\hat{x})) + (f(\hat{x}) - f(x)) \\
&= \text{számítási hiba} + \text{továbbterjedő adathiba}.
\end{aligned}$$

Ebben az összegben az első tag a pontos és a közelítő függvény különbsége ugyanazon bemenet mellett, tehát tiszta *számítási hibának* tekinthető. A második tag a pontos függvényértékek különbsége a bemenet hibája miatt, tehát tiszta *továbbterjedő adathibának* tekinthető. Megjegyezzük, hogy az algoritmus megválasztása nincs hatással a továbbterjedő adathibára.

1.2. Példa. Adathiba és számítási hiba. Tegyük fel, hogy nincs számítógépünk vagy számológépünk, és „gyors, de durva” közelítésre van szükségünk a $\sin(\pi/8)$ értékére. Először a π valamilyen értékére van szükségünk a bemenethez. Röviden fontolóra vesszük a $\pi \approx 22/7$ klasszikus, iskoláskorunkból megmaradt közelítést, de úgy döntünk, túl sok munka volna átváltani a kívánt tizedestört alakba, és inkább a $\pi \approx 3$ egyszerű „bibliai” közelítésnél maradunk, így

a tényleges bemenetünk 3/8. A függvényérték kiszámításához felidézzük az analízisből, hogy kis argumentumokra jó közelítést ad a Taylor-sor első tagja, ami $\sin(x)$ esetén egyszerűen x. Végeredményünk tehát

$$\sin(\pi/8) \approx \sin(3/8) \approx 3/8 = 0{,}3750.$$

A fenti közelítések közül az első – egy perturbált $\hat{x} = 3/8$ bemenet használata a valódi $x = \pi/8$ helyett – továbbterjedő adathibát okoz: még ha egzaktul számítanánk is ki a szinuszfüggvényt, hibás eredményt kapnánk, mert hibás bemenetet használtunk. A második közelítés egy számítási hibát jelent, noha a „számításunk" ebben az esetben csupán a bemenet lemásolása volt! (A számítási hibák gyakran ilyen „elhagyásból eredő" hibák, bár általában nem ennyire szélsőségesek.) A korábban bevezetett jelölésben az $\hat{f}(x) = x$ csonkolt matematikai kifejezést használtuk a valódi $f(x) = \sin(x)$ függvény helyett, ami azt jelenti, hogy még helyes bemenet esetén is helytelen eredményt kaptunk volna. A végeredmény pontosságát e két közelítés kombinációja határozza meg.

Később – miután hozzáférünk egy zsebszámológéphez – megállapítjuk, hogy négy tizedesjegy pontossággal a helyes válasz

$$\sin(\pi/8) \approx 0{,}3827,$$

így a teljes hiba

$$\hat{f}(\hat{x}) - f(x) \approx 0{,}3750 - 0{,}3827 = -0{,}0077.$$

Észrevéve, hogy a perturbált bemenetre a helyes válasz

$$f(\hat{x}) = \sin(3/8) \approx 0{,}3663,$$

látjuk, hogy a pontatlan bemenet használata által okozott továbbterjedő adathiba

$$f(\hat{x}) - f(x) = \sin(3/8) - \sin(\pi/8) \approx 0{,}3663 - 0{,}3827 = -0{,}0164.$$

A végtelen sor csonkolásából adódó számítási hiba pedig

$$\hat{f}(\hat{x}) - f(\hat{x}) = 3/8 - \sin(3/8) \approx 0{,}3750 - 0{,}3663 = 0{,}0087.$$

E két hiba összege adja a megfigyelt teljes hibát. Ebben a konkrét példában a két hibának ellentétes az előjele, tehát részben kioltják egymást; más körülmények között azonos előjelűek is lehetnek, és ekkor felerősítik egymást. Ennél a bemenetnél a továbbterjedő adathiba és a számítási hiba nagyságrendileg hasonló – körülbelül kétszeres szorzóval tér el –, de bármelyik hibaforrás dominánssá válhat más bemenő értékek esetén. Ha a π-re és a $\sin(x)$-re ugyanezeket a közelítéseket használjuk, a továbbterjedő adathiba sokkal kisebb bemeneteknél lenne domináns, míg a számítási hiba sokkal nagyobb bemeneteknél (Miért?). A teljes hiba csökkentésére használhatnánk pontosabb értéket π-re (ami csökkentené a továbbterjedő adathibát), vagy pontosabb matematikai leírást $\sin(x)$-re (pl. a végtelen sor több tagját), ami csökkentené a számítási hibát.

1.2.4 Csonkítási hiba és kerekítési hiba

A számítási hiba (azaz a számítás során keletkező hiba) tovább bontható *csonkítási* (vagy *diszkretizációs*) *hibára* és *kerekítési hibára*:

- A csonkítási hiba a valódi eredmény (a tényleges bemenet mellett) és az adott algoritmus egzakt aritmetikával kapott eredménye közötti különbség. Olyan közelítésekből ered, mint egy végtelen sor csonkolása, a deriváltak végesdifferencia-formulákkal való helyettesítése, vagy egy iterációs eljárás konvergencia előtti megszakítása.
- A kerekítési hiba az adott algoritmus egzakt aritmetikával kapott eredménye és ugyanezen algoritmus véges precíziójú, kerekített aritmetikával számított eredménye közötti különbség. A valós számok és a rajtuk végzett aritmetikai műveletek ábrázolásának pontatlanságából ered, amelyet az 1.3. szakaszban részletesen is tárgyalunk.

A definíció szerint tehát a számítási hiba egyszerűen a csonkítási hiba és a kerekítési hiba összege. Az 1.2. példában a bemenetet kerekítettük, de a számítás során nem volt kerekítési hiba, így a számítási hiba kizárólag a végtelen sor egyetlen tagjának használatából eredő csonkítási hibából állt. Több tag használata a sorban csökkentette volna a csonkítási hibát, de valószínűleg némi kerekítési hibát is bevezetett volna a sor kiszámításához szükséges aritmetikába. A csonkítási és a kerekítési hibák közötti ehhez hasonló kompromisszumok egyáltalán nem szokatlanok.

1.3. Példa. Végesdifferencia-közelítés. Egy differenciálható $f : \mathbb{R} \to \mathbb{R}$ függvényre tekintsük az első derivált végesdifferencia-közelítését:

$$f'(x) \approx \frac{f(x+h) - f(x)}{h}.$$

A Taylor-tétel szerint

$$f(x+h) = f(x) + f'(x)h + f''(\theta)h^2/2$$

valamely $\theta \in [x, x+h]$ esetén, így a végesdifferencia-közelítés csonkítási hibája felülről korlátozható $Mh/2$-vel, ahol M egy $|f''(t)|$-re adott felső korlát az x környezetében. Feltéve, hogy a függvényértékek hibáját ϵ korlátozza, a végesdifferencia-képlet kiszámításának kerekítési hibája $2\epsilon/h$-val becsülhető. A teljes számítási hiba így felülről korlátozható két tag összegével:

$$\frac{Mh}{2} + \frac{2\epsilon}{h},$$

ahol az első tag h csökkenésével egyre kisebb lesz, a második pedig egyre nő. Ezért a h lépésköz megválasztásánál kompromisszum áll fenn a csonkítási hiba és a kerekítési hiba között. Ezt a kifejezést h szerint deriválva és a deriváltat nullával egyenlővé téve látható, hogy a teljes számítási hibára adott korlát a minimumát

$$h = 2\sqrt{\epsilon/M}$$

esetén veszi fel. Egy tipikus példa az 1.1. ábrán látható, ahol a végesdifferencia-közelítés teljes számítási hibáját – a csonkítási és kerekítési hibákra adott külön-külön korlátokkal együtt – az $f(x) = \sin(x)$ függvényre $x = 1$-ben ábrázoltuk a h lépésköz függvényében, $M = 1$ mellett és egy

$\epsilon \approx 10^{-16}$ precíziójú számítógépen. Láthatjuk, hogy a teljes hiba valóban $h \approx 10^{-8} \approx \sqrt{\epsilon}$ környékén éri el a minimumát. A teljes hiba a túl nagy h értékek esetén a növekvő csonkítási hiba miatt, a túl kicsi h értékek esetén pedig a növekvő kerekítési hiba miatt indul növekedésnek.

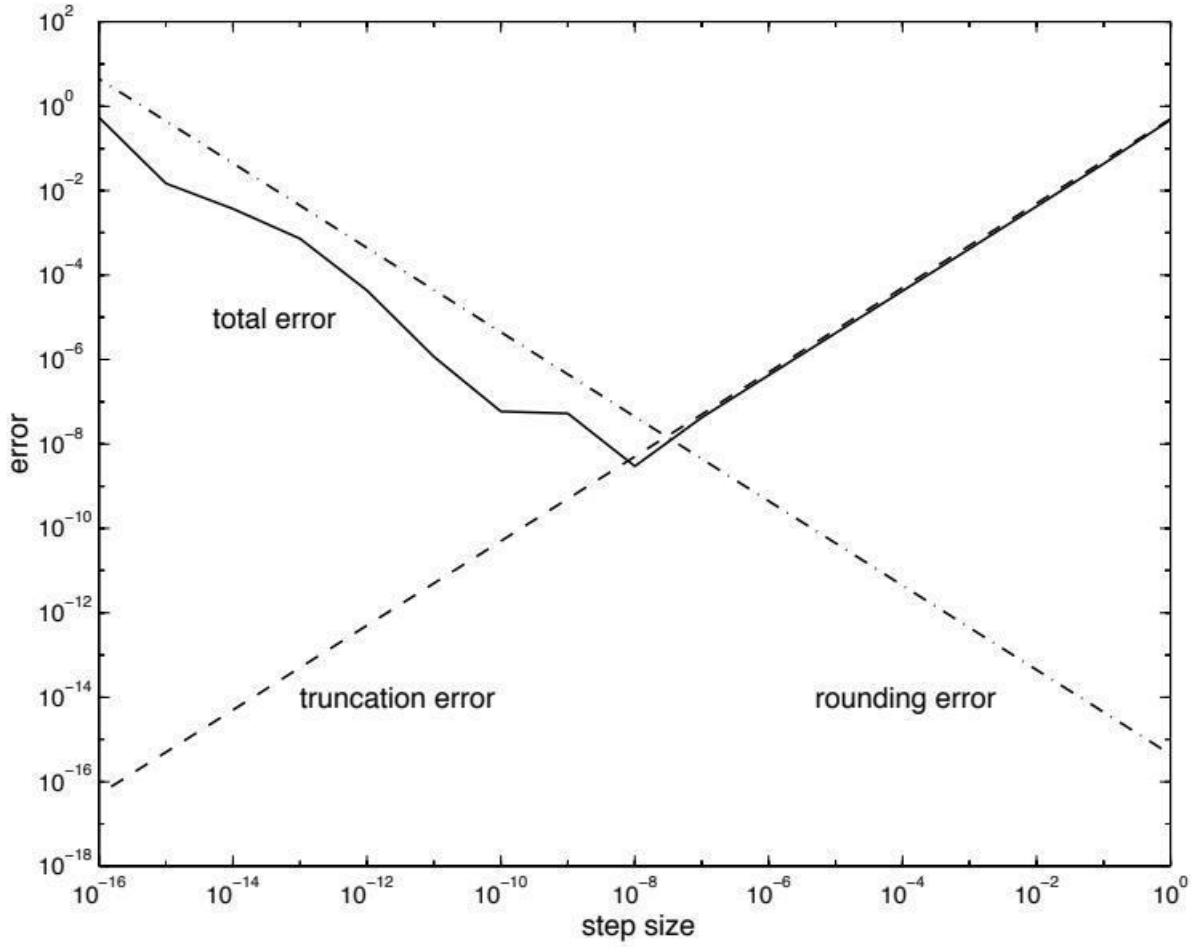

1.1. ábra: A végesdifferencia-közelítés számítási hibája adott lépésközre.

A csonkítási hiba csökkenthető lenne pontosabb végesdifferencia-formula használatával, például a középpontos differencia-közelítéssel (lásd a 8.6.1. szakaszt):

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}.$$

A kerekítési hiba magasabb precíziójú aritmetikával csökkenthető, ha rendelkezésre áll.

Bár egy adott számításban a csonkítási hiba és a kerekítési hiba egyaránt fontos szerepet játszhat, általában egyik vagy másik válik a teljes számítási hiba domináns tényezőjévé. Nagyjából elmondható, hogy a kerekítési hiba rendszerint a tisztán algebrai, véges megoldási algoritmusú feladatokban dominál, míg a csonkítási hiba az integrálokat, deriváltakat vagy nemlinearitást tartalmazó feladatokban, amelyek gyakran elméletileg végtelen megoldási folyamatot igényelnek.

A különböző hibatípusok között tett megkülönböztetéseink fontosak a numerikus algoritmusok

viselkedésének és a pontosságukat befolyásoló tényezők megértéséhez, de az egyes hibatípusokat általában nem szükséges – és nem is mindig lehetséges – pontosan kvantifikálni. Valójában, amint hamarosan látni fogjuk, gyakran előnyös, ha az összes hibát összevonjuk és a bemenő adatok hibájára visszavezetjük.

1.2.5 Előreható hiba és hátraható hiba

Egy számított eredmény minősége egyéb tényezők mellett a bemenő adatok minőségétől is függ. Ha például a bemenő adatok csak – mondjuk – négy értékes jegyre pontosak, akkor legfeljebb négy értékes jegyet várhatunk a számított eredményben is, bárhogy is végezzük a számítást. A jól ismert számítástechnikai alapigazság, a „szemét megy be, szemét jön ki" (garbage in, garbage out) ezt a megfigyelést viszi a logikus végletekig. Ezért a számított eredmények minőségének értékelésekor nem szabad figyelmen kívül hagynunk a bemenő adatok – bizonytalansági szintjükön belüli – perturbációinak lehetséges hatásait.

1.4. Példa. Az adathiba hatásai. Tegyük fel, hogy egy ország népességét szeretnénk előrejelezni tíz év múlva. Először egy matematikai modellre van szükségünk, amely leírja a népesség időbeli változásait. Feltéve, hogy a születések és a halálozások egyaránt arányosak a mindenkori népességgel, a

$$P(t + \Delta t) = P(t) + (B - D)P(t)\Delta t$$

egyszerű modellhez jutunk, ahol $P(t)$ a népességet jelöli a t időpontban, Δt egy adott időintervallum (mondjuk egy év), B és D pedig a születési és halálozási ráta (például a nettó növekedési ráta $B - D = 0{,}04$, azaz évi 4 százalék lehet). Használhatjuk ezt a diszkrét modellt egy rögzített Δt időintervallummal, vagy vehetjük a $\Delta t \to 0$ határátmenetet, hogy a

$$dP(t)/dt = (B - D)P(t)$$

differenciálegyenlethez jussunk, amelynek megoldása a jól ismert exponenciális növekedési törvény:

$$P(t) = P(0)\exp\big((B - D)t\big).$$

Mindkét esetben a modell nyilvánvalóan csak közelítése a valóságnak; például elhanyagoltuk a bevándorlást és a korlátozott eltartóképesség (kapacitás) esetleges hatásait. Bár e szemléltetésben az ilyen modellezési hibákat figyelmen kívül hagyjuk, szinte minden valós tudományos feladatban való jelenlétük miatt mérsékelnünk kell a további számításokban elérhető pontossággal szembeni elvárásainkat. Akár a diszkrét, akár a folytonos modellt használjuk népesség-előrejelzéshez, ismernünk kell a jelenlegi népességet, valamint a születési és halálozási rátákat. Közismert, hogy egy népszámlálásnál nehéz mindenkit megszámolni anélkül, hogy valakit kihagynánk, így a kiindulási népesség csak korlátozott pontossággal ismert. Ennek megfelelően a kiindulási népességet rendszerint „kerek számokkal" (azaz csak néhány értékes jeggyel) adják meg, utalva az érték bizonytalansági szintjére. Ezt nem szabad kerekítési hibának tekinteni, mert a kapott érték éppúgy lehet helyes, mint egy precízebbnek tűnő érték, hiszen az elhagyott jegyek kétségesek vagy értelmetlenek voltak. Hasonlóképpen a születési és halálozási ráták is – amelyek sok diszkrét eseményre vett átlagok – csak korlátozott pontossággal ismertek.

A modellünk bemenetében lévő bizonytalanságok szükségszerűen bizonyos bizonytalanságot okoznak a kapott népesség-előrejelzésben is. Következésképpen úgy tekinthetjük a modellünket, hogy a bemeneti tér egy „elmosódott” tartományát a kimeneti tér egy „elmosódott” tartományára képezi le (ez utóbbi az összes lehetséges bemenet-kombináció bizonytalansági tartományán belül adódó összes lehetséges eredmény halmaza). A modell implementálása során némi számítási hiba (csonkítási vagy kerekítési hiba) léphet fel, de amíg az előállított eredmény a bemenő adatok bizonytalanságának megfelelő kimeneti tér elmosódott tartományában marad, addig az eredmény aligha kifogásolható. Másként fogalmazva: bármely eredmény – bárhogy is kaptuk –, amely egzakt eredménye egy ugyanolyan valószínűséggel helyes bemenetnek, mint amilyet ténylegesen használtunk, annyira jó válasz, amennyire csak joggal elvárhatunk.

Most formalizáljuk ezeket a fogalmakat, ismét az egyszerűség kedvéért egydimenziós feladatokra összpontosítva. Tegyük fel, hogy egy $y = f(x)$ függvényérték kiszámítása a cél, ahol $f : \mathbb{R} \to \mathbb{R}$, de helyette egy közelítő $\hat{y}$ értéket kapunk. A számított és a valódi érték közötti eltérést, $\Delta y = \hat{y} - y$, *előreható hibának* nevezzük. A számított eredmény minősége értékelésének egyik módja, hogy megpróbáljuk megbecsülni ennek az előreható hibának a relatív nagyságát, ami a konkrét körülményektől függően lehet könnyű vagy nehéz. Általában azonban egy számításban a hibák előrefelé történő terjedésének (propagálásának) elemzése – a későbbiekben látható okokból – gyakran nehéz. Sőt, a minden szakaszban feltételezett legrosszabb esetek gyakran nagyon pesszimista korlathoz vezetnek a teljes hibára nézve.

Egy alternatív megközelítés, ha a kapott közelítő megoldást úgy tekintjük, mint egy módosított feladat egzakt megoldását, és megkérdezzük: mekkora módosítás szükséges az eredeti feladathoz ahhoz, hogy éppen a ténylegesen kapott eredményt adja? Más szóval: mekkora adathibára volna szükség a kiindulási bemenetben, hogy megmagyarázza a végső számított eredmény összes hibáját? Formálisabban a $\Delta x = \hat{x} - x$ mennyiséget – ahol $f(\hat{x}) = \hat{y}$ – *hátraható hibának* nevezzük, amelynek relatív nagyságát a hátraható hibaelemzésben próbáljuk megbecsülni. Ebből a nézőpontból egy adott feladatra adott közelítő megoldás akkor jó, ha egy „közeli” feladat egzakt megoldása (azaz a relatív hátraható hiba kicsi). Ha pedig a közeli feladat a bemenő adatok bizonytalanságán belül van, akkor a $\hat{y}$ számított megoldás valójában lehet „a” valódi megoldás, amennyire tudhatjuk (vagy tudhatnánk, tekintve a bemenet bizonytalanságát), tehát aligha kifogásolható.

Ezeket az összefüggéseket sematikusan (nem méretarányosan) az 1.2. ábra szemlélteti, ahol x és f rendre az egzakt bemenet és az egzakt függvény, $\hat{f}$ a ténylegesen számított közelítő függvény, $\hat{x}$ pedig egy olyan bemeneti érték, amelyre az egzakt függvény éppen ezt a számított eredményt adná. Megjegyezzük, hogy a $\hat{f}(x) = f(\hat{x})$ egyenlőség éppen $\hat{x}$ választásából adódik; valójában ez a követelmény definiálja $\hat{x}$-et. Az 1.2.6. szakaszban számszerűsítjük az előreható és a hátraható hiba közötti kapcsolatot.

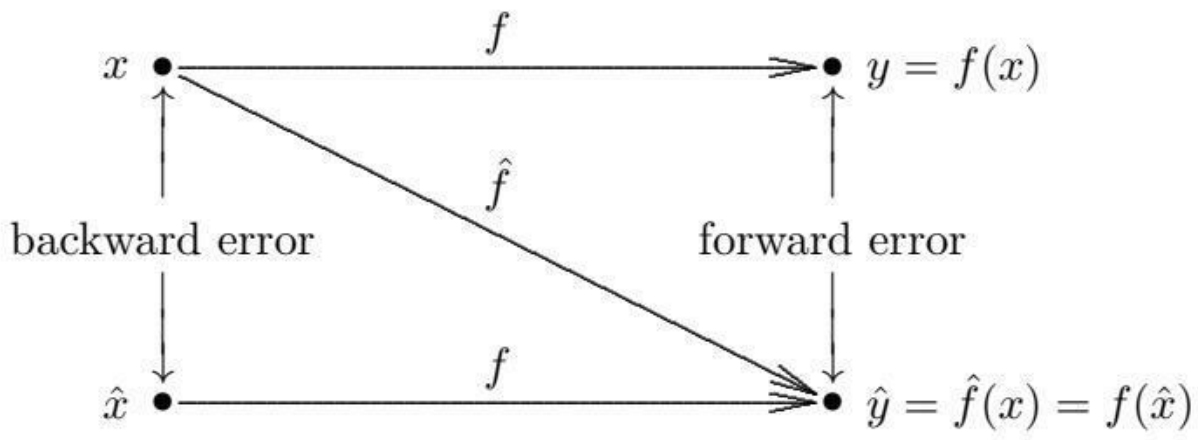

1.2. ábra: Sematikus ábra az előreható és a hátraható hiba szemléltetésére.

1.5. Példa. Előreható és hátraható hiba. A $y = \sqrt{2}$ közelítéseként a $\hat{y} = 1{,}4$ érték abszolút előreható hibája

$$|\Delta y| = |\hat{y} - y| = |1{,}4 - 1{,}41421\ldots| \approx 0{,}0142,$$

azaz körülbelül 1 százalékos relatív előreható hiba. A hátraható hiba meghatározásához megfigyeljük, hogy $\sqrt{1{,}96} = 1{,}4$, tehát az abszolút hátraható hiba

$$|\Delta x| = |\hat{x} - x| = |1{,}96 - 2| = 0{,}04,$$

azaz 2 százalékos relatív hátraható hiba.

1.6. Példa. Hátraható hibaelemzés. Tegyük fel, hogy egyszerű közelítést keresünk a $y = f(x) = \cos(x)$ koszinuszfüggvényre az $x = 1$ helyen. A koszinuszfüggvényt a

$$\cos(x) = 1 - \frac{x^2}{2!} + \frac{x^4}{4!} - \frac{x^6}{6!} + \cdots$$

végtelen sor adja meg, így fontolóra vehetjük a sor csonkolását, mondjuk két tag után, hogy a

$$\hat{y} = \hat{f}(x) = 1 - x^2/2$$

közelítést kapjuk. Ekkor a közelítés előreható hibája

$$\Delta y = \hat{y} - y = \hat{f}(x) - f(x) = 1 - x^2/2 - \cos(x).$$

A hátraható hiba meghatározásához meg kell találnunk azt a $\hat{x}$ bemenő értéket f-re, amely a ténylegesen kapott $\hat{y}$ kimenő értéket adja, azaz amelyre $\hat{f}(x) = f(\hat{x})$. A koszinuszfüggvény esetén ezt az értéket

$$\hat{x} = \arccos(\hat{f}(x)) = \arccos(\hat{y})$$

adja meg. Így $x = 1$ esetén:

$$y = f(1) = \cos(1) \approx 0{,}5403,$$

$$\hat{y} = \hat{f}(1) = 1 - 1^2/2 = 0{,}5,$$

$$\hat{x} = \arccos(\hat{y}) = \arccos(0{,}5) \approx 1{,}0472,$$

$$\text{előreható hiba} = \Delta y = \hat{y} - y \approx 0{,}5 - 0{,}5403 = -0{,}0403,$$

$$\text{hátraható hiba} = \Delta x = \hat{x} - x \approx 1{,}0472 - 1 = 0{,}0472.$$

Az előreható hiba arra utal, hogy a pontosság meglehetősen jó, mert a kimenet közel van ahhoz, amit számítani szerettünk volna; a hátraható hiba pedig arra utal, hogy a pontosság jó, mert a kapott kimenet helyes egy csak kissé perturbált bemenetre. A következőkben látni fogjuk, hogyan kapcsolódik az előreható és a hátraható hiba egymáshoz számszerűen.

1.2.6 Érzékenység és kondicionáltság

Egy pontatlan megoldás nem feltétlenül egy rosszul megtervezett algoritmus következménye; a pontatlanság a megoldandó feladat eredendő tulajdonsága is lehet. Még egzakt számítás esetén is előfordulhat, hogy a feladat megoldása rendkívül érzékeny a bemenő adatok perturbációira. Az érzékenység kvalitatív fogalma és annak kvantitatív mértéke – a kondicionáltság – a továbbterjedő adathibával foglalkozik, azaz a bemenő adatok perturbációinak a megoldásra gyakorolt hatását vizsgálja.

Egy feladatot érzéketlennek, vagy *jól kondicionáltnak* nevezünk, ha a bemenő adatok egy adott relatív változása a megoldásban azzal összemérhető (vele arányos) relatív változást okoz. Egy feladatot érzékenynek, vagy *rosszul kondicionáltnak* nevezünk, ha a megoldásban bekövetkező relatív változás nagyságrendekkel nagyobb lehet, mint a bemenő adatokban bekövetkező változás. Aki valaha tapasztalta már, hogy a zuhany vize a hőmérséklet-szabályozó legkisebb elállítására is fagyosból forróvá (vagy fordítva) vált, az első kézből tapasztalhatta meg, milyen egy érzékeny rendszer: a hatás aránytalanul nagy a kiváltó okhoz képest.

Pontosabban, egy feladat *kondíciószámát* a megoldás relatív változásának és a bemenet relatív változásának hányadosaként definiáljuk. Egy feladat akkor rosszul kondicionált (azaz érzékeny), ha a kondíciószáma sokkal nagyobb 1-nél. Egy függvény kiszámításának korábbi példájában használt jelölésekkel:

$$\text{kondíciószám} = \frac{\big|(f(\hat{x}) - f(x))/f(x)\big|}{\big|(\hat{x} - x)/x\big|} = \frac{|(\hat{y} - y)/y|}{|(\hat{x} - x)/x|} = \frac{|\Delta y/y|}{|\Delta x/x|}.$$

A tört számlálójában és nevezőjében rendre a relatív előreható, illetve a relatív hátraható hibát ismerhetjük fel, így az összefüggés a következőképpen is felírható:

$$|\text{relatív előreható hiba}| = \text{kondíciószám} \times |\text{relatív hátraható hiba}|.$$

A kondíciószám tehát egyfajta „erősítési tényezőként” értelmezhető, amely összekapcsolja az előreható és a hátraható hibát. Ha egy feladat rosszul kondicionált (azaz a kondíciószáma nagy), akkor a relatív előreható hiba (a megoldás relatív perturbációja) akkor is nagy lehet, ha a relatív hátraható hiba (a bemenet relatív perturbációja) csekély.

A kondíciószám általában a bemenettől függően változik, és a gyakorlatban ritkán ismerjük a pontos értékét. Ezért gyakran meg kell elégednünk a kondíciószám durva becslésével vagy egy adott bemeneti tartományra vonatkozó felső korlátjával; emiatt a hátraható és az előreható hiba közötti összefüggés közelítő egyenlőtlenséggé válik:

$$|\text{relatív előreható hiba}| \lesssim \text{kondíciószám} \times |\text{relatív hátraható hiba}|,$$

amely felülről korlátozza a legrosszabb esetben fellépő előreható hibát, de nem feltétlenül éles (nem feltétlenül valósul meg) minden bemenet esetén. Ezen összefüggés alapján a kondíciószám lehetővé teszi a (számunkra általában legfontosabb) előreható hiba becslését a (gyakran könnyebben meghatározható) hátraható hiba függvényében.

Egy differenciálható $f : \mathbb{R} \to \mathbb{R}$ függvény kiszámításának kondíciószámát az analízis eszközeivel közelíthetjük:

$$\text{abszolút előreható hiba} = f(x + \Delta x) - f(x) \approx f'(x)\Delta x,$$

így

$$\text{relatív előreható hiba} = \frac{f(x + \Delta x) - f(x)}{f(x)} \approx \frac{f'(x)\Delta x}{f(x)},$$

és ezért

$$\text{kondíciószám} \approx \left| \frac{f'(x)\Delta x / f(x)}{\Delta x / x} \right| = \left| \frac{x\, f'(x)}{f(x)} \right|.$$

Így a kimenő függvényérték relatív hibája sokkal nagyobb, de akár sokkal kisebb is lehet a bemenet relatív hibájánál, a szóban forgó függvény tulajdonságaitól és a bemenet konkrét értékétől függően.

Egy adott feladat *inverz feladata* annak meghatározása, hogy melyik bemenet eredményezne egy adott kimenetet. Egy $y = f(x)$ függvény esetében az inverz feladat – jelölésben $x = f^{-1}(y)$ – az, hogy egy adott y értékhez meghatározzuk azt az x értéket, amelyre $f(x) = y$. A definícióból jól látható, hogy az inverz feladat kondíciószáma az eredeti feladat kondíciószámának reciproka. Következésképpen, ha a kondíciószám közel van 1-hez, akkor mind a feladat, mind annak inverze jól kondicionált. Ha azonban a kondíciószám sokkal nagyobb vagy sokkal kisebb 1-nél, akkor rendre a feladat vagy az inverze rosszul kondicionált.

Felidézve az analízisből tanultakat, ha g az inverz függvény, azaz $g(y) = f^{-1}(y)$, és x és y olyan értékek, amelyekre $y = f(x)$, akkor $g'(y) = 1/f'(x)$, feltéve, hogy $f'(x) \neq 0$. Így a g inverz függvény kondíciószáma:

$$\text{kondíciószám} \approx \left|\frac{y\,g'(y)}{g(y)}\right| = \left|\frac{f(x)\,(1/f'(x))}{x}\right| = \left|\frac{f(x)}{x\,f'(x)}\right|,$$

ami az eredeti f függvény kondíciószámának reciproka.

1.7. Példa. Kondíciószám. Tekintsük az $f(x) = \sqrt{x}$ függvényt. Mivel $f'(x) = 1/(2\sqrt{x})$,

$$\text{kondíciószám} \approx \left|\frac{x f'(x)}{f(x)}\right| = \left|\frac{x/(2\sqrt{x})}{\sqrt{x}}\right| = \frac{1}{2}.$$

Ez azt jelenti, hogy a bemenet adott relatív változása a kimenetben körülbelül fele akkora relatív változást okoz. Vagyis a relatív előreható hiba megközelítőleg fele a relatív hátraható hibának, ahogy ezt az 1.5. példában is láttuk ugyanezen feladat kapcsán. Így a négyzetgyökvonás feladata kifejezetten jól kondicionált. Megjegyezzük, hogy az inverz feladat, a $g(y) = y^2$ kondíciószáma $|y\,g'(y)/g(y)| = |y(2y)/y^2| = 2$, ami a négyzetgyökvonás kondíciószámának reciproka, ahogy vártuk.

1.8. Példa. Érzékenység. Tekintsük a tangensfüggvényt, $f(x) = \tan(x)$. Mivel $f'(x) = \sec^2(x) = 1 + \tan^2(x)$,

$$\text{kondíciószám} \approx \left|\frac{x f'(x)}{f(x)}\right| = \left|\frac{x(1+\tan^2(x))}{\tan(x)}\right| = \left|x\left(\frac{1}{\tan(x)} + \tan(x)\right)\right|.$$

Így a $\tan(x)$ nagyon érzékeny a $\pi/2$ bármely páratlan többszörösének közelében, ahol a függvényérték a végtelenhez tart. Például az $x = 1{,}57079$ helyen a kondíciószám körülbelül $2{,}48275 \times 10^5$. Ennek hatását úgy szemléltethetjük, ha a függvényt két közeli pontban kiszámítjuk:

$$\tan(1{,}57079) \approx 1{,}58058 \times 10^5, \qquad \tan(1{,}57078) \approx 6{,}12490 \times 10^4.$$

Jól látható, hogy a kimenet relatív változása – körülbelül 1,58 – nagyjából negyedmilliószorosa a bemenet relatív változásának, ami körülbelül $6{,}37 \times 10^{-6}$. Másfelől a $g(y) = \arctan(y)$ inverz függvény kondíciószáma $|y\,g'(y)/g(y)| = |y\,(1/(1+y^2))/\arctan(y)|$. Az $y = 1{,}58058 \times 10^5$ értékre ez a kondíciószám körülbelül $4{,}0278 \times 10^{-6}$, ami a tangensfüggvény megfelelő x-re vett kondíciószámának reciproka. Így az $\arctan(y)$ rendkívül érzéketlen (jól kondicionált) ebben a pontban.

Az így definiált kondíciószámot néha *relatív* kondíciószámnak nevezik, mivel a bemenet és a kimenet relatív változásaira, illetve relatív hibáira nézve van definiálva. Általában ez a legmegfelelőbb megközelítés, de nincs értelmezve, ha a bemeneti x vagy a kimeneti y érték nulla. Ilyen esetekben az *abszolút* kondíciószám – a megoldás abszolút változásának és a bemenet abszolút változásának hányadosa, $|\Delta y|/|\Delta x|$ – az érzékenység megfelelő mértéke. Ilyen helyzet merül fel például a *gyökkeresés* során: egy $f : \mathbb{R} \to \mathbb{R}$ függvényhez olyan x^* értéket keresünk, amelyre $f(x^*) = 0$ (lásd az 5. fejezetet). Az $f(x)$ függvény egy ilyen x^* gyök közelében vett abszolút kondíciószáma:

$$\frac{|\Delta y|}{|\Delta x|} \approx |f'(x^*)|,$$

a gyök meghatározására vonatkozó inverz feladat – azaz egy olyan x bemeneti érték keresése, amely az $y = f(x) = 0$ kimenetet adja – abszolút kondíciószáma pedig $1/|f'(x^*)|$, feltéve, hogy $f'(x^*) \neq 0$.

1.2.7 Stabilitás és pontosság

Egy számítási algoritmus *stabilitásának* fogalma analóg egy matematikai feladat kondicionáltságával abban az értelemben, hogy mindkettő a perturbációk hatásairól szól. A különbség az, hogy a stabilitás a számítási hibának a számított eredményre gyakorolt hatására vonatkozik, míg a kondicionáltság az adathibának a feladat megoldására gyakorolt hatását írja le. Egy algoritmus *stabil*, ha a kiszámított eredmény viszonylag érzéketlen a számítás során alkalmazott közelítések miatti perturbációkra. A hátraható hibaelemzés szemszögéből egy algoritmus akkor stabil, ha az általa adott eredmény egy közeli feladat egzakt megoldása, azaz a számítás során fellépő perturbációk hatása nem rosszabb, mint amilyen hatással egy kis mennyiségű adathiba lenne az eredeti feladat bemenetében. Ezen definíció értelmében egy stabil algoritmus egzaktul a helyes eredményt adja egy közelítőleg helyes (kissé perturbált) feladatra. Sok – de nem minden – hasznos algoritmus stabil ebben az erős értelemben. Bizonyos kontextusokban hasznos egy gyengébb stabilitási fogalom is: az, hogy az algoritmus közelítőleg helyes eredményt ad egy közelítőleg helyes feladatra.

A *pontosság* a számított megoldás és a vizsgált feladat valódi megoldása közötti közelséget jelenti. Egy algoritmus stabilitása önmagában nem garantálja, hogy a számított eredmény pontos is lesz: a pontosság egyszerre függ a feladat kondicionáltságától és az algoritmus stabilitásától. A stabilitás azt mondja meg, hogy a kapott megoldás egzakt egy közeli feladatra nézve, de ennek a közeli feladatnak a megoldása nem feltétlenül van közel az eredeti feladat megoldásához, hacsak a feladat nem jól kondicionált. Így pontatlanság eredhet akár egy stabil algoritmusnak egy rosszul kondicionált feladatra való alkalmazásából, akár egy instabil algoritmusnak egy jól kondicionált feladatra való alkalmazásából. Ezzel szemben, ha egy stabil algoritmust egy jól kondicionált feladatra alkalmazunk, akkor pontos megoldáshoz jutunk.

1.3 Számítógépes aritmetika

Ahogy már említettük, a tudományos számításokban az egyik elkerülhetetlen közelítés a valós számok számítógépes ábrázolásában rejlik. Ebben a szakaszban részletesebben megvizsgáljuk azokat a véges precíziójú aritmetikai rendszereket, amelyeket a digitális számítógépeken végzett tudományos számítások túlnyomó többségében használunk.

1.3.1 Lebegőpontos számok

Egy digitális számítógépen a matematikai $\mathbb{R}$ valós számrendszert egy *lebegőpontos számrendszerrel* ábrázoljuk. Az alapötlet a tudományos jelölésmódra (normálalakra) hasonlít, amelyben egy nagyon nagy vagy nagyon kicsi abszolút értékű számot egy mérsékelt méretű szám és a tíz megfelelő hatványának szorzataként fejezünk ki. Például a 2347 és a 0,0007396 rendre $2{,}347 \times 10^3$ és $7{,}396 \times 10^{-4}$ alakban írható. Ebben a formátumban a tizedespont mozog, vagyis „lebeg”, ahogy a 10 hatványa változik. Formálisan egy F lebegőpontos számrendszert négy egész szám jellemez:

$$\begin{aligned} \beta &\quad \text{a számrendszer alapja (radix)} \\ p &\quad \text{precízió (a mantissza hossza)} \\ [L, U] &\quad \text{exponens-tartomány} \end{aligned}$$

Bármely $x \in F$ lebegőpontos szám alakja

$$x = \pm \left(d_0 + \frac{d_1}{\beta} + \frac{d_2}{\beta^2} + \cdots + \frac{d_{p-1}}{\beta^{p-1}} \right) \beta^E,$$

ahol a d_i olyan egész szám, amelyre

$$0 \leq d_i \leq \beta - 1, \quad i = 0, \ldots, p-1,$$

E pedig olyan egész szám, amelyre

$$L \leq E \leq U.$$

A zárójelben lévő részt, amelyet a $d_0 d_1 \cdots d_{p-1}$ p darab β-alapú számjegyből álló sorozat ábrázol, *mantisszának* vagy *szignifikándnak* nevezzük, E-t pedig az x lebegőpontos szám *exponensének* vagy *karakterisztikájának*. A mantissza $d_1 d_2 \cdots d_{p-1}$ része a *törtrész*. Egy számítógépen az előjelet, az exponenst és a mantisszát egy adott lebegőpontos szó külön mezőiben tárolják, amelyek mindegyike rögzített szélességű. A nulla egyedi ábrázolást igényel, például úgy, hogy mind a mantisszája, mind az exponense nulla, vagy úgy, hogy a törtrésze nulla és az exponens egy speciális értéket vesz fel.

Manapság a legtöbb számítógép bináris ($\beta = 2$) aritmetikát használ, de más alapok is előfordultak a múltban: például hexadecimális ($\beta = 16$) az IBM mainframe-eken, illetve $\beta = 3$ egy balsorsú orosz számítógépen. Az oktális ($\beta = 8$) és a hexadecimális jelölést gyakran használjuk kényelmes rövidítésként a bináris számok hármas, illetve négyes bitcsoportokba rendezett leírására. Nyilvánvaló okokból a decimális ($\beta = 10$) aritmetika népszerű a zsebszámológépekben. Az emberi interakció megkönnyítése érdekében egy számítógép általában a bevitt számértékeket decimális jelölésről belső ábrázolásra, a kimeneten pedig vissza decimális jelölésre alakítja át, függetlenül attól, milyen alapot használ belsőleg. Néhány tipikus lebegőpontos rendszer paramétereit az 1.1. táblázat tartalmazza, amely jól illusztrálja a mezőszélességekből adódó kompromisszumot a precízió és az exponens-tartomány között. Például ugyanolyan 64 bites szóhosszúság mellett a Cray rendszer szélesebb exponens-tartománnyal rendelkezik, mint az IEEE dupla pontosságú ábrázolás, cserébe viszont kisebb pontossággal (precízióval) fizet.

Az IEEE szabvány szerinti egyszeres pontosságú (SP) és dupla pontosságú (DP) bináris lebegőpontos rendszerek ma messze a legfontosabbak. Szinte egyetemesen elterjedtek a személyi számítógépekben és munkaállomásokon, valamint számos mainframe- és szuperszámítógépen is. Az IEEE szabványt gondosan úgy tervezték, hogy kiküszöbölje a korábbi, gyártóspecifikus lebegőpontos implementációk számos anomáliáját és kétértelműségét, és ezzel nagyban elősegítette a hordozható és megbízható numerikus szoftverek fejlesztését. Emellett lehetővé teszi a kivételes helyzetek – például a nullával való osztás – értelmes és következetes kezelését.

Rendszer	β	p	L	U
IEEE SP	2	24	−126	127
IEEE DP	2	53	−1022	1023
Cray	2	48	−16 383	16 384
HP számológép	10	12	−499	499
IBM mainframe	16	6	−64	63

1.1. táblázat: Tipikus lebegőpontos rendszerek paraméterei.

1.3.2 Normalizáltság

Egy lebegőpontos rendszert *normalizáltnak* nevezünk, ha a vezető d_0 számjegy mindig nullától különböző, kivéve, ha az ábrázolt szám nulla. Így egy normalizált lebegőpontos rendszerben egy adott, nem nulla lebegőpontos szám m mantisszájára mindig fennáll, hogy

$$1 \leq m < \beta.$$

(Egy másik konvenció szerint d_0 mindig nulla, ebben az esetben egy lebegőpontos szám akkor normalizált, ha $d_1 \neq 0$, és ekkor $\beta^{-1} \leq m < 1$.) A lebegőpontos rendszereket általában normalizálják, mert:

- Így minden szám ábrázolása egyértelmű.
- Nem pazarolunk el számjegyeket vezető nullákra, és ezzel maximalizáljuk a precíziót.
- Egy bináris ($\beta = 2$) rendszerben a vezető bit mindig 1, így nem kell tárolni, és ezáltal egy adott mezőszélességen belül egy bittel nagyobb precíziót nyerünk.

1.3.3 A lebegőpontos rendszerek tulajdonságai

Egy lebegőpontos számrendszer véges és diszkrét. Egy adott lebegőpontos rendszerben a normalizált lebegőpontos számok száma

$$2(\beta - 1)\,\beta^{p-1}\,(U - L + 1) + 1,$$

mivel az előjelre két választási lehetőség van, a mantissza vezető számjegyére $\beta - 1$, a mantissza további $p - 1$ számjegyének mindegyikére β, az exponensre pedig $U - L + 1$ lehetséges érték. A $+1$-et azért adjuk hozzá, mert a szám lehet nulla is.

Létezik egy legkisebb pozitív normalizált lebegőpontos szám,

$$\text{UFL (alulcsordulási szint)} = \beta^L,$$

amelyben a vezető számjegy 1, a mantissza többi számjegye 0, az exponens pedig a legkisebb lehetséges érték. Létezik egy legnagyobb lebegőpontos szám,

$$\text{OFL (túlcsordulási szint)} = \beta^{U+1}(1 - \beta^{-p}),$$

amelyben a mantissza minden számjegye $\beta - 1$, az exponens pedig a legnagyobb lehetséges érték. Az adott lebegőpontos rendszerben nem ábrázolható az OFL-nél nagyobb szám, sem az UFL-nél kisebb pozitív szám. A lebegőpontos számok nem egyenletesen oszlanak el az értékkészletükben, hanem csak az egymást követő β-hatványok között egyenletes a távolságuk.

1.9. Példa. Lebegőpontos rendszer. Egy példa lebegőpontos rendszert szemléltet az 1.3. ábra, ahol a skálajelek a $\beta = 2$, $p = 3$, $L = -1$, $U = 1$ paraméterű rendszer mind a 25 lebegőpontos számát jelzik. Ebben a rendszerben a legnagyobb szám OFL $= (1{,}11)_2 \times 2^1 = (3{,}5)_{10}$, a legkisebb pozitív normalizált szám pedig UFL $= (1{,}00)_2 \times 2^{-1} = (0{,}5)_{10}$. Ez egy nagyon apró, szemléltető célú „játékrendszer”, mégis jellemző a lebegőpontos rendszerekre általában: kellően nagy nagyítás

mellett minden normalizált lebegőpontos rendszer lényegében így néz ki – szemcsés és egyenetlen eloszlású.

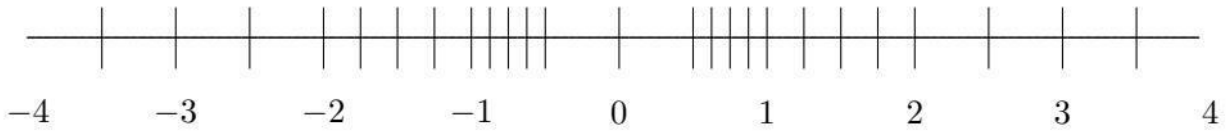

1.3. ábra: Példa lebegőpontos számrendszer.

1.3.4 Kerekítés

Azokat a valós számokat, amelyek egy adott lebegőpontos rendszerben pontosan ábrázolhatók, *gépi számoknak* nevezzük. Ha egy adott x valós szám nem ábrázolható pontosan lebegőpontos számként, akkor valamilyen „közeli" lebegőpontos számmal kell közelítenünk. Egy x valós szám lebegőpontos közelítését $\mathrm{fl}(x)$-szel jelöljük. Azt a folyamatot, amelynek során egy adott x valós számhoz egy közeli $\mathrm{fl}(x)$ lebegőpontos számot választunk, *kerekítésnek* nevezzük, az ilyen közelítés által bevezetett hibát pedig *kerekítési hibának*. Két gyakran használt kerekítési szabály:

- Csonkítás: az x szám β-alapú kifejtését a $(p-1)$-edik számjegy után elvágjuk. Mivel az $\mathrm{fl}(x)$ a következő lebegőpontos szám x-től a nulla felé haladva, ezt a szabályt néha *nulla felé kerekítésnek* is nevezik.
- Kerekítés a legközelebbihez: $\mathrm{fl}(x)$ az x-hez legközelebbi lebegőpontos szám; döntetlen esetén azt a lebegőpontos számot választjuk, amelynek az utolsó tárolt számjegye páros. Ez utóbbi tulajdonság miatt ezt a szabályt *páros felé kerekítésnek* is nevezik.

A legközelebbihez való kerekítés a legpontosabb és torzítatlan, de helyes megvalósítása valamivel költségesebb. Egyes régebbi rendszerek olcsóbban megvalósítható szabályokat használtak, például csonkítást, de az IEEE szabványos rendszerekben a legközelebbihez való kerekítés az alapértelmezett szabály.

1.10. Példa. Kerekítési szabályok. Az alábbi decimális számok két számjegyre kerekítése mindkét szabály szerint a következő eredményt adja:

Szám	Csonkítás	Legközelebbi	Szám	Csonkítás	Legközelebbi
1,649	1,6	1,6	1,749	1,7	1,7
1,650	1,6	1,6	1,750	1,7	1,8
1,651	1,6	1,7	1,751	1,7	1,8
1,699	1,6	1,7	1,799	1,7	1,8

Egy további, gyakran figyelmen kívül hagyott hibaforrás a lebegőpontos számok bevitelekor és kiírásakor szokásosan elvégzett decimális-bináris és bináris-decimális átváltásokban rejlik. Ezekre az átváltásokra az IEEE szabvány nem terjed ki; a szabvány csak a belső aritmetikai műveleteket rögzíti. A helyesen kerekített bevitel és kiírás ésszerű költséggel megvalósítható, de nem minden számítógépes rendszerben alkalmazzák. A helyesen kerekített bináris-decimális és decimális-bináris átváltásokra hatékony, hordozható rutinok – a `dtoa` és az `strtod` – érhetők el a Netlibről (lásd az 1.4.1. szakaszt).

1.3.5 Gépi pontosság

Egy lebegőpontos rendszer pontosságát olyan mennyiség jellemzi, amelyet *gépi epszilonnak* (unit roundoff), *kerekítési egységnek* vagy *gépi pontosságnak* is neveznek. Ennek értéke – amelyet ϵ_{mach}-kal jelölünk – az alkalmazott kerekítési szabálytól függ. Csonkítás esetén

$$\epsilon_{\text{mach}} = \beta^{1-p},$$

a legközelebbihez való kerekítés esetén pedig

$$\epsilon_{\text{mach}} = \tfrac{1}{2}\,\beta^{1-p}.$$

A gépi epszilon azért fontos, mert felső korlátot ad arra a *relatív hibára*, amellyel egy lebegőpontos rendszer normalizált tartományában bármely nem nulla x valós szám ábrázolható:

$$\left|\frac{\text{fl}(x) - x}{x}\right| \leq \epsilon_{\text{mach}}.$$

A gépi epszilon egy másik megfogalmazása, amellyel néha találkozhatunk, hogy ϵ_{mach} a legkisebb olyan ϵ szám, amelyre

$$\text{fl}(1+\epsilon) > 1,$$

ám ez nem teljesen ekvivalens az előbbi definícióval, ha a páros felé kerekítés szabályát alkalmazzuk. Egy további, esetenként használt definíció szerint ϵ_{mach} az 1 és az azt követő lebegőpontos szám közötti távolság, ám ez is eltérhet az előző két definíciótól. Részleteikben különbözhetnek, de az ϵ_{mach} mindhárom definíciójának ugyanaz az alapvető célja: a lebegőpontos rendszer relatív szemcsézettségének mérése.

Az 1.9. példa szemléltető játékrendszerében csonkítás esetén $\epsilon_{\text{mach}} = 0{,}25$, a legközelebbihez való kerekítés esetén pedig $\epsilon_{\text{mach}} = 0{,}125$. Az IEEE bináris lebegőpontos rendszerekben $\epsilon_{\text{mach}} = 2^{-24} \approx 10^{-7}$ egyszeres pontosság mellett, és $\epsilon_{\text{mach}} = 2^{-53} \approx 10^{-16}$ dupla pontosság mellett. Ezért azt mondjuk, hogy az IEEE egyszeres, illetve dupla pontosságú lebegőpontos rendszerek körülbelül 7, illetve 16 decimális értékes jegy pontosságúak.

Bár mindkettő „kicsi”, a gépi epszilont nem szabad összetéveszteni az alulcsordulási szinttel. Az ϵ_{mach} gépi epszilont a lebegőpontos rendszer mantisszamezejének hossza (számjegyeinek száma) határozza meg, míg az UFL alulcsordulási szintet az exponensmező hossza. Minden gyakorlatban használt lebegőpontos rendszerben fennáll, hogy

$$0 < \text{UFL} < \epsilon_{\text{mach}} < \text{OFL}.$$

1.3.6 Szubnormális számok és fokozatos alulcsordulás

Az 1.3. ábrán bemutatott szemléltető lebegőpontos rendszerben észrevehető rés van a nulla körül. Ez a rés – amely valamilyen mértékben minden lebegőpontos rendszerben jelen van – a normalizáltság következménye: a legkisebb lehetséges mantissza 1,00..., a legkisebb lehetséges exponens pedig L, így nincs lebegőpontos szám a nulla és β^L között. Ha feladjuk a normalizáltsági követelményt, és

megengedjük, hogy a vezető számjegy nulla legyen (de csak akkor, amikor az exponens a minimális értékén áll), akkor a nulla körüli rést további lebegőpontos számokkal „tölthetjük ki”. A szemléltető játékrendszerünkben ez az enyhítés hat további lebegőpontos számot eredményez, amelyek közül a legkisebb pozitív a $(0{,}01)_2 \times 2^{-1} = (0{,}125)_{10}$, ahogy azt az 1.4. ábra mutatja.

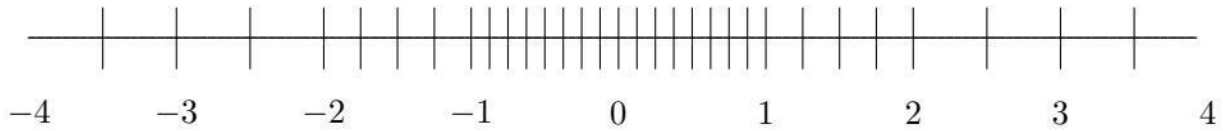

1.4. ábra: Példa lebegőpontos rendszer szubnormális számokkal.

Az így a rendszerhez hozzáadott további számokat *szubnormális* vagy *denormalizált* lebegőpontos számoknak nevezzük. Noha hasznosan kiterjesztik az ábrázolható abszolút értékek tartományát, a szubnormális számoknak eredendően kisebb a pontosságuk, mint a normalizált számokénak, mert a törtrészükben kevesebb értékes jegy szerepel. Különösen fontos megjegyezni, hogy a tartomány ilyen módon történő kiterjesztése nem csökkenti az ϵ_{mach} gépi epszilont.

Az ilyen módon kiterjesztett lebegőpontos rendszerről azt mondjuk, hogy *fokozatos alulcsordulást* (gradual underflow) valósít meg, mivel az ábrázolható abszolút értékek alsó tartományát kiterjeszti, ahelyett, hogy a minimális exponensérték alá csökkenéskor hirtelen nullára csordulna (flush to zero). Az IEEE szabvány előírja a szubnormális számok használatát és a fokozatos alulcsordulást. A fokozatos alulcsordulást az exponensmező egy speciális, lefoglalt értékén keresztül valósítják meg, mivel a vezető bináris számjegyet fizikailag nem tárolják, így azt nem lehet a denormalizáltság jelzésére felhasználni.

1.3.7 Kivételes értékek

Az IEEE lebegőpontos szabvány két további speciális értéket biztosít a kivételes helyzetek jelzésére:

- `Inf`, amely a végtelent jelöli, és egy véges szám nullával való osztásakor áll elő, például 1/0.
- `NaN`, amely a *nem szám* (not a number) rövidítése, és definiálatlan vagy határozatlan művelet eredménye, például 0/0, $0 \cdot \text{Inf}$ vagy Inf/Inf.

Az `Inf` és a `NaN` az IEEE aritmetikában az exponensmező speciális, fenntartott értékeinek segítségével valósul meg.

Az, hogy az `Inf` és a `NaN` támogatott-e felhasználói szinten egy adott számítási környezetben, a nyelvtől, a fordítótól és a futásidejű rendszertől függ. Ha elérhetők, akkor ezek a mennyiségek segíthetnek olyan szoftvert tervezni, amely a kivételes helyzeteket elegánsan kezeli, és nem szakítja meg hirtelen a programot. A MATLAB-ban (lásd az 1.4.2. szakaszt) például, ha `Inf` vagy `NaN` lép fel, a rendszer azokat értelemszerűen továbbviszi a számítás során (pl. $1 + \text{Inf} = \text{Inf}$). Ennek ellenére érdemes, ha lehetséges, teljesen elkerülni az ilyen kivételes helyzeteket. Amellett, hogy felhívják a felhasználó figyelmét az aritmetikai kivételekre, ezek a speciális értékek jelzőként (flag) is hasznosak lehetnek, mivel egyetlen érvényes numerikus értékkel sem téveszthetők össze. Például a `NaN` használható egy tömb még definiálatlan részének megjelölésére.

1.3.8 Lebegőpontos aritmetika

Két lebegőpontos szám összeadásánál vagy kivonásánál a mantisszák összeadása vagy kivonása előtt az exponenseknek meg kell egyezniük. Ha kezdetben nem egyeznek meg, akkor az egyik szám mantisszáját addig kell eltolni, amíg az exponensek azonosak nem lesznek. Egy ilyen eltolás során

az (abszolút értékben) kisebb szám utolsó számjegyei a mantisszamező rögzített szélességén túlra kerülhetnek, így az aritmetikai művelet helyes eredménye nem ábrázolható pontosan a lebegőpontos rendszerben. Sőt, ha az abszolút értékek közötti különbség túl nagy, akkor a kisebb szám teljes mantisszája kicsúszhat a mezőszélességből, és így az eredmény egyszerűen a két operandus közül a nagyobbik lesz. Másképpen fogalmazva: ha két p számjegyű szám valódi összege p-nél több számjegyet tartalmaz, akkor a p számjegyre kerekítéskor a felesleges számjegyek elvesznek, és a legrosszabb esetben a kisebb abszolút értékű operandus teljesen eltűnhet.

Két lebegőpontos szám szorzásához nem szükséges, hogy exponenseik megegyezzenek – az exponenseket egyszerűen összeadjuk, a mantisszákat pedig összeszorozzuk. Két p számjegyű mantissza szorzata azonban általában akár $2p$ számjegyet is tartalmazhat, így a helyes eredmény ismételten nem ábrázolható pontosan a lebegőpontos rendszerben, ezért kerekíteni kell.

1.11. Példa. Lebegőpontos aritmetika. Tekintsünk egy $\beta = 10$ és $p = 6$ paraméterű lebegőpontos rendszert. Ha $x = 1{,}92403 \times 10^2$ és $y = 6{,}35782 \times 10^{-1}$, akkor a lebegőpontos összeadás – a legközelebbihez való kerekítés mellett – az $x + y = 1{,}93039 \times 10^2$ eredményt adja. Vegyük észre, hogy y utolsó két számjegye nem befolyásolja az eredményt. Még kisebb exponens esetén y egyáltalán nem is hatott volna az eredményre. Hasonlóképpen, a lebegőpontos szorzás az $x \cdot y = 1{,}22326 \times 10^2$ eredményt adja, ami a valódi szorzat számjegyeinek a felét eldobja.

Két lebegőpontos szám osztása is adhat olyan eredményt, amely nem ábrázolható pontosan. Például az 1 és a 10 pontosan ábrázolható bináris lebegőpontos számként, de hányadosuk, az 1/10 nem véges bináris kifejtésű, így nem ábrázolható pontosan bináris lebegőpontos számként.

Minden fent említett esetben egy lebegőpontos aritmetikai művelet eredménye eltérhet attól, amit a megfelelő valós aritmetikai művelet adna ugyanazokra az operandusokra, egyszerűen azért, mert a helyes valós eredmény ábrázolásához nincs elegendő pontosság. A valós eredmény azért is lehet nem ábrázolható, mert az exponense a lebegőpontos rendszer rendelkezésre álló tartományán kívül esik (túlcsordulás vagy alulcsordulás). A túlcsordulás általában súlyosabb probléma, mint az alulcsordulás, abban az értelemben, hogy egy lebegőpontos rendszerben nincs jó közelítés a tetszőlegesen nagy számokra, míg a nulla gyakran ésszerű közelítés a tetszőlegesen kis számokra. Ezért sok számítógépes rendszerben a túlcsordulás bekövetkezése végzetes hibával megszakítja a programot, az alulcsordulást viszont a rendszer csendben nullára állíthatja a végrehajtás megzavarása nélkül.

1.12. Példa. Sor összegzése. E kérdések szemléltetéseként a

$$\sum_{n=1}^{\infty} \frac{1}{n}$$

végtelen sornak véges az összege lebegőpontos aritmetikában, noha a valós sor divergens. Első ránézésre azt gondolhatnánk, hogy ez azért van, mert az $1/n$ előbb-utóbb alulcsordul, vagy a részletösszeg előbb-utóbb túlcsordul – ami végül valóban meg is történik. De mielőtt ezek bármelyike bekövetkezne, a részletösszeg már megszűnik változni, amint az $1/n$ a részletösszeghez képest elhanyagolhatóvá válik, azaz amikor $1/n < \epsilon_{\text{mach}} \sum_{k=1}^{n-1}(1/k)$, így az összeg véges marad (lásd az 1.8. számítógépes feladatot).

Amint megjegyeztük, két lebegőpontos számon elvégzett valós aritmetikai művelet eredménye nem feltétlenül egy újabb, pontos lebegőpontos szám. Ha a számítógépbe olyan szám kerül, amely lebegőpontos számként nem ábrázolható pontosan, vagy egy későbbi aritmetikai művelet ilyet

állít elő, akkor azt a korábban megadott kerekítési szabályok valamelyikével kerekíteni kell, hogy lebegőpontos számot kapjunk. Mivel a lebegőpontos számok nem egyenletes eloszlásúak, az ilyen közelítésben fellépő abszolút hiba nem egyenletes, a relatív hibát azonban az ϵ_{mach} gépi epszilon korlátozza.

Ideális esetben $x \operatorname{flop} y = \operatorname{fl}(x \operatorname{op} y)$ (azaz a lebegőpontos aritmetikai műveletek helyesen kerekített eredményt adnak), és sok számítógép – például az IEEE lebegőpontos szabványnak megfelelőek – el is éri ezt az ideált, amíg az $x \operatorname{op} y$ a lebegőpontos rendszer tartományán belül marad. Ennek ellenére a valós aritmetika néhány alapvető törvénye nem feltétlenül érvényes a lebegőpontos rendszerekben. Érdemes kiemelni, hogy a lebegőpontos összeadás és szorzás kommutatív, de nem asszociatív. Például ha ϵ az ϵ_{mach} gépi epszilonnál egy picit kisebb pozitív lebegőpontos szám, akkor $(1+\epsilon)+\epsilon = 1$, de $1 + (\epsilon + \epsilon) > 1$. Az, hogy a lebegőpontos aritmetika nem teljesíti a valós aritmetika szokásos törvényeit, az egyik fő oka annak, hogy az előreható hibaelemzés nehéz feladat. A hátraható hibaelemzés egyik nagy előnye éppen az, hogy az elemzés során lehetővé teszi a valós aritmetika szabályainak használatát.

A kerekítési hibaelemzés rendszerint a következő szabványos modellre épül a lebegőpontos aritmetikára vonatkozóan:

$$\operatorname{fl}(x \operatorname{op} y) = (x \operatorname{op} y)(1 + \delta),$$

ahol $|\delta| \leq \epsilon_{\text{mach}}$, és az op a $+$, $-$, $\times$, $/$ szabványos aritmetikai műveletek valamelyike. Átrendezve láthatjuk, hogy ez a modell értelmezhető a relatív előreható hibára vonatkozó állításként is:

$$\frac{|\operatorname{fl}(x \operatorname{op} y) - (x \operatorname{op} y)|}{|(x \operatorname{op} y)|} = |\delta| \leq \epsilon_{\text{mach}}.$$

De ugyanígy értelmezhető a hátraható hibára vonatkozó állításként is. Például op $= +$ esetén

$$\operatorname{fl}(x + y) = (x + y)(1 + \delta) = x(1 + \delta) + y(1 + \delta),$$

ami azt jelenti, hogy a lebegőpontos összeadás eredménye egzakt olyan x és y operandusokra nézve, amelyek mindegyike $|\delta|$ relatív mértékben perturbált.

1.13. Példa. Kerekítési hibaelemzés. Tekintsük az $x(y+z)$ egyszerű számítást. Lebegőpontos aritmetikában

$$\operatorname{fl}(y + z) = (y + z)(1 + \delta_1), \quad |\delta_1| \leq \epsilon_{\text{mach}},$$

és így

$$\begin{aligned}
\operatorname{fl}(x(y + z)) &= (x((y + z)(1 + \delta_1)))(1 + \delta_2), \quad |\delta_2| \leq \epsilon_{\text{mach}} \\
&= x(y + z)(1 + \delta_1 + \delta_2 + \delta_1\delta_2) \\
&\approx x(y + z)(1 + \delta_1 + \delta_2) \\
&= x(y + z)(1 + \delta), \quad |\delta| = |\delta_1 + \delta_2| \leq 2\epsilon_{\text{mach}}.
\end{aligned}$$

Ahogy korábban láttuk, ez a korlát egyaránt értelmezhető az előreható hiba (a számított és a kívánt eredmény közötti eltérés) vagy a hátraható hiba (operandusperturbációk) szempontjából is, de meglehetősen pesszimista lehet. Például δ_1 és δ_2 lehet ellentétes előjelű, és így ki is olthatják egymást, aminek eredményeként a teljes hiba sokkal kisebb lehet, mint amit a legrosszabb esetre vonatkozó elemzés sugall. Bonyolultabb számítások hasonló elemzése általában az ϵ_{mach} ennek megfelelő, nagyobb többszöröseit tartalmazó hibakorlátokhoz vezet. Szerencsére az ϵ_{mach} olyannyira pici, hogy a gyakorlatban az eredmény rendkívül ritkán romlik le súlyosan pusztán a számítási lépések nagy száma miatt.

1.3.9 Számjegykioltás

A kerekítés nem az egyetlen szükséges rossz a véges precíziójú aritmetikában. Két azonos előjelű és hasonló abszolút értékű p számjegyű szám kivonása p-nél kevesebb értékes számjegyet tartalmazó eredményt ad, ezért az mindig pontosan ábrázolható (feltéve, hogy a két szám abszolút értéke nem több mint kétszeresen tér el egymástól). Ennek oka, hogy a két szám vezető számjegyei kioltják egymást (azaz különbségük nulla). Például ismét a $\beta = 10$ és $p = 6$ értékeket véve, ha $x = 1{,}92403 \times 10^2$ és $z = 1{,}92275 \times 10^2$, akkor $x - z = 1{,}28000 \times 10^{-1}$ adódik, amely mindössze három értékes jegyével pontosan ábrázolható.

Bár az eredmény pontos, az ilyen számjegykioltás gyakran mégis jelentős információvesztést jelent. A probléma az, hogy az operandusok a kerekítés vagy más korábbi hibák miatt gyakran eleve bizonytalanok, ezért a különbségben megjelenő relatív bizonytalanság nagyon nagy lehet. Más szóval: ha két közel azonos szám csak a kerekítési hiba pontosságáig helyes, akkor a különbségük már kizárólag csak a kerekítési hibát fogja tartalmazni.

Egyszerű példaként: ha ϵ az ϵ_{mach} gépi epszilonnál kicsit kisebb pozitív szám, akkor $(1+\epsilon)-(1-\epsilon) = 1 - 1 = 0$ lebegőpontos aritmetikában, ami az utolsó kivonás tényleges operandusaira nézve helyes, de a teljes számítás valódi eredménye, a 2ϵ, teljesen elveszik. Maga a kivonás nem hibás: csupán felszínre hozza a már korábban bekövetkezett információvesztést.

Természetesen az információvesztés nem mindig teljes, de tény marad, hogy a számjegykioltás során elveszett számjegyek a legfontosabb, vezető számjegyek, míg a kerekítés során elveszett számjegyek a legkevésbé fontos, utolsó számjegyek. Emiatt a hatás miatt egy kis mennyiség kiszámítása két nagy mennyiség különbségeként általában rossz ötlet, mert a kerekítési hiba valószínűleg dominálni fogja a végeredményt. Például egy váltakozó előjelű sor összegzése, mint az

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots$$

$x < 0$ esetén, a katasztrofális számjegykioltás miatt végzetesen rossz eredményt adhat (lásd az 1.9. számítógépes feladatot).

1.14. Példa. Számjegykioltás. A számjegykioltás nemcsak a számítógépes aritmetikában okoz problémát, hanem bármely olyan helyzetben, ahol csak korlátozott pontosság érhető el – például empirikus mérések vagy laboratóriumi kísérletek során. Például Manhattan és Staten Island közötti távolság meghatározása a két hely Los Angelestől mért távolságainak különbségeként nagyon rossz eredményt adna, hacsak ez utóbbi távolságokat nem ismerjük rendkívül nagy pontossággal.

Másik példaként a fizikusok évek óta próbálják a héliumatom teljes energiáját első elvekből kiszámítani Monte-Carlo-módszerekkel. E számítások pontosságát nagyrészt a felhasznált véletlen minták száma határozza meg. Ahogy a gyorsabb számítógépek elérhetővé válnak, és a számítási

technikák finomodnak, úgy javul az elérhető pontosság is. A teljes energia a mozgási és a potenciális energia összege, amelyeket külön-külön számítanak ki, és ellentétes előjelűek. Így a teljes energia valójában különbségként áll elő, és számjegykioltástól szenved. Az 1.2. táblázat az évek során kapott értékek sorozatát mutatja be (ezeket az adatokat Dr. Robert Panoff bocsátotta rendelkezésre). Ebben az időszakban a mozgási és a potenciális energiára számított értékek legfeljebb 6 százalékkal változtak, a teljes energiára adott becslés azonban 144 százalékkal. A korábbi számítások egy-két értékes jegye a későbbi kivonás során teljesen elveszett.

Év	Mozgási	Potenciális	Teljes
1971	13,0	−14,0	−1,0
1977	12,76	−14,02	−1,26
1980	12,22	−14,35	−2,13
1985	12,28	−14,65	−2,37
1988	12,40	−14,84	−2,44

1.2. táblázat: A héliumatom teljes energiájára számított értékek.

1.15. Példa. Másodfokú megoldóképlet. A számjegykioltás és egyéb numerikus buktatók nem feltétlenül igényelnek hosszú számítássorozatot. Például a másodfokú egyenlet gyökeire szolgáló szabványos képlet használata tele van numerikus csapdákkal. Ahogy minden iskolás megtanulja, az

$$ax^2 + bx + c = 0$$

másodfokú egyenlet két megoldását a megoldóképlet adja:

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}.$$

Az együtthatók bizonyos értékei esetén e képlet naiv alkalmazása a lebegőpontos aritmetikában túlcsordulást, alulcsordulást vagy katasztrofális számjegykioltást okozhat.

Ha például az együtthatók nagyon nagyok vagy nagyon kicsik, akkor a b^2 vagy a $4ac$ túlcsordulhat vagy alulcsordulhat. A túlcsordulás lehetősége az együtthatók átskálázásával elkerülhető, például úgy, hogy mindhárom együtthatót elosztjuk a legnagyobb abszolút értékűvel. Ez az átskálázás nem változtatja meg a másodfokú egyenlet gyökeit, ám a legnagyobb együttható mostantól 1, így a b^2 vagy a $4ac$ számításakor nem léphet fel túlcsordulás. A művelet ugyan nem szünteti meg teljesen az alulcsordulás lehetőségét, de megelőzi a felesleges alulcsordulást, amely egyébként bekövetkezhetne, ha mindhárom együttható nagyon kicsi lenne.

A $-b$ és a négyzetgyök közötti számjegykioltás elkerülhető, ha az egyik gyököt az

$$x = \frac{2c}{-b \mp \sqrt{b^2 - 4ac}}$$

alternatív képlet szerint számoljuk, amelyben az előjelek a szabványos képlet ellentettjei. A négyzetgyök alatti kioltás azonban nehezen kerülhető el nagyobb pontosság használata nélkül (ha a diszkrimináns az együtthatókhoz képest kicsi, akkor a két gyök nagyon közel van egymáshoz, és a feladat eredendően rosszul kondicionált).

Szemléltetésképpen négy számjegyű decimális aritmetikát – a legközelebbihez való kerekítéssel – használunk az $a = 0{,}05010$, $b = -98{,}78$, $c = 5{,}015$ együtthatójú másodfokú egyenlet gyökeinek számítására. Összehasonlításul a helyes gyökök, tíz értékes jegyre kerekítve:

$$1971{,}605916 \quad \text{és} \quad 0{,}05077069387.$$

A diszkrimináns négy számjegyű aritmetikában

$$b^2 - 4ac = 9757 - 1{,}005 = 9756,$$

így

$$\sqrt{b^2 - 4ac} = 98{,}77.$$

A szabványos megoldóképlet ekkor a

$$\frac{98{,}78 \pm 98{,}77}{0{,}1002} = 1972 \quad \text{és} \quad 0{,}09980$$

gyököket adja. Az első gyök a helyesen kerekített négy számjegyű eredmény, a másik viszont teljesen hibás, körülbelül 100 százalékos hibával. A probléma forrása a számjegykioltás – nem abban az értelemben, hogy a végső kivonás helytelen volna (sőt, az teljesen pontos), hanem abban, hogy a vezető számjegyek kioltása csak a korábbi kerekítési hibákat hagyta meg. Az alternatív megoldóképlet a

$$\frac{10{,}03}{98{,}78 \mp 98{,}77} = 1003 \quad \text{és} \quad 0{,}05077$$

gyököket adja. Ismét egy teljesen pontos és egy teljesen hibás gyököt kaptunk, de most éppen a másik gyök lett pontatlan. A magyarázat ismét a számjegykioltás, de az eltérő előjelminta miatt az ellenkező gyök szennyeződik. Általában az egyes gyökök számításához azt a képletet kell választanunk, amelyik – b előjelétől függően – elkerüli a kioltást.

1.16. Példa. Szórás. Egy véges x_i $(i = 1, \dots, n)$ valós sorozat átlagának definíciója

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i,$$

a szórásé pedig

$$\sigma = \left[\frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 \right]^{1/2}.$$

Ezen képletek használata azt jelenti, hogy kétszer kell végigmenni az adatokon: egyszer az átlag, másszor pedig a szórás kiszámításához. A hatékonyság érdekében csábító lehet a matematikailag ekvivalens

$$\sigma = \left[\frac{1}{n-1} \left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2 \right) \right]^{1/2}$$

képletet használni a szórás számítására, hiszen így az összeg és a négyzetösszeg egyetlen lépésben (menetben) számítható.

Sajnos az egylépéses képlet végén fellépő egyetlen számjegykioltás numerikusan gyakran sokkal rombolóbb, mint a kétlépéses képletben fellépő összes kerekítési hiba együttvéve. A probléma az, hogy az egylépéses képletben kivonandó két mennyiség általában viszonylag nagy és közel azonos, így a különbségükben fellépő relatív hiba hatalmas lehet (sőt, a kerekítések miatt az eredmény akár negatív is lehet, és ilyenkor a négyzetgyökvonás is meghiúsul).

1.17. Példa. Reziduumok számítása. Tegyük fel, hogy az $ax = b$ skaláris lineáris egyenletet oldjuk meg az x ismeretlenre, és kaptunk egy $\hat{x}$ közelítő megoldást. A válaszunk minőségének egyik mérőszámaként kiszámítjuk az $r = b - a\hat{x}$ reziduumot. Lebegőpontos aritmetikában

$$\mathrm{fl}(a\hat{x}) = a\hat{x}(1+\delta_1), \quad |\delta_1| \le \epsilon_{\mathrm{mach}},$$

így

$$\begin{aligned}
\mathrm{fl}(b - a\hat{x}) &= (b - a\hat{x}(1+\delta_1))(1+\delta_2), \quad |\delta_2| \le \epsilon_{\mathrm{mach}} \\
&= (r - a\hat{x}\delta_1)(1+\delta_2) \\
&= r(1+\delta_2) - a\hat{x}\delta_1 - a\hat{x}\delta_1\delta_2 \\
&\approx r(1+\delta_2) - \delta_1 b.
\end{aligned}$$

Ám a $\delta_1 b$ tag akár $\epsilon_{\mathrm{mach}} b$ nagyságrendű is lehet, ami viszont már megegyezhet r nagyságrendjével – ez azt jelenti, hogy a reziduum kiszámításában fellépő hiba elérheti a 100 százalékot, vagy akár annál is nagyobb lehet. Ezért az r reziduum értelmes (pontos) kiszámításához sokszor kétszeres pontosság szükséges.

Szemléltetésként tegyük fel, hogy három számjegyű decimális aritmetikát használunk, és legyen $a = 2{,}78$, $b = 3{,}14$, $\hat{x} = 1{,}13$. Három számjegyű aritmetikában $2{,}78 \times 1{,}13 = 3{,}14$, így a három számjegyű reziduum 0. Ez az eredmény egyfelől megnyugtató, mert azt mutatja, hogy a felhasznált precízió mellett a lehető legjobbat hoztuk ki a feladatból, másfelől viszont nem tartalmaz egyetlen helyes értékes jegyet sem a valódi reziduumból, amely amúgy $3{,}14 - 2{,}78 \times 1{,}13 = 3{,}14 - 3{,}1414 = -0{,}0014$. Ami történt: b és $a\hat{x}$ jellegükből fakadóan csaknem egyenlők, így a különbségük már csak a kerekítési hibát tartalmazza. A feladat korábbi elemzése szerint

$$3{,}14 = \mathrm{fl}(a\hat{x}) = a\hat{x}(1+\delta_1) = 3{,}1414(1+\delta_1),$$

amelyből $\delta_1 = -0{,}0014/3{,}1414 \approx -0{,}00044566$. A későbbi kivonásban nincs kerekítési hiba (mint a kioltás esetén általában), így $\delta_2 = 0$. A kapott számított reziduum

$$\mathrm{fl}(b - a\hat{x}) \approx r(1+\delta_2) - \delta_1 b = r - \delta_1 b \approx -0{,}0014 - (-0{,}0014) = 0.$$

Általánosságban a reziduum pontos kiszámításához a munka során használt precíziónak akár a kétszeresére is szükség lehet.

1.3.10 Más aritmetikai rendszerek

Manapság a tudományos számítások túlnyomó többségében az IEEE szabvány szerinti lebegőpontos aritmetikát használjuk. Mivel szinte minden modern mikroprocesszor hardveresen támogatja, az IEEE lebegőpontos aritmetika rendkívül gyors, a dupla pontosságú ábrázolás pedig a legtöbb gyakorlati célra több mint elegendő precíziót biztosít. Időnként előfordulhatnak azonban olyan esetek, amikor ennél nagyobb pontosságra van szükség – például egy elkerülhetetlenül nagyon érzékeny (rosszul kondicionált) feladat megoldásakor, vagy esetleg a számítási műveletek puszta mennyisége miatt (bár ehhez rendszerint valóban hatalmas számítási volumen szükséges). Ilyenkor a rendelkezésre álló pontosság kiterjesztésére több alternatíva is adódik, ám sietve hozzá kell tennünk, hogy a kiterjesztett pontosság használata nem helyettesítheti a feladatok gondos megfogalmazását és a megbízható megoldási technikákat.

Néhány számítógépes rendszer hardveresen is biztosít négyszeres pontosságot, és ez valószínűleg egyre elterjedtebbé válik, ahogy a processzorok gyorsulnak, a memóriák pedig egyre nagyobbak lesznek. Számos olyan szoftvercsomag is elérhető, amely többszörös pontosságú lebegőpontos aritmetikát kínál (lásd az 1.4.3. szakaszt). Egyes szimbolikus számítási környezetek – például a Maple és a Mathematica (lásd az 1.4.2. szakaszt) – tetszőleges pontosságú aritmetikát biztosítanak abban az értelemben, hogy a pontosság szükség szerint növelhető, így a számítás során végig megőrizhetők az egzakt eredmények. Az ilyen szoftveres megközelítéseknek azonban jelentős hátrányaik vannak a sebesség és a memóriaigény terén: a szoftveresen végzett aritmetika nagyságrendekkel lassabb lehet, mint a megfelelő hardveres lebegőpontos műveletek, és nagy mennyiségű memóriára lehet szükség a kapott hosszú számjegysorozatok tárolásához. Még ha a pontosság abban az értelemben tetszőleges is, hogy dinamikusan változhat, végső soron az adott számítógépen rendelkezésre álló véges memória mindig határt szab neki.

Bármilyen pontosságot is használunk, a numerikus analízis egyik fő kérdése, hogy egy adott számításban valójában milyen pontosságot érünk el. Ahogy ebben a fejezetben láttuk – és a könyv hátralévő részében is látni fogjuk –, a hagyományos hibaelemzés a megoldandó feladat, a használt algoritmus, valamint azon aritmetika tulajdonságainak matematikai vizsgálatán nyugszik, amelyen az algoritmust végrehajtjuk. Az *intervallumanalízis* egy olyan alternatív megközelítés, amely a bizonytalanságok továbbterjedését magába az aritmetikai rendszerbe építi be, és ezzel legalábbis elvben automatikusan meghatározza a pontosságot. Az alapötlet az, hogy minden numerikus mennyiséget egy zárt intervallumként – mondjuk $[a, b]$ – ábrázolunk, amelyet az adott mennyiség összes lehetséges értéke halmazának tekintünk. Az intervallum hossza ekkor a mennyiség bizonytalanságát, azaz a lehetséges hibáját képviseli (ha nincs bizonytalanság, akkor $a = b$).

Két intervallumon végzett aritmetikai művelet eredménye a megfelelő valós aritmetikai művelet összes lehetséges eredményének halmaza, ha az operandusokat a két intervallumból vesszük:

$$[a, b] \text{ op } [c, d] = \{x \text{ op } y : x \in [a, b] \text{ és } y \in [c, d]\},$$

ahol op a $+$, $-$, $\times$, $/$ műveletek valamelyike. Az eredményül kapott halmaz maga is intervallum, amelynek végpontjai a következő szabályok szerint számíthatók ki:

$$
\begin{aligned}
[a,b]+[c,d] &= [a+c,\ b+d],\\
[a,b]-[c,d] &= [a-d,\ b-c],\\
[a,b]\times[c,d] &= \big[\min(ac,ad,bc,bd),\ \max(ac,ad,bc,bd)\big],\\
[a,b]/[c,d] &= [a,b]\times[1/d,\ 1/c], \quad \text{feltéve, hogy } 0\notin[c,d].
\end{aligned}
$$

Lebegőpontos aritmetikában való megvalósításkor az intervallum végpontjainak kiszámítását megfelelően kell kerekíteni annak érdekében, hogy a számított intervallum biztosan tartalmazza a megfelelő egzakt intervallumot (a bal végpontot $-\infty$ felé, a jobb végpontot $+\infty$ felé kerekítjük; ez az úgynevezett *irányított kerekítés* az IEEE aritmetikában opcióként elérhető).

A bizonytalanságok (köztük a kezdeti bemenet bizonytalanságának) továbbterjesztése a számítási folyamaton keresztül egyszerű módszernek tűnhet az automatikus hibaelemzéshez, a gyakorlatban azonban a kapott intervallumok gyakran túl szélesek ahhoz, hogy hasznosak legyenek – nagyjából ugyanabból az okból kifolyólag, amiért az előreható hibaelemzés is gyakran túlzottan pesszimista korlátokat ad. Ha a számítást rögzített precízióval dolgozó, egymás után alkalmazott függvények kompozíciójának tekintjük, akkor a végső intervallum szélessége az összes érintett függvény kondíciószámának szorzatával arányos. Ha sok ilyen függvény van, vagy ha rosszul kondicionáltak, akkor a végső intervallum valószínűleg túl széles lesz ahhoz, hogy érdemi információt nyújtson. További probléma, hogy az intervallumanalízis hajlamos figyelmen kívül hagyni a számítási változók közötti függőségeket – például, ha ugyanaz a változó többször is megjelenik egy számításban –, és ezeket független bizonytalansági forrásokként kezeli, ami ismét feleslegesen széles intervallumokhoz vezethet. Egy triviális példa: $[a,b]-[a,b]=[a-b,\ b-a]$ adódik a várt $[0,0]$ helyett.

Az intervallumaritmetika által kapott intervallumszélességek kordában tarthatók, ha a rendszert változó precízióval valósítjuk meg. Az úgynevezett *tartomány-aritmetikában* (range arithmetic) például a szokásos lebegőpontos aritmetikát két módon is kibővítjük: egyrészt a mantissza tetszőleges hosszúságú lehet egy előre meghatározott precíziókorlátig, másrészt egy további r *tartományjegyet* tartunk fenn, amely a mantissza bizonytalanságát ($\pm r$) jelöli. A tartományszámokon végzett aritmetikai műveletek a korábban megadott szokásos intervallumaritmetikai szabályokat követik. A számítások előrehaladtával, ha egy adott érték bizonytalansága nő, akkor a mantisszájának hosszát ennek megfelelően csökkentik. Ha a végső eredmény mantisszája túl kevés számjegyet tartalmaz a pontossági követelmény teljesítéséhez, akkor a precíziókorlátot megemelik, és az egész számítást annyiszor ismétlik meg, ahányszor csak szükséges. Ily módon sok (de nem minden) számítási feladat megoldható tetszőlegesen előírt pontossággal, ám gyakran megjósolhatatlan (és potenciálisan hatalmas) futásidő- és memóriaigény árán.

Több olyan szoftvercsomag is elérhető, amely intervallum- vagy tartomány-aritmetikát valósít meg (lásd az 1.4.3. szakaszt). Az említett hátrányok korlátozták e módszerek széles körű elterjedését az általános tudományos számításokban, ám az intervallumos módszerek ennek ellenére a kevés jól használható alternatíva egyikét nyújtják bizonyos speciális feladatoknál – ilyenek például a nemlineáris egyenletrendszerek többdimenziós garantált megoldási módszerei és a globális optimalizálási feladatok. Bár az intervallumos módszerek részletes bemutatása meghaladja e könyv kereteit, a megfelelő helyeken jelezni fogjuk az intervallum-alapú szoftverek elérhetőségét.

1.3.11 Komplex aritmetika

Ahogyan az m/n alakú törtek – ahol m és n egész számok – az egész számok halmazát bővítve a racionális számokat alkotják, az algebrai számok (például $\sqrt{2}$) és a transzcendens számok (például π) pedig a racionális számokat bővítve a valós számokat, úgy a valós számok $\sqrt{-1}$-gyel való bővítése a *komplex* számokat eredményezi. Ebben a könyvben a komplex számokat kifejezetten csak a sajátérték-feladatok (4. fejezet) és a Fourier-transzformációk (12. fejezet) tárgyalásánál használjuk. Máshol az egyszerűség kedvéért nagyrészt a valós esetre szorítkozunk, ám az általunk tárgyalt algoritmusok többsége a komplex esetre is alkalmazható.

Ahogy a matematikában szokásos, ebben a könyvben is a $\sqrt{-1}$ képzetes egységet i-vel jelöljük, noha egyes mérnöki tudományágak ehelyett j-t használnak. Egy adott z komplex szám felírható a

$$z = x + iy$$

alakban, ahol az $x = \mathrm{Re}(z)$ és $y = \mathrm{Im}(z)$ valós számok rendre a z valós és képzetes részei. Az összes komplex szám halmazát a $\mathbb{C} = \{x + iy : x, y \in \mathbb{R}\}$ jelöli. Egy z komplex szám *valós*, ha $\mathrm{Im}(z) = 0$, és *képzetes* (vagy tisztán képzetes), ha $\mathrm{Re}(z) = 0$.

$\mathbb{C}$-t elképzelhetjük egy kétdimenziós Descartes-féle síkként – ez a *komplex számsík* (vagy más néven *Argand-diagram*) –, amelynek két valós koordinátáját egy adott komplex szám valós és képzetes része adja meg. Konvenció szerint a valós rész a vízszintes, a képzetes rész pedig a függőleges tengelyen szerepel a komplex számsíkban (lásd az 1.5. ábrát). Az $i = \sqrt{-1}$-vel való szorzás a komplex számsíkban $\pi/2$-vel való elforgatásnak felel meg. Hasonlóképpen az $i^2 = -1$-gyel való szorzás π-vel való elforgatásnak, az $i^4 = 1$-gyel való szorzás pedig 2π-vel való elforgatásnak (azaz az 1, ahogy várható, a multiplikatív egység).

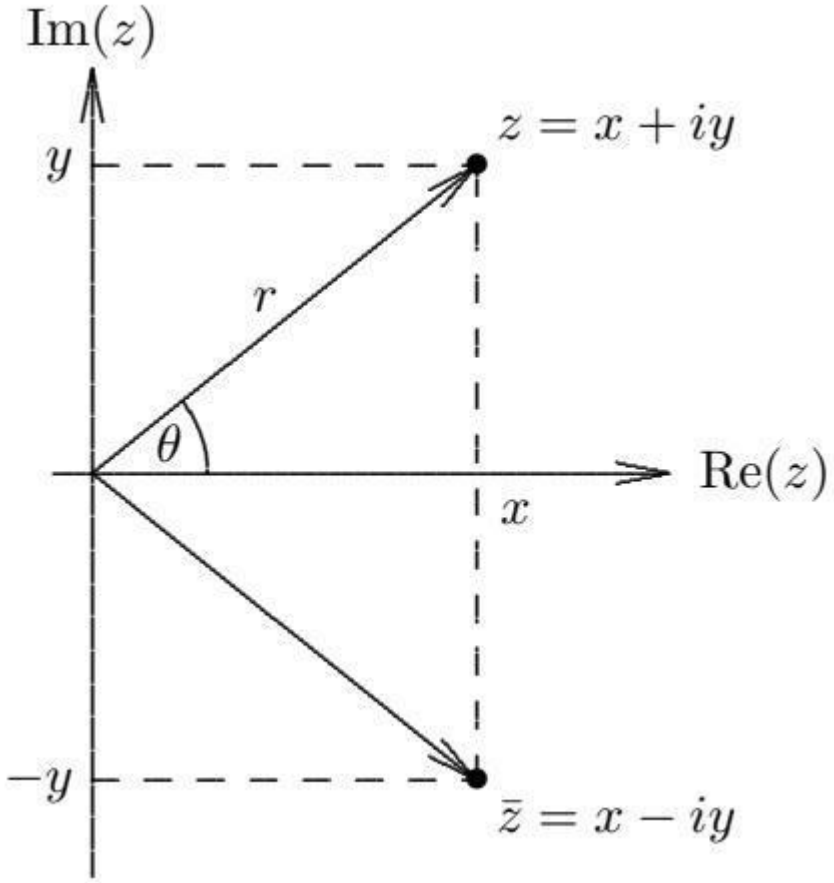

1.5. ábra: Komplex számsík a z komplex szám és $\bar{z}$ komplex konjugáltjának Descartes- és polárkoordinátás ábrázolásával.

Két $z_1 = x_1 + iy_1$ és $z_2 = x_2 + iy_2$ komplex szám szabványos aritmetikai műveletei a következőképpen definiáltak:

$$\begin{aligned}
z_1 + z_2 &= (x_1 + x_2) + i(y_1 + y_2),\\
z_1 - z_2 &= (x_1 - x_2) + i(y_1 - y_2),\\
z_1 \times z_2 &= (x_1x_2 - y_1y_2) + i(x_1y_2 + x_2y_1),\\
z_1/z_2 &= \left(\frac{x_1x_2 + y_1y_2}{x_2^2 + y_2^2}\right) + i\left(\frac{x_2y_1 - x_1y_2}{x_2^2 + y_2^2}\right), \quad \text{feltéve, hogy } z_2 \neq 0.
\end{aligned}$$

Megjegyezzük, hogy két komplex számon végzett aritmetikai művelet kettőtől tizenegy valós aritmetikai műveletet igényel – a konkrét komplex művelettől függően –, így a komplex aritmetika lényegesen költségesebb lehet, mint a valós aritmetika.

Egy $z = x + iy$ komplex szám *komplex konjugáltját* $\bar{z}$ jelöli, és

$$\bar{z} = x - iy.$$

Egy komplex szám és komplex konjugáltja tehát a valós tengelyre nézve szimmetrikus (egymás

tükörképei) (lásd az 1.5. ábrát). Bármely $z = x + iy$ komplex számra

$$z\bar{z} = (x + iy)(x - iy) = x^2 + y^2$$

mindig valós és nemnegatív, így egy $z = x + iy$ komplex szám *modulusa* (más néven *abszolút értéke*) definiálható:

$$|z| = \sqrt{z\bar{z}} = \sqrt{x^2 + y^2},$$

amely éppen az (x, y) pont és az origó $(0, 0)$ közötti szokásos euklideszi távolság a komplex számsíkban.

Egy z komplex szám egy másik hasznos ábrázolása a polárkoordinátás alak:

$$z = x + iy = r(\cos\theta + i\sin\theta),$$

ahol $r = |z|$ és $\theta = \arctan(y/x)$ (lásd az 1.5. ábrát). Az Euler-azonosságot használva,

$$e^{i\theta} = \cos\theta + i\sin\theta,$$

megkapjuk az exponenciális ábrázolást:

$$z = re^{i\theta}.$$

Ez utóbbi különösen fontos lesz a Fourier-transzformációk tárgyalásánál (lásd a 12. fejezetet). Vegyük észre, hogy az exponenciális ábrázolásban a komplex szorzás és osztás egyszerűbb alakú:

$$\begin{aligned} z_1 \times z_2 &= r_1 r_2\, e^{i(\theta_1+\theta_2)}, \\ z_1/z_2 &= (r_1/r_2)\, e^{i(\theta_1-\theta_2)}. \end{aligned}$$

Egy számítógépen egy komplex számot jellemzően két szokásos lebegőpontos értékkel ábrázolunk, amelyek a valós és a képzetes résznek felelnek meg. A komplex aritmetika támogatása nyelvenként és rendszerenként változó; a Fortran minden változata például kifejezett támogatást ad a komplex adattípusokhoz és aritmetikához, míg a C és leszármazottai jellemzően nem. A MATLAB (lásd az 1.4.2. szakaszt) zökkenőmentesen támogatja a komplex aritmetikát; sőt a MATLAB elsődleges numerikus adattípusa komplex. A komplex aritmetikát a Python is támogatja – a képzetes számok `j` utótagúak, az ezekhez tartozó függvények pedig a `cmath` modulban találhatók.

1.4 Matematikai szoftver

Ez a könyv a numerikus analízis és a tudományos számítások témáinak széles körét tárgyalja. Bár minden témának érintjük az alapvető aspektusait, arra nincs lehetőségünk, hogy bármelyiket is kimerítően tárgyaljuk. Ahhoz, hogy érdekes számítási feladatokat tudjunk megoldani, gyakran szakemberek által fejlesztett matematikai szoftverekre támaszkodunk. Ha az algoritmikus részleteket az ilyen szoftverekre bízzuk, figyelmünket a helyes feladatmegfogalmazásra és az eredmények értelmezésére összpontosíthatjuk. Minden feladattípusnál csak a legalapvetőbb

algoritmusokat tekintjük át, elsősorban az általuk nyújtott betekintés kedvéért – hogy megalapozottan tudjunk megfelelő módszert választani, és azt körültekintően alkalmazni. Elsődleges célunk az, hogy a matematikai szoftverek értő felhasználói legyünk, ne pedig az alkotói.

Mielőtt rátérnénk a jó matematikai szoftverek konkrét forrásaira, foglaljuk össze azokat a kívánatos tulajdonságokat, amelyekkel az ilyen szoftvereknek rendelkezniük kell (a felsorolás nem tükröz fontossági sorrendet):

- **Megbízhatóság:** könnyű feladatok esetén mindig helyesen működik.
- **Robusztusság:** nehéz feladatok esetén is rendszerint működik, ám amikor mégis kudarcot vall, azt elegánsan és informatív módon teszi.
- **Pontosság:** a feladat és a bemenő adatok által indokolt mértékben pontos eredményt ad, lehetőleg az elért pontosság becslésével együtt.
- **Hatékonyság:** a végrehajtási idő és a memóriaigény megközelíti a megoldandó feladat elméleti minimumát.
- **Hordozhatóság:** kis módosítással vagy anélkül is adaptálható az új számítási környezetekhez.
- **Karbantarthatóság:** könnyen érthető és módosítható.
- **Használhatóság:** kényelmes és jól dokumentált felhasználói felülettel rendelkezik.
- **Alkalmazhatóság:** feladatok széles körét képes megoldani.

Nyilvánvaló, hogy ezek a tulajdonságok gyakran ütköznek egymással, és ritka az olyan szoftver, amely mindegyiknek maradéktalanul megfelel. Ez a lista azonban segít a matematikai szoftverek felhasználóinak felismerni, milyen tulajdonságokat érdemes keresniük, a fejlesztők számára pedig kijelöl néhány elérendő célt.

1.4.1 Matematikai szoftverkönyvtárak Itt sorolunk fel néhány széles körben elérhető, általános célú matematikai szoftverforrást. Ennek a könyvnek minden fejezete végén konkrét rutinokat ismertetünk adott típusú feladatokhoz – mind ezekből az általános könyvtárakból, mind specializáltabb csomagokból.

- **FMM:** Forsythe, Malcolm és Moler *Computer Methods for Mathematical Computations* című könyvéhez [152] tartozó szoftver. Elérhető a Netlibről.
- **GAMS:** *Guide to Available Mathematical Software*, amelyet a National Institute of Standards and Technology (NIST) állít össze. `gams.nist.gov`
- **GSL (GNU Scientific Library):** Átfogó matematikai szoftverkönyvtár C és C++ nyelvhez. `www.gnu.org/software/gsl/`
- **HSL (Harwell Subroutine Library):** Az angliai Harwell Laboratóriumban kifejlesztett szoftver. `www.hsl.rl.ac.uk`
- **IMSL (International Mathematical and Statistical Libraries):** Átfogó matematikai szoftverkönyvtár. A Rogue Wave Software, Inc. kereskedelmi terméke. `www.roguewave.com/products-servi`
- **KMN:** Kahaner, Moler és Nash *Numerical Methods and Software* [262] könyvéhez tartozó szoftver.
- **NAG (Numerical Algorithms Group):** Átfogó matematikai szoftverkönyvtár. A NAG Inc. kereskedelmi terméke. `www.nag.com`
- **NAPACK:** Hager *Applied Numerical Linear Algebra* [220] könyvéhez tartozó szoftver. A lineáris algebrán kívül rutinokat tartalmaz nemlineáris egyenletekhez, feltétel nélküli optimalizáláshoz és gyors Fourier-transzformációkhoz is. Elérhető a Netlibről.
- **Netlib:** Sokféle forrásból származó ingyenes szoftver. `www.netlib.org`
- **NR (Numerical Recipes):** Press, Teukolsky, Vetterling és Flannery *Numerical Recipes* [377] könyvéhez tartozó szoftver. Elérhető Fortran-, C- és C++-változatban. `numerical.recipes`

- **NUMAL:** Az amszterdami Mathematisch Centrumban kifejlesztett szoftver. Algol- és Fortran-változatban is létezik, de leginkább Lau *A Numerical Library for Scientists and Engineers* [297, 298] könyveiből érhető el C és Java változatban.
- **NUMERALGO:** A *Numerical Algorithms* folyóiratban megjelent szoftverek. Elérhető a Netlibről.
- **PORT:** A Bell Laboratories-ben kifejlesztett szoftver. Egyes rutinok szabadon elérhetők a Netlibről, más részek csak kereskedelmi licenc alatt.
- **SciPy/NumPy:** Átfogó, nyílt forráskódú matematikai szoftverkönyvtár Pythonhoz. `www.scipy.org`
- **SLATEC:** Egy USA-beli kormányzati laboratóriumokból álló konzorcium által összeállított szoftver. Elérhető a Netlibről.
- **SOL:** Optimalizálási és kapcsolódó feladatokhoz készült szoftver a Stanford University Systems Optimization Laboratoryjából. `web.stanford.edu/~saunders/brochure/brochure.html`
- **TOMS:** Az *ACM Transactions on Mathematical Software* (korábban *Collected Algorithms of the ACM*) folyóiratban megjelent szoftverek. Az algoritmusokat szám (megjelenési sorrendben) és név szerint egyaránt azonosítjuk. Elérhető a Netlibről.

1.4.2 Tudományos számítási környezetek Az imént felsorolt szoftverkönyvtárak olyan szubrutinokat tartalmaznak, amelyeket a felhasználó által írt – rendszerint egy hagyományos programozási nyelvben, például Fortranban vagy C-ben készült – programoknak kell meghívniuk. A tudományos számítások egyre népszerűbb alternatívája az olyan interaktív környezetek használata, amelyek erőteljes, kényelmesen elérhető, beépített matematikai képességeket kínálnak, gyakran kifinomult grafikával és egy nagyon magas szintű programozási nyelvvel párosítva, amely új algoritmusok gyors prototipizálására alkalmas.

Az egyik leggyakrabban használt ilyen számítási környezet a MATLAB, amely a The MathWorks, Inc. (`www.mathworks.com`) kereskedelmi terméke. A MATLAB (MATrix LABoratory) egy interaktív rendszer, amely kiterjedt matematikai képességeket – különösen lineáris algebrában –, nagy teljesítményű tudományos vizualizációt, magas szintű programozási nyelvet és többféle választható „toolboxot” ötvöz, amelyek speciális képességeket nyújtanak egy-egy alkalmazási területhez, például jelfeldolgozáshoz, képfeldolgozáshoz, szabályozáshoz, rendszeridentifikációhoz, optimalizáláshoz vagy statisztikához. A MATLAB sokféle számítógépre elérhető, szakmai és hallgatói kiadásban egyaránt. Hasonló képességeket nyújt az Octave, amely szabadon elérhető (`www.gnu.org/software/octave`). További, egyre népszerűbb alternatíva a Python, amely általános célú magas szintű programozási nyelvet, interaktív végrehajtási környezetet, kiterjedt matematikai szoftverkönyvtárakat (pl. SciPy) és átfogó ábrázolási képességeket (Matplotlib) kínál.

Az interaktív számítási környezetek egy másik családja elsősorban szimbolikus (nem pedig numerikus) számításon alapul, amit gyakran *komputeralgebrának* neveznek. Ezek a csomagok – az Axiom, Derive, Magma, Maple, Mathematica, Maxima és Reduce – sok ugyanolyan matematikai és grafikus képességet nyújtanak, és ezenfelül szimbolikus differenciálást, integrálást, egyenletmegoldást, polinommanipulációt és hasonlókat kínálnak, valamint tetszőleges pontosságú aritmetikát is. A MATLAB egy „Symbolic Math” toolbox révén szintén rendelkezik szimbolikus számítási képességekkel, Pythonhoz pedig a SymPy könyvtár kínál hasonló lehetőségeket.

Mivel a MATLAB és a Python ezek közül a környezetek közül a leggyakrabban használtak a könyvben tárgyalt feladattípusokhoz, az egyes feladatkategóriákhoz rendelkezésre álló szoftverek összegzéseiben a hagyományos szoftverkönyvtárak mellett konkrét MATLAB- és Python-függvényeket – akár az alapkörnyezetből, akár a kiegészítő toolboxokból és könyvtárakból – is

felsorolunk.

1.4.3 Kiterjesztett aritmetikai csomagok A többszörös pontosságú aritmetikát biztosító szoftvercsomagok közé tartoznak a TOMS-ból származó MP(#524), FM(#693), MPFUN(#719) és ZM(#786); a CLN (Class Library for Numbers); a GMP (GNU Multiple Precision Arithmetic Library); a Python `mpmath` könyvtára; valamint az NR [377] és [378] rutinjai. Intervallum- vagy tartomány-aritmetikát megvalósító szoftvercsomagok és rendszerek többek között a TOMS-ból származó INTLIB(#737, #763); a PROFIL/BIAS [278]; az Arb (`arblib.org`); a MATLAB-hoz készült INTLAB eszköztár; valamint az [1]-hez tartozó szoftver.

1.4.4 Gyakorlati tanácsok a szoftverhasználathoz Ez a szakasz gyakorlati tanácsokat tartalmaz a könyvben hivatkozott szoftverek beszerzésére és használatára, különös tekintettel az egyes fejezetek végén található számítógépes feladatok alapján készíthető programozási házi feladatokra. A számítógépes feladatok egyik konkrét szoftvertől vagy programozási nyelvtől sem függnek, így több lehetőség is rendelkezésre áll. Egy adott esetben a legjobb választás a felhasználó tapasztalatától, erőforrásaitól és céljaitól függ.

A hivatkozott szoftverek sokféle forrásból származnak: nagy kereskedelmi könyvtárakból, például az IMSL-ből és a NAG-ból; nyilvános, szabadon hozzáférhető tárolókból, például a Netlibről; valamint tudományos számítási környezetekből, például a MATLAB-ból és a Pythonból. Sok akadémiai és ipari számítási központban és laboratóriumban az ilyen szoftverek reprezentatív mintája már telepítve és használatra kész állapotban rendelkezésre áll. Mindenesetre e könyv összes számítógépes feladatához bőséges mennyiségű szoftver szerezhető be ingyenesen az interneten keresztül, vagy jelképes összegért egyéb forrásokból (például a kísérő tankönyvekből). A megfelelő szoftver megtalálása, letöltése és telepítése hasznos, valós tapasztalatot jelent, és az ennek során megszerzett készségek fontos gyakorlati kiegészítői a könyvben tanultaknak.

Talán a legfontosabb döntés a programozási nyelv megválasztása. Ahogy az 1.4.2. szakaszban már tárgyaltuk, a MATLAB (vagy az Octave) és a Python környezetei nemcsak magas szintű programozási nyelvet nyújtanak, hanem viszonylag zökkenőmentes hozzáférést adnak kiterjedt matematikai szoftverkönyvtárakhoz is. Az ilyen környezetek felhasználói több előnyt is élvezhetnek. A felhasználói programok általában sokkal rövidebbek lesznek az explicit deklarációk, a memóriakezelés és sok ciklus mellőzhetősége miatt. További bónusz a beépített grafika, amely feleslegessé teszi az adatok külön utófeldolgozási fázisban történő ábrázolását.

A hagyományos programozási nyelvek közül a Fortran volt a tudományos számítások eredeti nyelve, és a korábbi szoftverkönyvtárak és alkalmazási kódok nagy része Fortranban íródott. E könyv használata során a Fortran-felhasználók előnyére válik, hogy ebben a nyelvben áll rendelkezésre a legszélesebb szoftverválaszték, és kompatibilis a létező alkalmazási kódok túlnyomó többségével. Emellett, mivel a Fortran viszonylag szigorú nyelv, és a hozzá tartozó fordítók sok év optimalizálási munkáján vannak túl, a Fortran-fordítók egyes számítógépes rendszereken gyakran hatékonyabb futtatható kódot állítanak elő.

A C sokoldalúbb és kifejezőbb nyelv, mint a Fortran, és a C (valamint rokon nyelvei, például a C++ és a Java) gyakrabban szerepel a kezdő programozási tárgyak tananyagában. Ha ezzel a könyvvel C-t szeretnél használni, bőséges mennyiségű szoftver áll rendelkezésedre. Ezenfelül sok számítógépes rendszeren viszonylag egyszerű Fortran-rutinokat C-programokból meghívni. A főbb eltérések, amelyekre figyelni kell: a rutinok nevei kissé módosulhatnak (gyakran a szokásos név elé vagy után kerül egy aláhúzás); minden argumentumot a Fortran-szubrutinoknak cím szerint (azaz mutatóként C-ben) kell átadni; továbbá a C és a Fortran ellentétes konvenciókat használ a tömbök

tárolására (a C a mátrixokat sorfolytonosan, a Fortran pedig oszlopfolytonosan tárolja). Végül a Fortran-forráskód automatikusan át is alakítható C-kódra a Netlibről elérhető `f2c` konverterrel, így az – például az interneten – beszerzett Fortran-rutinok könnyen használhatók C-programokkal.

A könyv egyes számítógépes feladatai grafikus kimenetet igényelnek. A szükséges ábrák előállítására több lehetőség is rendelkezésre áll, a használt számítási környezettől függően. Az olyan interaktív környezetekben, mint a MATLAB vagy a Python, kiterjedt grafikai képességek automatikusan elérhetők. A hagyományos programozási nyelvekkel való használatra szabadon elérhető grafikai csomagok többek között a `gnuplot` (`www.gnuplot.info`), a `pgplot` (`www.astro.caltech.edu/~tjp/pgplot`) és a `plplot` (`plplot.sourceforge.net`). Kifinomultabb és erőteljesebb tudományos vizualizációs rendszerek is léteznek, ám ezek képességei messze meghaladják a könyv számítógépes feladataihoz szükséges, viszonylag egyszerű ábrázolásokat.

Egy másik fontos programozási szempont a teljesítmény. A mai mikroprocesszor-alapú számítógépes rendszerek teljesítménye gyakran kritikusan függ a memóriahierarchia (regiszterek, gyorsítótár, RAM, lemez stb.) megfontolt kihasználásától, mind a programozó, mind az optimalizáló fordító részéről. Ezért nemcsak a megfelelő algoritmust kell megválasztani, hanem gondosan meg is kell azt valósítani, hogy maximalizáljuk az adatok újrafelhasználását, miközben azok a memóriahierarchia leggyorsabb elérési idejű részeiben vannak. A programozás teljesítményre vonatkozó szempontjairól lásd [121, 188, 201]. Szerencsére az ilyen szintű programozás részletei a könyvben ajánlott könyvtári rutinok belsejében általában rejtve maradnak a felhasználó elől. Ez csak egyike azon számos előnynek, amely a meglévő, szakemberek által írt tudományos szoftverek – ahol csak lehetséges – használatából fakad.

Ha olyan tudományos számítási környezetet használsz, mint a MATLAB vagy a Python, tudnod kell, hogy jelentős teljesítménykülönbségek lehetnek a beépített – általában nagyon gyors – műveletek, és a felhasználó által explicit módon megírt kódok között, amelyek az értelmező (interpreter) üzemmód és a memóriakezelés többletköltsége miatt általában sokkal lassabbak. Ezért ilyen körülmények között óvatosnak kell lenni a teljesítmény-összehasonlításokkal. Előfordulhat például, hogy egy algoritmus elvileg rosszabb egy másiknál, a gyakorlatban mégis jobban teljesít, pusztán azért, mert hatékonyabban hasznosítja a gyors, beépített műveleteket.

1.5 Történeti jegyzetek és további olvasnivaló

A ma numerikus analízisnek vagy tudományos számításoknak nevezett tudományág jóval megelőzi a modern számítógépek megjelenését. A ma is használatos fogalmak és módszerek közül sokat a huszadik század előtti nagyok – Newton (1642–1727), Euler (1707–1783), Lagrange (1736–1813), Laplace (1749–1827), Legendre (1752–1833), Gauss (1777–1855), Cauchy (1789–1857), Jacobi (1804–1851), Adams (1819–1892), Csebisev (1821–1894), Hermite (1822–1901), Laguerre (1834–1886) és mások – fogalmaztak meg először, és nevük újra meg újra felbukkan ebben a könyvben. A fő feladat akkoriban is, akárcsak ma, a fizikában, a csillagászatban, a geodéziában és más tudományterületeken felmerülő matematikai feladatok közelítő megoldására szolgáló hatékony módszerek megtalálása volt. Sőt, a számítási erőforrások hatékony felhasználása még kritikusabb volt, amikor ceruzával, papírral és emberi agyerővel (esetleg asztali számológéppel) dolgoztak, mint ma egy modern, nagy sebességű számítógéppel.

Nagyrészt a modern számítógépek egyszerűen megnövelték a megoldható feladatok méretét. Emellett szükségessé tették a kerekítési hibák gondosabb elemzését és kontrollját is, mert a számítást már nem ember végzi, aki szükség szerint további pontossággal dolgozhat. Nem kétséges azonban, hogy a digitális számítógépek kifejlődése adta a lökést a numerikus analízis virágzó,

termékeny és lendületesen fejlődő területté válásához, amely lehetővé tette, hogy a számítás ma a modern természettudomány és mérnöki gyakorlat minden területén mindenütt jelen legyen. Sőt a számítás az elmélet és a kísérlet mellett a tudományos ismeretek és a mérnöki gyakorlat előrehaladásának egyenrangú és nélkülözhetetlen partnerévé vált [267].

A numerikus analízis korai történetéről lásd [193]-at; a tudományos számításoknak a számítógépes korszakban való újabb fejlődéséről lásd [57, 63, 346]-ot. A numerikus analízis irodalma – a tankönyvektől a kutatási monográfiákon át a folyóiratokig – jóval terjedelmesebb annál, semhogy itt megfelelően tárgyalni lehetne. Ebben a szövegben megpróbáljuk megfelelően megadni az elismerést a bemutatott fő gondolatok eredetének (legalábbis azoknak, amelyek nem nyilvánvalók már a névről), és (rendszerint másodlagos) forrásokat idézünk a további olvasáshoz, ám ezek a hivatkozások és ajánlások semmiképpen sem teljesek. Túl sok kiváló általános numerikus analízis tankönyv létezik ahhoz, hogy mindegyiket megemlítsük, de közülük sok ma is érdemes olvasmány (beleértve a régebbieket is, amelyek közül sokat olcsó utánnyomásokban is újra kiadtak). Csak a tárgyalásunkhoz leginkább közvetlenül kapcsolódókat idézzük.

A legtöbb numerikus analízis tankönyv általánosan tárgyalja a hibaelemzést. A kerekítési hibák elemzésének alapművei közé tartozik az [500] – értékes meglátások kincsesháza. Szerzője, James H. Wilkinson kulcsszerepet játszott a hátraható hibaelemzés fogalmának kidolgozásában és elterjesztésében, és számos híres „számítási ellenpéldáért” is felelős, amelyek váratlan feladatokban és algoritmusokban fellépő numerikus instabilitásokat tárnak fel [502, 503]. Hasonló szellemben készült újabb munka a [237]. A hibaelemzés automatizálására – beleértve az intervallumaritmetikát – különféle megközelítésekről lásd [1, 6, 213, 254, 329, 337, 338, 348, 469]-et. Hibaelemzésre szolgáló MATLAB toolboxot tárgyal [69]. A kondicionáltság általános fogalmának egy korai tárgyalása [385]-ben található.

A számítógépes aritmetika általános tárgyalásai közé tartoznak [54, 282, 283, 287, 356, 363]. A lebegőpontos aritmetika részletes tárgyalásához lásd [345, 423]-at; rövidebb áttekintéshez [279]-et. A lebegőpontos aritmetika szabványosítására irányuló erőfeszítést és a létrejött szabvány magas színvonalát nagyrészt William Kahan inspirálta, aki számos ismert számítási ellenpéldáért is felelős. Az IEEE lebegőpontos szabvány [247]-ben található. A lebegőpontos aritmetikáról és az IEEE szabványról szóló hasznos bemutatók közé tartozik [189, 361].

A matematikai szoftver mint a numerikus analízis és az informatika részterületének megjelenéséről lásd a [80] áttekintést és a [42, 88, 131, 230, 251, 386, 387] gyűjteményeket. A szakmai minőségű szoftvereket (nem csak szemléltető kódrészleteket) tartalmazó talán legkorábbi numerikus módszerek tankönyv a [406] volt, amely hangvételében, stílusában és tartalmában hasonló Forsythe, Malcolm és Moler nagy hatású könyvéhez [152], amely ezt a megközelítést népszerűsítette. További, bevezető szintű tárgyalást és példákat nyújtó tankönyvek közé tartoznak [13, 18, 85, 123, 208, 214, 240, 262, 331, 353, 380, 407, 428, 472, 481]. Haladóbb, általános tankönyvek közé tartoznak [17, 87, 92, 93, 111, 172, 196, 248, 275, 358, 371, 379, 402, 429, 434, 448, 459, 474]. A numerikus számítás buktatóinak felismeréséhez és elkerüléséhez gyakorlati tanácsokat nyújt [3, 4, 127, 151, 422].

Strang könyvei [435, 439, 440, 441] kiváló hátteret és rálátást nyújtanak az alkalmazott matematika számos olyan területére, amelyek általában is – és különösen e könyv szinte minden fejezete szempontjából – fontosak a numerikus számításhoz. A tudományos programozás elemi bevezetéseihez lásd [265, 480, 482, 517, 518]-at. Numerikus szoftverek tervezéséhez, megvalósításához és teszteléséhez – nem pusztán a használatukhoz – lásd [43, 80, 127, 328, 354]-et. További számítógépes gyakorlatok és projektek találhatók [89, 94, 130, 155, 167, 170, 200, 203, 205, 294, 353, 418]-ban.

Áttekintő kérdések

- **1.1.** Igaz vagy hamis: Egy feladat rosszul kondicionált, ha a megoldása nagyon érzékeny a feladat adatainak kis változásaira.
- **1.2.** Igaz vagy hamis: Nagyobb precíziójú aritmetika használata egy rosszul kondicionált feladatot jobban kondicionálttá tesz.
- **1.3.** Igaz vagy hamis: Egy feladat kondicionáltsága függ a megoldására használt algoritmustól.
- **1.4.** Igaz vagy hamis: Egy jó algoritmus a feladat kondíciójától függetlenül pontos megoldást ad.
- **1.5.** Igaz vagy hamis: Egy feladat megoldására választott algoritmusnak nincs hatása a továbbterjedő adathibára.
- **1.6.** Igaz vagy hamis: Egy stabil algoritmus jól kondicionált feladatra alkalmazva szükségképpen pontos megoldást ad.
- **1.7.** Igaz vagy hamis: Ha két valós szám lebegőpontos számként pontosan ábrázolható, akkor a rajtuk végzett valós aritmetikai művelet eredménye is ábrázolható lebegőpontos számként.
- **1.8.** Igaz vagy hamis: A lebegőpontos számok egyenletesen oszlanak el az értékkészletükön.
- **1.9.** Igaz vagy hamis: A lebegőpontos összeadás asszociatív, de nem kommutatív.
- **1.10.** Igaz vagy hamis: Egy lebegőpontos számrendszerben az alulcsordulási szint az a legkisebb pozitív szám, amely az 1-hez hozzáadva perturbálja az 1-et.
- **1.11.** Igaz vagy hamis: Az IEEE dupla pontosságú lebegőpontos aritmetika mantisszája pontosan kétszer olyan hosszú, mint az IEEE egyszeres pontosságúé.
- **1.12.** Mely három tulajdonság jellemzi a jól kitűzött feladatot?
- **1.13.** Sorolj fel három hibaforrást a tudományos számításokban.
- **1.14.** Fejtsd ki a különbséget a csonkítási (vagy diszkretizációs) hiba és a kerekítési hiba között.
- **1.15.** Fejtsd ki a különbséget az abszolút és a relatív hiba között.
- **1.16.** Fejtsd ki a különbséget a számítási hiba és a továbbterjedő adathiba között.
- **1.17.** Fejtsd ki a különbséget a precízió és a pontosság között.
- **1.18.** (a) Mit értünk egy feladat kondicionáltságán? (b) Függ-e ez a megoldásra használt algoritmustól? (c) Függ-e ez a megoldáshoz használt aritmetika precíziójától?
- **1.19.** Ha egy számítási feladat kondíciószáma 1, ez jó vagy rossz? Miért?
- **1.20.** Fejtsd ki a különbséget a relatív és az abszolút kondíciószám között.
- **1.21.** Mi az inverz feladat? Hogyan viszonyul egymáshoz egy feladat és az inverz feladat kondicionáltsága?
- **1.22.** (a) Mit értünk egy számított eredmény hátraható hibáján? (b) A hátraható hibaelemzés szemszögéből mikor tekinthető jónak egy adott feladat közelítő megoldása?
- **1.23.** Tegyük fel, hogy egy adott feladatot egy adott algoritmussal oldunk meg. Az alábbiak mindegyikéről mondd meg, hogy függ-e az algoritmus stabilitásától, és miért: (a) továbbterjedő adathiba; (b) a számított eredmény pontossága; (c) a feladat kondicionáltsága.
- **1.24.** (a) Fejtsd ki a különbséget az előreható és a hátraható hiba között. (b) Hogyan kapcsolódik az előreható és a hátraható hiba mennyiségileg egymáshoz?
- **1.25.** Adott lebegőpontos számrendszer esetén írd le szavakkal a gépi számok eloszlását a valós egyenes mentén.
- **1.26.** Lebegőpontos aritmetikában általában melyik károsabb: az alulcsordulás vagy a túlcsordulás? Miért?
- **1.27.** Lebegőpontos aritmetikában az alábbi műveletek közül, két pozitív lebegőpontos operandusra, melyek okozhatnak túlcsordulást? (a) összeadás; (b) kivonás; (c) szorzás; (d) osztás.

- **1.28.** Lebegőpontos aritmetikában az alábbi műveletek közül, két pozitív lebegőpontos operandusra, melyek okozhatnak alulcsordulást? (a) összeadás; (b) kivonás; (c) szorzás; (d) osztás.
- **1.29.** Sorolj fel két okot, amiért a lebegőpontos számrendszereket rendszerint normalizálják.
- **1.30.** Egy lebegőpontos rendszerben mely mennyiség határozza meg egy adott valós szám gépi számmal való ábrázolásakor fellépő maximális relatív hibát?
- **1.31.** (a) Fejtsd ki a különbséget a „nulla felé kerekítés" és a „legközelebbihez kerekítés" szabályai között egy lebegőpontos rendszerben. (b) E két szabály közül melyik pontosabb? (c) Mekkora számszerű különbséget okoz ez az ϵ_{mach} gépi epszilonban?
- **1.32.** Egy p számjegyű bináris lebegőpontos rendszerben legközelebbihez kerekítés mellett mekkora az ϵ_{mach} gépi epszilon értéke?
- **1.33.** Egy fokozatos alulcsordulást (szubnormális számokat) engedélyező lebegőpontos rendszerben minden szám ábrázolása egyértelmű marad-e? Miért?
- **1.34.** Egy lebegőpontos rendszerben két gépi szám szorzata rendszerint pontosan ábrázolható a lebegőpontos rendszerben? Miért?
- **1.35.** Egy lebegőpontos rendszerben két nem nulla gépi szám hányadosa mindig pontosan ábrázolható a lebegőpontos rendszerben? Miért?
- **1.36.** (a) Adj példát, amely megmutatja, hogy a lebegőpontos összeadás nem feltétlenül asszociatív. (b) Adj példát, amely megmutatja, hogy a lebegőpontos szorzás nem feltétlenül asszociatív.
- **1.37.** (a) Milyen körülmények között lép fel számjegykioltás egy lebegőpontos rendszerben? (b) A kioltás fellépése azt jelenti-e, hogy az azt kiváltó konkrét művelet valódi eredménye nem ábrázolható pontosan a lebegőpontos rendszerben? Miért? (c) Miért általában rossz a kioltás?
- **1.38.** Adj példát olyan számra, amelynek a tízes számrendszerbeli alakja véges (azaz véges számú nem nulla számjegyet tartalmaz), de a bináris alakja nem.
- **1.39.** Adj példákat olyan lebegőpontos aritmetikai műveletekre, amelyek a `Inf` és a `NaN` kivételes értékek mindegyikét előállítják.
- **1.40.** Egy β alapú, p precíziójú, legközelebbihez kerekítést használó lebegőpontos rendszerben mi a maximális relatív hiba bármely nem nulla valós szám ábrázolásában, a rendszer tartományán belül?
- **1.41.** Fejtsd ki, miért gyakran rossz a két hasonló abszolút értékű szám kivonásakor fellépő kioltás, annak ellenére, hogy az eredmény az operandusokra nézve pontosan helyes lehet.
- **1.42.** Tegyük fel, hogy egy tízes alapú lebegőpontos rendszerrel dolgozunk, amelynek gépi precíziója $\epsilon_{\text{mach}} = 10^{-5}$, exponens-tartománya pedig ± 20. Mi az alábbi lebegőpontos aritmetikai műveletek eredménye? (a) $1 + 10^{-7}$; (b) $1 + 10^{3}$; (c) $1 + 10^{7}$; (d) $10^{10} + 10^{3}$; (e) $10^{10}/10^{-15}$; (f) $10^{-10} \times 10^{-15}$.
- **1.43.** Egy olyan lebegőpontos rendszerben, amelynek alulcsordulási szintje $\text{UFL} = 10^{-38}$, az alábbi számítások közül melyekben lép fel alulcsordulás?
  (a) $a = \sqrt{b^2 + c^2}$, ahol $b = 1$, $c = 10^{-25}$.
  (b) $a = \sqrt{b^2 + c^2}$, ahol $b = c = 10^{-25}$.
  (c) $u = (v \times w)/(y \times z)$, ahol $v = 10^{-15}$, $w = 10^{-30}$, $y = 10^{-20}$, $z = 10^{-25}$. Azokban az esetekben, ahol alulcsordulás lép fel, ésszerű-e egyszerűen nullára állítani az alulcsorduló mennyiséget?
- **1.44.** (a) Fejtsd ki szavakkal a különbséget egy lebegőpontos rendszer ϵ_{mach} gépi epszilonja és UFL alulcsordulási szintje között. E két mennyiség közül (b) melyik függ csak a mantissza mezőjében található számjegyek számától? (c) melyik függ csak az exponens mezőjében található számjegyek számától? (d) melyik nem függ a használt kerekítési szabálytól? (e) melyiket nem befolyásolja a szubnormális számok engedélyezése?

- **1.45.** Legyen x_k pozitív számok szigorúan csökkenő, véges sorozata (azaz $x_k > x_{k+1}$ minden k-ra). Ha a számokat tetszőleges általunk választott sorrendben vehetjük, milyen sorrendben kellene összegezni a sorozatot a kerekítési hiba minimalizálása érdekében?
- **1.46.** Példa-e a kioltás a kerekítési hibára? Miért?
- **1.47.** (a) Magyarázd meg, miért lehet véges az összege lebegőpontos aritmetikában egy olyan divergens végtelen sornak, mint

$$\sum_{n=1}^{\infty} \frac{1}{n}.$$

(b) Melyik ponton fognak a részletösszegek megszűnni változni?

- **1.48.** Lebegőpontos aritmetikában, ha egy pozitív tagú konvergens végtelen sor

$$S = \sum_{i=1}^{\infty} x_i$$

összegét számítod természetes sorrendben, milyen megállási kritériumot alkalmaznál a lehető legnagyobb pontosság eléréséhez a legkevesebb taggal? - **1.49.** Fejtsd ki, miért nehéz lebegőpontos aritmetikában pontosan kiértékelni egy váltakozó előjelű végtelen sort, például

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots$$

$x < 0$ esetén. - **1.50.** Ha f egy valós változós valós értékű függvény, akkor a deriváltjának

$$f'(x) \approx \frac{f(x+h) - f(x)}{h}$$

véges differencia közelítésében a csonkítási hiba $h \to 0$ esetén nullához tart. Ha lebegőpontos aritmetikát használunk, sorolj fel két tényezőt, amely korlátozza, mennyire kicsi h értéket tudunk a gyakorlatban használni. - **1.51.** Sorolj fel legalább két módot, ahogy a

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

másodfokú megoldóképlet kiértékelése lebegőpontos aritmetikában numerikus nehézségekbe ütközhet.

Feladatok

- **1.1.** Az átlagos emberi testhőmérsékletet szokás 98,6 Fahrenheit-fokként megadni, amiről azt gondolhatnánk, hogy egy nagy populáció átlaga, három értékes jegyre kerekítve. Valójában azonban a 98,6 egyszerűen a 37 Celsius-fokos érték Fahrenheit-megfelelője, amely csak két értékes jegyre pontos.
  (a) Mennyi a maximális relatív hiba az elfogadott értékben, feltéve, hogy az $\pm 0{,}05\,^\circ$F pontosságú?
  (b) Mennyi a maximális relatív hiba az elfogadott értékben, feltéve, hogy az $\pm 0{,}5\,^\circ$C pontosságú?

- **1.2.** Mennyi az abszolút és a relatív hiba, ha a π értékét a következő mennyiségekkel közelítjük?
  (a) 3; (b) 3,14; (c) 22/7.
- **1.3.** Ha az a a t pontos (valódi) értékű mennyiség közelítése, és a relatív hibája r, akkor a fogalmak definícióiból kiindulva bizonyítsd be, hogy $a = t(1 + r)$.
- **1.4.** Tekintsük a $\sin(x)$ függvény kiszámításának feladatát – különösen a továbbterjedő adathibát, azaz a függvényérték hibáját, amit az x argumentum h nagyságú perturbációja okoz.
  (a) Becsüld meg a $\sin(x)$ kiszámításának abszolút hibáját!
  (b) Becsüld meg a $\sin(x)$ kiszámításának relatív hibáját!
  (c) Becsüld meg a feladat kondíciószámát!
  (d) Az x argumentum mely értékeire nagyon érzékeny ez a feladat?
- **1.5.** Tekintsük az $f : \mathbb{R}^2 \to \mathbb{R}$ függvényt, amelyet az $f(x, y) = x - y$ definiál. A bemenet (x, y) nagyságát $|x| + |y|$-nal mérve, és feltételezve, hogy $|x| + |y| \approx 1$ és $x - y \approx \epsilon$, mutasd meg, hogy $\mathrm{cond}(f) \approx 1/\epsilon$. Mit mondhatsz a kivonás érzékenységéről?
- **1.6.** A szinuszfüggvényt a

$$\sin(x) = x - \frac{x^3}{3!} + \frac{x^5}{5!} - \frac{x^7}{7!} + \cdots$$

végtelen sor adja meg. (a) Mennyi az előreható és a hátraható hiba, ha a szinuszfüggvényt a sor első tagjával közelítjük – azaz $\sin(x) \approx x$ – $x = 0{,}1$, $0{,}5$ és $1{,}0$ esetén? (b) Mennyi az előreható és a hátraható hiba, ha a szinuszfüggvényt a sor első két tagjával közelítjük – azaz $\sin(x) \approx x - x^3/6$ – $x = 0{,}1$, $0{,}5$ és $1{,}0$ esetén? - **1.7.** Egy lebegőpontos számrendszert négy egész szám jellemez: a β alap, a p precízió, valamint az exponenstartomány L alsó és U felső korlátja. (a) Ha $\beta = 10$, mik a p és az U legkisebb, illetve L legnagyobb értékei ahhoz, hogy a 2365,27 és a 0,0000512 egyaránt pontosan ábrázolható legyen egy normalizált lebegőpontos rendszerben? (b) Hogyan változna a válaszod, ha a rendszer nem normalizált, azaz fokozatos alulcsordulást is engedélyezünk? - **1.8.** Egy tízes alapú, $p = 6$ precíziójú lebegőpontos rendszerben legyen $x = 1{,}23456$ és $y = 1{,}23579$. (a) Hány értékes jegyet tartalmaz az $y - x$ különbség? (b) Ha a lebegőpontos rendszer normalizált, mi a minimális exponenstartomány, amely esetén az x, az y és az $y - x$ mindegyike pontosan ábrázolható? (c) Az exponenstartománytól függetlenül pontosan ábrázolható-e az $y - x$ különbség, ha fokozatos alulcsordulás megengedett? Miért? - **1.9.** (a) Négy értékes jeggyel számoló decimális aritmetikával és az 1.1. példában adott képlettel számítsd ki a Föld felszínét $r = 6370$ km mellett! (b) Ugyanezzel a képlettel és precízióval számítsd ki a felszín megváltozását, ha a sugár értékét 1 km-rel növeljük! (c) Mivel $dA/dr = 8\pi r$, a felszín változása $8\pi rh$-val közelíthető, ahol h a sugár változása. Ezzel a képlettel – továbbra is négy számjegyű aritmetikával – számítsd ki a felszín megváltozását a sugár 1 km-es növekedése miatt! Hogyan viszonyul ez a közelítő képlettel kapott érték a (b) feladatrészben az „egzakt” képlettel számított értékhez? (d) Döntsd el, hogy az előző két eredmény közül melyik áll közelebb a helyeshez úgy, hogy mindkét számítást magasabb precízióval – mondjuk hat számjegyű decimális aritmetikával – megismétled! (e) Magyarázd meg az (a)–(d) pontokban kapott eredményeket! (f) Próbáld ki ezt a feladatot számítógépen is! Milyen pici h sugárváltoztatás esetén lép fel ugyanez a jelenség? Próbáld ki egyszeres és dupla pontossággal is, ha rendelkezésre áll! - **1.10.** Tekintsük az

$$\frac{1}{1-x} - \frac{1}{1+x}$$

kifejezést, feltételezve, hogy $x \neq \pm 1$. (a) Az x mely tartományában nehéz ezt a kifejezést pontosan kiszámítani lebegőpontos aritmetikában? (b) Add meg a tagok olyan átrendezését, amely az (a)-beli x-tartományban lebegőpontos aritmetikával pontosabb eredményt ad! - **1.11.** Ha $x \approx y$, akkor azt várnánk, hogy a $\log(x) - \log(y)$ kiszámítása során számjegykioltás lép fel. Másfelől $\log(x) - \log(y) = \log(x/y)$, és az utóbbiban nem lép fel számjegykioltás. Jelenti-e ez azt, hogy a $\log(x/y)$ kiszámítása valószínűleg jobb eredményt ad? (*Útmutatás:* Milyen értékre érzékeny a logaritmusfüggvény?) - **1.12.** (a) A matematikailag ekvivalens

$$x^2 - y^2 \quad \text{és} \quad (x-y)(x+y)$$

kifejezések közül melyik számítható ki pontosabban lebegőpontos aritmetikában? Miért? (b) Az x és y mely – egymáshoz viszonyított – értékeire van lényeges különbség a két kifejezés pontosságában? - **1.13.** Egy n-dimenziós x vektor euklideszi normáját az

$$\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}$$

képlet definiálja. Hogyan kerülheted el a túlcsordulást és a káros alulcsordulást ebben a számításban? - **1.14.** Egy $[a, b]$ intervallum m középpontjának lebegőpontos aritmetikával történő kiszámítására a következő két képlet közül melyik jobb, és miért? Mikor? (*Útmutatás:* Találj ki példákat, amelyekben a képlet által adott „középpont” az $[a, b]$ intervallumon kívülre esik.) (a) $m = (a+b)/2{,}0$ (b) $m = a + (b-a)/2{,}0$ - **1.15.** Adj konkrét példákat, amelyek megmutatják, hogy a lebegőpontos összeadás nem asszociatív, a következő lebegőpontos rendszerek mindegyikében: (a) az 1.9. példában szereplő „játék” lebegőpontos rendszer; (b) az IEEE egyszeres pontosságú lebegőpontos aritmetika. - **1.16.** Magyarázd meg, hogyan különbözhetnek a gyakorlatban az ϵ_{mach} gépi epszilon 1.3.5. szakaszban adott különféle definíciói! (*Útmutatás:* Tekintsd az 1.9. példa „játék” lebegőpontos rendszerét.) - **1.17.** Legyen x egy adott nem nulla lebegőpontos szám egy normalizált rendszerben, és y a vele szomszédos – szintén nem nulla – lebegőpontos szám. (a) Mi a minimális lehetséges távolság az x és y között? (b) Mi a maximális lehetséges távolság az x és y között? - **1.18.** Hány normalizált gépi szám van egy IEEE egyszeres pontosságú lebegőpontos rendszerben? Hány további gépi számot nyerünk, ha megengedjük a szubnormális számokat? - **1.19.** Egy IEEE egyszeres pontosságú lebegőpontos rendszerben mennyi az OFL legnagyobb gépi szám, és az UFL legkisebb pozitív normalizált gépi szám értéke? Hogyan változnak a válaszaid, ha a szubnormálisak is megengedettek? - **1.20.** Mi a 0,1 decimális tört IEEE egyszeres pontosságú bináris lebegőpontos ábrázolása (a) csonkítással? (b) legközelebbihez való kerekítéssel? - **1.21.** (a) Egy lebegőpontos rendszerben az ϵ_{mach} gépi epszilon szükségképpen gépi szám-e? (b) Létezhet-e olyan lebegőpontos rendszer, amelyben $\epsilon_{\text{mach}} < \text{UFL}$? Ha igen, adj rá példát! - **1.22.** Tegyük fel, hogy az $ax^2 + bx + c = 0$ másodfokú egyenletet oldjuk meg $a = 1{,}22$, $b = 3{,}34$, $c = 2{,}28$ mellett, egy $\beta = 10$, $p = 3$ normalizált lebegőpontos rendszerben. (a) Mi a diszkrimináns, azaz a $b^2 - 4ac$ számított értéke? (b) Mi a diszkrimináns helyes értéke valós (egzakt) aritmetikában? (c) Mi a diszkrimináns számított értékének relatív hibája? - **1.23.** Tekintsünk egy $\beta = 10$, $p = 3$, $L = -98$ normalizált lebegőpontos rendszert! (a) Mennyi az UFL alulcsordulási szint értéke ebben a rendszerben? (b) Ha $x = 6{,}87 \times 10^{-97}$ és $y = 6{,}81 \times 10^{-97}$, mi az $x - y$ eredménye? (c) Mi lenne az $x - y$ eredménye, ha a rendszer megengedné a fokozatos alulcsordulást? - **1.24.** Tekintsük a következő állítást: ha két azonos előjelű lebegőpontos szám, x és y aránya legfeljebb a β alap (azaz $1/\beta \leq x/y \leq \beta$), akkor a különbségük, az $x - y$ pontosan ábrázolható a lebegőpontos rendszerben. Mutasd meg, hogy ez az állítás igaz $\beta = 2$ esetén, de adj ellenpéldát $\beta > 2$ esetére! - **1.25.** Néhány

mikroprocesszor rendelkezik egy `mpyadd(a, b, c)` (szorzás-összeadás) utasítással, amely egyszeres pontosságú bemeneteket vár, és hozzáadja a c-t az a és b kétszeres pontosságú szorzatához, mielőtt normalizálná és egyszeres pontosságú eredményt adna vissza. Hogyan lehet egy ilyen utasítást felhasználni dupla pontosságú szorzatok kiszámítására úgy, hogy dupla pontosságú változókat egyáltalán nem használunk (azaz az a és b kétszeres pontosságú szorzata két egyszeres pontosságú változóban – például s-ben és t-ben – tárolódik)? - **1.26.** Igazold, hogy az 1.15. példában adott alternatív megoldóképlet valóban a másodfokú egyenlet helyes gyökeit adja (egzakt aritmetikában)! - **1.27.** Adj részletes magyarázatot a szórás számításához használt egylépéses képlet numerikus gyengeségére az 1.16. példában megadott kétlépéses képlethez képest!

Számítógépes feladatok

- **1.1.** Írj programot, amely kiszámítja a Stirling-formula

$$n! \approx \sqrt{2\pi n}\ (n/e)^n$$

által adott közelítés abszolút és relatív hibáját $n = 1, \ldots, 10$ esetén! Az abszolút hiba nő vagy csökken n növekedésével? És a relatív hiba? - **1.2.** Írj programot, amely közelítő értékeket határoz meg az ϵ_{mach} gépi epszilonra és az UFL alulcsordulási szintre, és teszteld egy valós számítógépen! (*Opcionális:* Meg tudod határozni a géped OFL túlcsordulási szintjét is? Ez trükkösebb, mert egy tényleges túlcsordulás végzetes programhibát okozhat.) Írasd ki a kapott értékeket decimális formában, és próbáld megállapítani a használt lebegőpontos rendszer mantissza- és exponensmezőjének bitszámát! - **1.3.** A legtöbb lebegőpontos rendszerben a gépi epszilonra gyors közelítés kapható az

$$\epsilon_{\text{mach}} \approx |3 \cdot (4/3 - 1) - 1|$$

kifejezés kiszámításával. (a) Magyarázd meg, miért működik ez a trükk! (b) Próbáld ki különféle számítógépeken (egyszeres és dupla pontossággal egyaránt) és számológépeken, hogy megerősítsd a működését! (c) Működne-e ez a trükk egy $\beta = 3$ alapú lebegőpontos rendszerben? - **1.4.** Írj programot, amely a természetes logaritmus e alapszámát az

$$e = \lim_{n\to\infty} (1 + 1/n)^n$$

definícióból számítja ki! Konkrétan számítsd ki az $(1 + 1/n)^n$ értékét az $n = 10^k$, $k = 1, 2, \ldots, 20$ helyeken! Ha a használt programnyelvben nincs hatványozási operátor, használhatod a matematikailag ekvivalens

$$(1 + 1/n)^n = \exp(n \log(1 + 1/n))$$

képletet, ahol az `exp` és a `log` a beépített függvények. Határozd meg a közelítéseid hibáját az `exp(1)` értékkel való összehasonlítás révén! A hiba mindig csökken n növekedésével? Magyarázd meg az eredményeidet! - **1.5.** (a) Tekintsük az

$$f(x) = (e^x - 1)/x$$

függvényt. A L'Hôpital-szabály alkalmazásával mutasd meg, hogy $\lim_{x\to 0} f(x) = 1$. (b) Ellenőrizd ezt az eredményt kísérletileg úgy, hogy írsz egy programot, amely kiszámítja az $f(x)$ értékét az $x = 10^{-k}$, $k = 1, \dots, 15$ helyeken! Az eredményeid megegyeznek az elméleti várakozásokkal? Magyarázd meg, miért! (c) Végezd el a (b)-beli kísérletet ismét, ezúttal a matematikailag ekvivalens

$$f(x) = (e^x - 1)/\log(e^x)$$

megfogalmazást használva pontosan a jelzett formában, minden egyszerűsítés nélkül! Ha ez a változat jobban működik, meg tudod magyarázni a jelenség okát? - **1.6.** Tegyük fel, hogy $n + 1$ egyenközű pontot kell generálnunk az $[a, b]$ intervallumon, $h = (b - a)/n$ lépésközzel. (a) Lebegőpontos aritmetikában a következő két módszer közül melyik a jobb, és miért?

$$x_0 = a, \quad x_k = x_{k-1} + h, \quad k = 1, \dots, n$$

vagy

$$x_k = a + kh, \quad k = 0, \dots, n.$$

(b) Írj programot, amely mindkét módszert megvalósítja, és találj egy példát – mondjuk $a = 0$ és $b = 1$ mellett –, amely jól szemlélteti a különbséget közöttük!

- **1.7.** (a) Írj programot, amely egy függvény deriváltjának közelítő értékét a

$$f'(x) \approx \frac{f(x+h) - f(x)}{h}$$

végesdifferencia-képlettel számítja. Teszteld a programot a $\tan(x)$ függvényen $x = 1$-nél. Határozd meg a hibát a beépített $\sec(x)$ függvény négyzetével való összehasonlítással. Ábrázold a hiba nagyságát h függvényében $h = 10^{-k}$-ra, $k = 0, \dots, 16$. Mind h-t, mind a hiba nagyságát logaritmikus skálán érdemes használni. Van a hiba nagyságának minimuma? Hogyan viszonyul a hozzá tartozó h érték az 1.3. példában levezetett $h \approx \sqrt{\epsilon_{\text{mach}}}$ ökölszabályhoz? (b) Ismételd meg a feladatot a

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}$$

középpontos differencia közelítéssel. - **1.8.** Tekintsük a

$$\sum_{n=1}^{\infty} \frac{1}{n}$$

végtelen sort. (a) Bizonyítsd be, hogy a sor divergens. (*Útmutatás:* Csoportosítsd a tagokat olyan halmazokba, amelyek az $1/(2^{k-1} + 1)$-től $1/2^k$-ig tartó tagokat tartalmazzák, $k = 1, 2, \dots$) (b) Magyarázd meg, miért ad véges összeget a sor lebegőpontos aritmetikában való összegzése. (c) Próbáld megjósolni, mikor szűnik meg változni a részletösszeg IEEE egyszeres, illetve dupla pontosságú lebegőpontos aritmetikában. A géped lebegőpontos műveletekre vonatkozó végrehajtási sebességét figyelembe véve próbáld megjósolni, mennyi ideig tartana minden egyes számítás befejezése. (d) Írj két programot a sor összegének kiszámítására: egyet egyszeres, egyet dupla

pontossággal. Kövesd az összegzés előrehaladását úgy, hogy az indexet és a részletösszeget időnként kiírod. Milyen megállási kritériumot használnál? Milyen eredményt ad ténylegesen a géped? Hasonlítsd össze az eredményeidet a jóslataiddal, beleértve a szükséges futásidőt is. (*Figyelem:* Az egyszeres pontosságú változat várhatóan viszonylag gyorsan befejeződik, a dupla pontosságú azonban sokkal tovább tarthat, így lehet, hogy nem gyakorlati befejezésig futtatni, még bőkezű számítási kerettel sem.) - **1.9.** (a) Írj programot, amely az e^x exponenciális függvényt az

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots$$

végtelen sorral számítja. (b) Természetes sorrendben összegezve milyen megállási kritériumot használnál? (c) Teszteld a programot $x = \pm 1, \pm 5, \pm 10, \pm 15, \pm 20$ értékekre, és hasonlítsd össze az eredményeket a beépített `exp(x)` függvénnyel. (d) Használhatod-e a sort ebben a formában pontos eredmények eléréséhez $x < 0$ esetén? (*Útmutatás:* $e^{-x} = 1/e^x$.) (e) Át tudod-e rendezni a sort, vagy át tudod-e csoportosítani a tagokat oly módon, hogy pontosabb eredményeket kapj $x < 0$ esetén? - **1.10.** Írj programot, amely az $ax^2 + bx + c = 0$ másodfokú egyenletet oldja meg a szabványos

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

képlettel vagy a

$$x = \frac{2c}{-b \mp \sqrt{b^2 - 4ac}}$$

alternatív képlettel. A programnak bemenetként a, b, c együtthatókat kell elfogadnia, kimenetként pedig az egyenlet két gyökét kell előállítania. A programnak észlelnie kell, ha a gyökök nem valósak, de nem szükséges explicit módon komplex aritmetikát használnia (például ebben az esetben visszaadhatja a komplex konjugált gyökpár valós és képzetes részét). Védekezz a felesleges túlcsordulás, alulcsordulás és a számjegykioltás ellen. Mikor kell használnod a két képlet közül melyiket? Tedd robusztussá a programot a szokatlan bemeneti értékekre is, például $a = 0$ vagy $c = 0$, amelyek egyébként az egyik képletet megbuktatnák. Bármely gyökhöz, amely a lebegőpontos rendszer tartományán belül van, pontosan számítsa ki az értékét, még akkor is, ha a másik gyök kívül esik. Teszteld a programot a következő együtthatóértékekkel:

a	b	c
6	5	-4
6×10^{154}	5×10^{154}	-4×10^{154}
0	1	1
1	-10^5	1
1	-4	$3{,}999999$
10^{-155}	-10^{155}	10^{155}

- **1.11.** A nem nulla vezető együtthatóval való osztással bármely harmadfokú egyenlet az

$$x^3 + ax^2 + bx + c = 0$$

alakra hozható. Ha az együtthatók valósak, akkor egy ilyen egyenletnek legalább egy valós gyöke van, amely zárt alakban a következőképpen számítható ki. Alkalmazd az $y = x + a/3$ helyettesítést. Az egyenlet ekkor a

$$y^3 + py + q = 0$$

alakra redukálódik, ahol

$$p = \frac{3b - a^2}{3}, \qquad q = \frac{2a^3}{27} - \frac{ab}{3} + c.$$

Ha a $D = (p/3)^3 + (q/2)^2$ diszkriminánsa pozitív, akkor csak egy valós gyök létezik, amelyet az

$$x = -\frac{a}{3} + \sqrt[3]{-\frac{q}{2} + \sqrt{D}} + \sqrt[3]{-\frac{q}{2} - \sqrt{D}}$$

képlet ad meg. Írj valós aritmetikát használó rutint ezzel a módszerrel (ügyelve arra, hogy az alkalmazott köbgyök valós legyen) egy valós együtthatós harmadfokú egyenlet valós gyökének kiszámítására abban az esetben, amikor csak egy gyök valós. Ha különösen ambiciózus vagy, kiszámíthatod a másik két gyököt is erre az esetre, vagy foglalkozhatsz a három valós gyök esetével, de ehhez komplex aritmetikára (vagy bonyolultabb trigonometrikus megoldásra) lesz szükség. Tedd a rutint a lehető legrobusztusabbá, védekezve a felesleges túlcsordulás, alulcsordulás és a számjegykioltás ellen. Mit kell tennie a rutinnak, ha a vezető együttható nulla? Teszteld a rutint különféle együtthatóértékekre, az előző feladathoz hasonlóan. Lásd még az 5.17. számítógépes feladatot. - **1.12.** (a) Írj programot, amely egy véges x_i sorozat $\bar{x}$ átlagát és σ szórását számítja. A program bemenetként egy n dimenziós x vektort fogadjon el, kimenetként pedig a sorozat átlagát és szórását adja meg. A szórásra próbáld ki mind a kétmenetes

$$\sigma = \left[\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2\right]^{1/2}$$

képletet, mind az egymenetes

$$\sigma = \left[\frac{1}{n-1}\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right)\right]^{1/2}$$

képletet, és hasonlítsd össze az eredményeket egy általad választott bemeneti sorozaton. (b) Ki tudsz találni olyan bemeneti adatsorozatot, amely drámaian szemlélteti a két matematikailag ekvivalens képlet numerikus különbségét? (*Figyelem:* Óvakodj egy negatív szám négyzetgyökének vételétől.) - **1.13.** Ha egy a összeget r kamatlábbal fektetnek be, és a kamatot évente n-szer tőkésítik, akkor az egy év végén kapott végérték

$$f = a(1 + r/n)^n.$$

Ez a kamatos kamat ismerős képlete. Egyszerű kamat esetén $n = 1$. Jellemzően negyedévente ($n = 4$), vagy akár naponta ($n = 365$) tőkésítenek. Nyilvánvaló, hogy minél gyakoribb a tőkésítés, annál nagyobb a végösszeg, hiszen a korábbi kamatra is kamatot kapunk. De mekkora különbséget okoz valójában ez a gyakoriság? Írj programot, amely a kamatos kamat képletet valósítja meg. Teszteld a programot $a = 100$ kezdeti befektetéssel, $r = 0{,}05$ (5 százalékos) kamatlábbal, és a következő n értékekkel: 1, 4, 12, 365. Kísérletezz azzal is, mi történik, ha n nagyon nagy lesz. Találsz-e olyan értéket, amelyre a végösszeg nem nő a tőkésítés gyakoriságával, ahogy kellene? (Ez könnyű, ha egyszeres pontosságot használsz, de jóval nehezebb, ha duplát.)

Implementáld a kamatos kamat képletet két különböző módon: (a) Ha a használt programnyelvben nincs hatványozási operátor (pl. C), akkor a képletet egy olyan ciklussal implementálhatod, amely a-t ismételten szorozza $(1 + r/n)$-nel, összesen n-szer. Még ha a programnyelved rendelkezik is hatványozási operátorral (pl. Fortran), implementáld a képletet egy ilyen ciklussal, és írd ki az eredményeket a bemeneti értékekre. (b) Az `exp(x)` és `log(x)` függvényekkel a kamatos kamat képlet a

$$f = a \exp(n \log(1 + r/n))$$

alakban is írható. Implementáld ezt a képletet a megfelelő beépített függvények használatával, és hasonlítsd össze az eredményeidet az első – ciklust használó – implementáció eredményeivel ugyanazon bemeneti értékekre. - **1.14.** Az $(x - 1)^6$ polinom $x = 1$-nél nulla, máshol pozitív. A polinom kifejtett alakja, $x^6 - 6x^5 + 15x^4 - 20x^3 + 15x^2 - 6x + 1$, matematikailag ekvivalens, de numerikusan nem feltétlenül adja ugyanazt az eredményt. Számítsd ki és ábrázold e polinom értékeit mindkét forma használatával a $[0{,}995, 1{,}005]$ intervallum 101 egyenletesen elhelyezett pontjában – azaz 0,0001 lépésközzel. A diagramot úgy skálázd, hogy mind az x, mind a polinom értékei a saját tengelyük teljes tartományát kihasználják. Meg tudod magyarázni ezt a viselkedést? - **1.15.** Egy n-dimenziós x vektor euklideszi normáját az

$$\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}$$

képlet definiálja. Implementálj robusztus rutint e mennyiség kiszámítására egy tetszőleges bemeneti x vektorra. A rutinnak el kell kerülnie a túlcsordulást és a káros alulcsordulást. Hasonlítsd össze a robusztus rutin pontosságát és teljesítményét egy egyszerűbb, naiv implementációval. Ki tudsz találni olyan vektort, amely jelentősen eltérő eredményeket ad a két rutintól? Mennyi teljesítményt áldoz fel a robusztus rutin? - **1.16.** Írj programot, amely n véletlen, egyszeres pontosságú lebegőpontos számot – x_i, a $[0, 1]$ intervallumon egyenletes eloszlású – összegez (lásd a 13.1. táblázatot egy megfelelő véletlenszám-generátorhoz). A számokat az alábbi módokon összegezd (csak egyszeres pontosságú lebegőpontos változókat használj, hacsak másképp nem jelezzük): (a) Összegezd a számokat a generálás sorrendjében, egy dupla pontosságú változót használva az összeg gyűjtésére. (b) Összegezd a számokat a generálás sorrendjében, ezúttal egy egyszeres pontosságú gyűjtőt használva. (c) Használd a következő (Kahan-féle) kompenzált összegzési algoritmust – szintén csak egyszeres pontosságot használva –, a számokat a generálás sorrendjében összegezve:

$$
\begin{aligned}
& s = x_1 \\
& c = 0 \\
& \textbf{for } i = 2 \text{ to } n \\
& \quad y = x_i - c \\
& \quad t = s + y \\
& \quad c = (t - s) - y \\
& \quad s = t \\
& \textbf{end}
\end{aligned}
$$

(d) Összegezd a számokat növekvő abszolút érték szerinti sorrendben (ehhez a számokat összegzés előtt rendezni kell, amihez használhatsz könyvtári rendezőrutint).

(e) Összegezd a számokat csökkenő abszolút érték szerinti sorrendben (azaz az összegzés sorrendjét fordítsd meg a (d)-beli sorrendhez képest).

Futtasd a programot különböző n értékekre, és hasonlítsd össze a (a)–(e) módszerek eredményeit. Lényeges eltérés megfigyeléséhez elég nagy n értéket érdemes használnod. Hogyan rangsorolhatók a módszerek pontosság szerint, és miért? Hogyan viszonyulnak egymáshoz a módszerek költségben? Meg tudod magyarázni, miért működik a (c)-beli algoritmus? - **1.17.** Írj programot, amely az

$$x_{k+1} = 2{,}25\, x_k - 0{,}5\, x_{k-1}$$

differenciaegyenlet első n tagját állítja elő, kezdőértékek

$$x_1 = \frac{1}{3} \quad \text{és} \quad x_2 = \frac{1}{12}.$$

Használd $n = 25$-öt egyszeres, vagy $n = 60$-at dupla pontosság esetén. Készíts féllogaritmikus ábrát a kapott értékekről k függvényében. A differenciaegyenlet egzakt megoldása

$$x_k = \frac{4^{1-k}}{3},$$

amely k növekedésével szigorúan monoton csökken. Igazolja-e az ábrád ezt az elméletileg várt viselkedést? Meg tudod magyarázni az eredményeidet? (*Útmutatás:* Keresd meg a differenciaegyenlet általános megoldását.) - **1.18.** Írj programot, amely az

$$x_{k+1} = 111 - (1130 - 3000/x_{k-1})/x_k$$

differenciaegyenlet első n tagját állítja elő, kezdőértékek

$$x_1 = \frac{11}{2} \quad \text{és} \quad x_2 = \frac{61}{11}.$$

Használd $n = 10$-et egyszeres, vagy $n = 20$-at dupla pontosság esetén. Az egzakt megoldás egy szigorúan monoton növekvő, 6-hoz konvergáló sorozat. Meg tudod magyarázni az eredményeidet?

Lineáris egyenletrendszerek

2.1 Lineáris rendszerek

A természetben sok összefüggés lineáris, vagyis a hatások az okaikkal arányosak. A mechanikában például Newton második törvénye, $F = ma$, azt mondja ki, hogy az erő arányos a gyorsulással, ahol az arányossági tényező a tárgy tömege. Ha ismerjük az erőt és a tömeget, akkor ezt a lineáris egyenletet a gyorsulásra nézve meg tudjuk oldani. Az elektromosságtanban az Ohm-törvény, $V = iR$, kimondja, hogy egy vezető két vége közötti feszültség (potenciálkülönbség) arányos a rajta átfolyó árammal, ahol az arányossági tényező az ellenállás. Ismét, ha ismerjük a feszültséget és az ellenállást, meg tudjuk oldani az egyenletet az áramra nézve. A rugalmasságtanban a Hooke-törvény szerint a mechanikai feszültség arányos a deformációval, ahol az arányossági tényező a Young-modulus.

Magasabb dimenziókban az ilyen lineáris kapcsolatokat egy $\mathcal{L}$ lineáris transzformáció fejezi ki, amely egy „okokat" tartalmazó u vektort egy „hatásokat" tartalmazó f vektorhoz rendel:

$$\mathcal{L}u = f.$$

Az Ohm-törvény és a Kirchhoff-törvények például lehetővé teszik, hogy felírjunk egy egész egyenletrendszert, amely egy sok vezetőből álló áramkörben a feszültségek és az áramok közötti lineáris kapcsolatot fejezi ki (lásd a 2.1. példát). Ahogy az elemi lineáris algebrából megtanultuk, két végesdimenziós vektortér közötti lineáris transzformációt kényelmesen egy mátrixszal ábrázolhatunk. Mátrix-vektor jelöléssel egy lineáris algebrai egyenletrendszer alakja

$$Ax = b,$$

ahol A egy ismert $m \times n$-es mátrix, b egy m-dimenziós vektor, x pedig egy n-dimenziós vektor. Ha ismerjük x-et, akkor egy ilyen lineáris kapcsolat lehetővé teszi, hogy a mátrix-vektor szorzás elvégzésével meghatározzuk a b hatást az x ok alapján: $b = Ax$. Gyakrabban azonban a lineáris egyenletrendszerek lehetőséget adnak a „visszafejtésre": ha ismerjük a hatások b vektorát, szeretnénk meghatározni a hozzá tartozó okok x vektorát. E fejezet tárgyát azok a numerikus módszerek képezik, amelyek ezt lehetővé teszik.

Még ha az összefüggések nemlineárisak is, gyakran jól közelíthetők lokálisan (azaz egy adott rögzített érték környezetében) egy lineáris modellel. Pontosan ezt teszi az analízisben a derivált: egy nemlineáris görbéhez lokális lineáris közelítést – az érintőegyenest – rendel. Ez a megfigyelés számos nemlineáris algebrai feladat numerikus megoldási módszerének is az alapja. Még a nem algebrai feladatokat is – például a differenciál- vagy integrálegyenleteket – végső soron lineáris algebrai egyenletrendszerekkel közelíthetjük, ahogyan azt a könyv későbbi részeiben látni fogjuk. Ezért a lineáris egyenletrendszerek megoldása számos gyakorlati számítási feladat numerikus algoritmusának sarokköve, és ennek megfelelően elengedhetetlen, hogy az ilyen rendszereket pontosan és hatékonyan tudjuk megoldani.

Az $Ax = b$ lineáris egyenletrendszer lényegében azt a kérdést teszi fel: „kifejezhető-e a b vektor az A mátrix oszlopainak lineáris kombinációjaként?" (azaz „benne van-e b a $\mathrm{span}(A) = \{Ax : x \in \mathbb{R}^n\}$ oszloptérben?"). Ha igen, akkor a rendszert *megoldhatónak (konzisztensnek)* mondjuk, és a lineáris kombináció együtthatóit az x megoldásvektor komponensei adják. Előfordulhat, hogy van megoldás, és az is, hogy nincs; ha van megoldás, az lehet egyértelmű, de lehetséges végtelen sok megoldás is. Ebben a fejezetben csak *négyzetes* rendszereket tekintünk, azaz $m = n$ – a mátrix

sorainak és oszlopainak száma megegyezik, vagyis az egyenletek száma (A és b sorai) megegyezik az ismeretlenek számával (x komponensei). Az $m \neq n$ esetet a 3. fejezetben tárgyaljuk. Az egyszerűség kedvéért figyelmünket elsősorban valós lineáris rendszerekre fordítjuk; a komplex rendszereket nagyon hasonlóan lehet kezelni.

2.1. Példa. Elektromos áramkör. Tekintsük a 2.1. ábrán látható elektromos áramkört. Adottak a V feszültségek és az R ellenállások, és azt szeretnénk meghatározni, milyen i áramok folynak az áramkör három hurkában. Ehhez az alábbi fizikai törvényeket alkalmazzuk:

- **Ohm-törvény:** egy R ellenálláson egy i áram irányában eső feszültségesés iR.
- **Kirchhoff huroktörvénye:** egy zárt hurokban a feszültségesések (és forrásfeszültségek) algebrai összege nulla.

Ezeket a törvényeket az áramkör minden hurkára alkalmazva a következő három lineáris egyenletből álló rendszert kapjuk:

$$\begin{aligned} i_1R_1 + (i_1 - i_2)R_2 + (i_1 - i_3)R_3 + V_1 &= 0, \\ (i_2 - i_1)R_2 + (i_2 - i_3)R_5 - V_2 &= 0, \\ (i_3 - i_1)R_3 + i_3R_4 + (i_3 - i_2)R_5 &= 0, \end{aligned}$$

amely mátrixalakban így írható:

$$\begin{bmatrix} R_1 + R_2 + R_3 & -R_2 & -R_3 \\ -R_2 & R_2 + R_5 & -R_5 \\ -R_3 & -R_5 & R_3 + R_4 + R_5 \end{bmatrix} \begin{bmatrix} i_1 \\ i_2 \\ i_3 \end{bmatrix} = \begin{bmatrix} -V_1 \\ V_2 \\ 0 \end{bmatrix}.$$

Így ez a feladat $Ax = b$ alakú, és megoldható az e fejezetben tanulmányozott módszerekkel.

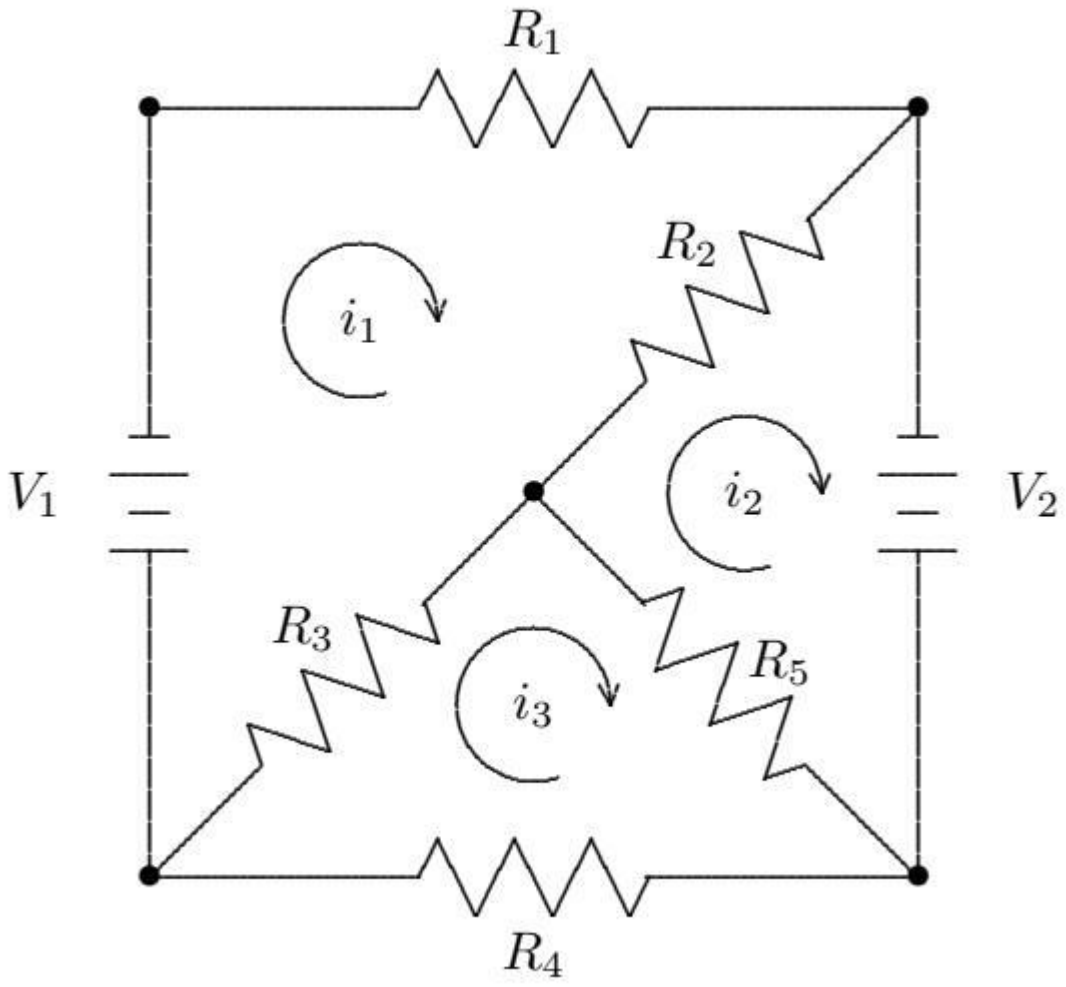

2.1. ábra: Ellenállásokkal és feszültségforrásokkal felépített elektromos áramkör.

2.2 Létezés és egyértelműség

Egy $n \times n$-es A mátrixot *reguláris*nak (*nemszinguláris*nak) nevezünk, ha az alábbi – egymással ekvivalens – feltételek bármelyike teljesül rá:

1. A-nak van inverze (azaz létezik egy olyan, A^{-1}-gyel jelölt $n \times n$-es mátrix, amelyre $AA^{-1} = A^{-1}A = I$, az egységmátrix).
2. $\det(A) \neq 0$ (azaz A determinánsa nem nulla).
3. $\operatorname{rank}(A) = n$ (egy mátrix rangja a benne található lineárisan független sorok vagy oszlopok maximális száma).
4. Bármely $z \neq 0$ vektorra $Az \neq 0$ (azaz A egyetlen nemtriviális vektort sem visz át a nullvektorba).

Minden más esetben a mátrix *szinguláris*. Az $Ax = b$ lineáris egyenletrendszer megoldásának létezése és egyértelműsége attól függ, hogy az A mátrix szinguláris vagy reguláris. Ha A reguláris, akkor létezik az inverze (A^{-1}), és az $Ax = b$ rendszernek mindig pontosan egy $x = A^{-1}b$ megoldása van, a b értékétől függetlenül. Ha viszont A szinguláris, akkor a megoldások száma a b jobb oldali

vektortól függ: adott b mellett előfordulhat, hogy nincs megoldás, de ha létezik olyan x megoldás, amelyre $Ax = b$, akkor az $A(x + \gamma z) = b$ is teljesül bármely γ skalárra, ahol $z \neq 0$ olyan vektor, amelyre $Az = 0$ (ilyen z-nek léteznie kell, hiszen ellenkező esetben a definíció 4. feltétele szerint a mátrix reguláris volna). Ezért egy négyzetes, konzisztens és szinguláris lineáris rendszer megoldása sosem lehet egyértelmű. Adott négyzetes A mátrixra és b jobb oldali vektorra a lehetőségeket az alábbiak foglalják össze:

- **Egyértelmű megoldás:** A reguláris, b tetszőleges.
- **Végtelen sok megoldás:** A szinguláris, $b \in \operatorname{span}(A)$ (konzisztens).
- **Nincs megoldás:** A szinguláris, $b \notin \operatorname{span}(A)$ (inkonzisztens).

Két dimenzióban a rendszer minden lineáris egyenlete egy egyenest határoz meg a síkban. A rendszer megoldása a két egyenes metszéspontja. Ha a két egyenes nem párhuzamos, akkor pontosan egy metszéspontjuk van (a reguláris eset). Ha a két egyenes párhuzamos, akkor vagy egyáltalán nem metszik egymást (nincs megoldás), vagy a két egyenes egybeesik (az egyenes bármely pontja megoldás). Magasabb dimenziókban minden egyenlet egy hipersíkot határoz meg. A reguláris esetben az egyértelmű megoldás az összes hipersík metszéspontja.

2.2. Példa. Szingularitás és regularitás. A 2×2-es

$$\begin{aligned} 2x_1 + 3x_2 &= b_1, \\ 5x_1 + 4x_2 &= b_2, \end{aligned}$$

rendszer – vagy mátrix-vektor jelöléssel:

$$Ax = \begin{bmatrix} 2 & 3 \\ 5 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} = b,$$

– a b értékétől függetlenül egyértelmű megoldással rendelkezik, mert az A reguláris. Például ha $b = \begin{bmatrix} 8 & 13 \end{bmatrix}^T$, akkor az egyértelmű megoldás $x = \begin{bmatrix} 1 & 2 \end{bmatrix}^T$.

Viszont a 2×2-es

$$Ax = \begin{bmatrix} 2 & 3 \\ 4 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} = b$$

rendszerben az A mátrix szinguláris, ezért a b konkrét értékétől függően előfordulhat, hogy van megoldás, de az is, hogy nincs, egyértelmű megoldása viszont semmiképpen sem lehet. Például ha $b = \begin{bmatrix} 4 & 7 \end{bmatrix}^T$, akkor nincs megoldás, ha viszont $b = \begin{bmatrix} 4 & 8 \end{bmatrix}^T$, akkor az

$$x = \begin{bmatrix} \gamma \\ (4 - 2\gamma)/3 \end{bmatrix}$$

megoldás bármely γ valós számra.

2.3 Érzékenység és kondicionáltság

Miután megfogalmaztuk az $Ax = b$ lineáris egyenletrendszer megoldásának létezésére és egyértelműségére vonatkozó feltételeket, most az x megoldás érzékenységét vizsgáljuk a bemeneti adatok perturbációival szemben, amelyek ebben a feladatban az A mátrix és a b jobb oldali vektor. Az ilyen perturbációk méréséhez szükségünk van a vektorok és mátrixok „méretének" valamilyen fogalmára. A nagyság, abszolút érték vagy modulus skaláris fogalma általánosítható a vektorok és mátrixok normáinak fogalmára.

2.3.1 Vektornormák

Bár általánosabb definíció is lehetséges, a továbbiakban használt vektornormák mind a p-normák speciális esetei, amelyeket egy $p \geq 1$ szám és egy n-dimenziós x vektor esetén a következőképpen definiálunk:

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{1/p}.$$

Fontos speciális esetek:

- 1-norma:

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|,$$

amelyet néha Manhattan-normának is neveznek, mivel két dimenzióban ez két pont „háztömbökben" mért távolságának felel meg.

- 2-norma:

$$\|x\|_2 = \left(\sum_{i=1}^{n} |x_i|^2 \right)^{1/2},$$

amely az euklideszi térben megszokott távolságfogalomnak felel meg, ezért euklideszi normának is nevezzük.

- ∞-norma (maximum norma):

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|,$$

amely $p \to \infty$ határesetként értelmezhető.

Ezek a normák kvalitatívan mind hasonló eredményeket adnak, de bizonyos körülmények között egy adott norma kezelhető a legkönnyebben analitikusan vagy számítási szempontból. A lineáris egyenletrendszerek megoldásainak érzékenységi vizsgálatához általában az 1-normát vagy az ∞-normát használjuk. A 2-normát később, más kontextusokban fogjuk kiterjedten alkalmazni. E normák közötti különbségeket $\mathbb{R}^2$-ben a 2.2. ábra szemlélteti, amely az egységgömböt, azaz az $\{x : \|x\|_p = 1\}$ halmazt mutatja $p = 1, 2, \infty$ esetén. (Megjegyzendő, hogy az egységgömböt – amelyet

két dimenzióban pontosabb lenne egységkörnek nevezni – csak a 2-normában valóban „kerek”, innen kapta a nevét.) Egy vektor normája egyszerűen az a tényező, amellyel a megfelelő egységgömböt ki kell tágítani vagy össze kell zsugorítani ahhoz, hogy az a vektort éppen magában foglalja.

2.3. Példa. Vektornormák. A 2.2. ábrán látható $x = [-1{,}6, 1{,}2]^T$ vektor esetén

$$\|x\|_1 = 2{,}8, \quad \|x\|_2 = 2{,}0, \quad \|x\|_\infty = 1{,}6.$$

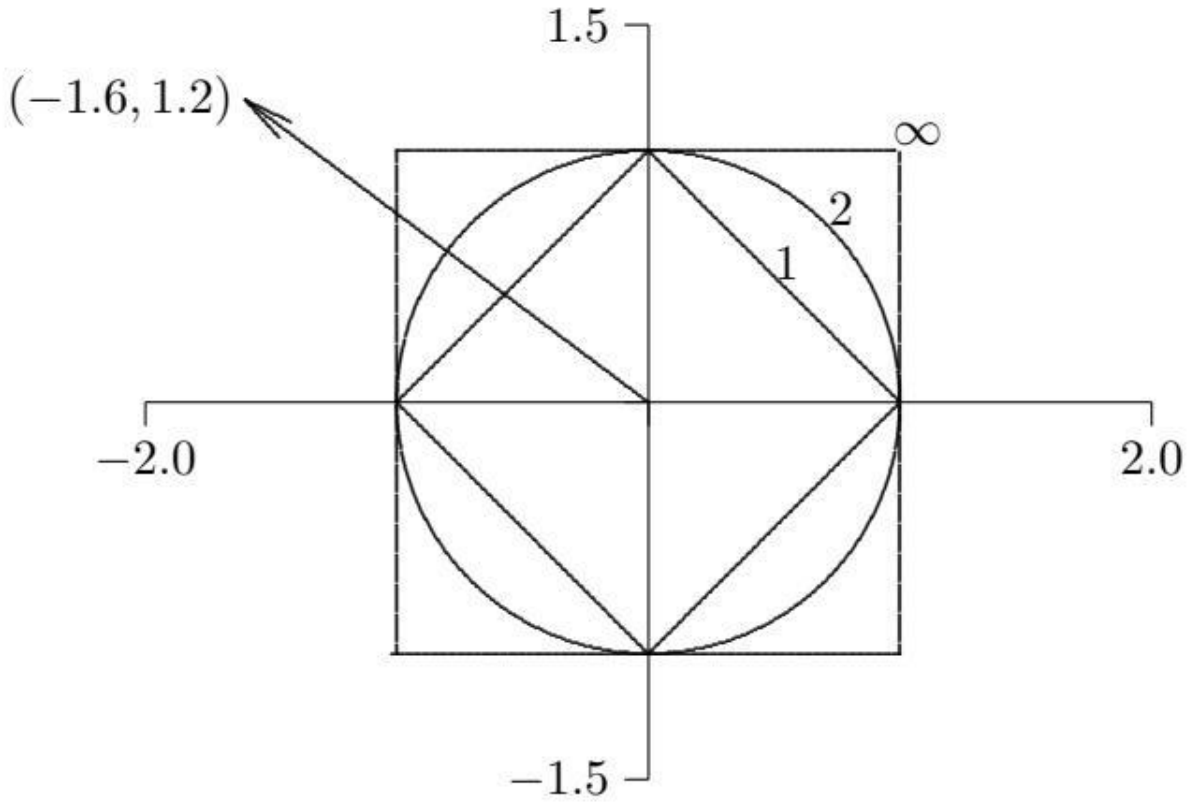

2.2. ábra: Egységgömbök különböző vektornormákban.

Általában tetszőleges n-dimenziós x vektor esetén:

$$\|x\|_1 \geq \|x\|_2 \geq \|x\|_\infty.$$

Másrészt az is fennáll, hogy

$$\|x\|_1 \leq \sqrt{n}\|x\|_2, \quad \|x\|_2 \leq \sqrt{n}\|x\|_\infty, \quad \text{és} \quad \|x\|_1 \leq n\|x\|_\infty.$$

Így adott n esetén e normák közül bármely kettő legfeljebb egy konstans szorzóban tér el egymástól, tehát abban az értelemben mind ekvivalensek, hogy ha az egyik kicsi, akkor valamennyinek arányosan kicsinek kell lennie (valójában minden p-norma ekvivalens ebben az értelemben). Ezért mindig azt a normát választhatjuk, amelyik az adott kontextusban a legkényelmesebb. A könyv

hátralévő részében megfelelő alsó index jelöli majd a konkrét normát, amikor ez szükséges, de az alsó indexet elhagyjuk, ha mindegy, hogy éppen melyik normát használjuk.

Minden vektor p-norma rendelkezik a következő fontos tulajdonságokkal, ahol x és y tetszőleges vektorok:

1. $\|x\| > 0$, ha $x \neq 0$.
2. $\|\gamma x\| = |\gamma| \cdot \|x\|$ tetszőleges γ skalár esetén.
3. $\|x + y\| \leq \|x\| + \|y\|$ (háromszög-egyenlőtlenség).

Általánosabb megközelítésben egy vektornorma *definíciójaként* bármely olyan valós értékű függvényt tekinthetünk egy vektoron, amely e három tulajdonságot teljesíti. Megjegyzendő, hogy az első két tulajdonság együtt magában foglalja, hogy $\|x\| = 0$ akkor és csak akkor, ha $x = 0$. A háromszög-egyenlőtlenség hasznos változata:

$$|\|x\| - \|y\|| \leq \|x - y\|,$$

amely egyúttal azt is megmutatja, hogy a vektornorma folytonos függvény.

2.3.2 Mátrixnormák

A mátrixok méretének vagy nagyságának mérésére is szükségünk van valamilyen módszerre. Itt is lehetséges általánosabb definíció, de a továbbiakban használt mátrixnormákat mind egy alapul szolgáló vektornorma segítségével definiáljuk. Pontosabban: egy adott vektornorma mellett egy $m \times n$ méretű A mátrixhoz tartozó mátrixnormát a következőképpen értelmezzük:

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Az ilyen mátrixnormáról azt mondjuk, hogy a vektornorma által *indukált* (vagy annak szubordinált) normája. Szemléletesen: a mátrix normája azt a maximális nyújtást méri, amelyet a mátrix az adott vektornormában mérve bármely vektoron végrehajthat.

Egyes mátrixnormák sokkal könnyebben számíthatók ki, mint mások. Például az 1-es vektornorma által indukált mátrixnorma egyszerűen a mátrix maximális abszolút oszlopösszege:

$$\|A\|_1 = \max_j \sum_{i=1}^{m} |a_{ij}|,$$

a maximum-norma (∞-norma) által indukált mátrixnorma pedig egyszerűen a mátrix maximális abszolút sorösszege:

$$\|A\|_\infty = \max_i \sum_{j=1}^{n} |a_{ij}|.$$

Könnyű megjegyezni őket úgy, hogy ezek a mátrixnormák egy $n \times 1$ méretű mátrix (oszlopvektor) esetén megegyeznek a megfelelő vektornormákkal. Sajnos a 2-es vektornorma által indukált mátrixnormát nem olyan könnyű kiszámítani (lásd a 3.6.1. szakaszt).

2.4. Példa. Mátrixnormák. Az

$$A = \begin{bmatrix} 2 & -1 & 1 \\ 1 & 0 & 1 \\ 3 & -1 & 4 \end{bmatrix}$$

mátrix esetén a maximális abszolút oszlop- és sorösszegekből rendre

$$\|A\|_1 = 6 \quad \text{és} \quad \|A\|_\infty = 8$$

adódik. (E mátrix 2-normájához lásd a 3.17. példát.)

Az így definiált mátrixnormák a következő fontos tulajdonságokkal rendelkeznek, ahol A és B tetszőleges mátrixok:

1. $\|A\| > 0$, ha $A \neq O$.
2. $\|\gamma A\| = |\gamma| \cdot \|A\|$ tetszőleges γ skalár esetén.
3. $\|A + B\| \leq \|A\| + \|B\|$.
4. $\|AB\| \leq \|A\| \cdot \|B\|$.
5. $\|Ax\| \leq \|A\| \cdot \|x\|$ tetszőleges x vektor esetén.

Általánosabb megközelítésben egy mátrixnorma definíciójaként bármely olyan valós értékű mátrixfüggvényt tekinthetünk, amely az első három tulajdonságot teljesíti. A fennmaradó két tulajdonság, amelyeket *szubmultiplikatív* vagy konzisztenciafeltételeknek neveznek, az ilyen általánosabb mátrixnormákra nem feltétlenül teljesül, de a vektor p-normák által indukált mátrixnormákra mindig érvényes. Ismét megjegyezzük, hogy az első két tulajdonság együtt azt eredményezi, hogy $\|A\| = 0$ akkor és csak akkor, ha $A = O$ (ahol O a zérusmátrix).

2.3.3 Mátrix kondíciószáma

Egy reguláris A négyzetes mátrix adott mátrixnormára vonatkozó kondíciószámát a következőképpen definiáljuk:

$$\operatorname{cond}(A) = \|A\| \cdot \|A^{-1}\|.$$

Megállapodás szerint $\operatorname{cond}(A) = \infty$, ha A szinguláris. A 2.3.4. szakaszban látni fogjuk, hogy ez a fogalom összhangban van a kondíciószám 1.2.6. szakaszban bevezetett általános fogalmával, amennyiben a mátrix kondíciószáma felső korlátot ad a megoldás relatív változásának és a bemeneti adatok relatív változásának arányára.

2.5. Példa. Mátrix kondíciószáma. Mátrixszorzással könnyen ellenőrizhető, hogy a 2.4. példában szereplő mátrix inverze:

$$A^{-1} = \begin{bmatrix} 0{,}5 & 1{,}5 & -0{,}5 \\ -0{,}5 & 2{,}5 & -0{,}5 \\ -0{,}5 & -0{,}5 & 0{,}5 \end{bmatrix},$$

amelyből

$$\|A^{-1}\|_1 = 4{,}5 \quad \text{és} \quad \|A^{-1}\|_\infty = 3{,}5.$$

Ezek alapján

$$\mathrm{cond}_1(A) = \|A\|_1 \cdot \|A^{-1}\|_1 = 6 \cdot 4{,}5 = 27$$

és

$$\mathrm{cond}_\infty(A) = \|A\|_\infty \cdot \|A^{-1}\|_\infty = 8 \cdot 3{,}5 = 28.$$

E mátrix 2-normára vonatkozó kondíciószámát a 3.17. példa tárgyalja.

A 2.5. példából látható, hogy egy $n \times n$-es mátrix kondíciószámának értéke függ az alkalmazott normától (amit az alsó index jelez), de az alapul szolgáló vektornormák ekvivalenciája miatt ezek az értékek legfeljebb egy rögzített (csak n-től függő) konstans szorzó erejéig térnek el egymástól, így a kondicionáltság kvantitatív mértékeként egyaránt hasznosak.

Mivel

$$\|A\| \cdot \|A^{-1}\| = \left(\max_{x \neq 0} \frac{\|Ax\|}{\|x\|}\right) \cdot \left(\min_{x \neq 0} \frac{\|Ax\|}{\|x\|}\right)^{-1},$$

a mátrix kondíciószáma a maximális relatív nyújtás és a maximális relatív zsugorítás arányát méri, amelyet a mátrix bármely nem nulla vektoron végrehajthat. Úgy is fogalmazhatunk, hogy a mátrix kondíciószáma az egységgömb torzulásának mértékét jellemzi (a megfelelő vektornormában) a mátrixszal való transzformáció során. Minél nagyobb a kondíciószám, annál elnyújtottabb és torzabb lesz az egységgömb képe. Két dimenzióban például a 2-normabeli egységkörből egyre inkább szivar alakú ellipszis lesz, az 1-normában vagy az ∞-normában pedig az egységgömb (amely euklideszi értelemben négyzet) egyre ferdébb paralelogrammává torzul a kondíciószám növekedésével.

2.6. Példa. Mátrix kondíciószáma. A 2.3. ábra négy különböző mátrix hatását szemlélteti az $\mathbb{R}^2$-beli egységkörön, a 2-normát használva. A_1 az egységkört 30 fokkal az óramutató járásával megegyező irányba forgatja el, de egyik vektor euklideszi hosszát sem változtatja meg, így $\mathrm{cond}_2(A_1) = 1$. A_2 az e_1 bázisvektort 2-szeresére nyújtja, az e_2 bázisvektort pedig 0,5-szeresére zsugorítja; mivel mindkét változtatás maximális mértékű, $\mathrm{cond}_2(A_2) = 2/0{,}5 = 4$. A_3 egyszerre forgatja és torzítja az egységkört, de a maximális arány itt is megegyezik A_2 értékével, így $\mathrm{cond}_2(A_3) = 4$. Végül A_4 egy általánosabb transzformáció, amelynél a maximális nyújtási arány már nem a bázisvektoroknál jelentkezik, de a maximum értéke továbbra is ugyanaz, tehát $\mathrm{cond}_2(A_4) = 4$.

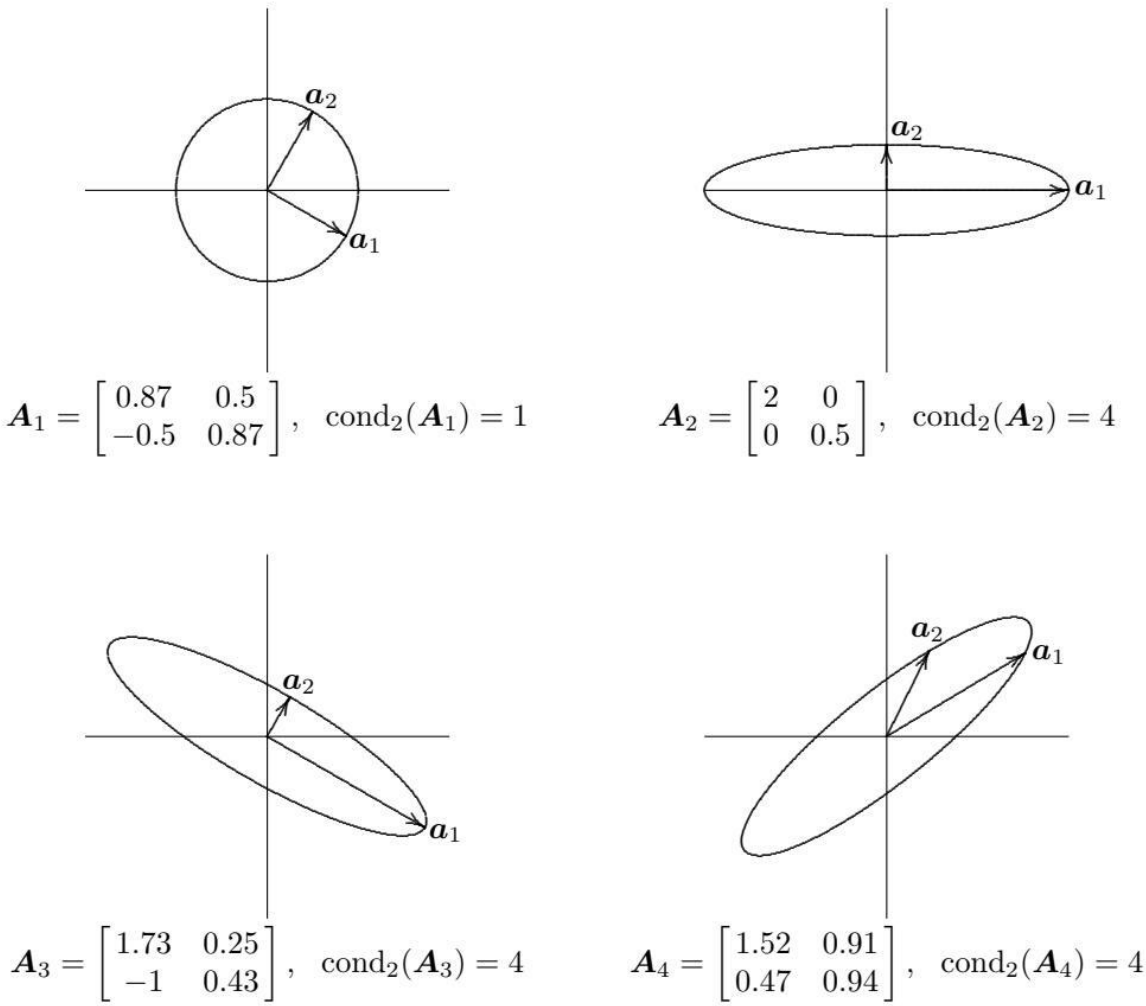

2.3. ábra: Az egységkör transzformációja 2-normában különböző mátrixokkal.

A kondíciószám következő fontos tulajdonságai a definícióból könnyen levezethetők, és tetszőleges normára érvényesek:

1. Tetszőleges A mátrix esetén $\mathrm{cond}(A) \geq 1$.
2. Az egységmátrixra $\mathrm{cond}(I) = 1$.
3. Tetszőleges A mátrix és nem nulla γ skalár esetén $\mathrm{cond}(\gamma A) = \mathrm{cond}(A)$.
4. Tetszőleges $D = \mathrm{diag}(d_i)$ diagonális mátrix esetén $\mathrm{cond}(D) = (\max |d_i|)/(\min |d_i|)$.

A kondíciószám azt méri, hogy a mátrix mennyire van közel a szingularitáshoz: egy nagy kondíciószámú mátrix (ezt a 2.3.4. szakaszban számszerűsítjük) közel szinguláris, míg az 1-hez közeli kondíciószámú mátrix távol van a szingularitástól. A definícióból adódik, hogy egy reguláris mátrix és az inverze kondíciószáma megegyezik. Ez szemléletesen is érthető: ha egy mátrix közel szinguláris, akkor az inverze is ugyanolyan mértékben „közel” van a szingularitáshoz.

Megjegyzendő, hogy a mátrix determinánsa nem megbízható mutatója a szingularitáshoz való közelségnek: bár az A mátrix szinguláris, ha $\det(A) = 0$, a nem nulla determináns nagysága önmagában semmilyen információt nem ad a kondicionáltságról. Például $\det(\alpha I_n) = \alpha^n$, ami

$|\alpha| < 1$ esetén tetszőlegesen kicsi lehet, ennek ellenére a mátrix bármely $\alpha \neq 0$ esetén tökéletesen jól kondicionált, kondíciószáma minden mátrixnormában pontosan 1.

A kondíciószám hasznossága a lineáris egyenletrendszerek megoldásának becsült pontosságában rejlik. Mivel a kondíciószám definíciója tartalmazza a mátrix inverzét, a kiszámítása nem triviális. Valójában a kondíciószám közvetlen kiszámítása lényegesen nagyobb munkát igényelne, mint magának az egyenletrendszernek a megoldása. A gyakorlatban ezért a kondíciószámot csupán becsüljük (rendszerint egy nagyságrendnyi pontossággal), a megoldási folyamat viszonylag olcsó „melléktermékeként".

Az $\|A\|$ mátrixnormát könnyen kiszámíthatjuk a maximális oszlop- vagy sorösszegként. A kihívást az $\|A^{-1}\|$ költséghatékony becslése jelenti. A normák tulajdonságaiból tudjuk, hogy ha z az $Az = y$ rendszer megoldása, akkor:

$$\|z\| = \|A^{-1}y\| \leq \|A^{-1}\| \cdot \|y\|,$$

így

$$\frac{\|z\|}{\|y\|} \leq \|A^{-1}\|,$$

és ez a korlát valamely optimálisan választott y vektor esetén egyenlőségként is teljesülhet. Ezért ha y-t úgy választjuk meg, hogy a $\|z\|/\|y\|$ hányados a lehető legnagyobb legyen, ésszerű becslést kapunk $\|A^{-1}\|$-re.

2.7. Példa. Kondícióbecslés. Tekintsük az alábbi mátrixot:

$$A = \begin{bmatrix} 0{,}913 & 0{,}659 \\ 0{,}457 & 0{,}330 \end{bmatrix}.$$

Ha $y = [0, 1{,}5]^T$-t választjuk, akkor $z = [-7780, 10780]^T$, tehát

$$\|A^{-1}\|_1 \approx \frac{\|z\|_1}{\|y\|_1} \approx 1{,}238 \times 10^4,$$

és így

$$\mathrm{cond}_1(A) = \|A\|_1 \cdot \|A^{-1}\|_1 \approx 1{,}370 \times 1{,}238 \times 10^4 = 1{,}696 \times 10^4,$$

ami – mint kiderül – a megadott tizedesjegyek erejéig pontos. E viszonylag nagy kondíciószám következményeit a 2.8. és a 2.17. példában vizsgáljuk meg.

A 2.7. példabeli y vektort gondosan úgy választottuk meg, hogy a maximális hányadost adja, és így $\|A^{-1}\|$ pontos értékét kapjuk meg. Egy ilyen optimális y megtalálása általában túl sok számítási kapacitást igényelne, de léteznek olcsóbb közelítések is. Az egyik heurisztika szerint y-t az $A^T y = c$ rendszer megoldásaként keressük, ahol c komponensei ± 1 értékűek, és az előjeleket úgy választjuk meg, hogy az adódó y a lehető legnagyobb legyen. Egy másik stratégia egyszerűen néhány

véletlenszerű y vektorral próbálkozik; a kapott legnagyobb hányados általában elegendő becslést ad $\|A^{-1}\|$-re.

A kondícióbecslés egy alternatív megközelítése, hogy a feladatot konvex optimalizálási problémaként kezeljük, ami heurisztikus algoritmusokkal nagyon hatékonyan megoldható. A 2-norma esetén lehetőség van a szingulárisérték-felbontásból (SVD) való származtatásra is (lásd 3.6.1. szakasz), de ez aránytalanul nagy számításigényű, hacsak az SVD-t egyéb okból amúgy sem számítjuk ki. Szerencsére a felhasználóknak ritkán kell ezekkel a részletekkel foglalkozniuk, mivel a modern szoftvercsomagok többsége tartalmaz hatékony és megbízható kondícióbecslőt (lásd a 2.1. táblázatot).

2.3.4 Hibakorlátok

A kondíciószám nemcsak a szingularitáshoz való közelség megbízható mutatója, hanem kvantitatív korlátot is ad a lineáris egyenletrendszer számított megoldásának hibájára. Legyen x a reguláris $Ax = b$ lineáris egyenletrendszer megoldása, és legyen $\hat{x}$ az $A\hat{x} = b + \Delta b$ perturbált jobb oldallal rendelkező rendszer megoldása. Ha definiáljuk a $\Delta x = \hat{x} - x$ hibavektort, akkor:

$$A\hat{x} = A(x + \Delta x) = Ax + A\,\Delta x = b + \Delta b.$$

Mivel $Ax = b$, ezért $A\,\Delta x = \Delta b$ kell hogy teljesüljön, amiből következik, hogy $\Delta x = A^{-1}\Delta b$. Normát véve kapjuk az

$$\|b\| = \|Ax\| \leq \|A\| \cdot \|x\|, \quad \text{vagyis} \quad \|x\| \geq \|b\|/\|A\|,$$

és a

$$\|\Delta x\| = \|A^{-1}\Delta b\| \leq \|A^{-1}\| \cdot \|\Delta b\|$$

egyenlőtlenségeket. E két összefüggést kombinálva adódik:

$$\frac{\|\Delta x\|}{\|x\|} \leq \|A^{-1}\| \cdot \|\Delta b\| \frac{\|A\|}{\|b\|}.$$

A definíció szerinti $\|A\| \cdot \|A^{-1}\| = \mathrm{cond}(A)$ behelyettesítésével a következő korlátot kapjuk:

$$\frac{\|\Delta x\|}{\|x\|} \leq \mathrm{cond}(A) \frac{\|\Delta b\|}{\|b\|}.$$

A mátrix kondíciószáma tehát egy „erősítési tényező”, amely a jobb oldali vektor adott relatív változásából fakadó megoldás maximális relatív változását korlátozza (vö. a kondíciószám 1.2.6. szakaszban megadott általános fogalmával).

Hasonló eredmény érvényes az A mátrix elemeinek relatív változásaira is. Ha $Ax = b$ és $(A+E)\hat{x} = b$, akkor:

$$\Delta x = \hat{x} - x = A^{-1}(A\hat{x} - b) = -A^{-1}E\hat{x}.$$

Normát véve az

$$\|\Delta x\| \leq \|A^{-1}\| \cdot \|E\| \cdot \|\hat{x}\|$$

egyenlőtlenséget kapjuk, amelyből $\mathrm{cond}(A)$ segítségével adódik a

$$\frac{\|\Delta x\|}{\|\hat{x}\|} \leq \mathrm{cond}(A)\frac{\|E\|}{\|A\|}$$

korlát.

Az iménti algebrai levezetések alternatívájaként a lineáris egyenletrendszerek érzékenységét differenciálszámítás segítségével is becsülhetjük. A t valós paraméter bevezetésével definiáljuk az $A(t) = A + tE$ és $b(t) = b + t\Delta b$ mennyiségeket, és tekintsük az $A(t)x(t) = b(t)$ rendszer $x(t)$ megoldását. Ezt az egyenletet t szerint differenciálva:

$$A^{'}(t)x(t) + A(t)x'(t) = b^{'}(t),$$

vagy ekvivalens módon

$$Ex(t) + A(t)x'(t) = \Delta b$$

adódik. Átrendezve kapjuk, hogy

$$x'(t) = A(t)^{-1}(\Delta b - Ex(t)),$$

amiből

$$x'(0) = A^{-1}(\Delta b - Ex(0)).$$

A Taylor-formula szerint $x(t) = x(0) + tx'(0) + \mathcal{O}(t^2)$, tehát:

$$x(t) - x(0) = tx'(0) + \mathcal{O}(t^2) = tA^{-1}(\Delta b - Ex(0)) + \mathcal{O}(t^2).$$

Legyen $x \equiv x(0)$; normát véve, majd $\|x\|$-szel osztva a

$$\frac{\|x(t) - x\|}{\|x\|} \leq \|A^{-1}\| \left(\frac{\|\Delta b\|}{\|x\|} + \|E\|\right) |t| + \mathcal{O}(t^2)$$

$$\leq \mathrm{cond}(A) \left(\frac{\|\Delta b\|}{\|A\| \cdot \|x\|} + \frac{\|E\|}{\|A\|}\right) |t| + \mathcal{O}(t^2)$$

$$\leq \mathrm{cond}(A) \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|E\|}{\|A\|}\right) |t| + \mathcal{O}(t^2)$$

korlátot kapjuk.

Ismét azt látjuk tehát, hogy a megoldás relatív változását a kondíciószám és a feladat adatainak relatív változásának szorzata korlátozza.

Az érzékenységi eredmények geometriai értelmezése két dimenzióban: ha a két egyenlet által meghatározott egyenesek közel párhuzamosak, akkor metszéspontjuk nem határozható meg élesen, amennyiben az egyenesek kerekítési vagy mérési hiba miatt némileg bizonytalanok. Ha viszont az egyenesek távol vannak a párhuzamostól, például közel merőlegesek, akkor metszéspontjuk viszonylag stabil marad. E két esetet a 2.4. ábra mutatja be, ahol a szaggatott vonalak jelölik az egyes folytonos vonalakhoz tartozó bizonytalansági tartományt, úgyhogy a metszéspont mindkét esetben a satírozott paralelogramma bármelyik pontja lehet. Így a nagy kondíciószám a megoldás nagy bizonytalanságával jár.

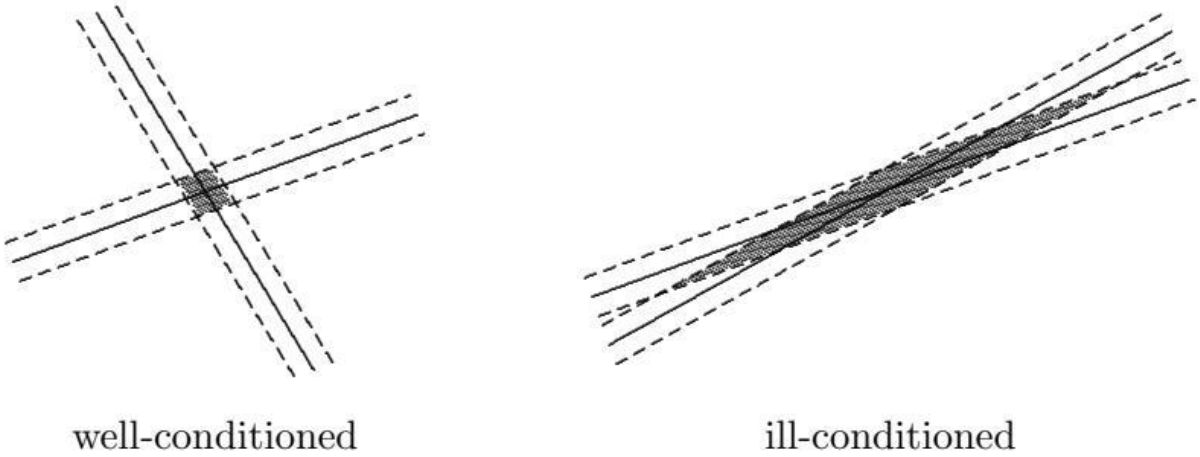

2.4. ábra: Jól kondicionált és rosszul kondicionált lineáris egyenletrendszerek.

Összefoglalva: ha a bemeneti adatok gépi pontosságig helyesek, akkor egy $Ax = b$ lineáris egyenletrendszer közelítő $\hat{x}$ megoldásának relatív hibájára a következő becslést várhatjuk:

$$\frac{\|\hat{x} - x\|}{\|x\|} \lessapprox \operatorname{cond}(A)\ \epsilon_{\text{mach}}.$$

Ezt az eredményt a hátraható hibaelemzés nyelvén úgy értelmezhetjük, hogy a számított megoldás a bemenet pontosságához képest körülbelül $\log_{10}(\operatorname{cond}(A))$ értékes jegyet veszít a pontosságából. A 2.7. példabeli mátrix kondíciószáma például nagyobb 10^4-nél, ezért az ilyen mátrixot tartalmazó lineáris egyenletrendszer megoldásában nem várhatunk helyes számjegyet, hacsak a bemeneti adatok négy értékes jegynél pontosabbak, és a munkapontosság is több mint négy értékes jegyet hordoz (lásd a 2.8. és a 2.17. példát).

Az érzékenység kvantitatív mértékeként a mátrix kondíciószáma a lineáris egyenletrendszerek megoldásának feladatában ugyanazt a szerepet tölti be — és ugyanolyan típusú kapcsolatot ad az előreható és a hátraható hiba között —, mint az 1.2.6. szakaszban definiált általános kondíciószám. Fontos különbség azonban, hogy a mátrix kondíciószáma soha nem lehet kisebb 1-nél.

A pontosság kondíciószámok alapján történő megítéléséhez érdemes figyelembe venni az alábbiakat:

- A fenti normaalapú elemzés a megoldásvektor *legnagyobb* komponenseinek relatív hibájára ad korlátot. A kisebb komponensek *relatív* hibája ennél jóval nagyobb is lehet, mivel a vektornormát a legnagyobb komponensek dominálják. Komponensenkénti hibakorlátok is nyerhetők, de ezek kiszámítása összetettebb, így ezzel itt nem foglalkozunk. Ezek a korlátok különösen akkor fontosak, ha a rendszer rosszul skálázott (lásd a 2.4.10. szakaszt).
- A mátrix kondíciószámát befolyásolja a skálázás (lásd a 2.10. példát). Nagy kondíciószám adódhat pusztán rossz skálázásból is (lásd a 2.20. példát), nem csak a szingularitás közelségéből. A mátrix átskálázása az előbbi problémán segíthet, az utóbbin nem (lásd a 2.4.10. szakaszt).

2.3.5 Reziduum

Egy egyenlet megoldásának egyik legegyszerűbb ellenőrzési módja, hogy az értéket visszahelyettesítjük az egyenletbe, és megnézzük, mennyire egyezik meg a bal és a jobb oldal. Az $Ax = b$ lineáris egyenletrendszer közelítő $\hat{x}$ megoldásának **reziduuma** az alábbi különbség:

$$r = b - A\hat{x}.$$

Ha az A mátrix reguláris, akkor elméletben a $\|\Delta x\| = \|\hat{x} - x\| = 0$ hiba akkor és csak akkor teljesül, ha $\|r\| = 0$. A gyakorlatban azonban ezek a mennyiségek nem feltétlenül egyszerre kicsik.

Először is fontos megjegyezni, hogy ha az $Ax = b$ egyenlet mindkét oldalát megszorozzuk egy tetszőleges nem nulla konstanssal, a megoldás változatlan marad, de a reziduum ugyanezzel a tényezővel szorzódik. Így a reziduum a feladat skálázásától függően tetszőlegesen naggyá vagy kicsivé tehető. Emiatt a reziduum nagysága önmagában nem informatív, hacsak nem a feladat adataihoz és a megoldás méretéhez viszonyítva vizsgáljuk. Ezért a $\hat{x}$ közelítő megoldás **relatív reziduumát** a következőképpen definiáljuk:

$$\frac{\|r\|}{\|A\| \cdot \|\hat{x}\|}.$$

A hiba és a reziduum kapcsolatának megállapításához vegyük észre a következő összefüggést:

$$\|\Delta x\| = \|\hat{x} - x\| = \|A^{-1}(A\hat{x} - b)\| = \| - A^{-1}r\| \leq \|A^{-1}\| \cdot \|r\|.$$

Mindkét oldalt $\|\hat{x}\|$ mennyiséggel osztva, és a $\mathrm{cond}(A)$ definícióját felhasználva kapjuk:

$$\frac{\|\Delta x\|}{\|\hat{x}\|} \leq \mathrm{cond}(A)\frac{\|r\|}{\|A\| \cdot \|\hat{x}\|}.$$

Látható, hogy a kis relatív reziduum **akkor és csak akkor** jelent kis relatív hibát a megoldásban, ha a mátrix jól kondicionált.

Ha a nagy reziduum következményeit vizsgáljuk, tegyük fel, hogy a számított $\hat{x}$ megoldás egzaktul kielégít egy perturbált egyenletet:

$$(A + E)\hat{x} = b.$$

Ekkor:

$$\|r\| = \|b - A\hat{x}\| = \|E\hat{x}\| \leq \|E\| \cdot \|\hat{x}\|,$$

amiből az alábbi egyenlőtlenség adódik:

$$\frac{\|r\|}{\|A\| \cdot \|\hat{x}\|} \leq \frac{\|E\|}{\|A\|}.$$

Ez azt jelenti, hogy a **nagy relatív reziduum** nagy hátraható hibát jelez a mátrixban, ami az algoritmus instabilitására utal. Másként fogalmazva: egy stabil algoritmus a feladat kondicionáltságától függetlenül mindig kis relatív reziduumú megoldást ad. Emiatt a kis reziduum önmagában keveset árul el a közelítő megoldás tényleges pontosságáról. (Erre a kérdésre a 2.4.5. szakaszban még visszatérünk.)

2.8. Példa. Kis reziduum. Tekintsük az alábbi lineáris egyenletrendszert, amelynek mátrixát a 2.7. példában vizsgáltuk:

$$Ax = \begin{bmatrix} 0{,}913 & 0{,}659 \\ 0{,}457 & 0{,}330 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0{,}254 \\ 0{,}127 \end{bmatrix} = b.$$

Vegyünk két közelítő megoldást:

$$\hat{x}_1 = \begin{bmatrix} 0{,}6391 \\ -0{,}5 \end{bmatrix}, \quad \hat{x}_2 = \begin{bmatrix} 0{,}999 \\ -1{,}001 \end{bmatrix}.$$

A megfelelő reziduumok normái:

$$\|r_1\|_1 = 7{,}0 \times 10^{-5}, \quad \|r_2\|_1 = 2{,}4 \times 10^{-2}.$$

Melyik a jobb megoldás? Első ránézésre $\hat{x}_1$-et választanánk a lényegesen kisebb reziduuma miatt. Azonban a rendszer egzakt megoldása $x = [1, -1]^T$, tehát $\hat{x}_2$ valójában sokkal pontosabb, mint $\hat{x}_1$.

Ez a meglepő viselkedés azért fordulhat elő, mert az A mátrix rosszul kondicionált ($\mathrm{cond}(A) > 10^4$). Rossz kondicionáltság esetén a kis reziduum nem garantál kis hibát a megoldásban. (Arra, hogy $\hat{x}_1$-et hogyan kaptuk, a 2.17. példa ad választ.)

2.4 Lineáris egyenletrendszerek megoldása

2.4.1 Feladatátalakítások

Az $Ax = b$ lineáris egyenletrendszer megoldásához az 1.1.2. szakaszban felvázolt általános stratégia azt sugallja, hogy a rendszert olyan rendszerré kell átalakítanunk, amelynek megoldása megegyezik az eredetiével, de könnyebben kiszámítható. Milyen típusú átalakítás hagyja változatlanul egy lineáris rendszer megoldását? Az $Ax = b$ lineáris rendszer mindkét oldalát balról bármely reguláris M mátrixszal megszorozhatjuk anélkül, hogy a megoldást befolyásolnánk. Ennek belátásához vegyük észre, hogy az $MAz = Mb$ lineáris rendszer megoldása:

$$z = (MA)^{-1}Mb = A^{-1}M^{-1}Mb = A^{-1}b = x.$$

2.9. Példa. Permutációk. Az ilyen átalakítások egyik fontos példája az a tény, hogy az A sorai és a b megfelelő elemei átrendezhetők az x megoldás megváltoztatása nélkül. Ez szemléletesen is nyilvánvaló: a rendszer összes egyenletének egyidejűleg kell teljesülnie, ezért az a sorrend, amelyben leírjuk őket, mellékes; akár véletlenszerűen is húzhatnánk őket egy kalapból. Formálisan a sorok ilyen átrendezését úgy valósítjuk meg, hogy az egyenlet mindkét oldalát balról megszorozzuk egy P permutációs mátrixszal. A permutációs mátrix olyan négyzetes mátrix, amelynek minden sorában és oszlopában pontosan egy 1-es szerepel, a többi elem pedig nulla (azaz egy olyan egységmátrix, amelynek sorai és oszlopai permutálva vannak). Például:

$$\begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} v_3 \\ v_1 \\ v_2 \end{bmatrix}.$$

Egy permutációs mátrix mindig reguláris; valójában az inverze egyszerűen a transzponáltja, $P^{-1} = P^T$. (Egy M mátrix transzponáltja, amelyet M^T jelöl, olyan mátrix, amelynek oszlopai az M sorai, azaz ha $N = M^T$, akkor $n_{ij} = m_{ji}$.) Így az átrendezett rendszer $PAx = Pb$ alakban írható, és az x megoldás változatlan marad.

Ha jobbról szorzunk meg egy mátrixot permutációs mátrixszal, akkor az az oszlopait rendezi át a sorok helyett. Az ilyen átalakítás megváltoztatja a megoldást, de csak annyiban, hogy a megoldás komponensei permutálódnak. Ennek belátásához figyeljük meg, hogy az $APz = b$ rendszer megoldása:

$$z = (AP)^{-1}b = P^{-1}A^{-1}b = P^TA^{-1}b = P^Tx,$$

és ennélfogva az eredeti $Ax = b$ rendszer megoldása $x = Pz$.

2.10. Példa. Diagonális skálázás. Egy másik egyszerű, de fontos átalakítási típus a diagonális skálázás. Emlékezzünk vissza, hogy egy D mátrix diagonális, ha $d_{ij} = 0$ minden $i \neq j$ esetén, azaz az egyetlen nemnulla elemei a főátlón lévő d_{ii} $(i = 1, \dots, n)$ elemek. Ha az $Ax = b$ lineáris rendszer mindkét oldalát balról megszorozzuk egy reguláris D diagonális mátrixszal, akkor a mátrix minden sorát és a jobb oldalt a D megfelelő átlóbeli elemével szorozzuk meg; ezt nevezzük soronkénti skálázásnak. Elvben a soronkénti skálázás nem változtatja meg a lineáris rendszer megoldását, a gyakorlatban azonban befolyásolhatja a numerikus megoldási folyamatot és az elérhető pontosságot, amint azt látni fogjuk.

Az oszloponkénti skálázás — egy lineáris rendszer mátrixának jobbról való megszorzása egy reguláris D diagonális mátrixszal — a mátrix minden oszlopát a D megfelelő átlóbeli elemével szorozza meg. Az ilyen átalakítás megváltoztatja a megoldást: gyakorlatilag azokat a mértékegységeket módosítja, amelyekben a megoldás komponenseit mérjük. A skálázott $ADz = b$ rendszer megoldása:

$$z = (AD)^{-1}b = D^{-1}A^{-1}b = D^{-1}x,$$

és ennélfogva az eredeti $Ax = b$ rendszer megoldása $x = Dz$.

2.4.2 Háromszögű lineáris egyenletrendszerek

A következő kérdés az, hogy milyen típusú lineáris rendszer oldható meg könnyen. Tegyük fel, hogy az $Ax = b$ rendszerben van egy olyan egyenlet, amely csak egyetlen ismeretlent tartalmaz (azaz az A ezen sorában csak egyetlen elem nemnulla). Ekkor ez az egyenlet egy egyszerű osztással megoldható erre az ismeretlenre. Tegyük fel most, hogy a rendszerben van egy másik egyenlet is, amely csak két ismeretlent tartalmaz, és ezek egyike a már meghatározott érték. Ha ezt behelyettesítjük a második egyenletbe, akkor könnyen megoldhatjuk azt a másik ismeretlenre. Ha ez a minta folytatódik — egyenletenként csak egy-egy új ismeretlen lép fel —, akkor a megoldás összes komponense egymás után kiszámítható. Az ilyen speciális tulajdonságú mátrixot *háromszögmátrixnak* nevezzük. Mivel a háromszögű lineáris rendszerek ezzel az egymás utáni helyettesítéssel könnyen megoldhatók, ez egy ideális célalak, amelyre az általános lineáris rendszereket átalakíthatjuk.

Bár a fent leírt általános háromszögalak elegendő ahhoz, hogy a rendszer egymás utáni helyettesítéssel megoldható legyen, számítási szempontból kényelmes két speciális alakot definiálnunk. Egy L mátrix *alsó háromszögmátrix*, ha a főátló feletti összes eleme nulla ($l_{ij} = 0$, ha $i < j$). Hasonlóan, egy U mátrix *felső háromszögmátrix*, ha a főátló alatti összes eleme nulla ($u_{ij} = 0$, ha $i > j$). Egy, a fentebb definiált általánosabb értelemben háromszög alakú mátrix a sorainak vagy oszlopainak alkalmas permutációjával felső vagy alsó háromszögalakba hozható.

Egy $Lx = b$ alsó háromszögű rendszer esetén az egymás utáni helyettesítést *előrehelyettesítésnek* (forward substitution) nevezzük, és matematikailag így fejezhetjük ki:

$$x_1 = b_1/l_{11}, \quad x_i = \left(b_i - \sum_{j=1}^{i-1} l_{ij} x_j \right) / l_{ii}, \quad i = 2, \dots, n.$$

Ennek megvalósítását mutatja a 2.1. algoritmus.

2.1. Algoritmus. Előrehelyettesítés alsó háromszögű rendszerre.

```
for j = 1 to n                        { ciklus az oszlopokra }
    if  jj = 0 then stop              { leállás, ha a mátrix szinguláris }
    xj = bj/ jj                       { megoldáskomponens kiszámítása }
    for i = j + 1 to n
        bi = bi -  ij xj              { jobb oldal frissítése }
    end
end
```

Hasonlóan, egy $Ux = b$ felső háromszögű rendszer esetén az egymás utáni helyettesítést *visszahelyettesítésnek* (back substitution) nevezzük:

$$x_n = b_n/u_{nn}, \quad x_i = \left(b_i - \sum_{j=i+1}^{n} u_{ij} x_j \right) / u_{ii}, \quad i = n-1, \dots, 1.$$

Ennek megvalósítását mutatja a 2.2. algoritmus.

Mindkét algoritmusban úgy választottuk meg a ciklusváltozók sorrendjét, hogy a mátrixhoz oszloponként (és nem soronként) férünk hozzá. A belső ciklus művelete egy skalár szorozva egy vektorral, amihez hozzáadunk egy másik vektort — ez az úgynevezett „saxpy” művelet (lásd a 2.7.2. szakaszt).

2.2. Algoritmus. Visszahelyettesítés felső háromszögű rendszerre.

```
for j = n to 1                      { ciklus az oszlopokra visszafelé }
    if ujj = 0 then stop            { leállás, ha a mátrix szinguláris }
    xj = bj/ujj                     { megoldáskomponens kiszámítása }
    for i = 1 to j - 1
        bi = bi - uij xj            { jobb oldal frissítése }
    end
end
```

Választhattuk volna a ciklusváltozók fordított sorrendjét is, ekkor a mátrixhoz soronként férnénk hozzá, és a belső ciklus művelete két vektor belső szorzata lenne (azaz „sdot” művelet). Ezek a választások jelentős hatással lehetnek a teljesítményre a programozási nyelvtől és a számítógépes architektúrától függően. Érdemes megjegyezni, hogy egy nulla átlóbeli elem mindkét algoritmus futását meghiúsítja, ami várható is, hiszen egy nulla átlóbeli elemű háromszögmátrix szükségképpen szinguláris.

2.11. Példa. Háromszögű lineáris egyenletrendszer. Tekintsük a következő felső háromszögű lineáris rendszert:

$$\begin{bmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ -6 \\ 1 \end{bmatrix}.$$

Az utolsó egyenlet, $-x_3 = 1$, közvetlenül megoldható: $x_3 = -1$. Ezt behelyettesítve a második egyenletbe $x_2 = 3$-at kapunk, végül x_3-at és x_2-t az első egyenletbe helyettesítve $x_1 = -1$ adódik.

2.4.3 Elemi eliminációs mátrixok

Stratégiánk lényege tehát az, hogy olyan reguláris lineáris transzformációkat tervezzünk, amelyek egy adott általános lineáris rendszert olyan háromszögű rendszerré alakítanak, amely azután egymás utáni helyettesítéssel könnyen megoldható. Ehhez olyan transzformációra van szükségünk, amely a mátrix kiválasztott elemeit nullázza ki. Ez a mátrix sorainak alkalmas lineáris kombinációival érhető el, amint azt most megmutatjuk.

Tekintsünk egy kétdimenziós $a = \begin{bmatrix} a_1 & a_2 \end{bmatrix}^T$ vektort. Ha $a_1 \neq 0$, akkor

$$\begin{bmatrix} 1 & 0 \\ -a_2/a_1 & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} a_1 \\ 0 \end{bmatrix}.$$

Általánosabban: egy n-dimenziós a vektor k-adik pozíciója alatti összes elemet nullázhatjuk ki — feltéve, hogy $a_k \neq 0$ — a következő transzformációval:

$$M_k\, a = \begin{bmatrix} 1 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & 0 & \cdots & 0 \\ 0 & \cdots & -m_{k+1} & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & -m_n & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ \vdots \\ a_k \\ a_{k+1} \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} a_1 \\ \vdots \\ a_k \\ 0 \\ \vdots \\ 0 \end{bmatrix},$$

ahol $m_i = a_i/a_k$, $i = k+1, \dots, n$. Az a_k osztót *főelemnek* (pivotnak) nevezzük. Az ilyen alakú mátrixot *elemi eliminációs mátrixnak* vagy *Gauss-transzformációnak* nevezzük. Egy vektorra gyakorolt hatása az, hogy a k-adik sor megfelelő többszörösét hozzáadja az összes alatta lévő sorhoz, úgy megválasztva az m_i szorzótényezőket, hogy az eredmény minden esetben nulla legyen. Vegyük észre az elemi eliminációs mátrixok alábbi tulajdonságait:

1. M_k alsó háromszögmátrix, amelynek főátlójában csupa egyes áll (egység-főátlójú), ezért szükségképpen reguláris.
2. $M_k = I - m_k e_k^T$, ahol $m_k = [0, \dots, 0, m_{k+1}, \dots, m_n]^T$, és e_k az egységmátrix k-adik oszlopa.
3. $M_k^{-1} = I + m_k e_k^T$, ami azt jelenti, hogy M_k^{-1} — amelyet L_k-val fogunk jelölni — szerkezete megegyezik M_k-ével, csak a szorzótényezők előjele ellentétes.
4. Ha M_j $(j > k)$ egy másik elemi eliminációs mátrix m_j szorzótényező-vektorral, akkor

$$M_k M_j = I - m_k e_k^T - m_j e_j^T + m_k e_k^T m_j e_j^T = I - m_k e_k^T - m_j e_j^T,$$

mivel $e_k^T m_j = 0$. Így szorzatuk lényegében a két mátrix elemeinek „egyesítése”. Mivel azonos alakúak, hasonló eredmény érvényes inverzeik $L_k L_j$ szorzatára is. Figyeljük meg, hogy a szorzás sorrendje lényeges; ezek az összefüggések a szorzás fordított sorrendjére nem teljesülnek.

2.12. Példa. Elemi eliminációs mátrixok. Ha $a = \begin{bmatrix} 2 & 4 & -2 \end{bmatrix}^T$, akkor

$$M_1 a = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}, \quad M_2 a = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0{,}5 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix}.$$

Megjegyezzük továbbá, hogy

$$L_1 = M_1^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & 0 & 1 \end{bmatrix}, \quad L_2 = M_2^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -0{,}5 & 1 \end{bmatrix},$$

és

$$M_1 M_2 = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 1 & 0{,}5 & 1 \end{bmatrix}, \quad L_1 L_2 = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -0{,}5 & 1 \end{bmatrix}.$$

2.4.4 Gauss-elimináció és LU-felbontás

Elemi eliminációs mátrixokat használva egy általános $Ax = b$ lineáris rendszert felső háromszögalakra redukálhatunk. Először a 2.4.3. szakaszban ismertetett módszer alapján választunk egy M_1 elemi eliminációs mátrixot úgy, hogy a főelem az első átlóbeli elem (a_{11}) legyen, és az A első oszlopa nullává váljon az első sor alatt. Természetesen A többi oszlopát és a b vektort is meg kell szorozni M_1-gyel, így az új rendszer $M_1 A x = M_1 b$ alakú lesz, de a megoldás változatlan marad.

Ezután a második átlóbeli elemet használjuk főelemként egy olyan M_2 mátrix meghatározásához, amely az új $M_1 A$ mátrix második oszlopának elemeit nullázza ki a főátló alatt. M_2-t ismét az egész

mátrixra és a jobb oldali vektorra alkalmazzuk, így az $M_2M_1Ax = M_2M_1b$ módosított rendszert kapjuk. Megjegyzendő, hogy M_1A első oszlopát M_2 nem befolyásolja. Ez a folyamat minden oszlopra folytatódik, amíg a mátrix összes főátló alatti eleme el nem tűnik. Ha $M = M_{n-1} \cdots M_1$, akkor a transzformált rendszer

$$MAx = M_{n-1} \cdots M_1 Ax = M_{n-1} \cdots M_1 b = Mb$$

felső háromszögű, és visszahelyettesítéssel megoldható.

Ezt az eljárást *Gauss-eliminációnak* nevezzük. *LU-felbontásnak* is hívják, mert az A mátrixot egy egység-főátlójú alsó háromszögmátrix (L) és egy felső háromszögmátrix (U) szorzatára bontja. Mivel az L_kL_j szorzat egység-főátlójú alsó háromszögmátrix, ha $k < j$, így

$$L = M^{-1} = (M_{n-1} \cdots M_1)^{-1} = M_1^{-1} \cdots M_{n-1}^{-1} = L_1 \cdots L_{n-1}$$

szintén egység-főátlójú alsó háromszögmátrix. Mivel $U = MA$ konstrukció szerint felső háromszögű, így A-t az

$$A = LU$$

szorzatként állítottuk elő. Egy ilyen felbontás birtokában az $Ax = b$ rendszer $LUx = b$ alakban írható, és két lépésben megoldható: előbb az $Ly = b$ rendszert előrehelyettesítéssel, majd az $Ux = y$ rendszert visszahelyettesítéssel oldjuk meg. Az y köztes megoldás megegyezik a transzformált jobb oldali Mb vektorral. Az LU-alak előnye, hogy világossá teszi: a felbontási fázist nem kell megismételni, ha ugyanazzal az A mátrixszal, de más jobb oldali vektorokkal kell rendszereket megoldanunk.

A Gauss-elimináció algoritmusát a 2.3. Algoritmus foglalja össze. Ez egyúttal az A LU-felbontását is elvégzi: L elemeit az m_{ik} szorzók adják, U elemei pedig A felülírt elemei lesznek. A gyakorlatban az eliminált elemek helyén (a főátló alatt) kényelmesen tárolhatók L megfelelő elemei; az algoritmus így „helyben” (in-place) végzi el a felbontást. Egy $Ax = b$ lineáris rendszer megoldása során a b jobb oldali vektor szükséges transzformációját beépíthetjük az LU-felbontási folyamatba, vagy különálló lépésként végezhetjük el, a 2.1. Algoritmust használva az $Ly = b$ alsó háromszögű rendszer megoldására, miután L-et a 2.3. Algoritmussal meghatároztuk. Bármelyik esetben a 2.2. Algoritmust használjuk ezután az $Ux = y$ felső háromszögű rendszer megoldására, hogy megkapjuk az x megoldást.

2.3. Algoritmus. LU-felbontás Gauss-eliminációval.

```
for k = 1 to n - 1                      { ciklus az oszlopokra }
    if akk = 0 then stop                { leállás, ha a főelem nulla }
    for i = k + 1 to n                  { szorzótényezők kiszámítása
        mik = aik/akk                       az aktuális oszlopra }
    end
    for j = k + 1 to n                  { transzformáció alkalmazása
        for i = k + 1 to n                  a reziduum részmátrixra }
            aij = aij - mik akj
        end
```

```
    end
end
```

2.13. Példa. Gauss-eliminációt. A Gauss-eliminációt a következő lineáris egyenletrendszer megoldásán illusztráljuk:

$$\begin{aligned} x_1 + 2x_2 + 2x_3 &= 3, \\ 4x_1 + 4x_2 + 2x_3 &= 6, \\ 4x_1 + 6x_2 + 4x_3 &= 10, \end{aligned}$$

vagy mátrix jelöléssel

$$Ax = \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = b.$$

A első oszlopának főátló alatti elemeinek nullázásához az első sor négyszeresét vonjuk ki a második és a harmadik sorból:

$$M_1 A = \begin{bmatrix} 1 & 0 & 0 \\ -4 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & -2 & -4 \end{bmatrix},$$

$$M_1 b = \begin{bmatrix} 1 & 0 & 0 \\ -4 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 6 \\ 10 \end{bmatrix} = \begin{bmatrix} 3 \\ -6 \\ -2 \end{bmatrix}.$$

Most az $M_1 A$ második oszlopa főátló alatti elemének nullázásához a második sor 0,5-szörösét vonjuk ki a harmadik sorból:

$$\mathbf{M}_2\mathbf{M}_1\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -0{,}5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & -2 & -4 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & 0 & -1 \end{bmatrix},$$

$$\mathbf{M}_2\mathbf{M}_1\mathbf{b} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -0{,}5 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ -6 \\ -2 \end{bmatrix} = \begin{bmatrix} 3 \\ -6 \\ 1 \end{bmatrix}.$$

Ezzel az eredeti rendszert a következő ekvivalens felső háromszögű rendszerre redukáltuk:

$$Ux = \begin{bmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ -6 \\ 1 \end{bmatrix} = Mb = y,$$

amelyet most visszahelyettesítéssel oldhatunk meg (mint a 2.11. Példában), és így $x = \begin{bmatrix} -1 & 3 & -1 \end{bmatrix}^T$ adódik. Az LU-felbontás explicit felírásához

$$L_1 L_2 = \begin{bmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 4 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0{,}5 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 4 & 0{,}5 & 1 \end{bmatrix} = L,$$

így

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 4 & 1 & 0 \\ 4 & 0{,}5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 \\ 0 & -4 & -6 \\ 0 & 0 & -1 \end{bmatrix} = \mathbf{LU}.$$

2.4.5 Főelemkiválasztás

A Gauss-eliminációs eljárás során, ahogy azt eddig tárgyaltuk, egy nyilvánvaló és egy némileg rejtettebb problémával is szembe kell néznünk. A kézenfekvő nehézség az, hogy az eljárás elakad, ha a mátrix még redukálatlan részének vezető átlóbeli eleme (a főelem) valamelyik lépésben nulla, mivel a szorzótényezők kiszámításához ezzel az elemmel kell osztanunk. A megoldás szintén egyszerű: ha a k-adik lépésben az átlóbeli elem nulla, cseréljük fel a rendszer k-adik sorát egy olyan későbbi sorral, amelynek k-adik oszlopbeli eleme nemnulla. A 2.9. példából tudjuk, hogy az ilyen csere nem változtatja meg a megoldást. Ezt a sorcserét *főelemkiválasztásnak* (pivoting) nevezzük.

2.14. Példa. Főelemkiválasztás és szingularitás. A főelemkiválasztás esetleges szüksége semmilyen kapcsolatban nem áll azzal, hogy a mátrix szinguláris-e. Például az

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

mátrix reguláris, mégsincs LU-felbontása, hacsak nem cseréljük fel a sorokat, míg a szinguláris

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

mátrixnak van LU-felbontása:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix} = LU.$$

Ha viszont a k-adik oszlop átlóján vagy az alatt egyáltalán nincs nemnulla elem, akkor az adott oszlopban nincs mit eliminálni, így továbbléphetünk a következőre ($M_k = I$). Ez a lépés nullát hagy a főátlón, így az U felső háromszögmátrix szinguláris lesz. Ez viszont azt jelenti, hogy az ezt követő visszahelyettesítés meghiúsul, mert U minden átlóbeli elemével osztani kellene, de ez nem meglepő, hiszen az eredeti A mátrixnak mindenképpen szingulárisnak kellett lennie. Lebegőpontos aritmetikában azonban sokkal alattomosabb hiba, ha a főelem nem nulla, de abszolút értékben nagyon kicsi — ez vezet el a finomabb, numerikus stabilitási kérdéshez.

Elvben bármely nemnulla érték megfelelhet főelemnek a szorzótényezők kiszámítására, de véges pontosságú aritmetikában a választást körültekintően kell meghozni, hogy minimalizáljuk a numerikus hiba terjedését. Konkrétan korlátozni szeretnénk a szorzótényezők nagyságát, hogy a korábbi kerekítési hibák ne erősödjenek fel, amikor a mátrix és a jobb oldal reziduum részét

megszorozzuk az egyes elemi eliminációs mátrixokkal. A szorzótényezők nagysága soha nem fogja meghaladni az 1-et, ha minden oszlopban az átlón vagy az alatt található legnagyobb abszolút értékű elemet választjuk főelemnek. Az ilyen eljárást *részleges főelemkiválasztásnak* nevezzük, és a gyakorlatban elengedhetetlen az általános lineáris rendszereken végzett Gauss-elimináció numerikusan stabil megvalósításához.

2.15. Példa. Kis főelemek. Véges pontosságú aritmetikában nemcsak a nulla főelemeket, hanem a *kis* főelemeket is kerülnünk kell, hogy megelőzzük az elfogadhatatlan hibanövekedést, mint az alábbi példa mutatja. Legyen

$$A = \begin{bmatrix} \epsilon & 1 \\ 1 & 1 \end{bmatrix},$$

ahol ϵ egy olyan pozitív szám, amely az adott lebegőpontos rendszer ϵ_{mach} gépi epszilonjánál (kerekítési egységénél) kisebb. Ha nem cseréljük fel a sorokat, akkor a főelem ϵ, és a kapott szorzótényező $-1/\epsilon$, így az eliminációs mátrix

$$M = \begin{bmatrix} 1 & 0 \\ -1/\epsilon & 1 \end{bmatrix},$$

és ennélfogva

$$L = \begin{bmatrix} 1 & 0 \\ 1/\epsilon & 1 \end{bmatrix} \quad \text{és} \quad U = \begin{bmatrix} \epsilon & 1 \\ 0 & 1 - 1/\epsilon \end{bmatrix} = \begin{bmatrix} \epsilon & 1 \\ 0 & -1/\epsilon \end{bmatrix}$$

lebegőpontos aritmetikában. De akkor

$$LU = \begin{bmatrix} 1 & 0 \\ 1/\epsilon & 1 \end{bmatrix} \begin{bmatrix} \epsilon & 1 \\ 0 & -1/\epsilon \end{bmatrix} = \begin{bmatrix} \epsilon & 1 \\ 1 & 0 \end{bmatrix} \neq A.$$

Egy kis főelem és az ennek megfelelő nagy szorzótényező használata a transzformált mátrixban helyrehozhatatlan információvesztést okozott. Ha viszont felcseréljük a sorokat, akkor a főelem 1, és a kapott szorzótényező $-\epsilon$, így az eliminációs mátrix

$$M = \begin{bmatrix} 1 & 0 \\ -\epsilon & 1 \end{bmatrix},$$

és ennélfogva

$$L = \begin{bmatrix} 1 & 0 \\ \epsilon & 1 \end{bmatrix} \quad \text{és} \quad U = \begin{bmatrix} 1 & 1 \\ 0 & 1 - \epsilon \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

lebegőpontos aritmetikában. Így

$$LU = \begin{bmatrix} 1 & 0 \\ \epsilon & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ \epsilon & 1 \end{bmatrix},$$

ami a permutálás utáni helyes eredmény.

Bár az előbbi példa meglehetősen szélsőséges, az elv általánosan érvényes: a nagyobb főelemek kisebb szorzótényezőkhöz, és így kisebb hibákhoz vezetnek. Különösen, ha minden oszlopban az átlón vagy az alatt található legnagyobb elemet használjuk főelemnek – mint a 2.4. Algoritmusban –, akkor a szorzótényezők nagysága 1-gyel felülről korlátozott. A részleges főelemkiválasztás által megkövetelt sorcserék némileg bonyolultabbá teszik az LU-felbontás korábban megadott formális leírását. Konkrétan minden M_k elemi eliminációs mátrix előtt egy P_k permutációs mátrix áll, amely sorcserékkel a k-adik oszlop átlón vagy alatt található legnagyobb abszolút értékű elemét az átlós főelempozícióba hozza. Továbbra is $MA = U$, ahol U felső háromszögű, de most

$$M = M_{n-1}P_{n-1} \cdots M_1 P_1.$$

M^{-1} továbbra is háromszögalakú a korábban definiált általános értelemben, de a permutációk miatt M^{-1} nem szükségképpen alsó háromszögű, bár továbbra is L-lel jelöljük. Így az „LU”-felbontás szó szerint már nem „alsó szorozva felső” háromszögmátrixot jelent, de a lineáris rendszerek egymás utáni helyettesítéssel való megoldására ugyanolyan hasznos.

2.4. Algoritmus. LU-felbontás Gauss-eliminációval részleges főelemkiválasztással.

```
for k = 1 to n - 1                          { ciklus az oszlopokra }
    Find index p such that                  { főelem keresése az
        |apk|   |aik| for k   i   n           aktuális oszlopban }
    if p   k then                          { sorok cseréje,
        interchange rows k and p                ha szükséges }
    if akk = 0 then                         { az aktuális oszlop átugrása,
        continue with next k                    ha már eleve nulla }
    for i = k + 1 to n                      { szorzótényezők kiszámítása
        mik = aik/akk                           az aktuális oszlopra }
    end
    for j = k + 1 to n                      { transzformáció alkalmazása
        for i = k + 1 to n                      a reziduum részmátrixra }
            aij = aij - mik akj
        end
    end
end
```

Megjegyezzük, hogy a

$$P = P_{n-1} \cdots P_1$$

permutációs mátrix a részleges főelemkiválasztás által meghatározott sorrendbe rendezi A sorait. Egy másik értelmezés szerint tehát a részleges főelemkiválasztásra úgy is tekinthetünk, mint egy olyan sorrend meghatározásának módjára, amelyben a numerikus stabilitás érdekében nem volna szükség semmilyen cserére (persze egy ilyen sorrendet előre meghatározni nem lehet). Így a

$$PA = LU$$

felbontást kapjuk, ahol most L valóban alsó háromszögmátrix. Az $Ax = b$ lineáris rendszer megoldásához először az $Ly = Pb$ alsó háromszögű rendszert előrehelyettesítéssel, majd az $Ux = y$ felső háromszögű rendszert visszahelyettesítéssel oldjuk meg.

2.16. Példa. Gauss-elimináció részleges főelemkiválasztással. A 2.13. Példában nem használtunk sorcseréket, és néhány szorzótényező nagysága meghaladta az 1-et. Most illusztráció kedvéért megismételjük ezt a példát, ezúttal részleges főelemkiválasztást alkalmazva. A 2.13. Példa rendszere

$$Ax = \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \\ 10 \end{bmatrix} = b.$$

Az első oszlop legnagyobb eleme 4, ezért felcseréljük az első két sort a

$$\mathbf{P}_1 = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

permutációs mátrixszal, így a permutált rendszer

$$P_1 Ax = \begin{bmatrix} 4 & 4 & 2 \\ 1 & 2 & 2 \\ 4 & 6 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 6 \\ 3 \\ 10 \end{bmatrix} = P_1 b.$$

Az első oszlop főátló alatti elemeinek eliminálásához a

$$\mathbf{M}_1 = \begin{bmatrix} 1 & 0 & 0 \\ -0{,}25 & 1 & 0 \\ -1 & 0 & 1 \end{bmatrix}$$

eliminációs mátrixot használjuk, így a transzformált rendszer

$$M_1 P_1 Ax = \begin{bmatrix} 4 & 4 & 2 \\ 0 & 1 & 1{,}5 \\ 0 & 2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 6 \\ 1{,}5 \\ 4 \end{bmatrix} = M_1 P_1 b.$$

A második oszlopban az átlón vagy az alatt található legnagyobb elem 2, ezért felcseréljük az utolsó két sort a

$$P_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

permutációs mátrixszal, így a permutált rendszer

$$P_2M_1P_1Ax = \begin{bmatrix} 4 & 4 & 2 \\ 0 & 2 & 2 \\ 0 & 1 & 1{,}5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 6 \\ 4 \\ 1{,}5 \end{bmatrix} = P_2M_1P_1b.$$

A második oszlop főátló alatti elemének eliminálásához a

$$\mathbf{M}_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -0{,}5 & 1 \end{bmatrix}$$

eliminációs mátrixot használjuk, így a transzformált rendszer

$$M_2P_2M_1P_1Ax = \begin{bmatrix} 4 & 4 & 2 \\ 0 & 2 & 2 \\ 0 & 0 & 0{,}5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 6 \\ 4 \\ -0{,}5 \end{bmatrix} = M_2P_2M_1P_1b.$$

Ezzel az eredeti rendszert egy ekvivalens felső háromszögű rendszerre redukáltuk, amelyet most visszahelyettesítéssel oldhatunk meg, és ugyanazt a megoldást kapjuk, mint korábban: $x = \begin{bmatrix} -1 & 3 & -1 \end{bmatrix}^T$.

Az LU-felbontás explicit felírásához

$$L = M^{-1} = (M_2P_2M_1P_1)^{-1} = P_1^TL_1P_2^TL_2 =$$

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0{,}25 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0{,}5 & 1 \end{bmatrix} = \begin{bmatrix} 0{,}25 & 0{,}5 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix},$$

és ennélfogva

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} = \begin{bmatrix} 0{,}25 & 0{,}5 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 4 & 4 & 2 \\ 0 & 2 & 2 \\ 0 & 0 & 0{,}5 \end{bmatrix} = \mathbf{LU}.$$

Vegyük észre, hogy L nem alsó háromszögű, de az általánosabb értelemben háromszögű (egy alsó háromszögmátrix permutációja). Alternatívaként választhatjuk a

$$P = P_2P_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix},$$

és

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0{,}25 & 0{,}5 & 1 \end{bmatrix}$$

megválasztást, így

$$PA = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0{,}25 & 0{,}5 & 1 \end{bmatrix} \begin{bmatrix} 4 & 4 & 2 \\ 0 & 2 & 2 \\ 0 & 0 & 0{,}5 \end{bmatrix} = LU,$$

ahol most L valóban alsó háromszögmátrix, de A permutálva van.

A „részleges” főelemkiválasztás elnevezés abból a tényből ered, hogy csak az aktuális oszlopban keresünk alkalmas főelemet. Egy kimerítőbb főelemkiválasztási stratégia a *teljes főelemkiválasztás*, amelyben a teljes reziduum, redukálatlan részmátrixban keressük a legnagyobb elemet, majd azt permutáljuk az átlós főelempozícióba. Vegyük észre, hogy ez a sorok cseréje mellett az oszlopok cseréjét is igényli, és ezért a

$$PAQ = LU$$

alakú felbontáshoz vezet, ahol L egység-főátlójú alsó háromszögmátrix, U felső háromszögmátrix, P és Q pedig permutációs mátrixok, amelyek rendre A sorait és oszlopait rendezik át. Az $Ax = b$ lineáris rendszer megoldásához először az $Ly = Pb$ alsó háromszögű rendszert előrehelyettesítéssel, majd az $Uz = y$ felső háromszögű rendszert visszahelyettesítéssel oldjuk meg, végül pedig a megoldás komponenseit permutáljuk, hogy megkapjuk $x = Qz$-t. Bár a teljes főelemkiválasztás numerikus stabilitása elméletben jobb, sokkal költségesebb főelem-keresést igényel, mint a részleges főelemkiválasztás. Mivel a részleges főelemkiválasztás numerikus stabilitása a gyakorlatban bőven elegendő, általános lineáris rendszerek Gauss-eliminációval történő megoldásában szinte univerzálisan ezt használják.

A főelem kiválasztása az egyes mátrixelemek nagyságától függ, így a konkrét választás nyilvánvalóan függ a mátrix skálázásától. A mátrix diagonális skálázása (emlékezzünk a 2.10. Példára) eltérő főelem-sorrendhez vezethet. Például egy adott oszlop bármelyik nemnulla eleme a legnagyobbá tehető abszolút értékben, ha az adott sornak kellően nagy súlyt adunk. Ez azonban nem jelenti azt, hogy tetszőleges főelem-sorrend elfogadható: egy rosszul eltorzított skálázás rosszul kondicionált rendszerhez és ennek megfelelően pontatlan megoldáshoz vezethet (lásd a 2.20. Példát). Egy jól megfogalmazott feladatban az ismeretlen változók mérésére megfelelően arányos mértékegységeket kell használni (oszloponkénti skálázás), és az egyes egyenleteknek a viszonylagos fontosságukat helyesen tükröző súlyozást kell kapniuk (sorkénti skálázás). Figyelembe kell venni a bemeneti adatok viszonylagos pontosságát is. Ezek között a körülmények között a főelemkiválasztási eljárás általában olyan megoldást produkál, amely annyira pontos, amennyire a feladat indokolja (lásd a 2.3.4. szakaszt).

A 2.3.5. szakaszban láttuk, hogy egy kiszámított megoldás relatív reziduuma kielégíti a

$$\frac{\|r\|}{\|A\| \cdot \|\hat{x}\|} \leq \frac{\|E\|}{\|A\|}$$

egyenlőtlenséget, ahol E az A mátrixhoz tartozó hátraható hiba. De mekkora is $\|E\|$ valójában a gyakorlatban? Wilkinson [499] megmutatta, hogy a Gauss-eliminációval végzett LU-felbontás esetén

$$\frac{\|E\|}{\|A\|} \leq \rho\, n^2\, \epsilon_{\text{mach}}$$

alakú korlát érvényes, ahol ρ – amelyet *növekedési tényezőnek* nevezünk – U legnagyobb abszolút értékű elemének és A legnagyobb abszolút értékű elemének hányadosa (technikailag a növekedési tényező a felbontási folyamat *bármely* lépésében előállított legnagyobb elemtől függ, de ez rendszerint az utolsó, azaz U). Főelemkiválasztás nélkül ρ tetszőlegesen nagy lehet, és ezért a főelemkiválasztás nélküli Gauss-elimináció instabil, amint azt már láttuk. Részleges főelemkiválasztás mellett a növekedési tényező legrosszabb esetben elérheti a 2^{n-1}-t (mivel legrosszabb esetben az elemek mérete az elimináció minden lépésében megduplázódhat), de az ilyen viselkedés rendkívül ritka. A gyakorlatban kicsi vagy egyáltalán nincs növekedés, és egy realisztikus korlátot a

$$\frac{\|E\|}{\|A\|} \lessapprox n\, \epsilon_{\text{mach}}$$

reláció ad. Ez a reláció azt jelenti, hogy egy lineáris rendszernek részleges főelemkiválasztásos Gauss-eliminációval, majd visszahelyettesítéssel való megoldása szinte mindig nagyon kicsi relatív reziduumot eredményez, függetlenül attól, mennyire rosszul kondicionált a rendszer. Így egy kicsi relatív reziduum önmagában nem feltétlenül jelenti, hogy a kiszámított megoldás pontos, hacsak a rendszer nem jól kondicionált. A teljes főelemkiválasztás még kisebb növekedési tényezőt eredményez, mind elméletben, mind a gyakorlatban, de az általa nyújtott további stabilitási tartalék rendszerint nem éri meg az extra költséget.

2.17. Példa. Kis reziduum. Tekintsük a

$$Ax = \begin{bmatrix} 0{,}913 & 0{,}659 \\ 0{,}457 & 0{,}330 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0{,}254 \\ 0{,}127 \end{bmatrix} = b$$

lineáris rendszert a 2.8. Példából. Négyjegyű decimális aritmetika használatával a Gauss-elimináció a

$$\begin{bmatrix} 0{,}9130 & 0{,}6590 \\ 0 & 0{,}0002 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0{,}2540 \\ -0{,}0001 \end{bmatrix}$$

háromszögű rendszert adja, majd a visszahelyettesítés az

$$\hat{x} = \begin{bmatrix} 0{,}6391 \\ -0{,}5 \end{bmatrix}$$

kiszámított megoldást szolgáltatja. Amint a 2.8. Példában láttuk, ennek a megoldásnak a reziduumnormája $\|r\|_1 = 7{,}04 \times 10^{-5}$, ami olyan kicsi, amilyenre négyjegyű aritmetikával számíthatunk. Mégis a rendszer pontos megoldása könnyen ellenőrizhetően $x = [1, -1]^T$, így a hiba ugyanakkora, mint a megoldás. Ennek a jelenségnek az oka az, hogy az A mátrix közel szinguláris: amint a 2.7. Példában láttuk, kondíciószáma nagyobb, mint 10^4. Az x_2-t meghatározó osztás két olyan mennyiség között történik, amelyek mindegyike a kerekítési hiba nagyságrendjébe esik (négyjegyű aritmetikában), és ezért az eredmény lényegében tetszőleges. Mégis, konstrukció szerint, amikor ezt az x_2-re vonatkozó tetszőleges értéket ezután behelyettesítjük az első egyenletbe, egy

olyan x_1 érték adódik, amelyre az első egyenlet teljesül. Így kicsi reziduumot, de rossz megoldást kapunk.

Amint az imént láttuk, a Gauss-elimináció stabilitásához általában szükség van a főelemkiválasztásra. Vannak azonban olyan mátrixosztályok, amelyekre a Gauss-elimináció főelemkiválasztás nélkül is stabil. Például ha az A mátrix *oszloponként diagonálisan domináns*, ami azt jelenti, hogy minden átlóbeli elem abszolút értéke nagyobb, mint az oszlopa többi eleme abszolút értékeinek összege,

$$\sum_{i=1, i\neq j}^{n} |a_{ij}| < |a_{jj}|, \quad j = 1, \dots, n,$$

akkor az LU-felbontás Gauss-eliminációval történő kiszámításához nincs szükség főelemkiválasztásra. Ha ilyen mátrixra részleges főelemkiválasztást alkalmazunk, akkor ténylegesen nem történik sorcsere. Egy másik fontos osztály, amelyre nincs szükség főelemkiválasztásra, a szimmetrikus és pozitív definit mátrixok, amelyeket a 2.5. szakaszban fogunk definiálni. A felesleges főelem-keresések elkerülése jelentős időmegtakarítást jelenthet a felbontás kiszámításában.

2.4.6 A Gauss-elimináció megvalósítása

A Gauss-elimináció, azaz az LU-felbontás, általános alakja egy háromszorosan egymásba ágyazott ciklus, amint azt a 2.5. Algoritmus sematikusan mutatja. A `for` ciklusok i, j és k indexeit tetszőleges sorrendben használhatjuk, így a ciklusok összesen $3! = 6$-féleképpen rendezhetők el. Néhány jelzett aritmetikai művelet nagyobb hatékonyság érdekében kivihető a legbelső ciklusból (mint például a 2.3. Algoritmusban), és a műveletek olyan további átrendezései is lehetségesek, amelyek esetleg nem szigorúan egymásba ágyazott ciklusokat eredményeznek. Az alapalgoritmus ezen változatainak eltérő hozzáférési mintáik (például sorkénti vagy oszloponkénti) vannak, és eltérőek abban, mennyire képesek kihasználni egy adott számítógép architekturális jellemzőit (például gyorsítótár, lapozás, vektorizáció, több processzor). Így teljesítményük adott számítógépen vagy különböző számítógépeken nagyon eltérő lehet, és nincs olyan egyetlen elrendezés, amely egyöntetűen felsőbbrendű volna.

2.5. Algoritmus. Általános Gauss-elimináció.

```
for ______

    for ______

        for ______

            aij = aij - (aik/akk) akj
        end
    end
end
```

Számos megvalósítási részlet ehhez hasonló módon változó lehet. Például az általunk leírt részleges főelemkiválasztási eljárás oszlopok mentén keres és sorokat cserél, de alternatívaként keresni lehetne sorok mentén és oszlopokat cserélni. Úgy is vettük, hogy L-nek egységnyi átlója van, de intézhetnénk úgy is, hogy U-nak legyen egységnyi átlója. A Gauss-elimináció ezen változatai közül némelyiket olyan fontosnak tartják, hogy nevet is kaptak, mint például a Crout- és Doolittle-módszer.

Bár a Gauss-elimináció sokféle lehetséges változata drámai hatással lehet a teljesítményre, reguláris A mátrix esetén mind lényegében ugyanazt a felbontást produkálják. Ha a sorok főelem-kiválasztási sorrendje ugyanaz, akkor két LU-felbontás, $PA = LU = \hat{L}\hat{U}$, esetén ez a kifejezés azt jelenti, hogy $\hat{L}^{-1}L = \hat{U}U^{-1} = D$ egyszerre alsó és felső háromszögű, és ennélfogva diagonális. Ha mind L-ről, mind $\hat{L}$-ről feltesszük, hogy egységnyi átlójú alsó háromszögmátrix, akkor D valójában az I egységmátrix kell legyen, és így $L = \hat{L}$ és $U = \hat{U}$, vagyis a felbontás egyértelmű. E feltevés nélkül azonban még mindig következtethetünk arra, hogy az LU-felbontás a tényezők diagonális skálázása erejéig egyértelmű. Ezt az egyértelműséget az LDU-felbontás, $PA = LDU$, teszi explicitté, ahol L egységnyi átlójú alsó háromszögmátrix, U egységnyi átlójú felső háromszögmátrix, D pedig diagonális.

A tárkezelés egy másik fontos megvalósítási kérdés. A tárgyalt számos mátrix – az M_k elemi eliminációs mátrixok, azok L_k inverzei és a P_k permutációs mátrixok – csupán formálisan írja le a felbontási folyamatot. A gyakorlati megvalósításban nem képezzük őket explicit módon. A tárhely megtakarítása érdekében az L és U tényezők felülírják a bemeneti A mátrix kezdeti tárterületét: a transzformált U mátrix A felső háromszögét (az átlót is beleértve) foglalja el, a szigorú alsó háromszögű L-t alkotó szorzótényezők pedig A (most már nulla) szigorú alsó háromszögét. L egységnyi átlóját nem kell tárolni.

Az adatmozgatás minimalizálása érdekében a főelemkiválasztás által megkövetelt sorcseréket rendszerint nem végezzük el ténylegesen. Ehelyett a sorok eredeti helyükön maradnak, és egy segéd egészértékű vektor nyilvántartja az új sorsorrendet. Megjegyzendő, hogy egyetlen ilyen vektor elegendő, mivel az összes csere nettó hatása még mindig csak az $1, \ldots, n$ egészek egy permutációja.

2.4.7 A lineáris egyenletrendszerek megoldásának komplexitása

Egy $n \times n$-es mátrix LU-felbontásának Gauss-eliminációval való kiszámítása körülbelül $n^3/3$ lebegőpontos szorzást és hasonló számú összeadást igényel. Az eredményül kapott háromszögű rendszer egyetlen jobb oldali vektorra való megoldása előre- és visszahelyettesítéssel körülbelül n^2 szorzást és hasonló számú összeadást igényel. Így ahogy a mátrix n mérete nő, a lineáris rendszerek megoldásának költségében az LU-felbontás fázisa egyre dominánsabbá válik.

Egy lineáris rendszert a mátrix explicit invertálásával is megoldhatunk, úgy, hogy a megoldást $x = A^{-1}b$ adja. De A^{-1} kiszámítása egyenértékű n darab lineáris rendszer megoldásával: A egy LU-felbontását, majd n darab előre- és visszahelyettesítést igényel, egyet az egységmátrix minden oszlopára. A teljes műveletszám körülbelül n^3 szorzás és hasonló számú összeadás (kihasználva a jobb oldali vektorok nullait az előrehelyettesítésnél). Az explicit invertálás tehát háromszor költségesebb, mint az LU-felbontás.

Az azt követő $x = A^{-1}b$ mátrix-vektor szorzás, amellyel a lineáris rendszert megoldjuk, körülbelül n^2 szorzást és hasonló számú összeadást igényel, ami hasonló az előre- és visszahelyettesítés összköltségéhez. Így, még több jobb oldali vektor esetén is, a mátrixinverzió költségesebb, mint az LU-felbontás, ha lineáris rendszereket szeretnénk megoldani. Ezen felül az explicit invertálás pontatlanabb választ ad. Egyszerű példaként, ha a $3x = 18$ 1×1-es lineáris rendszert osztással oldjuk meg, akkor $x = 18/3 = 6$-ot kapunk, de az explicit invertálás $x = 3^{-1} \times 18 = 0{,}333 \times 18 = 5{,}99$-et adna háromjegyű aritmetikát használva. Ebben a kis példában az invertáláshoz egy plusz aritmetikai műveletre van szükség, és kevésbé pontos eredményt ad. Az invertálás ezen hátrányai csak súlyosbodnak, ahogy a rendszer mérete nő.

Az explicit mátrixinverzek kényelmes jelölésként gyakran előfordulnak különféle képletekben, de ez a gyakorlat nem jelenti azt, hogy egy ilyen képlet megvalósításához explicit inverzre volna szükség.

Csupán megfelelő jobb oldallal – amely maga is lehet mátrix – egy lineáris rendszert kell megoldani. Így például egy $A^{-1}B$ alakú szorzatot A LU-felbontásával, majd B minden oszlopát használva elvégzett előre- és visszahelyettesítésekkel kell kiszámítani. A gyakorlatban rendkívül ritka, hogy tényleg explicit mátrixinverzre volna szükség, így amikor csak egy mátrixinverzet látsz egy képletben, mindig arra gondolj: „oldj meg egy rendszert”, ne arra, hogy „invertálj egy mátrixot”.

Egy másik lineáris rendszer megoldási módszer, amelyet kerülni kell, a Cramer-szabály, amelyben a megoldás minden komponensét determinánsok hányadosaként számítjuk ki. Bár elemi lineáris algebrai kurzusokon gyakran tanítják, ez a módszer nem triviális méretű teli mátrixok esetén csillagászatilag drága. A Cramer-szabály főként elméleti eszközként hasznos.

2.4.8 Gauss–Jordan-elimináció

A Gauss-elimináció mögötti motiváció az, hogy egy általános mátrixot háromszögalakra redukáljunk, mivel az így kapott lineáris rendszer könnyen megoldható. A diagonális lineáris rendszerek azonban még könnyebben megoldhatók, így a diagonális alak még kívánatosabb célnak tűnik. A *Gauss–Jordan-elimináció* a standard Gauss-elimináció olyan változata, amelyben a mátrixot nemcsak háromszög-, hanem diagonális alakra redukáljuk. A mátrixelemek eliminációjára ugyanolyan jellegű sorkombinációkat használunk, mint a standard Gauss-eliminációban, de ezeket mind az átló alatti, mind az átló feletti elemek nullázására alkalmazzuk. Így egy adott a oszlopvektorra alkalmazott eliminációs mátrix alakja

$$\begin{bmatrix} 1 & \cdots & 0 & -m_1 & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & -m_{k-1} & 0 & \cdots & 0 \\ 0 & \cdots & 0 & 1 & 0 & \cdots & 0 \\ 0 & \cdots & 0 & -m_{k+1} & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & -m_n & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ \vdots \\ a_{k-1} \\ a_k \\ a_{k+1} \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ a_k \\ 0 \\ \vdots \\ 0 \end{bmatrix},$$

ahol $m_i = a_i/a_k$, $i = 1, \dots, n$. Ez az eljárás körülbelül $n^3/2$ szorzást és hasonló számú összeadást igényel, ami 50 százalékkal drágább, mint a standard Gauss-elimináció.

A eliminációs fázis során ugyanezeket a sorműveleteket alkalmazzuk a lineáris egyenletrendszer jobb oldali vektorára (vagy vektoraira) is. Ha egyszer a eliminációs fázis befejeződött, és a mátrix diagonális alakba került, akkor a lineáris rendszer megoldásának komponensei egyszerűen úgy számíthatók ki, hogy a transzformált jobb oldal minden elemét a mátrix megfelelő átlóbeli elemével elosztjuk. Ez a számítás összesen csak n osztást igényel, ami jelentősen olcsóbb, mint egy háromszögű rendszer megoldása, de nem elég a költségesebb eliminációs fázis kompenzálására. A Gauss–Jordan-eliminációnak az a numerikus hátránya is megvan, hogy a szorzótényezők nagysága még főelemkiválasztás esetén is meghaladhatja az 1-et.

Nagyobb összköltsége ellenére bizonyos helyzetekben a Gauss–Jordan-elimináció előnyben részesíthető, mert végső megoldási fázisa rendkívül egyszerű. Például néha párhuzamos számítógépekre való megvalósításhoz ajánlják, mivel a felbontási fázis alatt egyenletes a munkaterhelés, és a megoldás minden komponense egyszerre számítható ki – nem pedig egyesével, ahogyan a közönséges visszahelyettesítésnél.

A Gauss–Jordan-eliminációt néha egy mátrix inverzének explicit kiszámítására is használják, ha arra szükség van. Ha a jobb oldali mátrixot az I egységmátrixra inicializáljuk, és az adott A

mátrixot Gauss–Jordan-eliminációval az egységmátrixra redukáljuk, akkor a transzformált jobb oldali mátrix A inverze lesz. Az inverz kiszámításához a Gauss–Jordan-elimináció körülbelül ugyanannyi műveletet igényel, mint a Gauss-eliminációval végzett explicit invertálás, amelyet előre- és visszahelyettesítés követ.

2.18. Példa. Gauss–Jordan-elimináció. A Gauss–Jordan-eliminációt annak használatával illusztráljuk, hogy kiszámítjuk a 2.13. Példa mátrixának inverzét. Az egyszerűség kedvéért a főelemkiválasztást kihagyjuk. Az A mátrixszal kezdünk, jobb oldalon az I egységmátrixszal bővítve, és ismételten eliminációs mátrixokat alkalmazunk A átlón kívüli elemeinek nullázására, amíg el nem érjük a diagonális alakot; majd a megmaradt átlóbeli elemekkel skálázva a bal oldalon az egységmátrixot, így a jobb oldalon az A^{-1} inverz mátrixot állítjuk elő.

$$\begin{bmatrix} 1 & 0 & 0 \\ -4 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 & 1 & 0 & 0 \\ 4 & 4 & 2 & 0 & 1 & 0 \\ 4 & 6 & 4 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 & 1 & 0 & 0 \\ 0 & -4 & -6 & -4 & 1 & 0 \\ 0 & -2 & -4 & -4 & 0 & 1 \end{bmatrix},$$

$$\begin{bmatrix} 1 & 0{,}5 & 0 \\ 0 & 1 & 0 \\ 0 & -0{,}5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 & 1 & 0 & 0 \\ 0 & -4 & -6 & -4 & 1 & 0 \\ 0 & -2 & -4 & -4 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & -1 & -1 & 0{,}5 & 0 \\ 0 & -4 & -6 & -4 & 1 & 0 \\ 0 & 0 & -1 & -2 & -0{,}5 & 1 \end{bmatrix},$$

$$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & -6 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & -1 & -1 & 0{,}5 & 0 \\ 0 & -4 & -6 & -4 & 1 & 0 \\ 0 & 0 & -1 & -2 & -0{,}5 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 1 & 1 & -1 \\ 0 & -4 & 0 & 8 & 4 & -6 \\ 0 & 0 & -1 & -2 & -0{,}5 & 1 \end{bmatrix},$$

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & -0{,}25 & 0 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 1 & 1 & -1 \\ 0 & -4 & 0 & 8 & 4 & -6 \\ 0 & 0 & -1 & -2 & -0{,}5 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 1 & 1 & -1 \\ 0 & 1 & 0 & -2 & -1 & 1{,}5 \\ 0 & 0 & 1 & 2 & 0{,}5 & -1 \end{bmatrix},$$

így

$$A^{-1} = \begin{bmatrix} 1 & 1 & -1 \\ -2 & -1 & 1{,}5 \\ 2 & 0{,}5 & -1 \end{bmatrix}.$$

2.4.9 Módosított feladatok megoldása

Számos gyakorlati helyzetben a lineáris rendszerek nem elszigetelten fordulnak elő, hanem rokon feladatok olyan sorozatának részeként, amelyek valamilyen szisztematikus módon változnak. Előfordulhat például, hogy olyan $Ax = b$ lineáris rendszerek sorozatát kell megoldani, amelyeknek ugyanaz az A mátrixuk, de eltérőek a b jobb oldalaik. Az első rendszer Gauss-eliminációval való megoldása után a már kiszámított L és U tényezőket fel lehet használni a további rendszereknek előre- és visszahelyettesítéssel való megoldására. A felbontási fázist a későbbi lineáris rendszerek megoldása során nem kell megismételni, hacsak a mátrix nem változik. Ez az eljárás jelentős munkamegtakarítást jelent, mivel a további háromszögű megoldások költsége csupán $\mathcal{O}(n^2)$, ellentétben egy felbontás $\mathcal{O}(n^3)$ költségével.

Sőt: bizonyos fontos különleges esetekben még akkor is elkerülhető egy új felbontás, ha a mátrix változik. Ilyen, gyakran előforduló eset egy olyan $n \times n$-es mátrix hozzáadása vagy kivonása,

amely két nemnulla n-dimenziós vektor, u és v, uv^T külső szorzata. Ezt *egyrangú módosításnak* nevezzük, mert az uv^T külső szorzatmátrix rangja egy (azaz csak egy lineárisan független sora vagy oszlopa van), és bármely egyrangú mátrix kifejezhető két vektor ilyen külső szorzataként (lásd a 2.25. Feladatot). Például ha az A mátrix egyetlen eleme változik meg – például a (j, k) elem a_{jk}-ról $\tilde{a}_{jk}$-ra –, akkor az új mátrix $A - \alpha e_j e_k^T$, ahol e_j és e_k az egységmátrix megfelelő oszlopai, és $\alpha = a_{jk} - \tilde{a}_{jk}$.

A Sherman–Morrison-formula,

$$(A - uv^T)^{-1} = A^{-1} + A^{-1}u(1 - v^T A^{-1} u)^{-1} v^T A^{-1},$$

ahol u és v n-dimenziós vektorok, megadja egy olyan mátrix inverzét, amely egy olyan mátrix egyrangú módosításából származik, amelynek inverze már ismert; ez közvetlen szorzással könnyen igazolható (lásd a 2.27. Feladatot). Ennek a képletnek a kiértékelése csak $\mathcal{O}(n^2)$ munkát (mátrix-vektor szorzásokat) igényel, szemben a módosított mátrix nulláról való invertálásához szükséges $\mathcal{O}(n^3)$ munkával.

Az $(A - uv^T)x = b$ új mátrixú lineáris rendszerre a Sherman–Morrison-formula az

$$x = (A - uv^T)^{-1} b = A^{-1}b + A^{-1}u(1 - v^T A^{-1} u)^{-1} v^T A^{-1} b$$

megoldást adja, de kerüljük az explicit inverzeket. Ha van LU-felbontásunk az eredeti A mátrixra, akkor a módosított rendszer megoldása a 2.6. Algoritmussal számítható, amely háromszögű rendszerek megoldását és vektorok belső szorzatának kiszámítását tartalmazza, így nem igényel explicit inverzet, és csak $\mathcal{O}(n^2)$ munkát igényel. Megjegyzendő, hogy az első lépés b-től független, és ezért nem kell megismételni, ha több b jobb oldali vektor van.

2.6. Algoritmus. Megoldás egyrangú frissítése.

```
Oldjuk meg Az = u-t z-re, így z = A^{-1} u
Oldjuk meg Ay = b-t y-ra, így y = A^{-1} b
x = y + ((v^T y) / (1 - v^T z)) z
```

Hasonló technikákkal az inverz vagy a megoldás helyett a felbontást is frissíthetjük. Ezeknek a frissítési képleteknek a használatakor azonban óvatosnak kell lennünk, mert a mátrix változása során az egymást követő frissítésekben általánosságban nincs garancia a numerikus stabilitásra. A Woodbury-formula,

$$(A - UV^T)^{-1} = A^{-1} + A^{-1}U(I - V^T A^{-1} U)^{-1} V^T A^{-1},$$

ahol U és V $n \times k$-as mátrixok, általánosítja a Sherman–Morrison-formulát a mátrix egy k-rangú módosítására (lásd a 2.28. Feladatot).

2.19. Példa. Megoldás egyrangú frissítése. Az egyrangú frissítést a

$$\begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 4 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \\ 10 \end{bmatrix}$$

lineáris rendszer megoldásán illusztráljuk, amely a 2.13. Példa rendszerének egyrangú módosítása, mivel csak az A mátrix $(3, 2)$ eleme változott 6-ról 4-re. A frissítővektorok egyik választási lehetősége

$$u = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \quad \text{és} \quad v = \begin{bmatrix} 0 \\ 2 \\ 0 \end{bmatrix},$$

így a módosított rendszer mátrixa $A - uv^T =$

$$\begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} - \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \begin{bmatrix} 0 & 2 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 6 & 4 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 2 \\ 4 & 4 & 2 \\ 4 & 4 & 4 \end{bmatrix},$$

a b jobb oldali vektor pedig nem változott.

A 2.13. Példában korábban kiszámított LU-felbontást felhasználva megoldhatjuk $Az = u$-t, így $z = \begin{bmatrix} -1 & 1{,}5 & -1 \end{bmatrix}^T$, és $Ay = b$-t már megoldottuk, így $y = \begin{bmatrix} -1 & 3 & -1 \end{bmatrix}^T$. Az utolsó lépés ezek után a frissített megoldás kiszámítása:

$$x = y + \frac{v^T y}{1 - v^T z} z = \begin{bmatrix} -1 \\ 3 \\ -1 \end{bmatrix} + \frac{6}{1-3} \begin{bmatrix} -1 \\ 1{,}5 \\ -1 \end{bmatrix} = \begin{bmatrix} 2 \\ -1{,}5 \\ 2 \end{bmatrix}.$$

Így a módosított rendszer megoldását anélkül számítottuk ki, hogy a módosított mátrixot újra felbontottuk volna.

2.4.10 A pontosság javítása

Bár egy lineáris rendszer megoldásában várható pontosság látszólag kőbe vésett, bizonyos esetekben a pontosság javítható a rendszer átskálázásával vagy a kezdetben kiszámított megoldás iteratív javításával. Ezek az eszközök nem mindig vihetők véghez, de kipróbálásuk megérheti, különösen erősen rosszul kondicionált rendszerek esetén.

A 2.10. Példából emlékezhetünk rá, hogy egy lineáris rendszer diagonális skálázása vagy változatlanul hagyja a megoldást (sorkénti skálázás), vagy úgy változtatja meg, hogy a megoldás könnyen visszanyerhető (oszloponkénti skálázás). A gyakorlatban azonban a skálázás befolyásolja a rendszer kondicionáltságát és a Gauss-eliminációban a főelemek kiválasztását, amelyek mindegyike viszont a kiszámított megoldás pontosságát befolyásolja. Így egy lineáris rendszer sorkénti és oszloponkénti skálázása lehetőséget adhat a numerikus stabilitás és pontosság javítására (vagy rontására).

A pontosság rendszerint javul, ha a mátrix minden eleme körülbelül azonos nagyságrendű – vagy ami még jobb, ha a mátrixelemekben lévő bizonytalanságok is körülbelül azonos méretűek. Néha puszta ránézésre is nyilvánvaló, hogyan skálázzuk a mátrixot úgy, hogy ilyen egyensúly álljon elő: az egyes változókhoz tartozó mértékegységek megválasztásával és az egyes egyenleteknek a viszonylagos fontosságuk és bizonytalanságuk szerinti súlyozásával. Olyan általános, automatikus technikát azonban még soha nem fejlesztettek ki, amely hatékony és megbízható módon optimális skálázást eredményezne. Ráadásul maga a skálázási folyamat is bevezethet kerekítési hibákat, hacsak nem vigyázunk (például ha csak az aritmetikai alap hatványait használjuk skálázási tényezőként).

2.20. Példa. Rossz skálázás. Egyszerű példaként az

$$\begin{bmatrix} 1 & 0 \\ 0 & \epsilon \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ \epsilon \end{bmatrix}$$

lineáris rendszer kondíciószáma $1/\epsilon$, és ezért nagyon rosszul kondicionált, ha ϵ nagyon kicsi. Ez a rossz kondicionáltság azt jelenti, hogy a bemeneti adatok kis perturbációi viszonylag nagy változásokat okozhatnak a megoldásban. Például ha a jobb oldalt a $\begin{bmatrix} 0 & -\epsilon \end{bmatrix}^T$ vektorral perturbáljuk, a megoldás $\begin{bmatrix} 1 & 1 \end{bmatrix}^T$-ról $\begin{bmatrix} 1 & 0 \end{bmatrix}^T$-ra változik. Ha viszont a második sort előbb $1/\epsilon$-nal szorozzuk, akkor a rendszer tökéletesen jól kondicionálttá válik, és ugyanaz a perturbáció most a megoldásban ezzel arányos kis változást eredményez. Így a látszólagos rossz kondicionáltság pusztán a rossz skálázásnak volt köszönhető. Sajnos az, hogy általános mátrixok esetén hogyan korrigáljuk a rossz skálázást, sokkal kevésbé kézenfekvő.

Az *iteratív finomítás* egy másik eszköz, amellyel egy kiszámított megoldás pontossága esetleg javítható. Tegyük fel, hogy az $Ax = b$ lineáris rendszerre kiszámítottunk egy közelítő x_0 megoldást – például valamilyen LU-felbontási alakkal –, és kiszámítjuk a

$$r_0 = b - Ax_0$$

reziduumot. Természetesen azt szeretnénk, ha a reziduum megfelelően kicsi volna, ha viszont nem az, akkor a korábban kiszámított LU-tényezőkkel megoldhatjuk az

$$As_0 = r_0$$

lineáris rendszert s_0-ra, és az

$$x_1 = x_0 + s_0$$

értéket vesszük új, „jobb” közelítő megoldásnak, mivel

$$Ax_1 = A(x_0 + s_0) = Ax_0 + As_0 = (b - r_0) + r_0 = b.$$

Ez az eljárás ismételhető a megoldás egymás utáni finomítására, konvergenciáig, esetleg olyan megoldást előállítva, amelynek reziduuma olyan kicsi, amennyire az alkalmazott aritmetikai pontosságon csak lehet.

Sajnos az iteratív finomítás dupla tárhelyet igényel, mivel mind az eredeti mátrixra, mind annak LU-felbontására szükség van (rendre a reziduum kiszámításához és a későbbi rendszerek megoldásához). Ráadásul ahhoz, hogy az iteratív finomítás maximális haszonnal járjon, a reziduumot rendszerint a kezdeti megoldás kiszámításához használt pontosságnál nagyobb pontossággal kell kiszámítani (emlékezzünk az 1.17. Példára).

Ezen okok miatt az iteratív finomítás gyakran nem praktikus rutinszerű használatra, bizonyos körülmények között azonban mégis hasznos lehet. Az iteratív finomítással például visszanyerhető a teljes pontosság a rosszul skálázott rendszerek esetén, és olykor stabilizálhatók vele az egyébként potenciálisan instabil megoldási módszerek. Ironikus módon, ha a kezdeti megoldás viszonylag rossz, akkor a reziduum elegendően nagy lehet ahhoz, hogy extra pontosság nélkül is kielégítő pontossággal legyen kiszámítható. Az iteratív finomításra a 11.7. Példában térünk vissza.

2.5 Lineáris egyenletrendszerek speciális típusai

Eddig azt feltételeztük, hogy a lineáris rendszer mátrixa általános és *sűrű*, azaz a mátrix bejegyzéseinek lényegében mindegyike nemnulla. Ha a mátrix rendelkezik valamilyen speciális tulajdonsággal, akkor a lineáris rendszer megoldásakor gyakran műveletet és tárhelyet lehet megtakarítani. A kihasználható speciális tulajdonságokra néhány példa a következő:

- Szimmetrikus: $A = A^T$, azaz $a_{ij} = a_{ji}$ minden i, j esetén.
- Pozitív definit: $x^T Ax > 0$ minden $x \neq \mathbf{0}$ vektorra.
- Sávos: $a_{ij} = 0$ minden $|i - j| > \beta$ esetén, ahol β az A mátrix sávszélessége. Fontos speciális eset a tridiagonális mátrix, amelyre $\beta = 1$.
- Ritka: az A bejegyzéseinek többsége nulla.

A szimmetrikus és sávos rendszerek kezelésének technikái a sűrű rendszerekre alkalmazott Gauss-elimináció viszonylag egyszerű változatai. Az általánosabb nemnulla-mintázatú ritka lineáris rendszerek ezzel szemben olyan kifinomultabb algoritmusokat és adatszerkezeteket igényelnek, amelyek elkerülik a mátrixban lévő nullák tárolását és a velük végzett műveleteket (lásd a 11.4.1. szakaszt).

A valós mátrixokra az imént definiált tulajdonságoknak komplex mátrixok esetén is megvannak a megfelelőik, de a komplex esetben a szokásos mátrixtranszponált helyébe a konjugált transzponált lép, amelyet H felső indexszel jelölünk. Ha $z = \alpha + i\beta$ komplex szám, ahol α és β valós számok és $i = \sqrt{-1}$, akkor a komplex konjugáltját a $\bar{z} = \alpha - i\beta$ definíció adja (lásd az 1.3.11. szakaszt). Egy A mátrix konjugált transzponáltját ezek után az $\{A^H\}_{ij} = \bar{a}_{ji}$ képlet adja meg. Természetesen egy valós A mátrixra $A^H = A^T$. Egy komplex mátrix *hermitikus*, ha $A = A^H$, és pozitív definit, ha $x^H Ax > 0$ minden $x \neq 0$ komplex vektorra.

2.5.1 Szimmetrikus pozitív definit rendszerek

Ha az A mátrix szimmetrikus és pozitív definit, akkor az LU-felbontás úgy is elrendezhető, hogy $U = L^T$ legyen, azaz $A = LL^T$, ahol L alsó háromszögmátrix pozitív diagonális bejegyzésekkel (de általában nem egység-főátlóval). Ezt nevezik az A Cholesky-felbontásának, és egy algoritmus a kiszámítására abból kapható, ha az A és a LL^T megfelelő bejegyzéseit egyenlővé tesszük, majd az L bejegyzéseit a helyes sorrendben állítjuk elő. Például a 2×2-es esetben

$$\begin{bmatrix} a_{11} & a_{21} \\ a_{21} & a_{22} \end{bmatrix} = \begin{bmatrix} \ell_{11} & 0 \\ \ell_{21} & \ell_{22} \end{bmatrix} \begin{bmatrix} \ell_{11} & \ell_{21} \\ 0 & \ell_{22} \end{bmatrix},$$

amiből adódik, hogy

$$\ell_{11} = \sqrt{a_{11}}, \quad \ell_{21} = a_{21}/\ell_{11}, \quad \ell_{22} = \sqrt{a_{22} - \ell_{21}^2}.$$

Az ezáltal nyert általános eljárás egyik lehetséges megszervezése a 2.7. algoritmus, amelyben a Cholesky-faktor L felülírja az eredeti A mátrixot.

A Cholesky-felbontási algoritmusnak számos olyan tulajdonsága van, amely nagyon vonzóvá és népszerűvé teszi szimmetrikus pozitív definit mátrixok esetén:

- A szükséges n négyzetgyökvonás mindegyike pozitív számra történik, így az algoritmus jól definiált.

- Numerikus stabilitás céljából nincs szükség főelemkiválasztásra.

2.7. Algoritmus. Cholesky-felbontás.

```
for k = 1 to n                          { ciklus az oszlopokon }
    akk = sqrt(akk)
    for i = k + 1 to n                  { az aktuális oszlop skálázása }
        aik = aik / akk
    end
    for j = k + 1 to n                  { reziduum részmátrix frissítése }
        for i = j to n
            aij = aij - aik · ajk
        end
    end
end
```

- Csak az A alsó háromszöge kerül elérésre, ezért a szigorú felső háromszög-részét nem kell tárolni.
- Csak körülbelül $n^3/6$ szorzásra és hozzávetőleg ugyanennyi összeadásra van szükség.

Így a Cholesky-felbontás csak körülbelül feleannyi műveletet és feleannyi tárhelyet igényel, mint egy általános mátrix Gauss-eliminációval való LU-felbontása. Sajnos ahhoz, hogy a tárhelynek ezt a megtakarítását ki is használjuk, rendszerint szükség van arra, hogy a szimmetrikus mátrix egyik háromszögét egy egydimenziós tömbbe csomagoljuk, ami kényelmetlenebb, mint a mátrixok szokásos kétdimenziós tárolása. Ezért a lineáris algebrai szoftvercsomagok szimmetrikus mátrixokra általában mind a csomagolt tárolású, mind a szabványos kétdimenziós tömbtárolású változatot felkínálják, hogy a felhasználó a kényelem és a tárhelytakarékosság között választhasson.

Bizonyos körülmények között előnyös lehet a Cholesky-felbontást $A = LDL^T$ alakban felírni, ahol L egység-főátlójú alsó háromszögmátrix, D pedig pozitív diagonális bejegyzésű diagonális mátrix. Egy ilyen felbontás a szabványos Cholesky-algoritmus egy egyszerű változatával számítható ki, és megvan az az előnye, hogy nem igényel négyzetgyökvonást. A LDL^T-felbontásban a D diagonális bejegyzései egyszerűen a LL^T-felbontásban szereplő L diagonális bejegyzéseinek négyzetei.

2.21. Példa. Cholesky-felbontás. Az algoritmus szemléltetésére kiszámítjuk a szimmetrikus pozitív definit

$$A = \begin{bmatrix} 3 & -1 & -1 \\ -1 & 3 & -1 \\ -1 & -1 & 3 \end{bmatrix}$$

mátrix Cholesky-felbontását. Mivel az algoritmus csak a mátrix alsó háromszögét érinti, a mátrix alsó háromszögének egymást követő transzformációit mutatjuk be. Az első oszlopot a diagonális bejegyzésének négyzetgyökével, $\sqrt{3} \approx 1{,}7321$-gyel elosztva

$$\begin{bmatrix} 1{,}7321 & & \\ -0{,}5774 & 3 & \\ -0{,}5774 & -1 & 3 \end{bmatrix}$$

adódik. A második oszlopot úgy módosítjuk, hogy kivonjuk belőle a $(2,1)$ bejegyzésnek, $-0{,}5774$-nek, az első oszlop megfelelő részével vett szorzatát, a harmadik oszlopot pedig úgy, hogy kivonjuk

belőle a $(3,1)$ bejegyzésnek, szintén $-0{,}5774$-nek, az első oszlop megfelelő részével vett szorzatát, ami

$$\begin{bmatrix} 1{,}7321 & & \\ -0{,}5774 & 2{,}6667 & \\ -0{,}5774 & -1{,}3333 & 2{,}6667 \end{bmatrix}$$

eredményre vezet. A második oszlopot ezután elosztjuk a diagonális bejegyzésének négyzetgyökével, $\sqrt{2{,}6667} \approx 1{,}6330$-cal, amivel

$$\begin{bmatrix} 1{,}7321 & & \\ -0{,}5774 & 1{,}6330 & \\ -0{,}5774 & -0{,}8165 & 2{,}6667 \end{bmatrix}$$

adódik. A harmadik oszlopot úgy módosítjuk, hogy kivonjuk belőle a $(3,2)$ bejegyzésnek, $-0{,}8165$-nek, a második oszlop megfelelő részével vett szorzatát, ami

$$\begin{bmatrix} 1{,}7321 & & \\ -0{,}5774 & 1{,}6330 & \\ -0{,}5774 & -0{,}8165 & 2{,}0000 \end{bmatrix}$$

eredményre vezet. A harmadik diagonális bejegyzés négyzetgyökét véve a végeredmény

$$L = \begin{bmatrix} 1{,}7321 & & \\ -0{,}5774 & 1{,}6330 & \\ -0{,}5774 & -0{,}8165 & 1{,}4142 \end{bmatrix}.$$

2.5.2 Szimmetrikus indefinit rendszerek

Ha az A mátrix szimmetrikus, de indefinit (azaz az $x^T Ax$ kifejezés x-től függően pozitív és negatív értékeket is felvehet), akkor a Cholesky-felbontás nem alkalmazható, és a numerikus stabilitáshoz általában valamilyen főelemkiválasztásra van szükség. Nyilvánvaló, hogy ha meg akarjuk őrizni a mátrix szimmetriáját, a főelemkiválasztásnak is szimmetrikusnak kell lennie, azaz PAP^T alakúnak, ahol P egy permutációs mátrix.

Szeretnénk olyan $PAP^T = LDL^T$ alakú felbontást kapni, ahol L egység-főátlójú alsó háromszögmátrix, D pedig diagonális. Sajnos tisztán diagonális D mátrixszal ilyen felbontás nem feltétlenül létezik, és létezése esetén sem számítható ki mindig stabilan pusztán szimmetrikus főelemkiválasztással. A legjobb megoldás, ha D-t vagy tridiagonálisnak, vagy 1×1-es és 2×2-es blokkokból álló **blokkdiagonális** mátrixnak választjuk. (Blokkmátrixnak nevezzük azt a mátrixot, amelynek elemeit kompatibilis méretű részmátrixokra, azaz „blokkokra” osztjuk. Egy blokkdiagonális mátrixban ezen részmátrixok mindegyike zérusmátrix, kivéve a főátló mentén elhelyezkedő blokkokat.)

Hatékony algoritmusokat dolgozott ki Aasen a tridiagonális felbontásra, valamint Bunch és Parlett (Bunch és Kaufman, illetve mások későbbi továbbfejlesztéseivel) a blokkdiagonális felbontásra. Mindkét esetben a főelemkiválasztási eljárás olyan stabil felbontást ad, amely csak körülbelül $n^3/6$ szorzást és hasonló számú összeadást igényel. Mivel a rákövetkező megoldási szakasz műveletigénye

is csupán $\mathcal{O}(n^2)$, a szimmetrikus indefinit rendszerek megoldásának költsége hasonló a pozitív definit rendszerekéhez, és csupán fele a nem szimmetrikus rendszerek Gauss-eliminációval történő megoldásának.

2.5.3 Sávos rendszerek

A Gauss-elimináció sávmátrixok esetén alig különbözik az általános esettől: az egyetlen algoritmikus változtatás a ciklusok határainak módosítása. Természetesen olyan adatszerkezetet érdemes használni, amely elkerüli a sávon kívüli nulla elemek tárolását. Ha a sáv sűrű, gyakori megoldás, hogy a mátrixot egy kétdimenziós tömbben, diagonálisonként tároljuk. Amennyiben a stabilitáshoz főelemkiválasztásra van szükség, az algoritmus bonyolultabbá válik, mert a sávszélesség megnövekedhet (legfeljebb a kétszeresére).

Rögzített, kis sávszélesség esetén azonban a sávos rendszermegoldó rendkívül egyszerűvé válik, különösen, ha nincs szükség főelemkiválasztásra. Tekintsük például a **tridiagonális** A mátrixot:

$$A = \begin{bmatrix} b_1 & c_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & a_{n-1} & b_{n-1} & c_{n-1} \\ 0 & \cdots & 0 & a_n & b_n \end{bmatrix}.$$

Ha nincs szükség főelemkiválasztásra — ami gyakori például diagonálisan domináns vagy pozitív definit rendszereknél —, akkor a Gauss-elimináció a 2.8. algoritmusra redukálódik. Az A mátrix háromszögű faktorai ekkor az alábbi alakúak:

$$L = \begin{bmatrix} 1 & 0 & \cdots & \cdots & 0 \\ m_2 & 1 & \ddots & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & m_{n-1} & 1 & 0 \\ 0 & \cdots & 0 & m_n & 1 \end{bmatrix}, \quad U = \begin{bmatrix} d_1 & c_1 & 0 & \cdots & 0 \\ 0 & d_2 & c_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & d_{n-1} & c_{n-1} \\ 0 & \cdots & \cdots & 0 & d_n \end{bmatrix}.$$

Általánosságban egy β sávszélességű rendszer csak $\mathcal{O}(\beta n)$ tárhelyet és $\mathcal{O}(\beta^2 n)$ műveletet igényel, ami jelentős megtakarítás a sűrű (telt) rendszerekhez képest, ha $\beta \ll n$.

2.8. Algoritmus. Tridiagonális LU-felbontás főelemkiválasztás nélkül

```
d1 = b1
for i = 2 to n
    mi = ai / d_{i-1}                    { szorzó kiszámítása }
    di = bi - mi * c_{i-1}               { transzformáció alkalmazása }
end
```

2.6 Iterációs módszerek lineáris egyenletrendszerekhez

A Gauss-elimináció a **direkt módszerek** közé tartozik, amelyek (pontos aritmetikát feltételezve) véges számú lépésben állítják elő a pontos megoldást. Ezzel szemben az **iterációs módszerek** egy kezdeti becslésből indulnak ki, és azt lépésenként javítják, amíg a megoldás el nem éri a kívánt

pontosságot. Elméletileg a konvergenciához végtelen sok lépésre lehet szükség, de a gyakorlatban az eljárást leállítjuk, ha a reziduum, $\|b - Ax\|$ – vagy más hibamérőszám – megfelelően kicsi lesz.

Egyes feladattípusoknál az iterációs módszereknek jelentős előnyei vannak a direkt módszerekkel szemben. E módszerek részletes tárgyalását a 11. fejezetben végezzük el, ahol a parciális differenciálegyenletek numerikus megoldásakor fellépő nagyméretű, ritka rendszerekkel foglalkozunk.

2.7 Szoftverek lineáris egyenletrendszerekhez

Szinte minden tudományos számítási szoftverkönyvtár tartalmaz különféle típusú lineáris rendszerek megoldására szolgáló rutinokat. A 2.1. táblázat valós, általános, sűrű lineáris rendszerek megoldására, valamint a kondíciószám becslésére szolgáló megfelelő rutinok listáját tartalmazza néhány széles körben elérhető szoftvergyűjteményből. Egyes csomagok a rutinnevekben különböző elő- vagy utótagokat használnak az adattípus jelölésére, tipikusan az `s` az egyszeres pontosságú valós, `d` a dupla pontosságú valós, `c` az egyszeres pontosságú komplex és `z` a dupla pontosságú komplex változatra utal; itt csak az egyszeres pontosságú valós változatokat soroljuk fel. A legtöbb ilyen szubrutinkönyvtárban speciálisabb rutinok is rendelkezésre állnak a lineáris rendszerek bizonyos típusaira, mint a szimmetrikus, pozitív definit, sávos rendszerek vagy ezek kombinációi. Ezek közül a rutinok közül néhányat a 2.2. táblázat sorol fel; más rutinok is rendelkezésre állhatnak, amelyek tárhelytakarékosabbak, vagy egyéb speciális feladatokra készültek.

Az $Ax = b$ lineáris rendszerek megoldására szolgáló hagyományos szoftver olykor egyetlen rutinként van megvalósítva, de felosztható két rutinra is: az egyik a felbontás kiszámítására, a másik a keletkező háromszögű rendszer megoldására. Mindkét esetben a felbontás megismétlésére nincs szükség, ha ugyanazzal a mátrixszal, de más jobb oldalakkal szeretnénk további megoldásokat. A tipikusan megkövetelt bemenet a következőket tartalmazza: egy kétdimenziós tömb az A mátrixszal, egy egydimenziós tömb a b jobb oldali vektorral (vagy egy kétdimenziós tömb több jobb oldali vektorra), a rendszer egész n rendje, az A-t tartalmazó tömb vezető dimenziója (hogy a szubrutin helyesen tudja értelmezni a tömbindexeket), valamint esetenként némi munkaterület és egy zászló az elvégzendő konkrét feladat jelzésére. Visszatéréskor az x megoldás rendszerint felülírja a b tárhelyét, a felbontás pedig az A tárhelyét. További kimenetként szerepelhet egy állapotjelző zászló a hibák vagy figyelmeztetések jelzésére, valamint a mátrix kondíciószámának egy becslése (vagy olykor a kondíciószám reciproka). A kondíciószám becslésének többletköltsége miatt ez a szolgáltatás általában opcionális.

Forrás	Felbontás	Megoldás	Kondícióbecslés
FMM [152]	`decomp`	`solve`	
GSL	`gsl_linalg_LU_decomp`	`gsl_linalg_LU_solve`	
HSL	`ma21`	`ma21`	
IMSL	`lftrg`	`lfsrg`	`lfcrg`
KMN [262]	`sgefs`	`sgefs`	`sgefs`
LAPACK [9]	`sgetrf`	`sgetrs`	`sgecon`
LINPACK [116]	`sgefa`	`sgesl`	`sgeco`
MATLAB	`lu`	`\`	`rcond` / `condest`
NAG	`f07adf`	`f07aef`	`f07agf`
NAPACK [220]	`fact`	`solve`	`con`
NR [377]	`ludcmp`	`lubksb`	
NUMAL [297]	`dec`	`sol`	
SciPy	`linalg.lu_factor`	`linalg.lu_solve`	`numpy.linalg.cond`

Forrás	Felbontás	Megoldás	Kondícióbecslés
SLATEC	`sgefa`	`sgesl`	`sgeco`

2.1. táblázat: Szoftverek általános lineáris rendszerek megoldására.

Lineáris rendszerek megoldása interaktív környezetben, például MATLAB-ban egyszerűbb, mint hagyományos szoftverrel, mert a csomag belsőleg nyilvántartja az olyan részleteket, mint a vektorok és mátrixok méretei, és sok mátrixművelet be van építve a nyelv szintaxisába és szemantikájába. Például az $Ax = b$ lineáris rendszer megoldását MATLAB-ban a „bal oldali osztás" operátor adja, amelyet fordított törtvonal jelöl, tehát `x = A \ b`. A megoldást belsőleg LU-felbontással, majd előre- és visszahelyettesítéssel számítja a rendszer, de a felhasználónak erről nem kell tudnia. Az LU-felbontás kifejezetten is kiszámítható, ha szükséges, a MATLAB `lu` függvényével: `[L, U] = lu(A)`, illetve ha a mátrix szimmetrikus és pozitív definit, akkor a Cholesky-felbontását az `L = chol(A)` adja.

2.7.1 LINPACK és LAPACK

A LINPACK átfogó szoftvercsomag sokféle lineáris egyenletrendszer megoldására, az általános sűrű rendszereken kívül olyanokat is beleértve, amelyeknek különféle speciális tulajdonságaik vannak, például szimmetrikusak vagy sávosak. A lineáris rendszerek megoldása annyira alapvető fontosságú a tudományos számításokban, hogy a LINPACK a számítógépek teljesítményének összehasonlítására szolgáló szabványos benchmarkká vált. A LINPACK kézikönyv [116] hasznos forrás gyakorlati tanácsokhoz a lineáris egyenletrendszerek megoldásához.

Forrás	Szimmetrikus pozitív definit	Szimmetrikus indefinit	Általános sávos
GSL	`gsl_linalg_cholesky_decomp`	`gsl_linalg_mcholesky_decomp`	
HSL	`ma22`	`ma29`	`ma35`
IMSL	`lftds` / `lfsds`	`lftsf` / `lfssf`	`lftrb` / `lfsrb`
LAPACK [9]	`spotrf` / `spotrs`	`ssytrf` / `ssytrs`	`sgbtrf` / `sgbtrs`
LINPACK [116]	`spofa` / `sposl`	`ssifa` / `ssisl`	`sgbfa` / `sgbsl`
NAG	`f07fdf` / `f07fef`	`f07mdf` / `f07mef`	`f07bdf` / `f07bef`
NAPACK [220]	`sfact` / `ssolve`	`ifact` / `isolve`	`bfact` / `bsolve`
NR [377]	`choldc` / `cholsl`		`bandec` / `banbks`
NUMAL [297]	`chldec2` / `chlsol2`	`decsym2` / `solsym2`	`decbnd` / `solbnd`
SciPy	`linalg.cholesky`	`linalg.ldl`	`linalg.solve_banded`
SLATEC	`spofa` / `sposl`	`ssifa` / `ssisl`	`sgbfa` / `sgbsl`

2.2. táblázat: Szoftverek speciális lineáris rendszerek megoldására.

A LAPACK nevű utódcsomag a teljes LINPACK-gyűjteményt frissíti, nagyobb teljesítményt nyújtva a modern számítógép-architektúrákon, egyes párhuzamos számítógépeket is beleértve. A LAPACK újabb algoritmusai sok esetben nagyobb pontosságot, robusztusságot és funkcionalitást is elérnek, mint a LINPACK-beli elődeik. A LAPACK a lineáris algebra összes jelentős számítási feladatához egyaránt tartalmaz egyszerű és szakértői meghajtókat, valamint a különféle felbontásokhoz, a háromszögű rendszerek megoldásához, a normabecsléshez, a skálázáshoz és az iteratív finomításhoz szükséges sokféle számítási és kiegészítő rutint. Mind a LINPACK, mind

a LAPACK elérhető a Netlibről, és számos egyéb könyvtár és csomag lineáris rendszermegoldóit közvetlenül ezekre építik.

2.7.2 Basic Linear Algebra Subprograms (BLAS)

A LINPACK és a LAPACK magas szintű rutinjai az alacsonyabb szintű Basic Linear Algebra Subprograms (BLAS) csomagon alapulnak. A BLAS-t eredetileg arra tervezték, hogy egységbe zárja a vektorokon végzett alapvető műveleteket, hogy azok egy adott számítógép-architektúrára optimalizálhatók legyenek, miközben a magasabb szintű, őket hívó rutinok hordozhatók maradnak. Az újabb számítógép-architektúrák arra ösztönöztek, hogy magasabb szintű BLAS-t fejlesszenek ki, amely a mátrix-vektor és a mátrix-mátrix műveleteket zárja egységbe a hierarchikus memóriának – például a gyorsítótárnak, a vektorregisztereknek és a lapozásos virtuális memóriának – a jobb kihasználása érdekében. A 2.3. táblázat felsorolja az egyes szintek néhány legfontosabb BLAS-rutinját.

A jó teljesítmény kulcsa az adat-újrafelhasználás, azaz az, hogy egy adott adaton minél több aritmetikai műveletet végezzünk, miközben az a memóriahierarchia leggyorsabban elérhető részében van tárolva. A 3. szintű BLAS-nak nagyobb lehetősége van az adat-újrafelhasználásra, mert $\mathcal{O}(n^3)$ műveletet végez $\mathcal{O}(n^2)$ adaton, míg az alacsonyabb szintű BLAS esetén a műveletek száma az adatok számával arányos. A BLAS általános változatai elérhetők a Netlibről, és számos számítógépgyártó kínál egyedi változatokat, amelyek a saját rendszerükön a legjobb teljesítményre vannak optimalizálva.

Szint	TOMS #	Munka	Példák	Funkció
1	539	$\mathcal{O}(n)$	`saxpy`	Skalár · vektor plusz vektor
			`sdot`	Két vektor belső szorzata
			`snrm2`	Vektor euklideszi normája
2	656	$\mathcal{O}(n^2)$	`sgemv`	Mátrix-vektor szorzás
			`strsv`	Háromszögű megoldás
			`sger`	Elsőrendű frissítés
3	679	$\mathcal{O}(n^3)$	`sgemm`	Mátrix-mátrix szorzás
			`strsm`	Többszörös háromszögű megoldás
			`ssyrk`	k-adrendű frissítés

2.3. táblázat: Példák az alapvető lineáris algebrai szubrutinokra (BLAS).

2.8 Történeti jegyzetek és további olvasnivaló

Gauss 1810-ben fogalmazta meg a eliminációs módszerét, de nem egy mátrix felbontásaként, hanem egy kvadratikus alak egyszerűsítéseként írta le. A mátrixokat ugyanis csak 1855-ben vezette be Cayley, és a Gauss-elimináció mátrixfelbontásként való értelmezését csak az 1940-es években ismerte fel Dwyer, von Neumann és mások (lásd [431]). A digitális számítások korai úttörőit – például von Neumannt [487] és Turingot [471] (a mátrix kondíciószámának fogalma Turingtól származik) – súlyosan aggasztotta, hogy a nagy lineáris rendszerek Gauss-eliminációval történő megoldásakor felhalmozódó kerekítési hiba használhatatlanná teszi-e az eredményeket, és kezdetben jelentős pesszimizmus övezte ezt a kérdést. A számítási tapasztalatok hamarosan megmutatták azonban, hogy a módszer a gyakorlatban meglepően stabil és pontos, és a hibaelemzések végül

követték a tapasztalatot, hogy magyarázatot adjanak erre a szerencsére (lásd különösen Wilkinson munkáit [499, 500, 501]).

Mint kiderült, a részleges főelemkiválasztással végzett Gauss-elimináció műveletszáma rosszabb az optimálisnál [444], a legrosszabb esetben instabil [499], és elméleti értelemben nem valósítható meg hatékonyan párhuzamosan [485]. Mégis a gyakorlatban – még párhuzamos számítógépeken is – következetesen eredményes, és a tudományos számítások egyik fő igáslova. A legtöbb numerikus algoritmus Murphy törvényének engedelmeskedik – „ha valami elromolhat, el is romlik" –, ám úgy tűnik, a Gauss-elimináció boldog kivétel. E figyelemre méltó algoritmus egyes „rejtélyeinek" további tárgyalásához lásd [461, 467]-et; „számítási ellenpéldákhoz" lásd [156, 510]-et.

A lineáris algebra hátteréhez az olvasó Strang kiváló tankönyveit [436, 441] veheti kézbe. Haladóbb mátrixelmélethez lásd [241, 242]-t. További példák, feladatok és a számítási lineáris algebra gyakorlati alkalmazásai megtalálhatók [238, 276, 314]-ben. A mátrixszámítások enciklopédikus referenciája [198]; tankönyvi tárgyalások közé tartoznak [40, 96, 104, 185, 220, 257, 426, 430, 466, 493, 496]. A lineáris rendszerek megoldásának egyik nagy hatású korai műve – és az elsők egyike, amely magas színvonalú szoftvert is tartalmaz – a [153]. A mátrixszámítások hasznos, Fortran és MATLAB nyelvű gyakorlati kézikönyve a [82].

A lineáris rendszerek és a lineáris algebra számos egyéb feladatának hibaelemzéséről és perturbációelméletéről szóló átfogó tárgyaláshoz lásd [237, 433]-at. A kondíciószám-becslésről áttekintést ad [235]. A lineáris algebrában a (normaszerű helyett) komponensenkénti perturbációelmélet részletes áttekintését adja [236]. A LINPACK és a LAPACK dokumentációja [116], illetve [9]. A BLAS (Basic Linear Algebra Subprograms) könyvtárról lásd [114, 115, 300]-at. A számítási környezetnek a Gauss-elimináció és más mátrixszámítások teljesítményére gyakorolt hatását vizsgáló egyik legkorábbi cikk [330] volt. Az erről a mára igen terjedelmessé vált témáról egy ízelítőhöz lásd [105, 117, 118, 357]-et.

Áttekintő kérdések

- **2.1.** Igaz vagy hamis: Ha egy A mátrix reguláris, akkor az $Ax = b$ lineáris egyenletrendszer megoldásainak száma a b jobb oldali vektor konkrét választásától függ.
- **2.2.** Igaz vagy hamis: Ha egy mátrix determinánsa nagyon kicsi, akkor a mátrix majdnem szinguláris.
- **2.3.** Igaz vagy hamis: Szimmetrikus A mátrixra mindig $\|A\|_1 = \|A\|_\infty$.
- **2.4.** Igaz vagy hamis: Ha egy háromszögmátrixnak van nullával egyenlő eleme a főátlóban, akkor a mátrix szükségképpen szinguláris.
- **2.5.** Igaz vagy hamis: Ha egy tetszőleges mátrixnak van nullával egyenlő eleme a főátlóban, akkor a mátrix szükségképpen szinguláris.
- **2.6.** Igaz vagy hamis: Egy alulhatározott $Ax = b$ lineáris egyenletrendszernek, ahol A egy $m \times n$-es mátrix $m < n$-nel, mindig van megoldása.
- **2.7.** Igaz vagy hamis: Két felső háromszögmátrix szorzata felső háromszögmátrix.
- **2.8.** Igaz vagy hamis: Két szimmetrikus mátrix szorzata szimmetrikus.
- **2.9.** Igaz vagy hamis: Egy reguláris felső háromszögmátrix inverze felső háromszögmátrix.
- **2.10.** Igaz vagy hamis: Ha egy $n \times n$-es A mátrix sorai lineárisan összefüggők, akkor az oszlopai is lineárisan összefüggők.
- **2.11.** Igaz vagy hamis: Az $Ax = b$ lineáris egyenletrendszernek akkor és csak akkor van megoldása, ha az $m \times n$-es A mátrix és az $m \times (n+1)$-es $[\,A\ b\,]$ kibővített mátrix rangja azonos.

- **2.12.** Igaz vagy hamis: Ha A tetszőleges $n \times n$-es mátrix és P tetszőleges $n \times n$-es permutációs mátrix, akkor $PA = AP$.
- **2.13.** Igaz vagy hamis: Ha sorcserék megengedettek, akkor az LU-felbontás mindig létezik, még szinguláris A mátrixra is.
- **2.14.** Igaz vagy hamis: Ha egy lineáris rendszer jól kondicionált, akkor a Gauss-eliminációban nincs szükség főelemkiválasztásra.
- **2.15.** Igaz vagy hamis: Ha egy mátrix szinguláris, akkor nem lehet LU-felbontása.
- **2.16.** Igaz vagy hamis: Ha egy reguláris szimmetrikus mátrix nem pozitív definit, akkor nem lehet Cholesky-felbontása.
- **2.17.** Igaz vagy hamis: Egy szimmetrikus pozitív definit mátrix mindig jól kondicionált.
- **2.18.** Igaz vagy hamis: A főelemkiválasztás nélküli Gauss-elimináció csak akkor hiúsul meg, ha a mátrix rosszul kondicionált vagy szinguláris.
- **2.19.** Igaz vagy hamis: Ha egy mátrix LU-felbontását már kiszámítottuk egy lineáris rendszer megoldásához, akkor az ugyanazzal a mátrixszal, de eltérő jobb oldali vektorokkal adott további lineáris rendszerek a mátrix újrafelbontása nélkül megoldhatók.
- **2.20.** Igaz vagy hamis: LU-felbontáson és háromszögű megoldáson alapuló explicit mátrixinvertálásban a munka többségét a felbontás adja.
- **2.21.** Igaz vagy hamis: Ha x tetszőleges n-dimenziós vektor, akkor $\|x\|_1 \geq \|x\|_\infty$.
- **2.22.** Igaz vagy hamis: Egy szinguláris mátrix normája nulla.
- **2.23.** Igaz vagy hamis: Ha $\|A\| = 0$, akkor $A = 0$.
- **2.24.** Igaz vagy hamis: $\|A\|_1 = \|A^T\|_\infty$.
- **2.25.** Igaz vagy hamis: Ha A tetszőleges $n \times n$-es reguláris mátrix, akkor $\mathrm{cond}(A) = \mathrm{cond}(A^{-1})$.
- **2.26.** Igaz vagy hamis: Nemszinguláris lineáris egyenletrendszer megoldásakor a részleges főelemkiválasztással végzett Gauss-elimináció általában kis reziduumot ad, még ha a mátrix rosszul kondicionált is.
- **2.27.** Igaz vagy hamis: A részleges főelemkiválasztással végzett Gauss-eliminációban a szorzótényezők abszolút értékben 1-gyel korlátosak, ezért az egymást követő redukált mátrixok elemei abszolút értékben nem növekedhetnek.
- **2.28.** Lehet-e egy $Ax = b$ lineáris egyenletrendszernek pontosan két különböző megoldása?
- **2.29.** Meghatározható-e egy $Ax = b$ lineáris rendszer megoldásainak száma valaha is pusztán az A mátrixból, a b jobb oldali vektor ismerete nélkül?
- **2.30.** Egy $Ax = b$ négyzetes lineáris egyenletrendszer megoldásakor melyik volna a súlyosabb nehézség: ha A sorai lineárisan összefüggők, vagy ha A oszlopai lineárisan összefüggők? Magyarázd meg.
- **2.31.** (a) Mondj ki egy definiáló tulajdonságot egy A szinguláris mátrixra. (b) Tegyük fel, hogy az $Ax = b$ lineáris rendszernek két különböző x és y megoldása van. Az (a)-ban megadott tulajdonsággal bizonyítsd be, hogy A szükségképpen szinguláris.
- **2.32.** Adott egy reguláris $Ax = b$ lineáris egyenletrendszer. Az alábbi műveletek mindegyikének milyen hatása van az x megoldásvektorra? (a) $[\,A\ b\,]$ sorainak permutálása; (b) A oszlopainak permutálása; (c) az egyenlet mindkét oldalának balról való szorzása egy M reguláris mátrixszal.
- **2.33.** Tegyük fel, hogy egy $Ax = b$ lineáris egyenletrendszer mindkét oldalát megszorozzuk egy nem nulla α skalárral. (a) Megváltozik-e ettől a valódi x megoldás? (b) Megváltozik-e ettől egy adott x-re az $r = b - Ax$ reziduumvektor? (c) Milyen következtetés vonható le egy számított megoldás minőségének megítéléséről?
- **2.34.** Tegyük fel, hogy egy $Ax = b$ lineáris egyenletrendszer mindkét oldalát balról megszorozzuk egy reguláris diagonális mátrixszal. (a) Megváltozik-e ettől a valódi x

megoldás? (b) Befolyásolhatja-e ez a rendszer kondicionáltságát? (c) Befolyásolhatja-e ez a Gauss-eliminációban a főelemek választását?

- **2.35.** Adj meg egy elemi eliminációs mátrixot, amely az alábbi vektor utolsó két komponensét nullává teszi:

$$\begin{bmatrix} 3 \\ 2 \\ -1 \\ 4 \end{bmatrix}.$$

- **2.36.** (a) Adj meg egy 4×4-es permutációs mátrixot, amely bármely 4-dimenziós vektor 2. és 4. komponensét felcseréli. (b) Adj meg egy 4×4-es permutációs mátrixot, amely bármely 4-dimenziós vektor komponenseinek sorrendjét megfordítja.
- **2.37.** Szinguláris mátrix és egzakt aritmetika használata esetén egy lineáris rendszer Gauss-eliminációval történő megoldásában hol fog a megoldási folyamat megakadni (a) részleges főelemkiválasztással? (b) főelemkiválasztás nélkül?
- **2.38.** (a) Mi a különbség a Gauss-eliminációban a részleges és a teljes főelemkiválasztás között? (b) Mondj a másikhoz képest egy-egy előnyt mindkét típusú főelemkiválasztásra.
- **2.39.** Tekintsük az alábbi A mátrixot, amelynek LU-felbontását Gauss-eliminációval szeretnénk kiszámítani:

$$A = \begin{bmatrix} 4 & -8 & 1 \\ 6 & 5 & 7 \\ 0 & -10 & -3 \end{bmatrix}.$$

Mi lesz a kezdeti főelem, ha (a) nem használunk főelemkiválasztást? (b) részleges főelemkiválasztást használunk? (c) teljes főelemkiválasztást használunk?

- **2.40.** Adj két okot arra, hogy a Gauss-elimináció numerikusan stabil megvalósításához miért lényeges a főelemkiválasztás.
- **2.41.** Ha A egy rosszul kondicionált mátrix, és az LU-felbontását részleges főelemkiválasztással végzett Gauss-eliminációval számítjuk, azt várnád-e, hogy a rossz kondicionáltság L-ben, U-ban vagy mindkettőben tükröződik? Miért?
- **2.42.** (a) Mi az alábbi mátrix inverze?

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & m_1 & 1 & 0 \\ 0 & m_2 & 0 & 1 \end{bmatrix}$$

(b) Hogyan merülhet fel egy ilyen mátrix a számítási gyakorlatban?

- **2.43.** (a) Felírható-e minden $n \times n$-es reguláris A mátrix $A = LU$ szorzat alakban, ahol L alsó háromszögmátrix és U felső háromszögmátrix? (b) Ha igen, milyen algoritmus valósítja ezt meg? Ha nem, adj ellenpéldát a szemléltetésre.
- **2.44.** Adott egy $n \times n$-es reguláris A mátrix és egy további $n \times n$-es B mátrix. Mi a legjobb módja az $n \times n$-es $A^{-1}B$ mátrix kiszámításának?
- **2.45.** Ha A és B $n \times n$-es mátrixok, A reguláris, és c egy n-dimenziós vektor, hogyan számítanád ki hatékonyan az $A^{-1}Bc$ szorzatot?

- **2.46.** Ha A egy $n \times n$-es mátrix és x egy n-dimenziós vektor, az alábbi számítások közül melyik igényel kevesebb munkát? Magyarázd meg. (a) $y = (x\,x^T)\,A$; (b) $y = x\,(x^T\,A)$.
- **2.47.** Hogyan viszonyul egy $n \times n$-es háromszögű lineáris egyenletrendszer megoldásához szükséges számítási munka egy általános $n \times n$-es rendszer megoldásához szükségesével?
- **2.48.** Tegyük fel, hogy egy reguláris A mátrix $A = LU$ LU-felbontását már kiszámítottad. Hogyan használnád fel az $A^T x = b$ lineáris rendszer megoldásához?
- **2.49.** Ha L egy reguláris alsó háromszögmátrix, P egy permutációs mátrix, és b egy adott vektor, hogyan oldanád meg az alábbi lineáris rendszerek mindegyikét? (a) $LPx = b$; (b) $PLx = b$.
- **2.50.** Az $\mathbb{R}^2$ síkban lehetséges-e olyan $x \neq 0$ vektor, amelyre $\|x\|_1 = \|x\|_\infty$? Ha igen, adj példát.
- **2.51.** Az $\mathbb{R}^2$ síkban lehetséges-e olyan x és y vektor, amelyekre $\|x\|_1 > \|y\|_1$, de $\|x\|_\infty < \|y\|_\infty$? Ha igen, adj példát.
- **2.52.** Általában melyik mátrixnormát könnyebb kiszámítani, $\|A\|_1$-et vagy $\|A\|_2$-t? Miért?
- **2.53.** (a) Egy mátrix determinánsának nagysága jó mutatója-e annak, hogy a mátrix majdnem szinguláris-e? (b) Ha igen, miért? Ha nem, mi a közelszingularitás jobb mutatója?
- **2.54.** (a) Hogyan definiáljuk egy A mátrix kondíciószámát egy adott mátrixnormára? (b) Hogyan használjuk a kondíciószámot az $Ax = b$ lineáris rendszer számított megoldásának pontosságbecslésére?
- **2.55.** Miért nem triviális feladat egy általános mátrix kondíciószámának kiszámítása?
- **2.56.** Adj példát egy 3×3-as A mátrixra – az egységmátrixtól különbözőre –, amelyre $\mathrm{cond}(A) = 1$.
- **2.57.** (a) Mi az alábbi mátrix kondíciószáma az 1-normát használva?

$$\begin{bmatrix} 4 & 0 & 0 \\ 0 & -6 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

(b) Eltér-e a válaszod, ha a ∞-normát használjuk?

- **2.58.** Tegyük fel, hogy az $n \times n$-es A mátrix tökéletesen jól kondicionált, azaz $\mathrm{cond}(A) = 1$. Az alábbi mátrixok közül melyek szükségképpen szintén ezzel a tulajdonsággal rendelkeznek? (a) cA, ahol c tetszőleges nem nulla skalár; (b) DA, ahol D egy reguláris diagonális mátrix; (c) PA, ahol P tetszőleges permutációs mátrix; (d) BA, ahol B tetszőleges reguláris mátrix; (e) A^{-1}, azaz A inverze; (f) A^T, azaz A transzponáltja.
- **2.59.** Legyen $A = \mathrm{diag}(1/2)$ egy $n \times n$-es diagonális mátrix, amelynek minden diagonális eleme $1/2$. (a) Mi $\det(A)$ értéke? (b) Mi $\mathrm{cond}(A)$ értéke? (c) Milyen következtetést lehet levonni ezekből az eredményekből?
- **2.60.** Tegyük fel, hogy az $n \times n$-es A mátrix egzaktul szinguláris, de a lebegőpontos ábrázolása, $fl(A)$, reguláris. Ebben az esetben mit várnál a $\mathrm{cond}(fl(A))$ kondíciószám nagyságrendjének?
- **2.61.** Sorold be az alábbi mátrixok mindegyikét, hogy jól vagy rosszul kondicionált-e:

$$(a) \quad \begin{bmatrix} 10^{10} & 0 \\ 0 & 10^{-10} \end{bmatrix}$$
$$(b) \quad \begin{bmatrix} 10^{10} & 0 \\ 0 & 10^{10} \end{bmatrix}$$
$$(c) \quad \begin{bmatrix} 10^{-10} & 0 \\ 0 & 10^{-10} \end{bmatrix}$$
$$(d) \quad \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

- **2.62.** Az alábbiak közül melyek jó mutatói annak, hogy egy mátrix majdnem szinguláris? (a) Determinánsa kicsi. (b) Normája kicsi. (c) Normája nagy. (d) Kondíciószáma nagy.
- **2.63.** (a) Egy $Ax = b$ lineáris rendszer megoldásakor mit értünk egy $\hat{x}$ közelítő megoldás reziduumán? (b) Kis relatív reziduum mindig azt jelenti-e, hogy a megoldás pontos? Miért? (c) Nagy relatív reziduum mindig azt jelenti-e, hogy a megoldás pontatlan? Miért?
- **2.64.** Egy 10 decimális jegy precíziójú lebegőpontos rendszerben, ha egy olyan lineáris rendszert oldunk meg részleges főelemkiválasztással végzett Gauss-eliminációval, amelynek mátrixa 10^3 kondíciószámú, és amelynek bemeneti adatai teljes gépi precízióval pontosak, körülbelül hány értékes jegyet várnál a megoldásban?
- **2.65.** Tegyük fel, hogy egy $Ax = b$ lineáris egyenletrendszert egy olyan számítógépen oldasz meg, amelynek lebegőpontos számrendszere 12 decimális jegy precíziójú, és hogy a feladat adatai teljes gépi precízióval pontosak. Körülbelül milyen nagy lehet az A mátrix kondíciószáma, mielőtt a számított x megoldás egyetlen értékes jegyet sem tartalmaz?
- **2.66.** Milyen körülmények között jelenti-e egy kis $r = b - Ax$ reziduumvektor, hogy x az $Ax = b$ lineáris rendszer pontos megoldása?
- **2.67.** Legyen A egy tetszőleges négyzetes mátrix, és c egy tetszőleges skalár. Az alábbi állítások közül melyek kell szükségképpen teljesüljenek? (a) $\|cA\| = |c| \cdot \|A\|$. (b) $\mathrm{cond}(cA) = |c| \cdot \mathrm{cond}(A)$.
- **2.68.** (a) Mi a fő különbség a Gauss-elimináció és a Gauss–Jordan-elimináció között? (b) Mondj a másikhoz képest egy-egy előnyt mindkét típusú eliminációra.
- **2.69.** Rangsorold az alábbi módszereket az n-ed rendű általános lineáris egyenletrendszer megoldásához szükséges munka mennyisége szerint: (a) Gauss–Jordan-elimináció; (b) részleges főelemkiválasztással végzett Gauss-elimináció; (c) Cramer-szabály; (d) explicit mátrixinvertálás, majd mátrix-vektor szorzás.
- **2.70.** (a) Mennyi tárhely szükséges egy egyrangú $n \times n$-es mátrix hatékony tárolásához? (b) Hány aritmetikai művelet szükséges egy n-dimenziós vektor és egy egyrangú $n \times n$-es mátrix szorzatának hatékony kiszámításához?
- **2.71.** Egy $Ax = b$ lineáris rendszer megoldásához a közönséges Gauss-elimináció és a Gauss–Jordan-elimináció összehasonlításakor (a) melyiknek költségesebb a felbontása? (b) melyiknek költségesebb a visszahelyettesítése? (c) melyiknek nagyobb az összköltsége?
- **2.72.** A lineáris rendszerek megoldására szolgáló alábbi eliminációs algoritmusok mindegyikére: van-e olyan főelemválasztási stratégia, amely biztosítani tudja, hogy minden szorzótényező abszolút értéke legfeljebb 1? (a) Gauss-elimináció; (b) Gauss–Jordan-elimináció.
- **2.73.** Egy A mátrix mely két tulajdonsága együtt implikálja, hogy A-nak van Cholesky-felbontása?
- **2.74.** Sorolj fel három előnyt, amelyet a Cholesky-felbontás az LU-felbontáshoz képest nyújt.
- **2.75.** Egy $n \times n$-es szimmetrikus pozitív definit mátrix Cholesky-felbontásának kiszámításához

hány négyzetgyökre van szükség?

- **2.76.** Legyen $A = \{a_{ij}\}$ egy $n \times n$-es szimmetrikus pozitív definit mátrix. (a) Mi a Cholesky-tényezőjének $(1,1)$ eleme? (b) Mi a Cholesky-tényezőjének $(n,1)$ eleme?
- **2.77.** Mi az alábbi mátrix Cholesky-felbontása?

$$\begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}$$

- **2.78.** (a) Lehetséges-e általában egy szimmetrikus indefinit lineáris rendszert hasonló költséggel megoldani, mint amennyibe egy szimmetrikus pozitív definit lineáris rendszer Cholesky-felbontással történő megoldása kerül? (b) Ha igen, milyen algoritmus valósítja ezt meg? Ha nem, miért?
- **2.79.** Adj két okot arra, hogy a lineáris rendszerek megoldására szolgáló iteratív finomítás miért gyakran nem valósítható meg a gyakorlatban.
- **2.80.** Tegyük fel, hogy egy $n \times n$-es $Ax = b$ lineáris rendszert LU-felbontással és visszahelyettesítéssel már megoldottál. Mi a további költsége (a nagyságrendi becslés elegendő) egy új rendszer megoldásának (a) ugyanazzal a mátrixszal, de más jobb oldali vektorral? (b) ha a mátrixot egy egyrangú mátrix hozzáadásával módosítjuk? (c) ha a mátrix teljesen megváltozik?

Feladatok

- **2.1.** A 2.2. szakaszban négy definiáló tulajdonságot adtunk meg egy szinguláris mátrixra. Mutasd meg, hogy ez a négy tulajdonság valóban ekvivalens.
- **2.2.** Tegyük fel, hogy egy $n \times n$-es A mátrix minden sorösszege nulla. Mutasd meg, hogy A szükségképpen szinguláris.
- **2.3.** Tegyük fel, hogy A egy szinguláris $n \times n$-es mátrix. Bizonyítsd be, hogy ha az $Ax = b$ lineáris rendszernek van legalább egy x megoldása, akkor végtelen sok megoldása van.
- **2.4.** (a) Mutasd meg, hogy az alábbi mátrix szinguláris.

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 1 & 3 & 2 \end{bmatrix}$$

(b) Ha $b = \begin{bmatrix} 2 & 4 & 6 \end{bmatrix}^T$, hány megoldása van az $Ax = b$ rendszernek?

- **2.5.** Mi az alábbi mátrix inverze?

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & -1 & 0 \\ 1 & -2 & 1 \end{bmatrix}$$

- **2.6.** Legyen A olyan $n \times n$-es mátrix, amelyre $A^2 = O$, azaz a nullmátrix. Mutasd meg, hogy A szükségképpen szinguláris.
- **2.7.** Legyen

$$A = \begin{bmatrix} 1 & 1+\epsilon \\ 1-\epsilon & 1 \end{bmatrix}.$$

(a) Mi A determinánsa? (b) Lebegőpontos aritmetikában ϵ mely értéktartományára lesz a determináns számított értéke nulla? (c) Mi A LU-felbontása? (d) Lebegőpontos aritmetikában ϵ mely értéktartományára lesz U számított értéke szinguláris?

- **2.8.** Legyen A és B tetszőleges két $n \times n$-es mátrix. (a) Bizonyítsd be, hogy $(AB)^T = B^T A^T$. (b) Ha A és B mindkettő reguláris, bizonyítsd be, hogy $(AB)^{-1} = B^{-1}A^{-1}$.
- **2.9.** Ha A tetszőleges reguláris valós mátrix, mutasd meg, hogy $(A^{-1})^T = (A^T)^{-1}$. Ennek következtében az A^{-T} jelölés egyértelműen használható e mátrix jelölésére. Hasonlóan, ha A tetszőleges reguláris komplex mátrix, akkor $(A^{-1})^H = (A^H)^{-1}$, és az A^{-H} jelölés egyértelműen használható e mátrix jelölésére.
- **2.10.** Legyen P egy tetszőleges permutációs mátrix. (a) Bizonyítsd be, hogy $P^{-1} = P^T$. (b) Bizonyítsd be, hogy P kifejezhető páronkénti cserék szorzataként.
- **2.11.** Írj részletes algoritmust egy $Lx = b$ alsó háromszögű lineáris rendszer előrehelyettesítéssel történő megoldására.
- **2.12.** Ellenőrizd, hogy egy n-ed rendű alsó háromszögű rendszer előrehelyettesítéssel történő megoldásának műveletszámában (szorzások vagy összeadások számában) a domináns tag $n^2/2$.
- **2.13.** Hogyan oldanád meg a következő alakú particionált lineáris rendszert?

$$\begin{bmatrix} L_1 & O \\ B & L_2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} b \\ c \end{bmatrix},$$

ahol L_1 és L_2 reguláris alsó háromszögmátrixok, és a megoldás- és jobb oldali vektorokat ennek megfelelően particionáljuk. Mutasd be a konkrét lépéseket a megadott almátrixok és vektorok segítségével.

- **2.14.** Bizonyítsd be az elemi eliminációs mátrixok 2.4.3. szakaszban felsorolt négy tulajdonságát.
- **2.15.** (a) Bizonyítsd be, hogy két alsó háromszögmátrix szorzata alsó háromszögmátrix. (b) Bizonyítsd be, hogy egy reguláris alsó háromszögmátrix inverze alsó háromszögmátrix.
- **2.16.** (a) Mi az alábbi mátrix LU-felbontása?

$$\begin{bmatrix} 1 & a \\ c & b \end{bmatrix}$$

(b) Milyen feltétel mellett szinguláris ez a mátrix?

- **2.17.** Írd fel az alábbi mátrix LU-felbontását (mutasd be mind az L-t, mind az U-t explicit módon):

$$\begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}.$$

- **2.18.** Bizonyítsd be, hogy az

$$\mathbf{A} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

mátrixnak nincs LU-felbontása, azaz nem létezik olyan L alsó háromszögmátrix és U felső háromszögmátrix, amelyekre $A = LU$.

- **2.19.** Legyen A egy $n \times n$-es reguláris mátrix. Tekintsük az alábbi algoritmust: 1. Végigfutva A 1-től n-ig terjedő oszlopain, permutáljuk a sorokat szükség szerint úgy, hogy minden oszlopban a főátlón vagy az alatta lévő elemek közül a főátlóbeli elem legyen az abszolút értékben legnagyobb. Az eredmény PA valamilyen P permutációs mátrixszal. 2. Ezután főelemkiválasztás nélküli Gauss-eliminációval számítsuk ki PA LU-felbontását. (a) Numerikusan stabil-e ez az algoritmus? (b) Ha igen, magyarázd meg miért. Ha nem, adj ellenpéldát a szemléltetésre.
- **2.20.** Bizonyítsd be, hogy ha részleges főelemkiválasztással végzett Gauss-eliminációt alkalmazunk egy oszloponként diagonálisan domináns A mátrixra, akkor sorcserék nem fognak bekövetkezni.
- **2.21.** Ha A, B és C $n \times n$-es mátrixok, B és C reguláris, és b egy n-dimenziós vektor, hogyan implementálnád az

$$x = B^{-1}(2A + I)(C^{-1} + A)b$$

képletet anélkül, hogy bármelyik mátrixinverzet kiszámítanád?

- **2.22.** Ellenőrizd, hogy egy n-ed rendű mátrix Gauss-eliminációval történő LU-felbontásának műveletszámában (szorzások vagy összeadások számában) a domináns tag $n^3/3$.
- **2.23.** Ellenőrizd, hogy egy n-ed rendű mátrix Gauss-eliminációval történő inverzének kiszámításához tartozó műveletszámban (szorzások vagy összeadások számában) a domináns tag n^3.
- **2.24.** Ellenőrizd, hogy egy n-ed rendű mátrixon végrehajtott Gauss–Jordan-elimináció műveletszámában (szorzások vagy összeadások számában) a domináns tag $n^3/2$.
- **2.25.** (a) Ha u és v nem nulla n-dimenziós vektorok, bizonyítsd be, hogy a uv^T $n \times n$-es külső szorzat mátrix rangja 1. (b) Ha A egy olyan $n \times n$-es mátrix, amelyre $\operatorname{rank}(A) = 1$, bizonyítsd be, hogy léteznek olyan nem nulla u és v n-dimenziós vektorok, amelyekre $A = uv^T$.
- **2.26.** Egy $n \times n$-es A mátrixot *elemi*nek nevezünk, ha az egységmátrixtól egy egyrangú mátrixban tér el, azaz $A = I - uv^T$ valamilyen u és v n-dimenziós vektorokkal. (a) Ha A elemi, milyen feltétel biztosítja u-ra és v-re, hogy A reguláris? (b) Ha A elemi és reguláris, bizonyítsd be, hogy A^{-1} is elemi, megmutatva, hogy $A^{-1} = I - \sigma uv^T$ valamilyen σ skalárral. Mi a konkrét σ érték u és v függvényében? (c) Elemi-e egy a 2.4.3. szakaszban definiált elemi eliminációs mátrix? Ha igen, mik u, v és σ ebben az esetben?
- **2.27.** Bizonyítsd be, hogy a 2.4.9. szakaszban megadott Sherman–Morrison-formula,

$$(A - uv^T)^{-1} = A^{-1} + A^{-1}u(1 - v^T A^{-1} u)^{-1} v^T A^{-1},$$

helyes. (*Útmutatás:* Szorozd meg mindkét oldalt $A - uv^T$-tal.)

- **2.28.** Bizonyítsd be, hogy a 2.4.9. szakaszban megadott Woodbury-formula,

$$(A - UV^T)^{-1} = A^{-1} + A^{-1}U(I - V^T A^{-1} U)^{-1} V^T A^{-1},$$

helyes. (*Útmutatás:* Szorozd meg mindkét oldalt $A - UV^T$-tal.)

- **2.29.** $p = 1, 2$ és ∞ esetén bizonyítsd be, hogy a vektor p-normák teljesítik a 2.3.1. szakasz végén megadott három tulajdonságot.

- **2.30.** $p = 1$ és ∞ esetén bizonyítsd be, hogy a mátrix p-normák teljesítik a 2.3.2. szakasz végén megadott öt tulajdonságot.
- **2.31.** Legyen A egy szimmetrikus pozitív definit mátrix. Mutasd meg, hogy az

$$\|x\|_A = (x^T A x)^{1/2}$$

függvény teljesíti a vektornorma 2.3.1. szakasz végén megadott három tulajdonságát. Ezt a vektornormát az A mátrix által *indukáltnak* mondjuk.

- **2.32.** Mutasd meg, hogy egy $m \times n$-es A mátrix alábbi függvényei teljesítik a mátrixnorma 2.3.2. szakasz végén megadott első három tulajdonságát, és ezért mátrixnormák az ott említett általánosabb értelemben. (a)

$$\|A\|_{\max} = \max_{i,j} |a_{ij}|$$

Figyeljük meg, hogy ez egyszerűen A-nak az $\mathbb{R}^{mn}$-beli vektorként tekintett ∞-normája. (b)

$$\|A\|_F = \left(\sum_{i,j} |a_{ij}|^2 \right)^{1/2}$$

Figyeljük meg, hogy ez egyszerűen A-nak az $\mathbb{R}^{mn}$-beli vektorként tekintett 2-normája. Ezt *Frobenius-mátrixnormának* nevezzük.

- **2.33.** Bizonyítsd be vagy adj ellenpéldát: Ha A reguláris mátrix, akkor $\|A^{-1}\| = \|A\|^{-1}$.
- **2.34.** Tegyük fel, hogy A pozitív definit mátrix. (a) Mutasd meg, hogy A szükségképpen reguláris. (b) Mutasd meg, hogy A^{-1} szükségképpen pozitív definit.
- **2.35.** Tegyük fel, hogy az A mátrixnak van $A = BB^T$ alakú felbontása, ahol B reguláris. Mutasd meg, hogy A szükségképpen szimmetrikus és pozitív definit.
- **2.36.** Vezess le egy algoritmust, amely egy $n \times n$-es szimmetrikus pozitív definit A mátrix LL^T Cholesky-felbontásának kiszámításához A és LL^T megfelelő elemeinek egyenlővé tételével kapható.
- **2.37.** Tegyük fel, hogy az

$$B = \begin{bmatrix} \alpha & a^T \\ a & A \end{bmatrix}$$

$(n + 1)$-ed rendű szimmetrikus mátrix pozitív definit. (a) Mutasd meg, hogy az α skalár szükségképpen pozitív, és az $n \times n$-es A mátrix szükségképpen pozitív definit. (b) Mi B Cholesky-felbontása az alkotó almátrixok segítségével?

- **2.38.** Tegyük fel, hogy az

$$B = \begin{bmatrix} A & a \\ a^T & \alpha \end{bmatrix}$$

$(n+1)$-ed rendű szimmetrikus mátrix pozitív definit. (a) Mutasd meg, hogy az α skalár szükségképpen pozitív, és az $n \times n$-es A mátrix szükségképpen pozitív definit. (b) Mi B Cholesky-felbontása az alkotó almátrixok segítségével?

- **2.39.** Ellenőrizd, hogy egy n-ed rendű szimmetrikus pozitív definit mátrix Cholesky-felbontásának műveletszámában (szorzások vagy összeadások számában) a domináns tag $n^3/6$.
- **2.40.** Legyen A egy β sávszélességű sávos mátrix, és tegyük fel, hogy a $PA = LU$ LU-felbontást részleges főelemkiválasztással végzett Gauss-eliminációval számítjuk. Mutasd meg, hogy az U felső háromszögű tényező sávszélessége legfeljebb 2β.
- **2.41.** Legyen A egy reguláris tridiagonális mátrix. (a) Mutasd meg, hogy általában A^{-1} sűrű. (b) Hasonlítsd össze az $Ax = b$ lineáris rendszer Gauss-eliminációval és visszahelyettesítéssel történő megoldásához, valamint a rendszer explicit mátrixinvertálással történő megoldásához szükséges munkát és tárhelyet.

Ez a példa egy további okot szemléltet arra, hogy az explicit mátrixinvertálás miért rendszerint rossz ötlet.

- **2.42.** (a) Készíts algoritmust egy reguláris $n \times n$-es háromszögmátrix inverzének helyben történő kiszámítására, azaz további tömbtárhely nélkül. (b) Lehetséges-e egy általános reguláris $n \times n$-es mátrix inverzét helyben kiszámítani? Ha igen, vázolj egy erre szolgáló algoritmust, ha nem, magyarázd meg miért. E feladat céljaira feltételezheted, hogy főelemkiválasztásra nincs szükség.
- **2.43.** Tegyük fel, hogy egy $Cz = d$ lineáris rendszert kell megoldanod, ahol C egy komplex $n \times n$-es mátrix, d és z pedig komplex n-dimenziós vektorok, de a lineáris egyenletrendszer-megoldód csak valós rendszereket kezel. Legyen $C = A + iB$ és $d = b + ic$, ahol A, B, b és c valósak, és $i = \sqrt{-1}$. Mutasd meg, hogy a $z = x + iy$ megoldást a

$$\begin{bmatrix} A & -B \\ B & A \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} b \\ c \end{bmatrix}$$

$2n \times 2n$-es valós lineáris rendszer adja. Jó módja-e ez a feladat megoldásának? Miért?

Számítógépes feladatok

- **2.1.** (a) Mutasd meg, hogy az

$$\mathbf{A} = \begin{bmatrix} 0{,}1 & 0{,}2 & 0{,}3 \\ 0{,}4 & 0{,}5 & 0{,}6 \\ 0{,}7 & 0{,}8 & 0{,}9 \end{bmatrix}$$

mátrix szinguláris. Írd le az $Ax = b$ rendszer megoldásainak halmazát, ha

$$b = \begin{bmatrix} 0{,}1 \\ 0{,}3 \\ 0{,}5 \end{bmatrix}.$$

(b) Ha részleges főelemkiválasztással végzett Gauss-eliminációval akarnánk megoldani ezt a rendszert egzakt aritmetikával, hol akadna meg a folyamat? (c) Mivel A néhány eleme nem

ábrázolható egzaktul egy bináris lebegőpontos rendszerben, a mátrix a számítógépbe bevitel után már nem egzaktul szinguláris, így a rendszer Gauss-eliminációval történő megoldása nem feltétlenül hiúsul meg. Oldd meg ezt a rendszert számítógépen egy Gauss-eliminációt végző könyvtári rutinnal. Hasonlítsd össze a számított megoldást az (a) részben adott megoldáshalmaz leírásával. Ha a szoftvered tartalmaz kondícióbecslőt, mi a cond(A) becsült értéke? Mennyi értékes jegyet várnál e becslés alapján a megoldásban?

- **2.2.** (a) Egy Gauss-eliminációt végző könyvtári rutinnal oldd meg az $Ax = b$ rendszert, ahol

$$A = \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -1 & 7 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix}.$$

(b) Az A mátrix már kiszámított LU-felbontását felhasználva – a mátrix újrafelbontása nélkül – oldd meg az $Ay = c$ rendszert, ahol

$$c = \begin{bmatrix} 4 \\ 8 \\ -6 \end{bmatrix}.$$

(c) Ha az A mátrix úgy változik, hogy $a_{1,2} = 2$, a Sherman–Morrison-féle frissítési technikával – a mátrix újrafelbontása nélkül – számítsd ki az új x megoldást az eredeti b jobb oldali vektort használva.

- **2.3.** Az alábbi ábra egy síkbeli rácsszerkezetet ábrázol, amely 13 rúdból (a számozott egyenesek) és 10 csomópontból (a számozott körök) áll. A jelzett terhelések, tonnában, a 2., az 5. és a 6. csomópontra hatnak, és meg szeretnénk határozni a rácsszerkezet egyes rúdjaira ható eredő erőt.

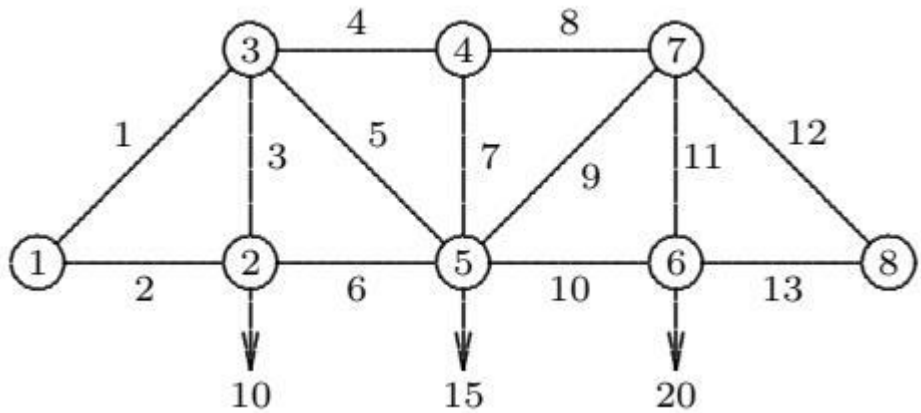

Ahhoz, hogy a rácsszerkezet statikus egyensúlyban legyen, minden csomópontban se vízszintes, se függőleges irányú eredő erő ne lépjen fel. Így a rúderőket úgy határozhatjuk meg, hogy minden csomópontban a balról és a jobbról ható vízszintes erőket, hasonlóképpen a felfelé és a lefelé ható függőleges erőket egyenlővé tesszük. A nyolc csomópontra ez 16 egyenletet adna, ami több, mint a 13 meghatározandó ismeretlen erő. Ahhoz, hogy a rácsszerkezet statikailag határozott legyen, azaz hogy egyetlen megoldás létezzen, feltételezzük, hogy az 1. csomópont vízszintesen és függőlegesen is mereven rögzített, a 8. csomópont pedig függőlegesen rögzített. A rúderőket vízszintes és függőleges

komponensekre felbontva és $\alpha = \sqrt{2}/2$-t bevezetve a rúderőkre, f_i-re, a következő egyenletrendszert kapjuk:

Egy könyvtári rutinnal oldd meg ezt a lineáris egyenletrendszert az f rúderővektorra. Megjegyzendő, hogy e rendszer mátrixa meglehetősen ritka, így érdemes lehet sávos rendszer-megoldóval vagy általánosabb ritka megoldóval is kísérletezned, bár ez a konkrét feladatpéldány túl kicsi ahhoz, hogy ezek egy általános megoldóhoz képest jelentős előnyt jelentsenek.

- **2.4.** Írj rutint egy A mátrix kondíciószámának becslésére. Használhatod akár az 1-normát, akár a ∞-normát (vagy próbáld ki mindkettőt, és hasonlítsd össze az eredményeket). Ki kell majd számítanod $\|A\|$-t, ami könnyű, és meg kell becsülnöd $\|A^{-1}\|$-t, ami nagyobb kihívás. Ahogy a 2.3.3. szakaszban tárgyaltuk, $\|A^{-1}\|$ becslésének egy módja, hogy olyan y vektort választunk, amelyre a $\|z\|/\|y\|$ arány nagy, ahol z az $Az = y$ megoldása. Próbálj ki két különböző megközelítést y választására: (a) Válaszd y-t az $A^T y = c$ rendszer megoldásaként, ahol c egy olyan vektor, amelynek minden komponense ± 1, és az egyes komponensekhez tartozó előjelet az alábbi heurisztikával választjuk. Az $\mathbf{A} = \mathbf{LU}$ felbontást felhasználva az $\mathbf{A}^T\mathbf{y} = \mathbf{c}$ rendszert két lépésben oldjuk meg: egymás után megoldjuk az $\mathbf{U}^T\mathbf{v} = \mathbf{c}$ és az $\mathbf{L}^T\mathbf{y} = \mathbf{v}$ háromszögű rendszereket. Az első háromszögű megoldás minden lépésében c megfelelő komponensét 1-nek vagy -1-nek választjuk, attól függően, hogy melyik választás teszi a kapott v-komponenst abszolút értékben nagyobbá. (Ehhez egy saját háromszögű megoldó rutint kell majd írnod e logika megvalósítására.) Ezután oldd meg a második háromszögű rendszert a szokott módon y-ra. Az ötlet az, hogy az A-ban jelen lévő rossz kondicionáltság U-ban fog tükröződni, viszonylag nagy v-t eredményezve. A viszonylag jól kondicionált egységháromszögű L mátrix aztán megőrzi ezt a viszonyt, viszonylag nagy y-t eredményezve. (b) Válassz néhány – mondjuk öt – különböző y vektort véletlenszerűen, és azt használd, amelyik a legnagyobb $\|z\|/\|y\|$ arányt adja. (Ehhez közönséges háromszögű megoldó rutint használhatsz.)

Az A szükséges LU-felbontásához könyvtári rutint használhatsz. Teszteld mindkét megközelítést az alábbi mátrixokon:

$$\mathbf{A}_1 = \begin{bmatrix} 10 & -7 & 0 \\ -3 & 2 & 6 \\ 5 & -1 & 5 \end{bmatrix},$$

$$\mathbf{A}_2 = \begin{bmatrix} -73 & 78 & 24 \\ 92 & 66 & 25 \\ -80 & 37 & 10 \end{bmatrix}.$$

Hogyan viszonyulnak egymáshoz a két módszerrel kapott eredmények? A becsléseid minőségének ellenőrzéséhez számítsd ki $\mathbf{A}^{-1}$-et explicit módon, hogy meghatározd a valódi normáját (ehhez a számításhoz is felhasználhatod a már kiszámított LU-felbontást). Ha van hozzáférésed olyan lineáris egyenletrendszer-szoftverhez, amely már tartalmaz kondícióbecslőt, hogyan viszonyulnak az eredményeid az övéhez?

- **2.5.** (a) Egy egyszeres pontosságú, Gauss-eliminációt végző rutinnal oldd meg az $Ax = b$ rendszert, ahol

$$A = \begin{bmatrix} 21{,}0 & 67{,}0 & 88{,}0 & 73{,}0 \\ 76{,}0 & 63{,}0 & 7{,}0 & 20{,}0 \\ 0{,}0 & 85{,}0 & 56{,}0 & 54{,}0 \\ 19{,}3 & 43{,}0 & 30{,}2 & 29{,}4 \end{bmatrix},$$

$$b = \begin{bmatrix} 141{,}0 \\ 109{,}0 \\ 218{,}0 \\ 93{,}7 \end{bmatrix}.$$

(b) Számítsd ki az $r = b - Ax$ reziduumot dupla pontosságú aritmetikával, ha elérhető (de a végső eredményt egyszeres pontosságú r vektorba tárolva). Megjegyzendő, hogy a megoldó rutin elpusztíthatja az A-t tartalmazó tömböt, így külön másolatot kell majd megőrizned a reziduum számításához. (Ha a használt számítási környezetben csak egyetlen precízió érhető el, akkor végezd el a teljes feladatot abban a precízióban.) (c) Oldd meg az $Az = r$ lineáris rendszert a „javított" $x + z$ megoldás megkapásához. Megjegyzendő, hogy A-t nem kell újrafelbontani. (d) Ismételd a (b) és (c) lépéseket, amíg további javulást nem tapasztalsz.

- **2.6.** Egy $n \times n$-es H Hilbert-mátrix elemei $h_{ij} = 1/(i + j - 1)$, így az alakja

$$\begin{bmatrix} 1 & 1/2 & 1/3 & \cdots \\ 1/2 & 1/3 & 1/4 & \cdots \\ 1/3 & 1/4 & 1/5 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}.$$

$n = 2, 3, ...$ esetén generáld az n-ed rendű Hilbert-mátrixot, valamint a $b = Hx$ n-dimenziós vektort, ahol x az az n-dimenziós vektor, amelynek minden komponense 1. Egy Gauss-eliminációt (vagy Cholesky-felbontást, mivel a Hilbert-mátrix szimmetrikus és pozitív definit) végző könyvtári rutinnal oldd meg a kapott $Hx = b$ lineáris rendszert, $\hat{x}$ közelítő megoldást kapva. Számítsd ki az $\mathbf{r} = \mathbf{b} - \mathbf{H}\hat{x}$ reziduum és a $\Delta\mathbf{x} = \hat{x} - \mathbf{x}$ hiba ∞-normáját, ahol $\mathbf{x}$ a csupa egyes vektor. Milyen nagyra veheted n-et, mielőtt a hiba 100 százalékossá válik (azaz a megoldásban nincs egyetlen értékes jegy sem)? Emellett egy kondícióbecslővel határozd meg $\mathrm{cond}(H)$-t minden n-re. Próbáld meg jellemezni a kondíciószámot n függvényében. Ahogy n változik, hogyan viszonyul a számított megoldás komponenseiben lévő helyes számjegyek száma a mátrix kondíciószámához?

- **2.7.** (a) Mi történik, ha részleges főelemkiválasztással végzett Gauss-eliminációt alkalmazunk a következő alakú mátrixra?

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ -1 & 1 & 0 & 0 & 1 \\ -1 & -1 & 1 & 0 & 1 \\ -1 & -1 & -1 & 1 & 1 \\ -1 & -1 & -1 & -1 & 1 \end{bmatrix}$$

Nőnek-e a transzformált mátrix elemei? Mi történik, ha ehelyett teljes főelemkiválasztást használunk? (Megjegyzendő, hogy az (a) rész nem igényel számítógépet.)

(b) Egy részleges főelemkiválasztással végzett Gauss-eliminációt alkalmazó könyvtári rutinnal oldj meg ilyen alakú, különböző méretű lineáris rendszereket, olyan jobb oldali vektorokat

választva, amelyek esetén a megoldás ismert. Hogyan viselkedik a hiba, a reziduum és a kondíciószám, ahogy a rendszerek egyre nagyobbak lesznek? Ez a mesterségesen megkonstruált rendszer a 2.4.5. szakaszban idézett, legrosszabb esetben fellépő növekedési tényezőt illusztrálja, és nem jellemző a részleges főelemkiválasztással végzett Gauss-elimináció szokásos viselkedésére.

- **2.8.** Egy $Ax = b$ lineáris rendszer mindkét oldalának egy D reguláris diagonális mátrixszal való szorzása, hogy egy új $DAx = Db$ rendszert kapjunk, egyszerűen átskálázza a rendszer sorait, és elméletben nem változtatja meg a megoldást. Az ilyen skálázás azonban befolyásolja a mátrix kondíciószámát és a Gauss-eliminációban a főelemek választását, így véges precíziójú aritmetikában befolyásolhatja a megoldás pontosságát. Megjegyzendő, hogy a skálázás némi kerekítési hibát vihet a mátrixba, hacsak D elemei nem a használt lebegőpontos aritmetikai rendszer alapjának hatványai (miért?).

Véletlenszerűen választott A mátrixú lineáris rendszer és olyan b jobb oldali vektor használatával, amely mellett a megoldás ismert, kísérletezz különféle D skálázó mátrixokkal, hogy milyen hatással vannak a DA mátrix kondíciószámára és a $DAx = Db$ lineáris rendszer megoldására egy erre szolgáló könyvtári rutin által adott megoldásra. Mindenképpen próbálj ki elég torz skálázásokat is, amelyeknél D diagonális elemeinek nagyságrendje jelentősen különbözik egymástól (a cél egy rosszul megválasztott mértékegységekkel adott rendszer szimulálása). Hasonlítsd össze mind a relatív reziduumokat, mind a különféle skálázások által adott hibát. Találsz-e olyan skálázást, amely nagyon rossz pontosságot ad? Ebben az esetben a reziduum továbbra is kicsi marad-e?

- **2.9.** (a) Főelemkiválasztás nélküli Gauss-eliminációval oldd meg az

$$\begin{bmatrix} \epsilon & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1+\epsilon \\ 2 \end{bmatrix}$$

lineáris rendszert $\epsilon = 10^{-2k}$ esetén, $k = 1, \ldots, 10$. Az egzakt megoldás $x = \begin{bmatrix} 1 & 1 \end{bmatrix}^T$, ϵ értékétől függetlenül. Hogyan viselkedik a számított megoldás pontossága, ahogy ϵ értéke csökken?

(b) Ismételd meg az (a) részt, továbbra is főelemkiválasztás nélküli Gauss-eliminációt használva, de ezúttal a megoldás javítására egy lépés iteratív finomítást is alkalmazz, a reziduumot ugyanolyan precízióval számítva, mint a számítások többi részét. Most hogyan viselkedik a számított megoldás pontossága, ahogy ϵ értéke csökken?

- **2.10.** Tekintsük az

$$\begin{bmatrix} 1 & 1+\epsilon \\ 1-\epsilon & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1+(1+\epsilon)\epsilon \\ 1 \end{bmatrix}$$

lineáris rendszert, ahol ϵ egy rögzítendő kis paraméter. Az egzakt megoldás nyilvánvalóan

$$x = \begin{bmatrix} 1 \\ \epsilon \end{bmatrix}$$

ϵ bármely értékére.

Egy Gauss-eliminación alapuló könyvtári rutinnal oldd meg ezt a rendszert. Kísérletezz ϵ különféle értékeivel, különösen a saját számítógéped $\sqrt{\epsilon_{\text{mach}}}$-ához közeli értékekkel. ϵ minden kipróbált

értékére becsüld meg a mátrix kondíciószámát és a megoldás minden komponensében lévő relatív hibát. Milyen pontosan van meghatározva az egyes komponensek? Hogyan viszonyul az egyes komponensekre kapott pontosság a mátrix kondíciószáma és a 2.3.4. szakaszban megadott hibakorlátok alapján várhatóhoz? Milyen következtetéseket tudsz levonni ebből a kísérletből?

- **2.11.** (a) Írj programokat, amelyek megvalósítják a főelemkiválasztás nélküli, a részleges főelemkiválasztással és a teljes főelemkiválasztással végzett Gauss-eliminációt. (b) Generálj több véletlen mátrixú lineáris rendszert (azaz a mátrix elemeinek előállítására használj véletlenszám-generátort), valamint olyan jobb oldali vektorokat, amelyek mellett a megoldás ismert, és hasonlítsd össze a három implementáció pontosságát, reziduumait és teljesítményét. (c) Tudsz-e alkotni egy (nem véletlen) mátrixot, amelyre a teljes főelemkiválasztás lényegesen pontosabb, mint a részleges főelemkiválasztás?
- **2.12.** Írj rutint tridiagonális lineáris egyenletrendszerek megoldására a 2.5.3. szakaszban megadott algoritmussal, és teszteld néhány mintapéldán. Írd le, hogyan változna a rutinod, ha részleges főelemkiválasztást vennél be. Írd le, hogyan változna a rutinod, ha a rendszer pozitív definit volna, és LU-felbontás helyett a Cholesky-felbontást számítanád ki.
- **2.13.** Egy háromszögmátrix determinánsa a főátlóbeli elemeinek szorzatával egyenlő. Használd ezt a tényt egy olyan rutin kidolgozásához, amely egy tetszőleges $n \times n$-es A mátrix determinánsát számítja ki az LU-felbontása segítségével. Használhatsz egy részleges főelemkiválasztással végzett Gauss-eliminációt megvalósító könyvtári rutint az LU-felbontás megszerzésére, vagy tervezheted saját rutinodat. Hogyan tudod meghatározni a determináns megfelelő előjelét? A túlcsordulás vagy alulcsordulás veszélyének elkerülésére érdemes lehet a determináns tényleges értéke helyett a logaritmusának kiszámítását fontolóra venned.
- **2.14.** Írj programokat, amelyek megvalósítják a $C = AB$ mátrixszorzást – ahol A egy $m \times n$-es és B egy $n \times k$-s mátrix – két különböző módon: (a) Számítsd ki az A sorainak és B oszlopainak mk darab belső szorzatát. (b) C minden oszlopát A oszlopainak lineáris kombinációjaként állítsd elő.

BLAS-terminológiában (lásd a 2.7.2. szakaszt) az első implementáció az `sdot`-ot, a második pedig az `saxpy`-t használja. Hasonlítsd össze e két implementáció teljesítményét a saját számítógépeden. Előfordulhat, hogy elég nagy mátrixokat kell kipróbálnod, mielőtt a teljesítménykülönbségek jelentőssé válnának. Tudj meg annyit a számítógéprendszeredről, amennyit csak tudsz (pl. a gyorsítótár mérete és kezelési stratégiája), és használd fel ezt az információt a megfigyelt eredmények magyarázatára.

- **2.15.** Valósítsd meg a Gauss-eliminációt a hármas egymásba ágyazott ciklus mind a hat különböző sorrendjével, és hasonlítsd össze a teljesítményüket a saját számítógépeden. E feladat céljaira a numerikus stabilitás érdekében végzett főelemkiválasztást figyelmen kívül hagyhatod, de mindenképpen olyan tesztmátrixokat használj, amelyek nem igényelnek főelemkiválasztást. Előfordulhat, hogy elég nagy rendszert kell kipróbálnod, mielőtt a teljesítménykülönbségek jelentőssé válnának. Tudj meg annyit a számítógéprendszeredről, amennyit csak tudsz (pl. a gyorsítótár mérete és kezelési stratégiája), és használd fel ezt az információt a megfigyelt eredmények magyarázatára.
- **2.16.** Háromszögű lineáris rendszerek megoldásához mind az előre-, mind a visszahelyettesítés olyan egymásba ágyazott ciklusokat tartalmaz, amelyek két indexe bármelyik sorrendben futhat. Valósítsd meg mind az előre-, mind a visszahelyettesítést a két indexsorrend mindegyikével (összesen négy algoritmust), és hasonlítsd össze teljesítményüket különböző méretű háromszögű tesztmátrixokon. Előfordulhat, hogy elég nagy rendszert kell kipróbálnod, mielőtt a teljesítménykülönbségek jelentőssé válnának. Az indexsorrendek legjobb választása

ugyanaz-e mindkét algoritmusnál? Tudj meg annyit a számítógéprendszeredről, amennyit csak tudsz (pl. a gyorsítótár mérete és kezelési stratégiája), és használd fel ezt az információt a megfigyelt eredmények magyarázatára.

- **2.17.** Tekintsünk egy vízszintes, egyik végén befogott, a hossza fennmaradó részén szabad tartót. A tartón ható erők egy diszkrét modellje egy $Ax = b$ lineáris egyenletrendszert ad, ahol az $n \times n$-es A mátrix a következő sávos alakú:

$$\begin{bmatrix} 9 & -4 & 1 & 0 & \cdots & \cdots & 0 \\ -4 & 6 & -4 & 1 & \ddots & & \vdots \\ 1 & -4 & 6 & -4 & 1 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & 1 & -4 & 6 & -4 & 1 \\ \vdots & & \ddots & 1 & -4 & 5 & -2 \\ 0 & \cdots & \cdots & 0 & 1 & -2 & 1 \end{bmatrix},$$

a b n-dimenziós vektor a tartóra ható ismert terhelés (a saját súlyával együtt), a x n-dimenziós vektor pedig a tartó meghatározandó, eredő lehajlását jelöli. A tartót egyenletesen terheltnek tekintjük, úgy, hogy a terhelésvektor minden komponensére $b_i = 1/n^4$.

(a) $n = 100$ esetén oldd meg ezt a lineáris rendszert mind egy sűrű lineáris rendszerekhez szolgáló standard könyvtári rutinnal, mind egy sávos (vagy általánosabb ritka) rendszerekhez tervezett könyvtári rutinnal. Hogyan viszonyul egymáshoz a két rutin a megoldás kiszámításához szükséges időben? Mennyire egyeznek meg a kapott válaszok egymással?

(b) Ellenőrizd, hogy az A mátrixnak van $A = RR^T$ UL-felbontása, ahol R a következő alakú felső háromszögmátrix:

[2]	-2	1	0		0]
0	-21 .	-2	1	.	:
:	.		.		0
:		.		-2	
:			.	1	$\begin{bmatrix} -2 \\ 1 \end{bmatrix}$
				0	1

$n = 1000$ esetén oldd meg a lineáris rendszert e felbontással (két háromszögű megoldásra lesz szükség). Emellett oldd meg a rendszert az eredeti alakjában is egy sávos (vagy általános ritka) rendszer-megoldóval, ahogy az (a) részben. Mennyire egyeznek meg a kapott válaszok egymással? Melyik megközelítés tűnik pontosabbnak? Mi A kondíciószáma, és milyen pontosságot sugall, hogy várnunk kellene? Próbáld ki az iteratív finomítást, hogy lássad, a kevésbé pontos módszernél javul-e a pontosság vagy a reziduum.

Lineáris legkisebb négyzetek

3.1 Lineáris legkisebb négyzetes feladatok

Tegyük fel, hogy szeretnénk tudni, mennyi a tipikus havi csapadékmennyiség Seattle-ben. Elegendő lenne ehhez egyetlen hónap mérései? Természetesen nem – egy adott hónap szokatlanul napos

vagy viharos is lehet. Ehelyett inkább több hónapon át – legalább egy éven, vagy talán tíz éven át – végeznénk méréseket, majd ezeket átlagolnánk. Az így kapott átlag ugyan nem lesz pontosan helyes egyetlen konkrét hónapra sem, mégis valamiféle megérzés azt súgja, hogy a tipikus csapadékmennyiségről sokkal pontosabb képet ad, mint amekkorát bármelyik egyedi mérés valaha is adhatna. Ez az elv – azaz hogy sok mérés elvégzésével elsimítjuk a mérési hibákat és más véletlen ingadozásokat – szinte általánosan elterjedt a megfigyeléses és kísérleti tudományokban. A földmérők szándékosan több mérést is végeznek, mint amennyi szigorúan szükséges volna a tájékozódási pontok közötti távolságok meghatározásához. A csillagászok és a távközlési mérnökök ezt az elvet alkalmazzák, amikor zajos adatokból értelmes jeleket nyernek ki. Még az ács mondása is, miszerint „kétszer mérj, egyszer vágj”, e megközelítés bölcsességének kiváló példája.

A csapadékpéldában egyetlen számot kerestünk, amely egy egész számsokaságot reprezentál, vagy valamilyen értelemben közelít. Általánosabban fogalmazva: különféle elméleti és gyakorlati okokból gyakran keresünk egy-egy magasabb dimenziós objektumhoz alacsonyabb dimenziós közelítést. Ennek célja lehet a hibák kisimítása vagy a lényegtelen részletek figyelmen kívül hagyása – például amikor zajos adatokból jelet vagy trendet nyerünk ki –, vagy az, hogy egy nagy adattömeget kezelhetőbb mennyiségre csökkentsünk, vagy hogy egy bonyolult függvényt egyszerű közelítéssel helyettesítsünk. Nem várjuk el, hogy egy ilyen közelítés egzakt legyen – a legtöbb célra nem is szeretnénk, hogy az legyen –, mindazonáltal azt akarjuk, hogy valamennyire emlékeztessen az eredeti adatokra. A lineáris algebra terminológiájával élve azt szeretnénk, hogy egy magasabb dimenziós térből vett vektort egy alacsonyabb dimenziós altérre vetítsünk. Ennek egyik legnépszerűbb és számítási szempontból legkényelmesebb módja a legkisebb négyzetek módszere, amelyet ebben a fejezetben tárgyalunk.

Figyelmünket egyelőre a lineáris feladatokra szűkítjük, a nemlineáris legkisebb négyzeteket a 6.6. szakaszra halasztva. A 2.2. szakaszban láttuk, hogy egy négyzetes lineáris egyenletrendszer pontosan meghatározott: ugyanannyi egyenlettel és ismeretlennel mindig pontosan egy megoldás létezik, feltéve, hogy a mátrix reguláris. Az interpolációnál például a paraméterek és az adatpontok száma közötti egyezést kihasználva bázisfüggvények lineáris kombinációjával illesztjük pontosan az adott adatokat (lásd a 7. fejezetet). A jelen helyzetben ezzel szemben feltételezzük, hogy az adott adatok zajosak vagy lényegtelen részleteket tartalmaznak, ezért semmilyen különleges előnnyel nem jár, ha pontosan illesztjük őket. Sőt, az ilyen ingadozásokat éppen azzal simíthatjuk ki, hogy lemondunk a pontos illeszkedésről, és a szükségesnél több adatpontot vagy mérést használunk, ami egy túlhatározott rendszerhez vezet, amelyben több az egyenlet, mint az ismeretlen. A lineáris egyenletrendszert mátrix-vektor jelöléssel felírva a következőt kapjuk:

$$Ax = b,$$

ahol A egy $m \times n$-es mátrix, amelyre $m > n$, b egy m-dimenziós vektor, x pedig egy n-dimenziós vektor. Általában, mivel az x vektorban mindössze n paraméter szerepel, nem várhatjuk el, hogy az A mátrix n darab oszlopának lineáris kombinációjaként reprodukálni tudjuk az m-dimenziós b vektort. Más szóval egy túlhatározott rendszernek a szokásos értelemben általában nincs megoldása. Ehelyett a bal és a jobb oldal közötti távolságot minimalizáljuk, azaz az $r = b - Ax$ reziduumvektor valamely normáját minimalizáljuk az x függvényeként. Elvileg bármelyik norma használható, de – ahogyan látni fogjuk – erős érvek szólnak az euklideszi norma (2-norma) mellett, ideértve a belső szorzattal és az ortogonalitással való kapcsolatát, a simaságát és szigorú konvexitását, valamint a számítási kényelmét. A 2-norma használata adja a legkisebb négyzetek módszerének nevét: a megoldás az az x vektor, amely a lineáris egyenletrendszer bal és jobb oldala komponenseinek

különbségei négyzetösszegét minimalizálja. A pontos egyenlőség hiányát tükrözendő egy lineáris legkisebb négyzetes feladatot a következő alakban írunk fel:

$$Ax \cong b,$$

ahol a közelítést a 2-norma, illetve a legkisebb négyzetek értelmében értjük.

3.1. Példa. Túlhatározott rendszer. Egy földmérőnek három domb magasságát kell meghatároznia egy referenciaponthoz képest. Először a referenciapontból mérve a földmérő a dombok magasságait rendre $x_1 = 1237$ lábnak, $x_2 = 1941$ lábnak és $x_3 = 2417$ lábnak méri. Ezen kezdeti mérések megerősítésére felmászik az első domb tetejére, és azt méri, hogy a második domb $x_2 - x_1 = 711$ lábbal, a harmadik pedig $x_3 - x_1 = 1177$ lábbal magasabb az elsőnél. Végül a második domb tetejére is felmászik, és azt méri, hogy a harmadik domb $x_3 - x_2 = 475$ lábbal magasabb a másodiknál. Észrevéve a mérések közötti ellentmondásokat, a földmérő a később bemutatandó módszereket használja a

$$Ax = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ -1 & 1 & 0 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 1237 \\ 1941 \\ 2417 \\ 711 \\ 1177 \\ 475 \end{bmatrix} = b$$

túlhatározott lineáris egyenletrendszer legkisebb négyzetes megoldásának meghatározására, amelyből $x = [1236,\ 1943,\ 2416]^T$ adódik. Ezek az értékek, amelyek enyhén eltérnek a három kezdeti magasságméréstől, olyan kompromisszumot képviselnek, amely (a legkisebb négyzetek értelmében) a lehető legjobban összehangolja a mérési hibákból eredő ellentmondásokat.

A legkisebb négyzetek módszerének korai fejlesztése nagyrészt Gaussnak köszönhető, aki csillagászati feladatok – különösen égitestek, például kisbolygók és üstökösök pályájának meghatározása – megoldására használta. Egy ilyen test elliptikus pályáját öt paraméter határozza meg (lásd a 3.5. számítógépes feladatot), így elvileg öt pozíciómegfigyelés elegendő lenne a teljes pálya meghatározásához. A mérési hibák miatt azonban egy csupán öt megfigyelésre alapozott pálya rendkívül megbízhatatlan volna. Ehelyett jóval több megfigyelést végeznek, és a legkisebb négyzetek módszerét alkalmazzák arra, hogy elsimítsák a hibákat, és pontosabb értékeket kapjanak a pályaparaméterekre. A legkisebb négyzetes közelítés a megfigyelések tucatjait vagy százait – amelyek egy megfelelően nagy dimenziós térben helyezkednek el – az elliptikus pályamodell ötdimenziós paramétertérévé redukálja.

3.2. Példa. Adatillesztés. A legkisebb négyzetek módszerének egyik leggyakoribb alkalmazási területe az *adatillesztés*, más néven a *görbeillesztés*, különösen akkor, amikor az adatokat valamilyen véletlen hiba terheli, mint a legtöbb empirikus laboratóriumi mérés vagy egyéb természeti megfigyelés esetében. Adott (t_i, y_i), $i = 1, \dots, m$ adatpontok esetén azt az n-dimenziós x paramétervektort keressük, amely az $f(t, x)$ *modellfüggvénnyel* – ahol $f : \mathbb{R}^{n+1} \to \mathbb{R}$ – a „legjobb illeszkedést” adja az adatokra, ahol a legjobb illeszkedést a legkisebb négyzetek értelmében értjük:

$$\min_x \sum_{i=1}^{m} (y_i - f(t_i, x))^2.$$

Egy adatillesztési feladat *lineáris*, ha az f függvény lineáris az x paramétervektor komponenseiben, azaz f a csak t-től függő ϕ_j függvények

$$f(t,x) = x_1\phi_1(t) + x_2\phi_2(t) + \cdots + x_n\phi_n(t)$$

lineáris kombinációja. Például a polinomillesztés, amelyre

$$f(t,x) = x_1 + x_2 t + x_3 t^2 + \cdots + x_n t^{n-1},$$

lineáris adatillesztési feladat, mert a polinom az x_j együtthatóiban lineáris, bár a t független változóban nemlineáris. Egy *nemlineáris* adatillesztési feladatra példa – amellyel a 6.6. szakaszban foglalkozunk – az exponenciálisok

$$f(t,x) = x_1 e^{x_2 t} + \cdots + x_{n-1} e^{x_n t}$$

alakú összege.

Ha definiáljuk az $a_{ij} = \phi_j(t_i)$ elemekkel rendelkező $m \times n$-es A mátrixot, valamint a $b_i = y_i$ komponensekkel rendelkező m-dimenziós b vektort, akkor egy lineáris legkisebb négyzetes adatillesztési feladat a

$$Ax \cong b$$

alakot ölti. Például ha egy háromparaméteres másodfokú polinomot illesztünk öt $(t_1, y_1), \ldots, (t_5, y_5)$ adatpontra, akkor az A mátrix 5×3-as, és a feladat alakja:

$$Ax = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ 1 & t_3 & t_3^2 \\ 1 & t_4 & t_4^2 \\ 1 & t_5 & t_5^2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{bmatrix} = b.$$

Egy ilyen alakú mátrixot, amelynek oszlopai (vagy sorai) egy független változó egymás utáni hatványai, *Vandermonde-mátrixnak* nevezünk.

Tegyük fel, hogy az alábbi mért adatokkal rendelkezünk.

Ez a 21 adatpont, amelyet a 3.1. ábrán pontokként ábrázoltunk, láthatóan tartalmaz bizonyos véletlen zajt, de úgy tűnik, nagyjából egy parabolaív mentén helyezkednek el (vagy talán valamilyen mögöttes fizikai folyamat, például egy lövedék röppályája parabolikus modellt sugall), ezért úgy döntünk, hogy egy másodfokú polinommal illesztjük őket. Nyilvánvaló, hogy egy másodfokú polinom nem illeszkedik pontosan az adatokra, de csupán az adatok általános trendjét kívánjuk meghatározni, és amúgy sem szeretnénk utánozni a véletlen mérési zajt, így a legkisebb négyzetes közelítés megfelelőnek tűnik. Az így kapott túlhatározott 21×3-as lineáris egyenletrendszer alakja:

$$Ax = \begin{bmatrix} 1 & 0{,}0 & 0{,}0 \\ 1 & 0{,}5 & 0{,}25 \\ 1 & 1{,}0 & 1{,}0 \\ \vdots & \vdots & \vdots \\ 1 & 10{,}0 & 100{,}0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 2{,}9 \\ 2{,}7 \\ 4{,}8 \\ \vdots \\ 4{,}1 \end{bmatrix} = b.$$

E rendszer megoldása – amelynek kiszámítását később ismertetjük – $x \approx \begin{bmatrix} 2{,}18 & 2{,}67 & -0{,}238 \end{bmatrix}^T$, ami azt jelenti, hogy a közelítő polinom, amelyet a 3.1. ábrán sima görbeként ábrázoltunk, a következő:

$$p(t) = 2{,}18 + 2{,}67t - 0{,}238t^2.$$

Ez a konkrét polinom olyan értelemben a legjobban illeszkedő polinom az adott adatokra az összes másodfokú polinom közül, hogy az adatpontok és a görbe közötti függőleges távolságok négyzetösszegét minimalizálja az összes lehetséges másodfokú polinom körében.

A legkisebb négyzetek módszere fontos eszköz a statisztikában, ahol regresszióanalízis néven is ismerik. Mi csak a legkisebb négyzetes feladatok megoldására szolgáló numerikus algoritmusokkal foglalkozunk. A legkisebb négyzetes feladatok felírásával és az eredmények helyes értelmezésével kapcsolatos sok fontos statisztikai szempontért lásd a regresszióanalízis vagy a többváltozós statisztika bármelyik tankönyvét.

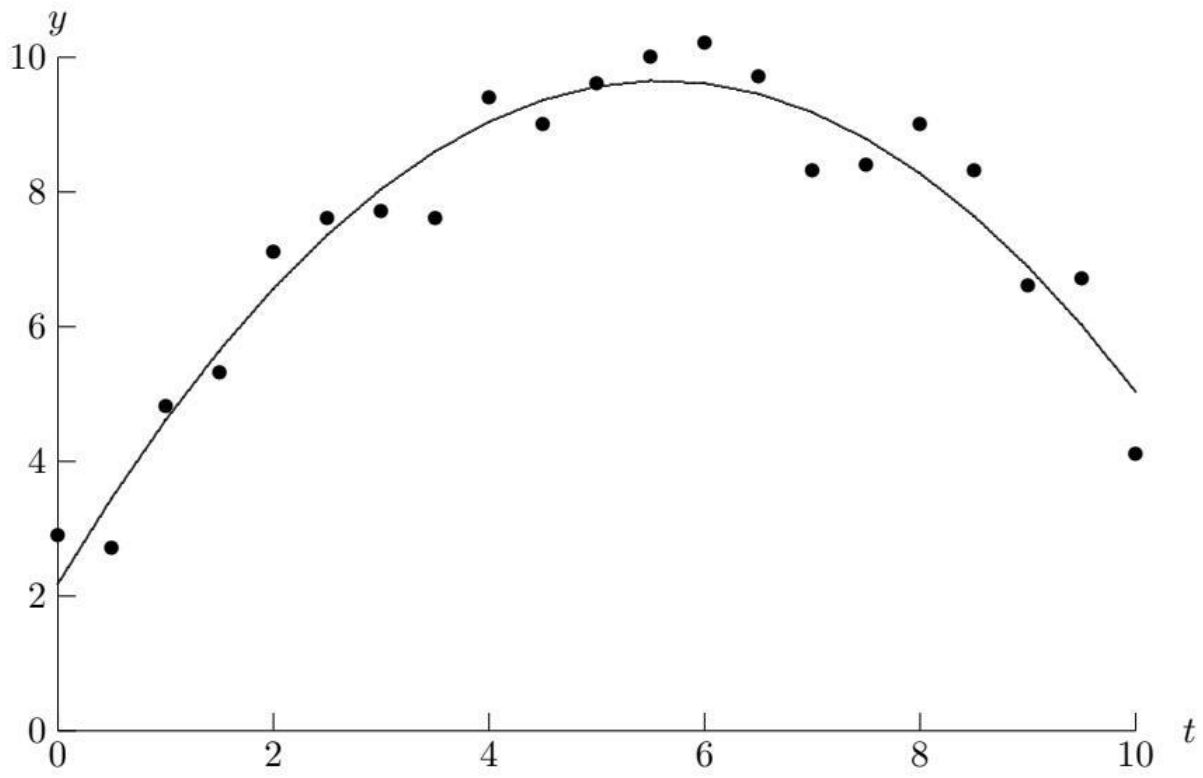

3.1. ábra: Másodfokú polinom legkisebb négyzetes illesztése az adott adatokra.

3.2 Létezés és egyértelműség

A 2.1. szakaszból felidézhetjük, hogy egy $m \times n$-es $Ax = b$ lineáris egyenletrendszer azt kérdezi, kifejezhető-e b az A oszlopainak lineáris kombinációjaként. Négyzetes rendszerek ($m = n$) esetén a válasz reguláris A-ra mindig „igen”. Túlhatározott rendszerek ($m > n$) esetén ezzel szemben a válasz általában „nem”, hacsak b történetesen a span(A)-ban fekszik, ami a legtöbb alkalmazásban igen valószínűtlen. A legkisebb négyzetek módszerénél azonban nem is várjuk el – és többnyire nem is kívánjuk –, hogy az egyenlet két oldala pontosan egyezzen, csupán a 2-norma szerinti lehető legjobb egyezést. A megoldás ezen másféle fogalmával a létezés és egyértelműség feltételei némileg eltérnek a négyzetes lineáris egyenletrendszerekéitől, ahogyan azt a továbbiakban látni fogjuk.

Először is megjegyezzük, hogy a legkisebb négyzetes megoldás létezése mindig biztosított: a $\phi(y) = \|b-y\|_2$ függvény folytonos és koercív $\mathbb{R}^m$-en, így ϕ-nek minimuma van a zárt, nem korlátos span(A) halmazon (lásd a 6.2. szakaszt), azaz létezik olyan $y \in \text{span}(A)$ m-dimenziós vektor, amely euklideszi normában a legközelebb van b-hez. Emellett ϕ szigorúan konvex a span(A) konvex halmazon, így a b-hez legközelebbi $y \in \text{span}(A)$ vektor egyértelmű (lásd a 6.2.1. szakaszt). Ez azonban nem jelenti azt, hogy a legkisebb négyzetes feladat x megoldása szükségképpen egyértelmű. Tegyük fel, hogy x_1 és x_2 ilyen megoldások, és legyen $z = x_2 - x_1$. Ekkor, mivel $Ax_1 = y = Ax_2$, azt kapjuk, hogy $Az = 0$. Márpedig ha $z \neq 0$, azaz $x_1 \neq x_2$, akkor az A oszlopai lineárisan összefüggők kell, hogy legyenek (vö. négyzetes mátrix nemszingularitásának 4. feltételével a 2.2. szakaszban). Arra a következtetésre jutunk, hogy egy $m \times n$-es $Ax \cong b$ legkisebb négyzetes feladat megoldása akkor és csak akkor egyértelmű, ha A teljes oszloprangú, azaz $\text{rank}(A) = n$ (vö. négyzetes mátrix nemszingularitásának 3. feltételével a 2.2. szakaszban). Ha $\text{rank}(A) < n$, akkor az A-t *ranghiányosnak* mondjuk, és bár a megfelelő legkisebb négyzetes feladatnak ekkor is kell, hogy legyen megoldása, ebben az esetben az nem lehet egyértelmű. A ranghiány következményeit később vizsgáljuk; egyelőre feltételezzük, hogy A teljes oszloprangú.

Az imént idézett létezési bizonyítás nem konstruktív, és kevés betekintést nyújt abba, miként jellemezzük vagy számítsuk ki egy lineáris legkisebb négyzetes feladat megoldását. A továbbiakban analitikus, geometriai és algebrai nézőpontokat tekintünk át, amelyek mélyebb betekintést nyújtanak a legkisebb négyzetes feladatok természetébe és a megoldásukra szolgáló különféle módszerekbe.

3.2.1 Normálegyenletek

Minimalizálási feladatként a legkisebb négyzetes feladat a többváltozós analízis eszközeivel kezelhető, hasonlóan ahhoz, ahogyan az egyváltozós analízisben a derivált nullával egyenlőségét írjuk elő. Az $r = b - Ax$ reziduumvektor euklideszi normájának négyzetét szeretnénk minimalizálni. Ezt a célfüggvényt $\phi : \mathbb{R}^n \to \mathbb{R}$-rel jelölve

$$\phi(x) = \|r\|_2^2 = r^T r = (b - Ax)^T (b - Ax) = b^T b - 2x^T A^T b + x^T A^T Ax.$$

A minimum szükséges feltétele, hogy x kritikus pontja legyen ϕ-nek, azaz a $\nabla\phi(x)$ gradiensvektor – amelynek i-edik komponensét $\partial\phi(x)/\partial x_i$ adja – nulla legyen (lásd a 6.2.2. szakaszt). Ezért teljesülnie kell, hogy

$$0 = \nabla\phi(x) = 2A^T Ax - 2A^T b,$$

tehát ϕ bármely x minimumhelyének ki kell elégítenie az $n \times n$-es szimmetrikus lineáris egyenletrendszert:

$$A^T Ax = A^T b.$$

Elegendő feltétel ahhoz, hogy egy ilyen x valóban minimum legyen, az, hogy a második parciális deriváltakból álló Hesse-mátrix – amely ebben az esetben éppen $2A^T A$ – pozitív definit (ismét lásd a 6.2.2. szakaszt). Könnyen belátható, hogy $A^T A$ akkor és csak akkor pozitív definit, ha az A oszlopai lineárisan függetlenek, azaz $\text{rank}(A) = n$, ami éppen az a kritérium, amelyet korábban a legkisebb négyzetes megoldás egyértelműségére vonatkozóan láttunk.

Az $A^T Ax = A^T b$ lineáris egyenletrendszert általánosan *normálegyenletek*nek nevezik. Az $A^T A$ mátrix (i, j) elemét az A i-edik és j-edik oszlopainak belső szorzata adja; emiatt az $A^T A$-t olykor az A keresztszorzat-mátrixának is nevezik. Ez a négyzetes lineáris egyenletrendszer egy módszert sugall – amelyet a 3.4.1. szakaszban részletesebben megvizsgálunk – a túlhatározott legkisebb négyzetes feladatok megoldására.

3.3. Példa. Normálegyenletek. A 3.1. példában szereplő lineáris legkisebb négyzetes feladat normálegyenlet-rendszere az alábbi szimmetrikus pozitív definit rendszer:

$$A^T Ax = \begin{bmatrix} 3 & -1 & -1 \\ -1 & 3 & -1 \\ -1 & -1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -651 \\ 2177 \\ 4069 \end{bmatrix} = A^T b,$$

amelynek megoldása $x = [1236,\ 1943,\ 2416]^T$, és a 2.21. példában kapott Cholesky-felbontással számítható ki; ez éri el a négyzetösszeg lehető legkisebb értékét, $\|r\|_2^2 = 35$.

3.2.2 Ortogonalitás és ortogonális projektorok A legkisebb négyzetes feladatok geometriai szemléletéhez szükségünk van az ortogonalitás fogalmára. Felidézzük, hogy $v_1, v_2 \in \mathbb{R}^m$ vektorokra

$$v_1^T v_2 = \|v_1\|_2 \cdot \|v_2\|_2 \cdot \cos(\theta),$$

ahol θ a v_1 és a v_2 által bezárt szög. Ennek megfelelően a v_1 és a v_2 *ortogonális* (vagy *merőleges*, illetve *normális*) egymásra, ha $v_1^T v_2 = 0$.

Egy $Ax \cong b$ legkisebb négyzetes feladatnál, ahol $m > n$, az m-dimenziós b vektor általában nem fekszik a legfeljebb n dimenziós $\text{span}(A)$ altérben. Az az $y = Ax \in \text{span}(A)$ vektor, amely euklideszi normában a legközelebb van b-hez, ott adódik, ahol az $r = b - Ax$ reziduumvektor ortogonális a $\text{span}(A)$-ra (lásd a 3.2. ábrát). Ezért az x legkisebb négyzetes megoldásra az $r = b - Ax$ reziduumvektornak az A minden oszlopára ortogonálisnak kell lennie, és így teljesülnie kell, hogy

$$0 = A^T r = A^T (b - Ax),$$

azaz

$$A^T Ax = A^T b,$$

ami ugyanaz a normálegyenlet-rendszer, mint amelyet korábban az analízis eszközeivel vezettünk le.

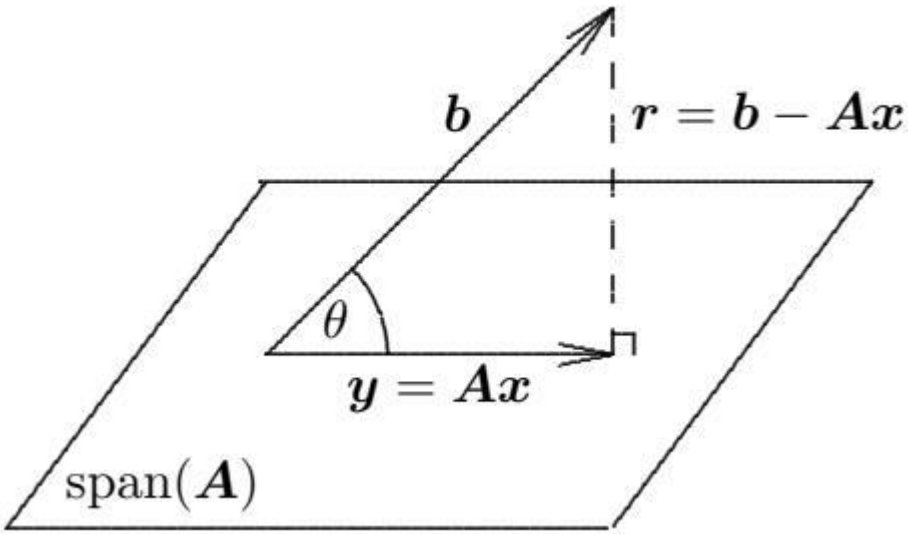

3.2. ábra: A lineáris legkisebb négyzetes feladat geometriai szemléltetése. A paralelogramma a span(A) alteret jelöli, amelyben b általában nem fekszik benne.

Az ortogonalitás iménti tárgyalásából, különösen a 3.2. ábrából intuitívan látható, hogy az a $y = Ax \in \text{span}(A)$ vektor, amely euklideszi normában a legközelebb van b-hez, nem más, mint b ortogonális projekciója a span(A)-ra. E megfigyelés a legkisebb négyzetes megoldások algebrai jellemzéséhez vezet, amelyet most formálisabban is megvizsgálunk.

Egy P négyzetes mátrixot *projektornak* nevezünk, ha idempotens (azaz $P^2 = P$). Egy ilyen mátrix bármely adott vektort egy altérre – nevezetesen a span(P)-re – vetít, viszont változatlanul hagy bármely olyan vektort, amely már eleve ebben az altérben fekszik. Ha egy P projektor ezen kívül szimmetrikus is (azaz $P^T = P$), akkor *ortogonális projektor*. Ha P ortogonális projektor, akkor $P_\perp = I - P$ is ortogonális projektor a span$(P)^\perp$-re, azaz a span(P) ortogonális kiegészítőjére – vagyis a span(P)-re ortogonális összes vektor alterére. Bármely $v \in \mathbb{R}^m$ vektor felírható

$$v = (P + (I - P))\, v = Pv + P_\perp v$$

alakban, kölcsönösen ortogonális vektorok összegeként, amelyek közül az egyik a span(P)-ben, a másik a span$(P)^\perp$-ben van.

Hogy ezeket a fogalmakat az $Ax \cong b$ legkisebb négyzetes feladatra alkalmazzuk, tegyük fel, hogy P ortogonális projektor a span(A)-ra. Ekkor

$$\begin{aligned}
\|b - Ax\|_2^2 &= \|P(b - Ax) + P_\perp(b - Ax)\|_2^2 \\
&= \|P(b - Ax)\|_2^2 + \|P_\perp(b - Ax)\|_2^2 \quad \text{(Pitagorasz-tétel alapján)} \\
&= \|Pb - Ax\|_2^2 + \|P_\perp b\|_2^2 \quad \text{(mivel } PA = A \text{ és } P_\perp A = O\text{)}.
\end{aligned}$$

A jobb oldal második tagja nem függ x-től, így a reziduumnorma akkor minimális, ha x-et úgy választjuk, hogy az első tag nulla legyen. A legkisebb négyzetes megoldást tehát a

$$Ax = Pb$$

túlhatározott, de konzisztens lineáris egyenletrendszer adja meg. Ebből az egyenletből úgy juthatunk négyzetes lineáris egyenletrendszerhez, hogy mindkét oldalát balról megszorozzuk A^T-vel, figyelembe véve, hogy $A^T P = A^T P^T = (PA)^T = A^T$, amiből

$$A^T Ax = A^T b$$

adódik, ami ismét a korábban levezetett normálegyenlet-rendszer.

Az ortogonális projektort az alábbi módon kaphatjuk meg explicit alakban: ha A teljes oszloprangú, úgyhogy $A^T A$ reguláris, akkor

$$P = A(A^T A)^{-1} A^T$$

szimmetrikus és idempotens, és így ortogonális projektor a $\mathrm{span}(A)$-ra. Ennélfogva az a $y \in \mathrm{span}(A)$ vektor, amely a legközelebb van b-hez, a

$$y = Pb = A(A^T A)^{-1} A^T b = Ax$$

ortogonális projekció, ahol x a normálegyenletek által megadott legkisebb négyzetes megoldás. Érdemes megjegyezni azt is, hogy b a

$$b = Pb + P_\perp b = Ax + (b - Ax) = y + r$$

alakban felírható két kölcsönösen ortogonális vektor összegeként, ahol $y \in \mathrm{span}(A)$ és $r \in \mathrm{span}(A)^\perp$.

Egy másik lehetőség: legyen Q egy olyan $m \times n$-es mátrix, amelynek oszlopai ortonormált bázist alkotnak (azaz $Q^T Q = I$) a $\mathrm{span}(A)$-ban. Ekkor $P = QQ^T$ szimmetrikus és idempotens, így ortogonális projektor a $\mathrm{span}(Q) = \mathrm{span}(A)$-ra. Ezzel a megközelítéssel az előbbi konzisztens túlhatározott rendszerből úgy kaphatunk négyzetes rendszert, hogy mindkét oldalát balról megszorozzuk Q^T-vel, és figyelembe vesszük, hogy $Q^T P = Q^T Q Q^T = Q^T$, amiből a

$$Q^T Ax = Q^T b$$

négyzetes rendszer adódik. Később látni fogjuk, hogyan számítható ki a Q mátrix úgy, hogy ez a rendszer felső háromszögű legyen, és ezért könnyen megoldható. A szokásos normálegyenletek felírásának ily módon való elkerülése pontosság és stabilitás szempontjából is előnyökkel jár, amint azt hamarosan látni fogjuk.

3.4. Példa. Ortogonalitás és projekciók. Ezeket a fogalmakat a 3.1. és 3.3. példában szereplő legkisebb négyzetes feladat folytatásaként szemléltetjük. Az $x = [1236,\ 1943,\ 2416]^T$ megoldáshelyen a reziduumvektor

$$r = b - Ax = b - y = \begin{bmatrix} 1237 \\ 1941 \\ 2417 \\ 711 \\ 1177 \\ 475 \end{bmatrix} - \begin{bmatrix} 1236 \\ 1943 \\ 2416 \\ 707 \\ 1180 \\ 473 \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \\ 1 \\ 4 \\ -3 \\ 2 \end{bmatrix}$$

ortogonális az A minden oszlopára, azaz $A^T r = 0$. A span(A)-ra vetítő ortogonális projektor

$$P = A(A^T A)^{-1} A^T = \frac{1}{4} \begin{bmatrix} 2 & 1 & 1 & -1 & -1 & 0 \\ 1 & 2 & 1 & 1 & 0 & -1 \\ 1 & 1 & 2 & 0 & 1 & 1 \\ -1 & 1 & 0 & 2 & 1 & -1 \\ -1 & 0 & 1 & 1 & 2 & 1 \\ 0 & -1 & 1 & -1 & 1 & 2 \end{bmatrix},$$

a span$(A)^\perp$-re vetítő ortogonális projektor pedig

$$P_\perp = I - P = \frac{1}{4} \begin{bmatrix} 2 & -1 & -1 & 1 & 1 & 0 \\ -1 & 2 & -1 & -1 & 0 & 1 \\ -1 & -1 & 2 & 0 & -1 & -1 \\ 1 & -1 & 0 & 2 & -1 & 1 \\ 1 & 0 & -1 & -1 & 2 & -1 \\ 0 & 1 & -1 & 1 & -1 & 2 \end{bmatrix},$$

úgyhogy $b = Pb + P_\perp b = y + r$.

3.3 Érzékenység és kondicionáltság

Most rátérünk a lineáris legkisebb négyzetes feladatnak érzékenységére és kondicionáltságára. Először is ki kell terjesztenünk a mátrix kondíciószámának fogalmát a téglalap alakú mátrixokra is. A négyzetes mátrixok kondíciószámának 2.3.3. szakaszban adott definíciója a mátrix inverzét használja. Egy nem négyzetes A mátrixnak a hagyományos értelemben vett inverze nincs, de definiálható egy *pszeudoinverz*, amelyet A^+ jelöl, és amely sok szempontból úgy viselkedik, mint egy inverz (lásd a 3.32. feladatot). Később egy általánosabb definíciót is látni fogunk, amely tetszőleges mátrixra érvényes, de egyelőre csak olyan A mátrixokat tekintünk, amelyek oszloprangja maximális. Ebben az esetben $A^T A$ reguláris, és az A pszeudoinverzét a következőképpen definiáljuk:

$$A^+ = (A^T A)^{-1} A^T.$$

Triviálisan adódik, hogy $A^+ A = I$, és a 3.2.2. szakaszból tudjuk, hogy $P = AA^+$ ortogonális projektor a span(A) altérre, úgyhogy az $Ax \cong b$ legkisebb négyzetes feladatnak megoldása

$$x = A^+ b.$$

Most az olyan $m \times n$-es mátrix kondíciószámát, amelyre $\operatorname{rank}(A) = n$, a következőképpen definiáljuk:

$$\operatorname{cond}(A) = \|A\|_2 \cdot \|A^+\|_2.$$

Megállapodás szerint $\operatorname{cond}(A) = \infty$, ha $\operatorname{rank}(A) < n$. Ahogyan egy négyzetes mátrix kondíciószáma a szingularitáshoz való közelséget méri, úgy egy téglalap alakú mátrix kondíciószáma a ranghiányhoz való közelséget jellemzi.

Míg egy négyzetes $Ax = b$ lineáris egyenletrendszer kondicionáltsága csak az A mátrixtól függ, addig az $Ax \cong b$ legkisebb négyzetes feladat kondicionáltsága az A mátrixon kívül a b jobb oldali vektortól is függ, ezért $\operatorname{cond}(A)$ önmagában nem elegendő az érzékenység jellemzésére. Nevezetesen, ha b közel van a $\operatorname{span}(A)$ altérhez, akkor b kis perturbációja viszonylag kevéssé változtatja meg az $y = Pb$ vetületet. Ha viszont b közel merőleges a $\operatorname{span}(A)$ altérre, akkor maga az $y = Pb$ is viszonylag kicsi lesz, így b kis változása viszonylag nagy változást okozhat y-ban, és ennélfogva az x legkisebb négyzetes megoldásban is. Így adott A mellett azt várjuk, hogy egy olyan b-vel felírt legkisebb négyzetes feladat, amely nagy reziduumot eredményez (vagyis az adatokra rossz illeszkedést ad), érzékenyebb lesz, mint egy kis reziduumot (azaz jó illeszkedést) adó feladat. Annak, hogy b mennyire van közel a $\operatorname{span}(A)$ altérhez, megfelelő mérőszáma a következő arány:

$$\frac{\|Ax\|_2}{\|b\|_2} = \frac{\|y\|_2}{\|b\|_2} = \cos(\theta),$$

ahol θ a b és az y közötti szög (lásd a 3.2. ábrát). Így nagyobb érzékenységre számítunk akkor, amikor ez az arány kicsi, vagyis θ közel van a $\pi/2$ értékhez.

Most kvantitatívabban értékeljük az $Ax \cong b$ legkisebb négyzetes feladat x megoldásának érzékenységét, ahol A oszloprangja maximális. Az egyszerűség kedvéért a b-beli és az A-beli perturbációkat külön-külön vizsgáljuk. A $b + \Delta b$ perturbált jobb oldali vektor esetén a perturbált megoldást a normálegyenletek adják meg:

$$A^T A(x + \Delta x) = A^T(b + \Delta b).$$

Mivel $A^T Ax = A^T b$, ezért

$$A^T A\, \Delta x = A^T \Delta b,$$

és így

$$\Delta x = (A^T A)^{-1} A^T \Delta b = A^+ \Delta b.$$

Normát véve mindkét oldalon:

$$\|\Delta x\|_2 \leq \|A^+\|_2 \cdot \|\Delta b\|_2.$$

Mindkét oldalt $\|x\|_2$-vel elosztva a következő korlátot kapjuk:

$$
\begin{aligned}
\frac{\|\Delta x\|_2}{\|x\|_2} &\leq \|A^+\|_2 \frac{\|\Delta b\|_2}{\|x\|_2} \\
&= \operatorname{cond}(A) \frac{\|b\|_2}{\|A\|_2 \cdot \|x\|_2} \frac{\|\Delta b\|_2}{\|b\|_2} \\
&\leq \operatorname{cond}(A) \frac{\|b\|_2}{\|Ax\|_2} \frac{\|\Delta b\|_2}{\|b\|_2} \\
&= \operatorname{cond}(A) \frac{1}{\cos(\theta)} \frac{\|\Delta b\|_2}{\|b\|_2}.
\end{aligned}
$$

Tehát a legkisebb négyzetes x megoldásnak a b-beli perturbációkra vonatkozó kondíciószáma függ $\operatorname{cond}(A)$-tól és a b és az Ax közötti θ szögtől is (lásd a 3.2. ábrát). Nevezetesen, a kondíciószám közelítőleg $\operatorname{cond}(A)$, amikor a reziduum kicsi, azaz $\cos(\theta) \approx 1$, de a kondíciószám tetszőlegesen rosszabb is lehet $\operatorname{cond}(A)$-nál, amikor a reziduum nagy, vagyis $\cos(\theta) \approx 0$.

Az $A + E$ perturbált mátrix esetén a perturbált megoldást a normálegyenletek adják meg:

$$
(A + E)^T (A + E)(x + \Delta x) = (A + E)^T b.
$$

Figyelembe véve, hogy $A^T Ax = A^T b$, elhagyva a másodrendű tagokat (azaz a kis perturbációk szorzatait), és átrendezve, azt kapjuk, hogy

$$
\begin{aligned}
A^T A \, \Delta x &\approx E^T b - E^T Ax - A^T Ex \\
&= E^T (b - Ax) - A^T Ex \\
&= E^T r - A^T Ex,
\end{aligned}
$$

így

$$
\Delta x \approx (A^T A)^{-1} E^T r - (A^T A)^{-1} A^T Ex = (A^T A)^{-1} E^T r - A^+ Ex.
$$

Normát véve:

$$
\|\Delta x\|_2 \lesssim \|(A^T A)^{-1}\|_2 \cdot \|E\|_2 \cdot \|r\|_2 + \|A^+\|_2 \cdot \|E\|_2 \cdot \|x\|_2.
$$

Mindkét oldalt $\|x\|_2$-vel elosztva, és felhasználva, hogy $\|A\|_2^2 \cdot \|(A^T A)^{-1}\|_2 = [\operatorname{cond}(A)]^2$, a következő korlátot kapjuk:

$$
\begin{aligned}
\frac{\|\Delta x\|_2}{\|x\|_2} &\lesssim \|(A^T A)^{-1}\|_2 \cdot \|E\|_2 \frac{\|r\|_2}{\|x\|_2} + \|A^+\|_2 \cdot \|E\|_2 \\
&= [\operatorname{cond}(A)]^2 \frac{\|E\|_2}{\|A\|_2} \frac{\|r\|_2}{\|A\|_2 \cdot \|x\|_2} + \operatorname{cond}(A) \frac{\|E\|_2}{\|A\|_2} \\
&\leq \left([\operatorname{cond}(A)]^2 \frac{\|r\|_2}{\|Ax\|_2} + \operatorname{cond}(A) \right) \frac{\|E\|_2}{\|A\|_2} \\
&= \left([\operatorname{cond}(A)]^2 \tan(\theta) + \operatorname{cond}(A) \right) \frac{\|E\|_2}{\|A\|_2}.
\end{aligned}
$$

Tehát a legkisebb négyzetes x megoldás A-beli perturbációkra vonatkozó kondíciószáma is függ $\mathrm{cond}(A)$-tól, valamint a b és az Ax közötti θ szögtől (lásd a 3.2. ábrát). Nevezetesen, a kondíciószám közelítőleg $\mathrm{cond}(A)$, amikor a reziduum kicsi, azaz $\tan(\theta) \approx 0$, de a kondíciószám lényegében négyzetre emelődik közepes nagyságú reziduum esetén, és tetszőlegesen naggyá válik, ha a reziduum ennél is nagyobb. Ezek az érzékenységi eredmények nemcsak a legkisebb négyzetes megoldások minőségének értékelését teszik majd lehetővé számunkra, hanem fontos szerepet játszanak az ilyen megoldások numerikus előállítására szolgáló különféle algoritmusok viszonylagos előnyeinek megértésében is.

3.5. Példa. Érzékenység és kondicionáltság. Ezeket a fogalmakat ismét a 3.1., a 3.3. és a 3.4. példák folytatásával szemléltetjük. A pszeudoinverz:

$$A^+ = (A^T A)^{-1} A^T = \frac{1}{4} \begin{bmatrix} 2 & 1 & 1 & -1 & -1 & 0 \\ 1 & 2 & 1 & 1 & 0 & -1 \\ 1 & 1 & 2 & 0 & 1 & 1 \end{bmatrix}.$$

A mátrixnormák kiszámítva:

$$\|A\|_2 = 2, \qquad \|A^+\|_2 = 1,$$

így

$$\mathrm{cond}(A) = \|A\|_2 \cdot \|A^+\|_2 = 2.$$

Az

$$\cos(\theta) = \frac{\|Ax\|_2}{\|b\|_2} = \frac{\|y\|_2}{\|b\|_2} \approx \frac{3640{,}8761}{3640{,}8809} \approx 0{,}99999868$$

arányból azt kapjuk, hogy a b és az y közötti θ szög körülbelül 0,001625, ami nagyon apró, ahogyan egy az adatokhoz nagyon szorosan illeszkedő feladat esetén várható. A kicsi kondíciószámból és a kicsi θ szögből azt a következtetést vonjuk le, hogy ez a konkrét legkisebb négyzetes feladat jól kondicionált.

3.6. Példa. A kondíciószám négyzetesedése. Tekintsük a következő mátrixot és perturbációt:

$$A = \begin{bmatrix} 1 & 1 \\ \epsilon & -\epsilon \\ 0 & 0 \end{bmatrix}, \qquad E = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ -\epsilon & \epsilon \end{bmatrix},$$

ahol $\epsilon \ll 1$, mondjuk ϵ körülbelül $\sqrt{\epsilon_{\mathrm{mach}}}$ nagyságrendű, amelyre

$$\mathrm{cond}(A) = 1/\epsilon, \qquad \|E\|_2/\|A\|_2 = \epsilon.$$

A $b = [1\ 0\ 0]^T$ jobb oldali vektor esetén $\|\Delta x\|_2/\|x\|_2 = 0{,}5\epsilon$, tehát a megoldás relatív perturbációja körülbelül annyi, mint $\mathrm{cond}(A)$-szorosa az A relatív perturbációjának. Ennél a jobb oldalnál nem lép

fel a kondíciószám négyzetesedésének hatása, mert a reziduum kicsi, és $\tan(\theta) \approx \epsilon$, így a perturbációs korlátban szereplő négyzetre emelt kondíciószámú tag lényegében elnyomódik.

A $b = [1\ 0\ 1]^T$ jobb oldali vektor esetén viszont $\|\Delta x\|_2/\|x\|_2 = 0{,}5/\epsilon$, tehát a megoldás relatív perturbációja körülbelül annyi, mint $[\mathrm{cond}(A)]^2$-szerese az A relatív perturbációjának. Ennél a jobb oldalnál a reziduum normája körülbelül 1, és $\tan(\theta) \approx 1$, így a perturbációs korlátban szereplő négyzetre emelt kondíciószámú tag nem nyomódik el, és a megoldás rendkívül érzékeny.

3.4 Feladat-átalakítások

Most több olyan módszert tekintünk, amellyel egy túlhatározott lineáris legkisebb négyzetek $Ax \cong b$ feladat négyzetes (végül is háromszögű) lineáris egyenletrendszerré alakítható át, így az a 2. fejezet módszereivel megoldható.

3.4.1 Normálegyenletek

Ahogyan a 3.2.1. szakaszban láttuk, ha az A oszloprangja maximális, akkor az $n \times n$-es, szimmetrikus, pozitív definit

$$A^T A x = A^T b$$

normálegyenletek megoldása ugyanaz az x, mint az $m \times n$-es $Ax \cong b$ legkisebb négyzetes feladaté. Ezt a négyzetes rendszert úgy oldjuk meg, hogy kiszámítjuk a Cholesky-felbontást (lásd a 2.5.1. szakaszt):

$$A^T A = L L^T,$$

ahol L alsó háromszögmátrix, majd az x megoldás az $Ly = A^T b$ és $L^T x = y$ háromszögű rendszerek megoldásával számítható ki.

A normálegyenletek használata egy túlhatározott legkisebb négyzetes feladat megoldására annak a korábban említett általános stratégiának a példája, amelyben egy nehéz feladatot azonos megoldású, egyre könnyebb feladatokká alakítunk át. Ebben az esetben a feladat-átalakítások sorozata:

téglalap alakú $\longrightarrow$ négyzetes $\longrightarrow$ háromszögű.

Ez a módszer azonban egyúttal egy másik fontos tényre is rávilágít, nevezetesen arra, hogy egy elméletileg helyes feladat-átalakítás numerikusan nem mindig ajánlott. A normálegyenletek rendszere elméletben a lineáris legkisebb négyzetes feladat pontos megoldását adja, a gyakorlatban azonban ez a megközelítés olykor kiábrándítóan pontatlan eredményeket szolgáltat. Ennek a viselkedésnek két oka van:

- A keresztszorzat-mátrix és a jobb oldali vektor képzése során információ veszhet el. Például legyen

$$A = \begin{bmatrix} 1 & 1 \\ \epsilon & 0 \\ 0 & \epsilon \end{bmatrix},$$

ahol $0 < \epsilon < \sqrt{\epsilon_{\text{mach}}}$ az adott lebegőpontos rendszerben. Ekkor lebegőpontos aritmetikában

$$A^T A = \begin{bmatrix} 1+\epsilon^2 & 1 \\ 1 & 1+\epsilon^2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

amely a munkapontosság erejéig szinguláris.

- A keresztszorzat-mátrix kondíciószáma – amely a normálegyenletek megoldásának érzékenységét határozza meg (lásd a 2.3. szakaszt) – az eredeti A mátrix kondíciószámának négyzete:

$$\text{cond}(A^T A) = [\text{cond}(A)]^2.$$

A 3.3. szakaszban láttuk, hogy a legkisebb négyzetes megoldások érzékenységében fellép a kondíciószám potenciális négyzetesedésének hatása, ez azonban csak akkor lenne jelentős tényező, amikor a reziduum nagy (vagyis az illeszkedés rossz). Sajnos a normálegyenletek akkor is elszenvedhetik a kondíciószám négyzetesedésének hatását, amikor az illeszkedés jó és a reziduum kicsi, így a számított megoldás érzékenyebbé válik, mint amennyit a mögöttes legkisebb négyzetes feladat önmagában indokolna. Ebben az értelemben a normálegyenletek módszere instabil.

Ezek a hiányosságok nem teszik használhatatlanná a normálegyenletek módszerét, de aggodalomra adnak okot, és indokolttá teszik, hogy numerikusan robusztusabb módszereket keressünk a lineáris legkisebb négyzetes feladatokra.

3.4.2 Kibővített rendszer

Egy másik mód, ahogyan egy legkisebb négyzetes feladat négyzetes lineáris egyenletrendszerré alakítható, az, hogy beágyazzuk egy nagyobb rendszerbe. A r reziduumvektor definíciója és az a követelmény, hogy a reziduum merőleges legyen az A oszlopaira, együtt a következő két egyenletből álló rendszert adja:

$$\begin{aligned} r + Ax &= b, \\ A^T r &= 0, \end{aligned}$$

amely mátrixalakban $(m+n) \times (m+n)$-es kibővített rendszerként írható fel:

$$\begin{bmatrix} I & A \\ A^T & O \end{bmatrix} \begin{bmatrix} r \\ x \end{bmatrix} = \begin{bmatrix} b \\ 0 \end{bmatrix},$$

amelynek megoldása a keresett x megoldást és az ahhoz tartozó r reziduumot egyszerre szolgáltatja.

Első pillantásra ez a módszer nem tűnik ígéretesnek: a kibővített rendszer szimmetrikus, de nem pozitív definit, nagyobb az eredeti rendszernél, és megköveteli, hogy az A két példányát tároljuk. Ráadásul, ha pusztán a főátló mentén választunk főelemet (ami a 2×2-es blokkrendszer blokkonkénti eliminációjával egyenértékű), akkor a normálegyenleteket kapjuk vissza, amelyek potenciális numerikus gyengeségét már megfigyeltük. Az egyetlen elért előny az, hogy most más főelemkiválasztási stratégiák is rendelkezésünkre állnak, amelyek numerikus vagy más okokból hasznosak lehetnek.

A kibővített rendszer mátrixának szimmetrikus indefinit (lásd a 2.5.2. szakaszt) vagy LU-felbontásában a főelemek megválasztása nyilvánvalóan a felső és az alsó blokksorokban szereplő elemek relatív nagyságától függ. A r és az x relatív skálái önkényesek, ezért egy α skálázási paramétert vezetünk be a reziduumhoz, ami a következő új rendszert adja:

$$\begin{bmatrix} \alpha I & A \\ A^T & O \end{bmatrix} \begin{bmatrix} r/\alpha \\ x \end{bmatrix} = \begin{bmatrix} b \\ 0 \end{bmatrix}.$$

Az α paraméter azt szabályozza, hogyan súlyozódnak a két alrendszer elemei egymáshoz képest a főelemek kiválasztásakor. Ésszerű ökölszabályként

$$\alpha = \max_{i,j} |a_{ij}|/1000$$

használható, de a legjobb érték meghatározásához némi kísérletezésre lehet szükség.

A módszer közvetlen implementációja aránytalanul nagy számításigényű lehet ($(m+n)^3$-nal arányos), ezért gondosan ki kell használni a kibővített mátrix speciális szerkezetét. A kibővített rendszer módszerét például a MATLAB hatékonyan használja nagy, ritka lineáris legkisebb négyzetes feladatokra.

3.4.3 Ortogonális transzformációk

A normálegyenletek megközelítésének potenciális numerikus nehézségei miatt szükségünk van egy olyan alternatívára, amely nem igényli a keresztszorzat-mátrix és a jobb oldali vektor képzését. Ezért egy numerikusan robusztusabb típusú transzformációt keresünk, amely egy egyszerűbb feladatra vezet, amelynek megoldása ugyanaz, mint az eredeti legkisebb négyzetes feladaté, de könnyebben számítható. Ahogyan a négyzetes lineáris egyenletrendszereknél, úgy itt is azt látjuk majd, hogy a háromszögű alak megfelelő célalak a legkisebb négyzetes feladatok egyszerűsítésére. Egy mátrix háromszögűvé alakítása Gauss-eliminációval azonban ebben a kontextusban nem megfelelő, mert egy ilyen transzformáció nem őrzi meg az euklideszi normát, és ennélfogva a legkisebb négyzetes megoldást sem.

Az ortogonalitásról korábban mondottakat alapul véve most olyan típusú lineáris transzformációt definiálunk, amely *megőrzi* az euklideszi normát. Egy négyzetes valós Q mátrixot *ortogonálisnak* mondunk, ha az oszlopai ortonormáltak, azaz ha $Q^TQ = I$, az egységmátrix. Egy Q ortogonális transzformáció tetszőleges v vektor euklideszi normáját megőrzi, hiszen

$$\|Qv\|_2^2 = (Qv)^TQv = v^TQ^TQv = v^Tv = \|v\|_2^2.$$

Az ortogonális mátrixok különböző módokon – például forgatással vagy tükrözéssel – transzformálhatnak vektorokat, de egy vektor euklideszi hosszát nem változtatják meg. Ennélfogva, ha egy lineáris legkisebb négyzetes feladat mindkét oldalát megszorozzuk egy ortogonális mátrixszal, a megoldás nem változik.

Az ortogonális mátrixok a numerikus számítások számos területén rendkívül fontosak, mert normamegőrző tulajdonságuk miatt nem erősítik fel a hibát. Így például ortogonális transzformációkkal négyzetes lineáris egyenletrendszerek is megoldhatók anélkül, hogy a numerikus stabilitás érdekében főelemkiválasztást kellene alkalmaznunk. Sajnos az ortogonalizáló módszerek

számítási szempontból lényegesen költségesebbek, mint a Gauss-eliminációra épülők, ezért jobb numerikus tulajdonságaikért olyan árat kell fizetni, amely a kontextustól függően megérheti, vagy sem.

3.4.4 Háromszögű legkisebb négyzetes feladatok

Most, hogy a birtokunkban van egy olyan transzformációcsalád, amely megőrzi a legkisebb négyzetes megoldást, a következő lépés, hogy találjunk egy megfelelő célalakot, amelyre egyszerűsítve a legkisebb négyzetes feladat könnyen megoldhatóvá válik. Ahogyan a négyzetes lineáris egyenletrendszereknél tettük, most is olyan legkisebb négyzetes feladatot tekintünk, amelyben felső háromszögmátrix szerepel. A túlhatározott esetben, azaz amikor $m > n$, egy ilyen feladat alakja

$$\begin{bmatrix} R \\ O \end{bmatrix} x \cong \begin{bmatrix} c_1 \\ c_2 \end{bmatrix},$$

ahol R egy $n \times n$-es felső háromszögmátrix, és a c jobb oldali vektort is hasonlóan particionáltuk. A legkisebb négyzetek reziduuma ekkor

$$\|r\|_2^2 = \|c_1 - Rx\|_2^2 + \|c_2\|_2^2.$$

Mivel a fenti összeg második tagja, $\|c_2\|_2^2$, független x-től, így arra nincs befolyásunk, az első tag azonban nullává tehető, ha x-et úgy választjuk meg, hogy kielégítse az

$$Rx = c_1$$

háromszögű rendszert, amely x-re visszahelyettesítéssel megoldható. Ezzel megtaláltuk az x legkisebb négyzetes megoldást, és azt is leszűrhetjük, hogy a négyzetösszeg minimuma

$$\|r\|_2^2 = \|c_2\|_2^2.$$

3.4.5 QR-felbontás

A háromszögű alakra való ortogonális transzformációt a QR-felbontással valósítjuk meg, amelynek alakja egy $m \times n$-es A mátrix esetén $m > n$ mellett

$$A = Q \begin{bmatrix} R \\ O \end{bmatrix},$$

ahol Q egy $m \times m$-es ortogonális mátrix, R pedig egy $n \times n$-es felső háromszögmátrix. Egy ilyen felbontás az $Ax \cong b$ lineáris legkisebb négyzetes feladatot azonos megoldású háromszögű legkisebb négyzetes feladattá alakítja, hiszen

$$\|r\|_2^2 = \|b - Ax\|_2^2 = \left\| b - Q \begin{bmatrix} R \\ O \end{bmatrix} x \right\|_2^2 = \left\| Q^T b - \begin{bmatrix} R \\ O \end{bmatrix} x \right\|_2^2 = \|c_1 - Rx\|_2^2 + \|c_2\|_2^2,$$

ahol a transzformált jobb oldalt

$$Q^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$$

úgy particionáltuk, hogy c_1 egy n-dimenziós vektor. Az x megoldás ekkor kielégíti az $n \times n$-es $Rx = c_1$ háromszögű lineáris egyenletrendszert, a minimális reziduumnorma értéke pedig $\|r\|_2 = \|c_2\|_2$. A következő szakaszban fogjuk látni, hogyan számítható ki a QR-felbontás.

A QR-felbontásnak a legkisebb négyzetes feladatok megoldásán kívül sok más alkalmazása is van. Ha a Q-t $Q = [Q_1 \; Q_2]$ alakban particionáljuk, ahol Q_1 a Q első n oszlopát, Q_2 pedig a reziduum $m - n$ oszlopot tartalmazza, akkor

$$A = Q \begin{bmatrix} R \\ O \end{bmatrix} = \begin{bmatrix} Q_1 & Q_2 \end{bmatrix} \begin{bmatrix} R \\ O \end{bmatrix} = Q_1 R.$$

Az olyan $A = Q_1 R$ alakú felbontást, amelyben Q_1 oszlopai ortonormáltak és Q_1 mérete megegyezik A-éval, R pedig négyzetes és felső háromszögű, olykor az A redukált, vagy „takarékos méretű” QR-felbontásának nevezik. Ha az A oszloprangja maximális, azaz R reguláris, akkor a Q_1 oszlopai a $\operatorname{span}(A)$ altér egy ortonormált bázisát alkotják, a Q_2 oszlopai pedig a $\operatorname{span}(A)$ ortogonális komplementumának, azaz a $\operatorname{span}(A)^\perp$ altérnek – amely megegyezik az A^T nullterével, $\{z \in \mathbb{R}^m : A^T z = 0\}$-val – egy ortonormált bázisát alkotják. Az ilyen ortonormált bázisok nemcsak a legkisebb négyzetek számításaiban hasznosak – amint azt a 3.2.2. szakasz végén láttuk –, hanem sajátérték-számításokban, optimalizálásban és számos további, a későbbiekben előkerülő feladatban is.

3.5 Ortogonalizációs módszerek

Egy mátrix QR-felbontásának kiszámításához hasonló megközelítést követünk, mint a Gauss-eliminációval végzett LU-felbontásnál: egymás után vezetünk be nullákat az A mátrixba, míg végül felső háromszögalakot kapunk; most azonban nem elemi eliminációs mátrixokat, hanem ortogonális transzformációkat használunk, hogy az euklideszi norma megmaradjon. Számos ilyen ortogonalizációs módszer elterjedt, többek között

- Householder-transzformációk (elemi tükrözések / reflektorok)
- Givens-transzformációk (síkbeli forgatások)
- Gram–Schmidt-ortogonalizáció

Elsősorban a Householder-transzformációk használatára összpontosítunk, hiszen ez a legelterjedtebb, és ebben a kontextusban általában a leghatékonyabb eljárás is, de a másik két módszert is felvázoljuk.

3.5.1 Householder-transzformációk Olyan ortogonális transzformációt keresünk, amely egy adott vektor kívánt komponenseit nullázza ki. Ennek egyik módja a *Householder-transzformáció*, más néven *elemi tükrözés / reflektor*, amely a

$$H = I - 2\frac{vv^T}{v^T v}$$

alakú mátrix, ahol v nem nulla vektor. A definícióból azonnal látszik, hogy $H = H^T = H^{-1}$, vagyis a H egyszerre ortogonális és szimmetrikus. Adott a vektor esetén a v vektort úgy szeretnénk megválasztani, hogy az a első komponensén kívül minden további komponens nullává váljon, azaz

$$Ha = \begin{bmatrix} \alpha \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \alpha \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \alpha e_1.$$

A H képletét felhasználva

$$\alpha\, e_1 = Ha = \left(I - 2\,\frac{vv^T}{v^T v} \right) a = a - 2\,v\,\frac{v^T a}{v^T v},$$

és így

$$v = (a - \alpha\, e_1)\,\frac{v^T v}{2v^T a}.$$

A skaláris szorzó azonban közömbös a v meghatározása szempontjából, mert a H képletéből úgyis kiesik, ezért vehetjük, hogy

$$v = a - \alpha\, e_1.$$

A norma megőrzéséhez szükségképpen $\alpha = \pm\|a\|_2$, az előjelet pedig úgy kell megválasztani, hogy elkerüljük a számjegykioltást (kiesést) (azaz $\alpha = -\mathrm{sign}(a_1)\|a\|_2$). További lehetséges numerikus nehézség, hogy a $\|a\|_2$ kiszámítása fölösleges túlcsorduláshoz vagy alulcsorduláshoz vezethet, ha az a komponensei nagyon nagyok vagy nagyon kicsik. Ezt elkerülhetjük, ha az a vektort már az elején elosztjuk a legnagyobb abszolút értékű komponensével. Ez a skálatényező a kapott H transzformációt sem változtatja meg.

A fenti algebrai levezetés mélyebb megértése érdekében tekintsük a 3.3. ábrán szemléltetett geometriai értelmezést. Az a vektort úgy vihetjük át az első koordinátatengelyre (ahol a többi komponense nullává válik) a normáját megőrizve, hogy tükrözzük azt valamelyik hipersíkra a kettő közül (a kétdimenziós ábrákon szaggatott vonalakkal jelölt hipersíkokra), amelyek az a és az első koordinátatengely közötti két szöget megfelezik. Az így kapott transzformált vektor $\pm\|a\|_2 e_1$ lesz, attól függően, hogy a két hipersík közül melyiket választjuk. Egy ilyen hipersík alakja $\mathrm{span}(v)^\perp = \{x : v^T x = 0\}$ valamilyen nem nulla v vektorra. Az ábrákból jól látszik, hogy a v párhuzamos kell, hogy legyen az $a - \alpha e_1$ vektorral, ahol $\alpha = \pm\|a\|_2$ – a hipersík választásától függően. Emlékezzünk a 3.2.2. szakaszból arra, hogy a $\mathrm{span}(v)$-re vetítő ortogonális projektor $P = v(v^T v)^{-1} v^T = (vv^T)/(v^T v)$, a $\mathrm{span}(v)^\perp$-re vetítő projektor pedig $I - P$. Ennélfogva $(I - P)a = a - v(v^T a)/(v^T v)$ adja az a vektornak a hipersíkra vett vetületét, de az első koordinátatengely eléréséhez kétszer olyan messzire kell elmennünk, azaz $a - 2v(v^T a)/(v^T v)$-ig, így a keresett transzformáció $H = I - 2P = I - 2(vv^T)/(v^T v)$. Elvben bármelyik hipersík választása működik, de ahhoz, hogy véges precíziójú aritmetikában a v kiszámítása során elkerüljük a számjegykioltást, az α-nak azt az előjelét kell választanunk, amelyhez az első koordinátatengelyen az a-tól távolabbi pont tartozik. Az ábrákon szereplő példavektor esetén a pozitív előjelet kell választani (azaz a jobb oldali ábrát), mert a_1 negatív.

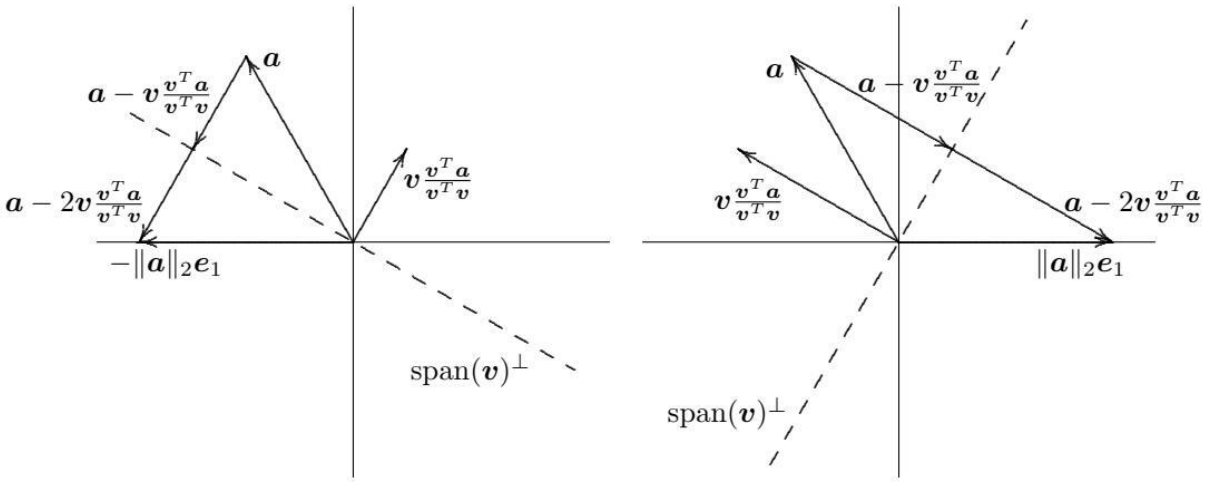

3.3. ábra: A Householder-transzformáció geometriai értelmezése tükrözésként.

3.7. Példa. Householder-transzformáció. A most leírt konstrukció szemléltetéséhez olyan Householder-transzformációt határozunk meg, amely a

$$a = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}$$

vektor első komponensén kívül minden komponensét kinullázza.

Az ismertetett recept szerint a

$$v = a - \alpha e_1 = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - \alpha \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - \begin{bmatrix} \alpha \\ 0 \\ 0 \end{bmatrix}$$

vektort választjuk, ahol $\alpha = \pm\|a\|_2 = \pm 3$. Mivel a_1 pozitív, a számjegykioltást úgy kerülhetjük el, ha az α-hoz a negatív előjelet választjuk. Így

$$v = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}.$$

Annak ellenőrzésére, hogy a Householder-transzformáció a vártnak megfelelően viselkedik, kiszámoljuk, hogy

$$Ha = a - 2\,\frac{v^T a}{v^T v}\,v = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - 2\,\frac{15}{30}\begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix},$$

ami azt mutatja, hogy az eredmény nullamintázata helyes, és a 2-norma megmarad. Figyeljük meg, hogy a H mátrixot nem kell explicit módon felírnunk, hiszen a H bármely vektorra való alkalmazásához elegendő a v vektor ismerete.

Eddig azt mutattuk meg, hogyan konstruálhatunk Householder-transzformációt, amely egy adott vektor első komponensén kívül minden komponensét kinullázza. Általánosabban, egy adott m-dimenziós a vektorhoz tekintsük a

$$a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}$$

partíciót, ahol a_1 egy $(k-1)$-dimenziós vektor, $1 \leq k < m$. Ha a Householder-vektort a

$$v = \begin{bmatrix} 0 \\ a_2 \end{bmatrix} - \alpha\, e_k$$

alakban vesszük, ahol $\alpha = -\mathrm{sign}(a_k)\|a_2\|_2$, akkor az ebből adódó Householder-transzformáció az a utolsó $m-k$ komponensét nullázza ki. Ilyen Householder-transzformációk sorozatát $k = 1, \dots, n$ értékekre alkalmazva egy $m \times n$-es A mátrix minden főátló alatti elemét kinullázhatjuk – oszloponként haladva balról jobbra –, és így a mátrixot felső háromszögalakra hozzuk. Minden Householder-transzformációt a mátrix még redukálatlan részére kell alkalmazni, de a már redukált korábbi oszlopokat nem érinti, ezért a nullák az egymás utáni transzformációk során megmaradnak. Egy tetszőleges u vektorra alkalmazott H Householder-transzformáció esetén

$$Hu = \left(I - 2\frac{vv^T}{v^Tv}\right) u = u - \left(2\frac{v^Tu}{v^Tv}\right) v,$$

amelynek kiszámítása lényegesen olcsóbb, mint egy általános mátrix-vektor szorzásé, és csupán a v vektor ismeretét igényli, a H mátrix explicit felírását nem. Egy $m \times n$-es A mátrix Householder-transzformációkkal történő QR-felbontását a 3.1. algoritmus foglalja össze; benne az A mátrix j-edik oszlopát a_j jelöli, az egyszerűség kedvéért pedig elhagytuk azt a skálázást, amely robusztus megvalósításhoz elengedhetetlen volna. Hatékony megvalósításban kerülnénk az egyes v_k vezető nulláival végzett műveleteket. Az algoritmus végén a mátrix felső háromszögű lesz.

Vegyük észre, hogy ha valamely k lépésnél $\beta_k = 0$, akkor az ebben a lépésben kinullázandó főátló alatti elemek már eleve nullák, így egyszerűen továbbléphetünk a következő oszlopra, és a QR-felbontás ettől még befejezhető. Az α_k előjelének választása miatt azonban β_k csak akkor lehet nulla, ha a_{kk} is nulla, ami azt jelenti, hogy az A k-adik oszlopa lineárisan függ az első $k-1$ oszloptól, tehát az A nem teljes oszlopú rangú. Ekkor a kapott R felső háromszögmátrixnak lesz nulla főátlóeleme, és így szinguláris lesz. Alattomosabb gond, ha a főátlóban egy nagyon kicsi, de nem nulla elem jelenik meg, ami közel ranghiányra utal. A ranghiány és a közel ranghiány következményeit a 3.5.4. szakaszban tárgyaljuk.

A most leírt folyamat egy

$$H_n \cdots H_1 A = \begin{bmatrix} R \\ O \end{bmatrix}$$

alakú felbontást ad,

3.1. Algoritmus. Householder-féle QR-felbontás.

```
for k = 1 to min(n, m - 1)                          { ciklus az oszlopokra }
     k = -sign(akk) √(akk² + … + amk²)
    vk = [0 … 0  akk … amk]  -  k ek                { Householder-vektor
                                                       kiszámítása a
                                                       jelenlegi oszlopra }
     k = vk  vk
    if  k = 0 then                                  { az aktuális oszlop
        continue with next k                           átugrása, ha az
                                                       már nulla }
    for j = k to n                                  { transzformáció
         j = vk  aj                                  alkalmazása a reziduum
        aj = aj - (2 j/ k) vk                        részmátrixra }
    end
end
```

ahol R felső háromszögű. Az egymást követő Householder-transzformációk $H_n \cdots H_1$ szorzata maga is ortogonális mátrix. Így ha bevezetjük a

$$Q^T = H_n \cdots H_1,$$

vagy ezzel ekvivalens módon a $Q = H_1 \cdots H_n$ jelölést, akkor

$$A = Q \begin{bmatrix} R \\ O \end{bmatrix}.$$

Ezzel tehát valóban kiszámítottuk az A mátrix QR-felbontását, amellyel a lineáris legkisebb négyzetes feladat most már megoldható. A megoldás megőrzéséhez azonban ugyanezen Householder-transzformációk sorozatával a b jobb oldali vektort is transzformálnunk kell. Ezek után az ezzel ekvivalens, háromszögű legkisebb négyzetes feladatot oldjuk meg:

$$\begin{bmatrix} R \\ O \end{bmatrix} x \cong Q^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}.$$

A lineáris legkisebb négyzetes feladatnak megoldásához a Householder-transzformációk Q szorzatát nem szükséges explicit módon felírni. Az erre a feladatra készült szoftverek többségében a R-t az eredetileg az A-t tartalmazó tömb felső háromszögében tárolják, a Householder-transzformációk felírásához szükséges v_k Householder-vektorok nem nulla részeit pedig az A (most nullákká vált) alsó háromszögű részében helyezik el. (Szigorúan véve ehhez még egy n-dimenziós vektornyi memóriára van szükség, mivel minden Householder-vektornak eggyel több nem nulla komponense van, mint ahányat az A megfelelő oszlopának főátló alatti része el tud tárolni.) Amint már láttuk, a Householder-transzformációkat amúgy is legegyszerűbben ebben az alakban alkalmazzuk (nem pedig explicit mátrix-vektor szorzással), így a v_k vektorok elegendőek mind az eredeti legkisebb négyzetes feladat, mind minden további, ugyanolyan mátrixú, de más jobb oldali vektort tartalmazó feladat megoldásához. Ha azonban a Q-ra valamilyen más okból explicit alakban volna szükségünk, úgy az kiszámítható az egyes Householder-transzformációk egymás utáni szorzataként, kiindulásként az I egységmátrixszal – ehhez viszont további memória szükséges.

3.8. Példa. Householder-féle QR-felbontás. A Householder-féle QR-felbontást a 3.1. példában szereplő legkisebb négyzetes feladat megoldásával szemléltetjük. Az A első oszlopa főátló alatti elemeinek kinullázásához a v_1 Householder-vektor

$$v_1 = a_1 - \alpha\, e_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ -1 \\ -1 \\ 0 \end{bmatrix} - \begin{bmatrix} -1{,}7321 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2{,}7321 \\ 0 \\ 0 \\ -1 \\ -1 \\ 0 \end{bmatrix}.$$

Az ebből adódó H_1 Householder-transzformáció alkalmazásával

$$H_1 A = \begin{bmatrix} -1{,}7321 & 0{,}5774 & 0{,}5774 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0{,}7887 & -0{,}2113 \\ 0 & -0{,}2113 & 0{,}7887 \\ 0 & -1 & 1 \end{bmatrix}, \qquad H_1 b = \begin{bmatrix} 376 \\ 1941 \\ 2417 \\ 1026 \\ 1492 \\ 475 \end{bmatrix}.$$

A $H_1 A$ második oszlopa főátló alatti elemeinek kinullázásához a v_2 Householder-vektor

$$v_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0{,}7887 \\ -0{,}2113 \\ -1 \end{bmatrix} - \begin{bmatrix} 0 \\ -1{,}6330 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 2{,}6330 \\ 0 \\ 0{,}7887 \\ -0{,}2113 \\ -1 \end{bmatrix}.$$

Az ebből adódó H_2 Householder-transzformáció alkalmazásával

$$H_2 H_1 A = \begin{bmatrix} -1{,}7321 & 0{,}5774 & 0{,}5774 \\ 0 & -1{,}6330 & 0{,}8165 \\ 0 & 0 & 1 \\ 0 & 0 & 0{,}0332 \\ 0 & 0 & 0{,}7231 \\ 0 & 0 & 0{,}6899 \end{bmatrix}, \qquad H_2 H_1 b = \begin{bmatrix} 376 \\ -1200 \\ 2417 \\ 85 \\ 1744 \\ 1668 \end{bmatrix}.$$

A $H_2 H_1 A$ harmadik oszlopa főátló alatti elemeinek kinullázásához a v_3 Householder-vektor

$$v_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0{,}0332 \\ 0{,}7231 \\ 0{,}6899 \end{bmatrix} - \begin{bmatrix} 0 \\ 0 \\ -1{,}4142 \\ 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 2{,}4142 \\ 0{,}0332 \\ 0{,}7231 \\ 0{,}6899 \end{bmatrix}.$$

Az ebből adódó H_3 Householder-transzformáció alkalmazásával

$$H_3H_2H_1A = \begin{bmatrix} -1{,}7321 & 0{,}5774 & 0{,}5774 \\ 0 & -1{,}6330 & 0{,}8165 \\ 0 & 0 & -1{,}4142 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} R \\ O \end{bmatrix}$$

és

$$H_3H_2H_1b = \begin{bmatrix} 376 \\ -1200 \\ -3417 \\ 5 \\ 3 \\ 1 \end{bmatrix} = Q^Tb = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}.$$

Az $Rx = c_1$ felső háromszögű rendszert mostantól visszahelyettesítéssel oldhatjuk meg, és az $x = [1236, 1943, 2416]^T$ megoldást kapjuk. Mind a megoldás, mind a minimális reziduum négyzetösszege – $\|r\|_2^2 = \|c_2\|_2^2 = 35$ – megegyezik a 3.3. példában kapott értékekkel.

3.5.2 Givens-forgatások A Householder-transzformációk egyszerre sok nullát vezetnek be egy oszlopba. Bár hatékonyság szempontjából ez általában előnyös, a megközelítés túlságosan „durva” is lehet, ha nagyobb szelektivitásra van szükségünk a nullák bevezetésekor. Ezért bizonyos esetekben érdemesebb Givens-forgatásokat használni, amelyek egyszerre egy-egy nullát vezetnek be.

Olyan ortogonális mátrixot keresünk, amely egy adott vektor egyetlen komponensét nullázza ki. Ennek egyik módja a *síkbeli forgatás*, amelyet a QR-felbontás kontextusában gyakran *Givens-forgatásnak* neveznek; alakja

$$G = \begin{bmatrix} c & s \\ -s & c \end{bmatrix},$$

ahol c és s a forgatási szög koszinusza és szinusza. Az ortogonalitás megköveteli, hogy $c^2 + s^2 = 1$ teljesüljön, ami természetesen bármely szög koszinuszára és szinuszára igaz. Itt egy adott $a = \begin{bmatrix} a_1 & a_2 \end{bmatrix}^T$ 2-dimenziós vektorra úgy szeretnénk megválasztani c-t és s-t, hogy

$$Ga = \begin{bmatrix} c & s \\ -s & c \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \alpha \\ 0 \end{bmatrix}.$$

Azaz: ha az a vektort úgy forgatjuk el, hogy az első koordinátatengellyel párhuzamos legyen, akkor a második komponense nullává válik. A fenti egyenlet átírható a következő alakba:

$$\begin{bmatrix} a_1 & a_2 \\ a_2 & -a_1 \end{bmatrix} \begin{bmatrix} c \\ s \end{bmatrix} = \begin{bmatrix} \alpha \\ 0 \end{bmatrix}.$$

Erre a rendszerre Gauss-eliminációt végrehajtva a

$$\begin{bmatrix} a_1 & a_2 \\ 0 & -a_1 - a_2^2/a_1 \end{bmatrix} \begin{bmatrix} c \\ s \end{bmatrix} = \begin{bmatrix} \alpha \\ -\alpha a_2/a_1 \end{bmatrix}$$

háromszögű rendszert kapjuk. Visszahelyettesítéssel ezután

$$s = \frac{\alpha a_2}{a_1^2 + a_2^2}, \qquad c = \frac{\alpha a_1}{a_1^2 + a_2^2}.$$

Végül a $c^2 + s^2 = 1$ követelmény, amelyből $\alpha = \sqrt{a_1^2 + a_2^2}$, azt adja, hogy

$$c = \frac{a_1}{\sqrt{a_1^2 + a_2^2}}, \qquad s = \frac{a_2}{\sqrt{a_1^2 + a_2^2}}.$$

A Householder-transzformációkhoz hasonlóan a fölösleges túlcsordulás vagy alulcsordulás megfelelő skálázással elkerülhető. Ha $|a_1| > |a_2|$, akkor dolgozhatunk a forgatási szög tangensével, $t = s/c = a_2/a_1$, így a koszinuszt és a szinuszt a

$$c = 1/\sqrt{1 + t^2}, \qquad s = c \cdot t$$

képletek adják. Ha viszont $|a_2| > |a_1|$, akkor a $\tau = c/s = a_1/a_2$ kotangenssel analóg képleteket használhatjuk, így

$$s = 1/\sqrt{1 + \tau^2}, \qquad c = s \cdot \tau.$$

Mindkét esetben elkerüljük, hogy 1-nél nagyobb abszolút értékű számot négyzetre emeljünk. A forgatási szöget nem szükséges explicit módon meghatározni, csak a szinuszára és a koszinuszára van szükségünk.

3.9. Példa. Givens-forgatás. A most leírt konstrukciót úgy szemléltetjük, hogy meghatározunk egy olyan Givens-forgatást, amely az

$$a = \begin{bmatrix} 4 \\ 3 \end{bmatrix}$$

vektor második komponensét nullázza ki.

Ennél a feladatnál a koszinuszt és a szinuszt biztonságosan közvetlenül is kiszámíthatjuk:

$$c = \frac{a_1}{\sqrt{a_1^2 + a_2^2}} = \frac{4}{5} = 0{,}8, \qquad s = \frac{a_2}{\sqrt{a_1^2 + a_2^2}} = \frac{3}{5} = 0{,}6,$$

vagy ezzel ekvivalens módon használhatjuk a $t = a_2/a_1 = 3/4 = 0{,}75$ tangenst is:

$$c = \frac{1}{\sqrt{1 + (0{,}75)^2}} = \frac{1}{1{,}25} = 0{,}8, \qquad s = c \cdot t = (0{,}8)(0{,}75) = 0{,}6.$$

Így a forgatást a

$$G = \begin{bmatrix} c & s \\ -s & c \end{bmatrix} = \begin{bmatrix} 0{,}8 & 0{,}6 \\ -0{,}6 & 0{,}8 \end{bmatrix}$$

mátrix adja. Annak ellenőrzésére, hogy a forgatás a vártnak megfelelően viselkedik, kiszámoljuk, hogy

$$Ga = \begin{bmatrix} 0{,}8 & 0{,}6 \\ -0{,}6 & 0{,}8 \end{bmatrix} \begin{bmatrix} 4 \\ 3 \end{bmatrix} = \begin{bmatrix} 5 \\ 0 \end{bmatrix},$$

ami azt mutatja, hogy az eredmény nullamintázata helyes, és a 2-norma megmarad. A forgatási szög értéke – ebben az esetben körülbelül 36,87 fok – közvetlenül nem szerepel a számításban, és nem is szükséges explicit módon meghatározni.

Láttuk, hogyan tervezhetünk síkbeli forgatást egy 2-dimenziós vektor egyik komponensének kinullázására. Egy m-dimenziós vektor bármely kívánt komponensének kinullázásához ugyanezt a technikát alkalmazhatjuk: a célkomponenst – legyen ez a j-edik – egy másik komponenssel – mondjuk az i-edikkel – együtt forgatjuk. A vektor e két kiválasztott komponense a fentiek szerint határozza meg a megfelelő 2×2-es forgatási mátrixot, amelyet azután 2×2-es részmátrixként beágyazunk az m-dimenziós I_m egységmátrix i-edik és j-edik sorába, illetve oszlopába – ahogy az alábbiakban bemutatjuk az $m = 5$, $i = 2$, $j = 4$ esetben:

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & c & 0 & s & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & -s & 0 & c & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \\ a_5 \end{bmatrix} = \begin{bmatrix} a_1 \\ \alpha \\ a_3 \\ 0 \\ a_5 \end{bmatrix}.$$

Ilyen Givens-forgatások sorozatával az A mátrix egyes elemeit egymás után kinullázhatjuk, míg végül a mátrixot felső háromszögalakra nem hozzuk. Az egyetlen megszorítás az elemek kinullázásának sorrendjére az, hogy ne vezessünk vissza nem nulla értékeket olyan mátrixelemekbe, amelyeket korábban már kinulláztunk; ez azonban sokféle sorrenddel megvalósítható. Itt is a forgatások szorzata egy olyan ortogonális mátrix, amely megadja a keresett QR-felbontást.

Az általános lineáris legkisebb négyzetes feladatok megoldására szolgáló Givens-módszer egyszerű megvalósítása körülbelül 50 százalékkal több munkát igényel, mint a Householder-módszer. Több memóriát is igényel, mivel minden forgatást két szám – c és s – határoz meg (így a kinullázott a_{ij} elem nem elegendő a forgatás tárolására). Ezek a munkával és a memóriával kapcsolatos hátrányok leküzdhetők annyira, hogy a Givens-módszer versenyképes legyen a Householder-módszerrel, de ennek ára a bonyolultabb megvalósítás. A Givens-módszert ezért általában azokra a helyzetekre tartjuk fenn, amelyekben a nagyobb szelektivitás kiemelt jelentőségű – például amikor a mátrix ritka, vagy amikor a meglévő nullák valamilyen adott mintázatát meg kell őriznünk.

A Householder-transzformációkhoz hasonlóan a Q mátrixot nem szükséges explicit módon felírni, mivel az egymást követő forgatásokkal való szorzás ugyanazt az eredményt adja, mint a Q-val való szorzás. Ha azonban a Q-ra valamilyen más okból explicit alakban volna szükségünk, úgy az kiszámítható az egyes forgatások egymás utáni szorzataként, kiindulásként az I egységmátrixszal.

3.10. Példa. Givens-féle QR-felbontás. A Givens-féle QR-felbontást a 3.1. példában szereplő legkisebb négyzetes feladat megoldásával szemléltetjük. Ennek a feladatnak a mátrixában a főátló alatt mindössze hat nem nulla elem van, amelyek Givens-forgatásokkal egyenként, szelektíven kinullázhatók (a Householder-módszer az ilyen ritkaságot nem tudja könnyen kihasználni, mivel egyszerre egy egész oszlopot nulláz ki).

Az első oszlopban alulról felfelé haladva, az A első nem nulla eleme az $(5,1)$ pozícióban van; ez kinullázható egy olyan Givens-forgatással, amely az A első oszlopának első és ötödik elemére épül. Egy megfelelő forgatást a $c = 1/\sqrt{2}$, $s = -1/\sqrt{2}$ értékek adnak, amelyet a 6×6-os egységmátrixba beágyazva

$$G_1 = \begin{bmatrix} 0{,}7071 & 0 & 0 & 0 & -0{,}7071 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0{,}7071 & 0 & 0 & 0 & 0{,}7071 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}.$$

Ezt a forgatást az A-ra és a b-re alkalmazva

$$G_1 A = \begin{bmatrix} 1{,}4142 & 0 & -0{,}7071 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ -1 & 1 & 0 \\ 0 & 0 & 0{,}7071 \\ 0 & -1 & 1 \end{bmatrix}, \qquad G_1 b = \begin{bmatrix} 42 \\ 1941 \\ 2417 \\ 711 \\ 1707 \\ 475 \end{bmatrix}.$$

Ezek után a $(4,1)$ elemet nullázzuk ki egy olyan Givens-forgatással, amely az első oszlop első és negyedik elemére épül. Egy megfelelő forgatást a $c = \sqrt{2}/\sqrt{3}$, $s = -1/\sqrt{3}$ értékek adnak, amelyet az egységmátrixba beágyazva

$$G_2 = \begin{bmatrix} 0{,}8165 & 0 & 0 & -0{,}5774 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0{,}5774 & 0 & 0 & 0{,}8165 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}.$$

Ezt a forgatást alkalmazva

$$G_2 G_1 A = \begin{bmatrix} 1{,}7321 & -0{,}5744 & -0{,}5744 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0{,}8165 & -0{,}4082 \\ 0 & 0 & 0{,}7071 \\ 0 & -1 & 1 \end{bmatrix}, \qquad G_2 G_1 b = \begin{bmatrix} -376 \\ 1941 \\ 2417 \\ 605 \\ 1707 \\ 475 \end{bmatrix}.$$

Ezzel az első oszlop készen van, így ezután a második oszlopra lépnénk tovább, és hasonló módon egyenként kinulláznánk a főátló alatti nem nulla elemeit, majd végül ugyanígy járnánk el a harmadik oszloppal is, míg a végén megkapnánk a felső háromszögű mátrixot és a transzformált jobb oldalt:

$$Q^T A = \begin{bmatrix} 1{,}7321 & -0{,}5774 & -0{,}5774 \\ 0 & 1{,}6330 & -0{,}8165 \\ 0 & 0 & 1{,}4142 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \qquad Q^T b = \begin{bmatrix} -376 \\ 1200 \\ 3417 \\ 5{,}66 \\ -1{,}63 \\ -0{,}56 \end{bmatrix},$$

ahol Q^T az összes felhasznált Givens-forgatás szorzata. A felső háromszögű rendszert mostantól visszahelyettesítéssel oldhatjuk meg, és az $x = [1236, 1943, 2416]^T$ megoldást kapjuk.### 3.5.3 Gram–Schmidt-ortogonalizáció

A QR-felbontás kiszámításának egy másik módszere a Gram–Schmidt-ortogonalizáció. Adott két lineárisan független m-dimenziós vektor, a_1 és a_2; célunk két olyan ortonormált m-dimenziós q_1 és q_2 vektor meghatározása, amelyek ugyanazt az alteret feszítik ki, mint a_1 és a_2. Először a_1-et normáljuk, és így megkapjuk $q_1 = a_1/\|a_1\|_2$-t. Ezután a_2-ből le szeretnénk vonni annak q_1 irányú összetevőjét, amit úgy érhetünk el, hogy a_2-t ortogonálisan levetítjük a span(q_1) altérre; lásd a 3.4. ábrát. Ez utóbbi ekvivalens az alábbi $m \times 1$ méretű legkisebb négyzetes feladattal:

$$q_1 \gamma \cong a_2,$$

amelynek megoldása a normálegyenleten keresztül

$$\gamma = \left(q_1^T q_1\right)^{-1} \left(q_1^T a_2\right) = q_1^T a_2.$$

A kívánt q_2 vektort tehát úgy kapjuk meg, hogy normáljuk az $r = a_2 - (q_1^T a_2) q_1$ reziduumvektort ehhez az $m \times 1$ méretű legkisebb négyzetes feladathoz.

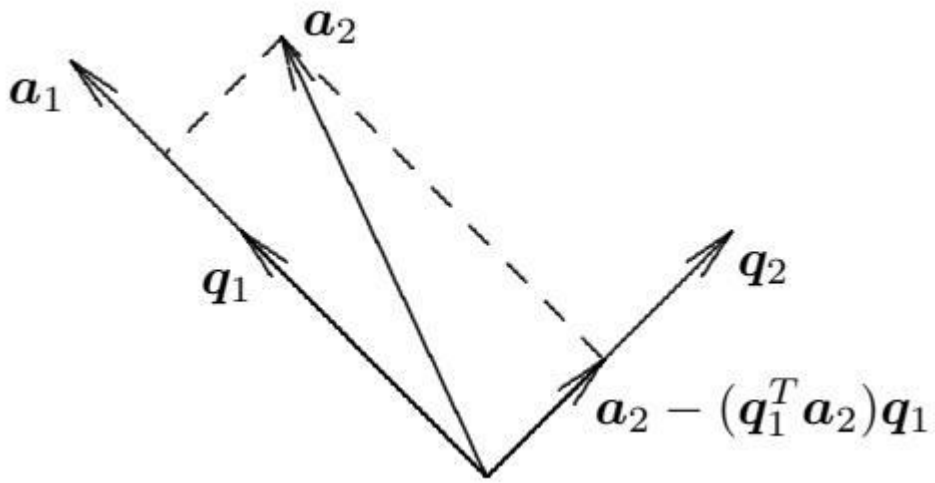

3.4. ábra: A Gram–Schmidt-ortogonalizáció egyetlen lépése.

Az imént leírt folyamat tetszőleges számú $a_1, \dots, a_k$, $1 \le k \le m$ vektorra kiterjeszthető úgy, hogy minden egyes új vektort ortogonalizálunk az összes megelőző vektorhoz képest; ezt nevezzük a *klasszikus* Gram–Schmidt-ortogonalizációs eljárásnak, amelyet a 3.2. algoritmus mutat be. Ha az a_k vektorok az $m \times n$-es A mátrix oszlopai, akkor a keletkező q_k vektorok az $m \times n$-es Q_1 mátrix oszlopai lesznek, az r_{jk} értékek pedig

3.2. Algoritmus. Klasszikus Gram–Schmidt-ortogonalizáció

```
for k = 1 to n
    qk = ak
    for j = 1 to k - 1
        rjk = qj^T * ak
        qk = qk - rjk * qj
    end
    rkk = ||qk||2
    if rkk = 0 then stop
    qk = qk / rkk
end
                                    { oszlopokon futó ciklus }
                                    { a jelenlegi oszlopból levonjuk
                                        az őt megelőző oszlopok
                                        irányú komponenseit }
                                    { megállás, ha lineárisan összefüggő }
                                    { a jelenlegi oszlop normálása }
```

az A redukált QR-felbontásában szereplő $n \times n$-es felső háromszögű R mátrix elemei (lásd a 3.4.5. szakaszt).

Sajnos a klasszikus Gram–Schmidt-eljárás véges pontosságú aritmetikával megvalósítva nem kielégítő, mert a kiszámított q_k vektorok ortogonalitása a kerekítési hibák miatt hajlamos elveszni. Ráadásul a klasszikus Gram–Schmidt-eljárás külön memóriát igényel az A és a Q_1 (valamint az R) számára, mert az eredeti a_k-t a belső ciklusban is használjuk, ezért a belső ciklusban frissülő q_k nem írhatja felül. Mindkét hiányosság egyszerűen orvosolható, ha a belső ciklusban a_k helyett q_k-t használjuk; ez egy olyan Gram–Schmidt-változatot ad, amely továbbra is oszloponként állítja elő az R-t. A számítás alaposabb átrendezése azonban további előnnyel is jár.

Mégpedig, amint kiszámítottuk az új q_k vektort, rögtön ortogonalizáljuk hozzá az összes hátralévő vektort, így az R-t nem oszloponként, hanem soronként állítjuk elő. Ez az átrendezés a módosított Gram–Schmidt-ortogonalizációs eljárást adja, amelyet a 3.3. algoritmus mutat be; ez matematikailag ekvivalens a klasszikus Gram–Schmidttel, de numerikusan jobb nála. A Gram–Schmidt mindkét változatában, ha valamelyik k lépésnél $r_{kk} = 0$, akkor az A k-adik oszlopa szükségképpen lineárisan függ az első $k-1$ oszloptól, ezért A nem teljes oszlopranggal rendelkezik. Az itt közölt formában egyik algoritmus sem folytatható ebben a helyzetben. Az oszloponkénti Gram–Schmidt-eljárásokkal ellentétben azonban a soronkénti módosított Gram–Schmidt-eljárás lehetővé teszi az oszloponkénti főelemkiválasztás használatát az A oszlopai közül egy maximális lineárisan független részhalmaz kiválasztására (lásd a 3.5.4. szakaszt). Alattomosabb probléma, ha r_{kk} értéke nagyon kicsi, de nem nulla: ez a közeli ranghiányt jelzi, és szintén elegánsan kezelhető oszloponkénti főelemkiválasztással, a soronkénti módosított Gram–Schmidt-eljárással együtt.

A 3.3. algoritmusban a világosság kedvéért továbbra is külön írtuk a_k-t és q_k-t, de valójában

most már közös memóriát használhatnak (egy programozó eleve így is fogalmazta volna meg az algoritmust). Sajnos a Q_1 és az R továbbra is külön memóriát igényel, ami hátrány a Householder-módszerhez képest, ahol az R és a Q implicit reprezentációja osztozhat az A által korábban elfoglalt területen. Másrészt a Gram–Schmidt explicit reprezentációt ad a Q_1-re,

3.3. Algoritmus. Módosított Gram–Schmidt-ortogonalizáció

```
for k = 1 to n
    rkk = ||ak||2
    if rkk = 0 then stop                    { oszlopokon futó ciklus }
    qk = ak / rkk                           { megállás, ha lineárisan összefüggő }
    for j = k+1 to n                        { a jelenlegi oszlop normálása }
        rkj = qk^T * aj                     { a rákövetkező oszlopokból
        aj = aj - rkj * qk                      levonjuk a jelenlegi oszlop
    end                                         irányú komponenseiket }
end
```

amit a Householder-módszer esetén – ha szükséges – többlet-memória árán kapnánk meg.

Még a módosított Gram–Schmidt-eljárás esetén is előfordulhat számjegykioltás, amikor egyik vektorból egy másik irányú komponenst vonunk le, és ez a Q_1 oszlopainak ortogonalitásában jelentős veszteséghez vezethet, ha A rosszul kondicionált, bár a veszteség jóval enyhébb, mint a klasszikus Gram–Schmidtnél. Ezért, ha a módosított Gram–Schmidtet az $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldására használjuk, nem tanácsos a kiszámított Q_1-et explicit módon felhasználni a transzformált jobb oldal $c_1 = Q_1^T b$ kiszámításához. Numerikusan jobb, ha a b jobb oldali vektort $(n+1)$-edik oszlopként kezeljük, és a módosított Gram–Schmidtet használjuk az így kapott $m \times (n+1)$-es kibővített mátrix redukált QR-felbontásának kiszámítására:

$$\begin{bmatrix} A & b \end{bmatrix} = \begin{bmatrix} Q_1 & q_{n+1} \end{bmatrix} \begin{bmatrix} R & c_1 \\ 0^T & \rho \end{bmatrix},$$

ezután a legkisebb négyzetes feladat x megoldását az $Rx = c_1$ $n \times n$-es háromszögű lineáris egyenletrendszer megoldása adja.

A Gram–Schmidt-eljárás bármelyik változatával a kapott Q_1 mátrix ortogonalitása jelentősen javítható reortogonalizációval: egyszerűen ismételjük meg az eljárást Q_1-en. Ilyen reortogonalizáció ismételten is végezhető, iteratív finomítás gyanánt, de tipikusan már egyetlen reortogonalizáció is kielégítő eredményt ad.

3.11. Példa. Gram–Schmidt QR-felbontás. A módosított Gram–Schmidt-ortogonalizációt a 3.1. példa legkisebb négyzetes feladatnak megoldásával szemléltetjük. Az A első oszlopát normálva kapjuk:

$$r_{1,1} = \|a_1\|_2 = 1{,}7321, \qquad q_1 = a_1/r_{1,1} = \begin{bmatrix} 0{,}5774 \\ 0 \\ 0 \\ -0{,}5774 \\ -0{,}5774 \\ 0 \end{bmatrix}.$$

Az első oszlopot ortogonalizálva a rákövetkező oszlopokhoz képest, a következőt kapjuk:

$$r_{1,2} = q_1^T a_2 = -0{,}5774, \qquad r_{1,3} = q_1^T a_3 = -0{,}5774.$$

Levonva q_1 ezen többszöröseit a második, illetve a harmadik oszlopból, és q_1-et az első oszlop helyére írva, a transzformált mátrix:

$$\begin{bmatrix} 0{,}5774 & 0{,}3333 & 0{,}3333 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ -0{,}5774 & 0{,}6667 & -0{,}3333 \\ -0{,}5774 & -0{,}3333 & 0{,}6667 \\ 0 & -1 & 1 \end{bmatrix}.$$

A második oszlopot normálva kapjuk:

$$r_{2,2} = \|a_2\|_2 = 1{,}6330, \qquad q_2 = a_2/r_{2,2} = \begin{bmatrix} 0{,}2041 \\ 0{,}6124 \\ 0 \\ 0{,}4082 \\ -0{,}2041 \\ -0{,}6124 \end{bmatrix}.$$

A második oszlopot a harmadik oszlophoz képest ortogonalizálva:

$$r_{2,3} = q_2^T a_3 = -0{,}8165.$$

q_2 e többszörösét levonva a harmadik oszlopból, és q_2-t a második oszlop helyére írva, a transzformált mátrix:

$$\begin{bmatrix} 0{,}5774 & 0{,}2041 & 0{,}5 \\ 0 & 0{,}6124 & 0{,}5 \\ 0 & 0 & 1 \\ -0{,}5774 & 0{,}4082 & 0 \\ -0{,}5774 & -0{,}2041 & 0{,}5 \\ 0 & -0{,}6124 & 0{,}5 \end{bmatrix}.$$

Végül normáljuk a harmadik oszlopot:

$$r_{3,3} = \|a_3\|_2 = 1{,}4142, \qquad q_3 = a_3/r_{3,3} = \begin{bmatrix} 0{,}3536 \\ 0{,}3536 \\ 0{,}7071 \\ 0 \\ 0{,}3536 \\ 0{,}3536 \end{bmatrix}.$$

A harmadik oszlopot q_3-mal helyettesítve megkapjuk a redukált QR-felbontást:

$$A = \begin{bmatrix} 0{,}5774 & 0{,}2041 & 0{,}3536 \\ 0 & 0{,}6124 & 0{,}3536 \\ 0 & 0 & 0{,}7071 \\ -0{,}5774 & 0{,}4082 & 0 \\ -0{,}5774 & -0{,}2041 & 0{,}3536 \\ 0 & -0{,}6124 & 0{,}3536 \end{bmatrix} \begin{bmatrix} 1{,}7321 & -0{,}5774 & -0{,}5774 \\ 0 & 1{,}6330 & -0{,}8165 \\ 0 & 0 & 1{,}4142 \end{bmatrix} = Q_1 R.$$

Mivel a feladat jól kondicionált, a transzformált jobb oldalt biztonsággal kiszámíthatjuk explicit módon:

$$Q_1^T b = \begin{bmatrix} -376 \\ 1200 \\ 3417 \end{bmatrix} = c_1.$$

Az $Rx = c_1$ felső háromszögű rendszert visszahelyettesítéssel megoldva $x = [1236, 1943, 2416]^T$ adódik.

3.5.4 Ranghiány

Eddig feltettük, hogy A teljes oszloprangú, azaz $\operatorname{rank}(A) = n$. Ha ez nem teljesül, azaz ha A-nak lineárisan összefüggő oszlopai vannak, akkor a QR-felbontás még mindig létezik, de a felső háromszögű R faktor szinguláris (akárcsak az $A^T A$ mátrix). Így sok x vektor adja ugyanazt a minimális reziduumnormát, és a legkisebb négyzetek megoldás nem egyértelmű. Ez a helyzet rendszerint rosszul megtervezett kísérlet, hiányos adatok, vagy nem megfelelő, illetve redundáns modell következménye. Ezért a feladatot valószínűleg át kell fogalmazni vagy újra kell gondolni.

Ha mégis ragaszkodunk a továbblépéshez, bevett eljárás a minimális reziduumot adó megoldások közül a legkisebb euklideszi normájú x kiválasztása. Ez kiszámítható oszloponkénti főelemkiválasztással végzett QR-felbontással, amit alább tárgyalunk, vagy szingulárisérték-felbontással (SVD), amit a 3.6. szakaszban fogunk tárgyalni. Megjegyezzük, hogy a ranghiány ilyen kezelése lehetővé teszi az alulhatározott – $m < n$ – feladatok kezelését is, mert ebben az esetben A oszlopai szükségképpen lineárisan összefüggők.

3.12. Példa. Ranghiány. Tegyük fel, hogy a 3.1. példában szereplő földmérő csak az egyes dombpárok egymáshoz viszonyított relatív magasságát mérte meg, de egyik domb magasságát sem mérte meg közvetlenül a referenciaponthoz képest, így a 3×3-as lineáris egyenletrendszerünk:

$$Ax = \begin{bmatrix} -1 & 1 & 0 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 711 \\ 1177 \\ 475 \end{bmatrix} = b.$$

Elég információ áll-e még rendelkezésre a három domb magasságának meghatározásához? E kérdés megválaszolásához kiszámítjuk a QR-felbontást:

$$A = \begin{bmatrix} -0{,}7071 & 0{,}4082 & 0{,}5774 \\ -0{,}7071 & -0{,}4082 & -0{,}5774 \\ 0 & -0{,}8165 & 0{,}5774 \end{bmatrix} \begin{bmatrix} 1{,}4142 & -0{,}7071 & -0{,}7071 \\ 0 & 1{,}2247 & -1{,}2247 \\ 0 & 0 & 0 \end{bmatrix} = QR,$$

ami mutatja, hogy R szinguláris, és ezért A ranghiányos. Ebben az egyszerű példában ezt közvetlenül is láthattuk volna abból, hogy A minden sorösszege nulla (azaz $Ae = 0$), a gyakorlatban azonban a ranghiány ritkán ennyire nyilvánvaló.

A gyakorlatban egy mátrix rangja gyakran nem egyértelmű. Így a legkisebb négyzetes feladatok közeli ranghiányának kimutatására relatív tolerancia szolgál, pontosan úgy, mint a négyzetes lineáris egyenletrendszerek közeli szingularitásának kimutatására. Ha egy legkisebb négyzetes feladat majdnem ranghiányos, akkor a megoldás érzékeny lesz a bemeneti adatok perturbációira. Ezeket a kérdéseket pontosabban meg tudjuk majd vizsgálni, amikor a 3.6. szakaszban bevezetjük egy mátrix szinguláris érték-felbontását. A QR-felbontás keretein belül a ranghiány kimutatására és kezelésére egy megbízható módszer az oszloponkénti főelemkiválasztás, amit alább tárgyalunk.

3.13. Példa. Közeli ranghiány. Tekintsük a következő 3×2-es mátrixot:

$$A = \begin{bmatrix} 0{,}913 & 0{,}659 \\ 0{,}780 & 0{,}563 \\ 0{,}457 & 0{,}330 \end{bmatrix}.$$

Ha kiszámítjuk az A QR-felbontását, azt találjuk, hogy

$$R = \begin{bmatrix} -1{,}28484 & -0{,}92744 \\ 0 & 0{,}00013 \end{bmatrix}.$$

Tehát R rendkívül közel áll ahhoz, hogy szinguláris legyen, és ha R-et használjuk egy legkisebb négyzetes feladat megoldására, az eredmény ennek megfelelően érzékeny lesz a feladat adatainak perturbációira. Gyakorlati célokra az A rangja csak egy, nem pedig kettő, hiszen az oszlopai közel lineárisan összefüggők.

Az A mátrix oszlopait tekinthetjük vektorok rendezetlen halmazának, amelyből egy maximális lineárisan független részhalmazt szeretnénk kiválasztani. A QR-felbontás kiszámításakor ahelyett, hogy az oszlopokat a természetes sorrendjükben dolgoznánk fel, minden lépésben a hátralévő, még redukálatlan részmátrix maximális euklideszi normájú oszlopát választjuk ki redukálásra. Ezt az oszlopot (explicit módon vagy implicit módon) felcseréljük a természetes sorrendben következő oszloppal, majd az átló alatti részét a szokásos módon lenullázzuk. Az ehhez szükséges transzformációt ezután alkalmazni kell a hátralévő redukálatlan oszlopokra, majd az eljárást megismételjük. Az imént leírt folyamat neve az *oszloponkénti főelemkiválasztással végzett QR-felbontás*. Megjegyezzük, hogy az oszloponkénti főelemkiválasztás működésének feltétele, hogy a

QR-felbontási folyamat minden lépésében a hátralévő oszlopoknak ne legyen komponensük a már feldolgozott oszlopok irányában. Ez igaz a Householder-, a Givens- és a soronkénti módosított Gram–Schmidt-algoritmusra, de nem igaz az oszloponkénti Gram–Schmidt-algoritmusokra (sem a klasszikusra, sem a módosítottra), ezért ez utóbbiak nem használhatók oszloponkénti főelemkiválasztással.

Ha $\operatorname{rank}(A) = k < n$, akkor az oszloponkénti főelemkiválasztással végzett QR-felbontás k lépése után a hátralévő redukálatlan oszlopok normái a k-adik sor alatt nullák (vagy véges pontosságú aritmetikában „elhanyagolhatóak") lesznek. Így a következő alakú ortogonális felbontást állítottuk elő:

$$Q^T AP = \begin{bmatrix} R & S \\ O & O \end{bmatrix},$$

ahol R $k \times k$-as felső háromszögű és reguláris, P pedig az oszlopcseréket végrehajtó permutációs mátrix. Ezen a ponton az $Ax \cong b$ legkisebb négyzetes feladat egy bázismegoldása (azaz egy legfeljebb k darab nem nulla komponenssel rendelkező megoldás) kiszámítható úgy, hogy megoldjuk az $Rz = c_1$ háromszögű rendszert, ahol c_1 a $Q^T b$ vektor első k komponenséből álló vektor, majd vesszük

$$x = P \begin{bmatrix} z \\ 0 \end{bmatrix}.$$

Az adatillesztés szempontjából ez az eljárás azt jelenti, hogy figyelmen kívül hagyjuk a modell azon komponenseit, amelyek redundánsak vagy rosszul meghatározottak. Ha azonban a *minimális normájú megoldásra* van szükségünk, ez is kiszámítható, további ortogonális transzformációk költségén, amelyeket jobbról alkalmazunk, hogy S-et is nullázzuk.

3.14. Példa. Bázis- és minimális normájú megoldás. A 3.12. példát folytatva egy bázismegoldás az egyik dombhoz nulla magasságot rendel (hogy melyik dombot választjuk, az a QR-felbontásban szereplő P oszlop-permutációtól függ), ami ezután lehetővé teszi a másik két domb magasságának meghatározását ehhez képest egy kisebb rendszer megoldásával. Ebben a példában a harmadik dombnak nulla magasságot rendelve a $x^T = [-1180, -472, 0]$ bázismegoldást kapjuk (a negatív magasságok egyszerűen azt jelentik, hogy az első két domb a nulla magasságúnak választott domb alatt van). Megjegyezzük, hogy ez a megoldás nem elégíti ki egzaktul a lineáris egyenletrendszert (tükrözve azt, hogy a rendszer inkonzisztens, ami négyzetes rendszernél csak ranghiány esetén lehetséges), de ez egy (nem egyértelmű) legkisebb négyzetek megoldás. Ennek a ranghiányos feladatnak a minimális normájú megoldása $x^T = [-629, 79, 551]$ (lásd a 3.16. példát).

A gyakorlatban A rangja általában ismeretlen, ezért az oszloponkénti főelemkiválasztási folyamatot a rang felderítésére használjuk: a hátralévő redukálatlan oszlopok normáit figyeljük, és a felbontást akkor állítjuk le, amikor a maximális érték egy relatív tolerancia alá esik. QR-felbontáson alapuló, kifinomultabb rangfelderítő technikák is léteznek, valamint a szingulárisérték-felbontás, amely a rang numerikus meghatározásának legmegbízhatóbb (de legköltségesebb) módja (lásd a 3.6.1. szakaszt).

3.6 Szingulárisérték-felbontás

Akárcsak a négyzetes lineáris egyenletrendszereknél, egy diagonális lineáris legkisebb négyzetes feladat még könnyebben megoldható, mint egy háromszögű. Idézzük fel a háromszögű LU-felbontás

és a négyzetes mátrix Gauss–Jordan-eliminációval kapott diagonális felbontása közötti összefüggést (lásd a 2.4.8. szakaszt). Bizonyos mértékig hasonló módon a háromszögű QR-felbontáson túl is el lehet jutni: téglalap alakú mátrix diagonális felbontását is meg lehet kapni ortogonális transzformációkkal.

Egy $m \times n$-es A mátrix szinguláris érték-felbontása (SVD) a következő alakú:

$$A = U\Sigma V^T,$$

ahol az U egy $m \times m$-es ortogonális mátrix, a V egy $n \times n$-es ortogonális mátrix, a Σ pedig egy $m \times n$-es diagonális mátrix, amelyre

$$\sigma_{ij} = \begin{cases} 0 & \text{ha } i \neq j, \\ \sigma_i \geq 0 & \text{ha } i = j. \end{cases}$$

A σ_i diagonális elemeket az A mátrix szinguláris értékeinek nevezzük, és rendszerint úgy rendezzük őket, hogy $\sigma_{i-1} \geq \sigma_i$, $i = 2, \dots, \min\{m, n\}$. Az U u_i oszlopai, illetve a V v_i oszlopai az ezeknek megfelelő bal és jobb oldali szinguláris vektorok. Mivel az SVD kiszámítása szorosan kapcsolódik a sajátértékek kiszámításának algoritmusaihoz, az SVD kiszámításának tárgyalását a 4.7. szakaszra halasztjuk; az SVD alkalmazásait viszont itt tárgyaljuk, mivel a legkisebb négyzetek és kapcsolódó feladatok megoldásában fontos szerepet játszik.

3.15. Példa. Szinguláris érték-felbontás. Az

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix}$$

mátrix szinguláris érték-felbontása $U\Sigma V^T =$

$$\begin{bmatrix} 0{,}141 & 0{,}825 & -0{,}420 & -0{,}351 \\ 0{,}344 & 0{,}426 & 0{,}298 & 0{,}782 \\ 0{,}547 & 0{,}028 & 0{,}664 & -0{,}509 \\ 0{,}750 & -0{,}371 & -0{,}542 & 0{,}079 \end{bmatrix} \begin{bmatrix} 25{,}5 & 0 & 0 \\ 0 & 1{,}29 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0{,}504 & 0{,}574 & 0{,}644 \\ -0{,}761 & -0{,}057 & 0{,}646 \\ 0{,}408 & -0{,}816 & 0{,}408 \end{bmatrix}.$$

Tehát $\sigma_1 = 25{,}5$, $\sigma_2 = 1{,}29$ és $\sigma_3 = 0$. Egy nullával egyenlő szinguláris érték azt jelzi, hogy a mátrix ranghiányos; általánosabban egy mátrix rangja egyenlő a nem nulla szinguláris értékek számával, ami ebben a példában kettő.

Az SVD különösen rugalmas módszert nyújt tetszőleges alakú és rangú lineáris legkisebb négyzetes feladatok megoldására. Tekintsük először a túlhatározott, teljes rangú esetet. Ha A egy $m \times n$-es mátrix $\operatorname{rank}(A) = n$ esetén, akkor

$$A = U\Sigma V^T = \begin{bmatrix} U_1 & U_2 \end{bmatrix} \begin{bmatrix} \Sigma_1 \\ O \end{bmatrix} V^T = U_1 \Sigma_1 V^T,$$

ahol az U_1 egy $m \times n$-es, a Σ_1 pedig egy $n \times n$-es, reguláris mátrix; ez az A redukált, „takarékos méretű” SVD-je. Az $Ax \cong b$ legkisebb négyzetes feladat megoldását ekkor a

$$x = V\Sigma_1^{-1}U_1^T b$$

összefüggés adja, amint az A redukált SVD-jét a normálegyenletbe behelyettesítve könnyen ellenőrizhető. Általánosabban, tetszőleges alakú és rangú A esetén az $Ax \cong b$ legkisebb négyzetes feladat minimális euklideszi normájú megoldását a

$$x = \sum_{\sigma_i \neq 0} \frac{u_i^T b}{\sigma_i} v_i$$

összefüggés adja. Az SVD különösen hasznos rosszul kondicionált vagy közel ranghiányos feladatoknál, mert az összegzésből tetszőleges, relatív értelemben kicsi szinguláris értékek elhagyhatók, és így a megoldás jóval kevésbé érzékeny az adatok perturbációira.

3.16. Példa. Minimális normájú megoldás. A 3.12. példában szereplő A mátrix SVD-je $A = U\Sigma V^T =$

$$\begin{bmatrix} -0{,}707 & 0{,}408 & 0{,}577 \\ -0{,}707 & -0{,}408 & -0{,}577 \\ 0 & -0{,}816 & 0{,}577 \end{bmatrix} \begin{bmatrix} 1{,}732 & 0 & 0 \\ 0 & 1{,}732 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0{,}816 & -0{,}408 & -0{,}408 \\ 0 & 0{,}707 & -0{,}707 \\ -0{,}577 & -0{,}577 & -0{,}577 \end{bmatrix},$$

így a minimális euklideszi normájú legkisebb négyzetek megoldás:

$$x = \frac{u_1^T b}{\sigma_1} v_1 + \frac{u_2^T b}{\sigma_2} v_2 = \frac{-1335}{1{,}732} \begin{bmatrix} 0{,}816 \\ -0{,}408 \\ -0{,}408 \end{bmatrix} + \frac{-578}{1{,}732} \begin{bmatrix} 0 \\ 0{,}707 \\ -0{,}707 \end{bmatrix} = \begin{bmatrix} -629 \\ 79 \\ 551 \end{bmatrix}.$$

3.6.1 Az SVD további alkalmazásai

Az $A = U\Sigma V^T$ szingulárisérték-felbontásnak számos más fontos alkalmazása is van, köztük az alábbiak:

Euklideszi mátrixnorma. Az euklideszi vektornorma által indukált mátrixnormát a mátrix legnagyobb szinguláris értéke adja:

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sigma_{\max}.$$

Még nem áll módunkban belátni, miért igaz ez, mert sajátértékek (4. fejezet) és optimalizálás (6. fejezet) ismeretét igényli.

Euklideszi kondíciószám. Egy tetszőleges A mátrix euklideszi normában vett kondíciószámát a

$$\mathrm{cond}_2(A) = \sigma_{\max}/\sigma_{\min}$$

hányados adja. Ez a definíció egybeesik a $\mathrm{cond}(A)$ 2.3.3. szakaszban adott, négyzetes mátrixra vonatkozó – euklideszi normát használó – definíciójával, valamint a 3.3. szakaszban megadott, teljes oszloprangú túlhatározott mátrix kondíciószámával is. Ez mindkettőt általánosítja tetszőleges alakú és rangú téglalap alakú mátrixra. Figyeljük meg, hogy ezzel a definícióval, akárcsak korábban, $\mathrm{cond}_2(A) = \infty$ ha $\mathrm{rank}(A) < \min(m, n)$, mert ebben az esetben $\sigma_{\min} = 0$. Ahogyan egy négyzetes mátrix kondíciószáma a szingularitáshoz való közelséget méri, úgy egy téglalap alakú mátrix kondíciószáma a ranghiányhoz való közelséget méri.

3.17. Példa. Euklideszi mátrixnorma és kondíciószám. A 2.4. és 2.5. példában szereplő A mátrix SVD-je $A = U\Sigma V^T =$

$$\begin{bmatrix} 0{,}392 & -0{,}920 & -0{,}021 \\ 0{,}240 & 0{,}081 & 0{,}967 \\ 0{,}888 & 0{,}384 & -0{,}253 \end{bmatrix} \begin{bmatrix} 5{,}723 & 0 & 0 \\ 0 & 1{,}068 & 0 \\ 0 & 0 & 0{,}327 \end{bmatrix} \begin{bmatrix} 0{,}645 & -0{,}224 & 0{,}731 \\ -0{,}567 & 0{,}501 & 0{,}653 \\ 0{,}513 & 0{,}836 & -0{,}196 \end{bmatrix},$$

így

$$\|A\|_2 = 5{,}723, \quad \mathrm{cond}_2(A) = 5{,}723/0{,}327 = 17{,}5.$$

Rang meghatározása. Egy mátrix rangja egyenlő a nem nulla szinguláris értékeinek számával (lásd a 3.15. és 3.16. példát). A gyakorlatban azonban a rang nem feltétlenül egyértelmű, mert egyes szinguláris értékek nagyon kicsik lehetnek, de nem nullák. Sok célra célszerűbb elhanyagolhatónak tekinteni azokat a szinguláris értékeket, amelyek (a legnagyobb szinguláris értékhez viszonyítva) egy bizonyos küszöb alá esnek, és így határozni meg a mátrix „numerikus rangját”. Ennek egyik értelmezése, hogy az adott mátrix nagyon közel van (azaz az adott küszöbön belül) ahhoz a mátrixhoz, amelynek rangját így határoztuk meg. Az SVD használata a numerikus rang meghatározására megbízhatóbb (bár drágább), mint az oszloponkénti főelemkiválasztással végzett QR-felbontás használata (lásd a 3.5.4. szakaszt).

3.18. Példa. Rang meghatározása. A 3.13. példában szereplő A mátrix SVD-je $A = U\Sigma V^T =$

$$\begin{bmatrix} 0{,}71058 & -0{,}26631 & -0{,}65127 \\ 0{,}60707 & -0{,}23592 & 0{,}75882 \\ 0{,}35573 & 0{,}93457 & 0{,}00597 \end{bmatrix} \begin{bmatrix} 1{,}58460 & 0 \\ 0 & 0{,}00011 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0{,}81083 & 0{,}58528 \\ -0{,}58528 & 0{,}81083 \end{bmatrix}.$$

Tehát körülbelül 10^{-4} vagy nagyobb küszöb mellett a rangot egynek nyilvánítanánk, nem pedig kettőnek.

Pszeudoinverz. Egy σ skalár pszeudoinverzét $1/\sigma$-ként definiáljuk, ha $\sigma \neq 0$, egyébként nullaként. Egy (esetleg téglalap alakú) diagonális mátrix pszeudoinverzét a mátrix transzponálásával, majd minden elem skaláris pszeudoinverzének vételével definiáljuk. Ekkor egy általános $m \times n$-es A mátrix pszeudoinverzét a

$$A^+ = V\Sigma^+ U^T$$

összefüggés adja. Figyeljük meg, hogy a pszeudoinverz mindig létezik, függetlenül attól, hogy a mátrix négyzetes-e, vagy teljes rangú-e. Ha A négyzetes és reguláris, akkor a pszeudoinverz megegyezik a szokásos A^{-1} mátrixinverzzel. Ha A teljes oszloprangú, akkor ez a definíció egybeesik

a 3.3. szakaszban adottal (lásd a 3.33. feladatot). Minden esetben az $Ax \cong b$ legkisebb négyzetes feladat minimális euklideszi normájú megoldását A^+b adja.

3.19. Példa. Pszeudoinverz. A 3.16. példában látott SVD-ből azt látjuk, hogy a 3.12. példában szereplő A mátrix pszeudoinverze:

$$A^+ = \frac{1}{3}\begin{bmatrix} -1 & -1 & 0 \\ 1 & 0 & -1 \\ 0 & 1 & 1 \end{bmatrix},$$

így az $Ax \cong b$ legkisebb négyzetes feladat minimális euklideszi normájú megoldása:

$$x = A^+b = \frac{1}{3}\begin{bmatrix} -1 & -1 & 0 \\ 1 & 0 & -1 \\ 0 & 1 & 1 \end{bmatrix}\begin{bmatrix} 711 \\ 1177 \\ 475 \end{bmatrix} = \begin{bmatrix} -629 \\ 79 \\ 551 \end{bmatrix}.$$

Ortonormált bázisok. Ha $A = U\Sigma V^T$, akkor az U nem nulla szinguláris értékekhez tartozó oszlopai ortonormált bázist alkotnak a $\operatorname{span}(A)$ altérben, az U többi oszlopa pedig annak ortogonális kiegészítőjében, azaz a $\operatorname{span}(A)^\perp$ altérben. Hasonlóképpen, a V nulla szinguláris értékekhez tartozó oszlopai ortonormált bázist alkotnak az A nullterében, azaz az $\{x \in \mathbb{R}^n : Ax = 0\}$ altérben, a V többi oszlopa pedig a nulltér ortogonális kiegészítőjében.

Alacsonyabb rangú közelítés. Az SVD egy másik írásmódja:

$$A = U\Sigma V^T = \sigma_1 E_1 + \sigma_2 E_2 + \cdots + \sigma_n E_n,$$

ahol $E_i = u_i v_i^T$. Minden E_i egyrangú, és tárolása csupán $m + n$ memóriahelyet igényel. Ráadásul a $E_i x$ szorzat csupán $m + n$ szorzással képezhető. Így az A egy hasznos, tömörített közelítését kaphatjuk meg, ha a fenti összegzésből elhagyjuk a kisebb szinguláris értékekhez tartozó tagokat, hiszen azok az összeghez viszonylag keveset tesznek hozzá. Megmutatható, hogy a k legnagyobb szinguláris értékkel kapott közelítés a Frobenius-normában az A-hoz legközelebbi k rangú mátrix. (Egy $m \times n$-es mátrix Frobenius-normája a mátrix $\mathbb{R}^{mn}$-beli vektornak tekintett euklideszi normája.) Ez a közelítés hasznos a képfeldolgozásban, az adattömörítésben, az információ-visszakeresésben, a kriptográfiában és számos más alkalmazásban.

3.20. Példa. Alacsonyabb rangú közelítés. A 3.13. példában megadott A mátrix 3.18. példában látott SVD-jéből azt látjuk, hogy az

$$\sigma_1 E_1 = \sigma_1 u_1 v_1^T = 1{,}58460 \begin{bmatrix} 0{,}71058 \\ 0{,}60707 \\ 0{,}35573 \end{bmatrix} \begin{bmatrix} 0{,}81083 & 0{,}58528 \end{bmatrix} = \begin{bmatrix} 0{,}91298 & 0{,}65902 \\ 0{,}77999 & 0{,}56302 \\ 0{,}45706 & 0{,}32992 \end{bmatrix}$$

egyrangú mátrix rendkívül közeli közelítése az eredeti A mátrixnak, mert σ_2 olyan kicsi, hogy a hozzá tartozó tag szinte semmit sem tesz hozzá az összeghez.

Teljes legkisebb négyzetek. Egy közönséges $Ax \cong b$ lineáris legkisebb négyzetes feladatban implicit módon feltesszük, hogy az A elemei pontosan ismertek, míg a b elemei véletlen hibával terheltek, és ez indokolja az adatpontok és a görbe közötti függőleges távolságok minimalizálását. Amikor azonban az összes változó mérési hibával vagy egyéb bizonytalansággal terhelt, értelmesebb lehet az

adatpontok és a görbe közötti ortogonális távolságok minimalizálása; ez a *teljes legkisebb négyzetek* feladatmegoldást adja. Idézzük fel, hogy a közönséges legkisebb négyzetek esetén az $\|b - y\|_2$-t szeretnénk minimalizálni az $y \in \operatorname{span}(A)$ feltétel mellett, azaz a legközelebbi kompatibilis rendszert keressük, és csak a jobb oldalt engedjük változni. A teljes legkisebb négyzetek esetén is a legközelebbi kompatibilis rendszert keressük, de most a mátrix és a jobb oldal is változhat. Ahogy az előző bekezdésben láttuk, az ilyen mátrixközelítési feladat a szingulárisérték-felbontással megoldható. Nevezetesen, tekintsük az $m \times (n+1)$-es $[A\ b] = U\Sigma V^T$ SVD-jét. Ahhoz, hogy a közelítő $[\hat{A}\ y]$ rendszer kompatibilis legyen, azaz $y \in \operatorname{span}(\hat{A})$ teljesüljön, a rangjának legfeljebb n-nek kell lennie. Ahogy láttuk, a legközelebbi n rangú közelítő mátrixot úgy kapjuk meg, hogy az első n szinguláris értéket tartjuk meg, és σ_{n+1}-et elhagyjuk. A keletkező kompatibilis rendszer x megoldásának ki kell elégítenie a

$$[\hat{A}\ y] \begin{bmatrix} x \\ -1 \end{bmatrix} = 0$$

egyenletet, amiből látszik, hogy $[x^T\ -1]^T$-nek a $[\hat{A}\ y]$ nullterében kell lennie, ami viszont azt jelenti, hogy $[x^T\ -1]^T$ arányos v_{n+1}-gyel, azaz a σ_{n+1}-nek megfelelő jobb oldali szinguláris vektorral. Így a megoldás megszerzéséhez csupán annyit kell tennünk, hogy v_{n+1}-et úgy skálázzuk, hogy az utolsó komponense -1 legyen. Arra a következtetésre jutunk tehát, hogy amennyiben $\sigma_{n+1} < \sigma_n$ és $v_{n+1,n+1} \neq 0$, a teljes legkisebb négyzetek megoldását az

$$x = -\frac{1}{v_{n+1,n+1}} \begin{bmatrix} v_{1,n+1} \\ \vdots \\ v_{n,n+1} \end{bmatrix}$$

összefüggés adja. Általánosabb feladatok – például több jobb oldallal, vagy ha a változók egy része pontosan ismert – hasonló módon kezelhetők, de lényegesen bonyolultabbak (a részletekhez lásd [478]-at).

3.21. Példa. Teljes legkisebb négyzetek. Tekintsük az

$$f(t, x) = xt$$

modellfüggvény (azaz egy origón átmenő, meghatározandó x meredekségű egyenes) illesztését a következő adatpontokhoz:

t	-2	-1	3
y	-1	3	-2

Az y értékeknek t függvényeként való illesztése akkor célszerű, ha az y adatok hibával terheltek, a t-re vonatkozó adatok viszont pontosak. Az így kapott közönséges legkisebb négyzetek illesztés, amely a 3.5(a). ábrán látható, az egyenes és az adatpontok közötti függőleges távolságok négyzetösszegét minimalizálja, ami $x = -0{,}5$ meredekséget ad. Ha azonban a t-re vonatkozó adatok éppúgy hibával terheltek, akár meg is fordíthattuk volna a szerepeket, és t-t illeszthettük volna y függvényében. Az így kapott közönséges legkisebb négyzetek illesztés, amely a 3.5(b). ábrán látható, az egyenes és az adatpontok közötti vízszintes távolságok négyzetösszegét minimalizálja, ami $x = -2$ meredekséget ad. Ilyen helyzetben mindkettőnél jobb stratégia a teljes legkisebb négyzetek, amely minden adatot

egyenrangúan kezel. Az így kapott illesztés, amely a 3.5(c). ábrán látható, az egyenes és az adatpontok közötti legrövidebb (azaz merőleges) távolságok négyzetösszegét minimalizálja, ami $x = -1$ meredekséget ad. Ahhoz, hogy ezt az utóbbi illesztést hogyan kaptuk, észrevesszük, hogy ennek a feladatnak az A mátrixa csak egyetlen oszlopot tartalmaz, ezért kiszámítjuk az

$$[A\ b] = [t\ y] = \begin{bmatrix} -2 & -1 \\ -1 & 3 \\ 3 & -2 \end{bmatrix} =$$

$$\begin{bmatrix} -0{,}154 & 0{,}802 & 0{,}577 \\ -0{,}617 & -0{,}535 & 0{,}577 \\ 0{,}772 & -0{,}267 & 0{,}577 \end{bmatrix} \begin{bmatrix} 4{,}583 & 0 \\ 0 & 2{,}646 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0{,}707 & -0{,}707 \\ -0{,}707 & -0{,}707 \end{bmatrix} = U\Sigma V^T$$

SVD-t, így

$$x = -(1/v_{2,2})\, v_{1,2} = -(1/(-0{,}707))\,(-0{,}707) = -1.$$

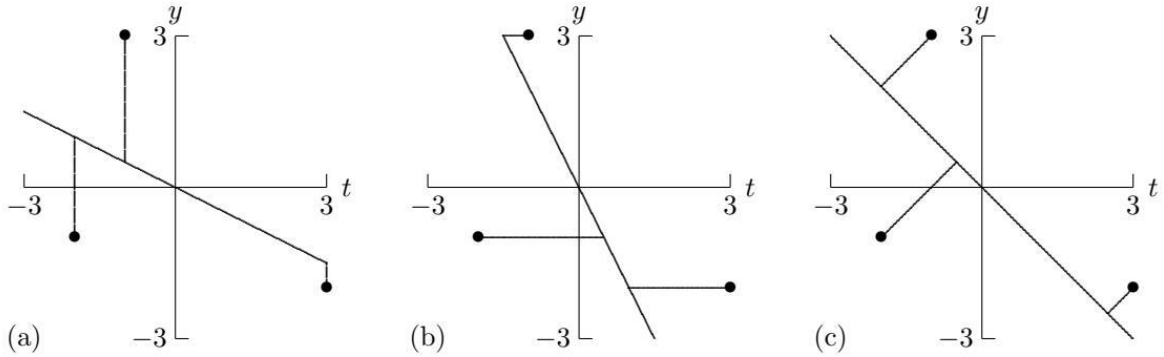

3.5. ábra: Egyenes közönséges és teljes legkisebb négyzetes illesztése adott adatokra.

3.7 Módszerek összehasonlítása

Eddig több módszert is láttunk legkisebb négyzetes feladatok megoldására. Hogy közülük melyiket választjuk, az a konkrét megoldandó feladattól függ, és a hatékonyság, a pontosság és a megbízhatóság közötti átváltásokkal jár.

A normálegyenletek módszere könnyen megvalósítható: csupán mátrixszorzást és Cholesky-felbontást igényel. Ráadásul rendkívül vonzó, hogy $m \gg n$ esetén a feladatot egy $n \times n$-es rendszerre redukálja. Ha kihasználjuk a szimmetriáját, az $A^T A$ keresztszorzat-mátrix előállítása körülbelül $mn^2/2$ szorzást és hasonló számú összeadást igényel. A keletkező lineáris egyenletrendszer megoldása Cholesky-felbontással körülbelül $n^3/6$ szorzást és hasonló számú összeadást igényel. Sajnos a normálegyenletek módszere olyan megoldást ad, amelynek relatív hibája $[\mathrm{cond}(A)]^2$-tel arányos, a szükséges Cholesky-felbontás pedig $\mathrm{cond}(A) \approx 1/\sqrt{\epsilon_{\mathrm{mach}}}$ vagy rosszabb esetén várhatóan meghiúsul.

Sűrű lineáris legkisebb négyzetes feladatok megoldására a Householder-módszer általában a leghatékonyabb és legpontosabb az ortogonalizációs módszerek közül. Körülbelül $mn^2 - n^3/3$ szorzást és hasonló számú összeadást igényel. Megmutatható, hogy a Householder-módszer olyan

megoldást ad, amelynek relatív hibája $\mathrm{cond}(A) + \|r\|_2[\mathrm{cond}(A)]^2$-tel arányos, ami a lehető legjobb, mivel ez a legkisebb négyzetes feladat megoldásának belső érzékenysége (idézzük fel a 3.3. szakaszt). Ráadásul a Householder-módszer (a visszahelyettesítési fázisban) csak akkor várhatóan hiúsul meg, ha $\mathrm{cond}(A) \approx 1/\epsilon_{\mathrm{mach}}$ vagy rosszabb.

Majdnem négyzetes feladatokra, $m \approx n$ esetén a normálegyenletek módszere és a Householder-módszer körülbelül ugyanannyi munkát igényel. Erősen túlhatározott feladatokra azonban, $m \gg n$, a Householder-módszer körülbelül kétszer annyi munkát igényel, mint a normálegyenletek módszere. Másrészt a Householder-módszer pontosabb és szélesebb körben alkalmazható, mint a normálegyenletek módszere. Ezek az előnyök azonban nem feltétlenül érik meg a többletköltséget, ha a feladat elég jól kondicionált ahhoz, hogy a normálegyenletek módszere kellően pontos eredményt szolgáltasson. Ranghiányos vagy közel ranghiányos feladatokra természetesen az oszloponkénti főelemkiválasztással végzett Householder-módszer használható eredményt adhat ott is, ahol a normálegyenletek módszere egyenesen meghiúsulna.

Végül az SVD a legköltségesebb módszer: költsége $mn^2 + n^3$-tel arányos, az arányossági állandó pedig 4-től 10-ig vagy annál is tovább terjedhet, az alkalmazott konkrét algoritmustól függően (lásd a 4.7. szakaszt). Így az SVD kiemelkedő robusztusságának és megbízhatóságának magas az ára, amit mindazonáltal különösen kritikus vagy kényes helyzetekben érdemes lehet megfizetni.

3.8 Szoftverek lineáris legkisebb négyzetes feladatokhoz

A 3.1. táblázat a lineáris legkisebb négyzetes feladatok megoldására alkalmas rutinok listáját tartalmazza, mind teljes rangú, mind ranghiányos esetre. A felsorolt rutinok többsége QR-felbontáson alapul. Sok csomag SVD-hez is tartalmaz szoftvert, amely – nagyobb számítási költséggel – szintén használható legkisebb négyzetes feladatok megoldására. Az SVD különösen megbízható módszert ad a numerikus rang meghatározására és a lehetséges ranghiány kezelésére (lásd a 3.6. szakaszt). Mivel az SVD kiszámításának módszerei szorosan kapcsolódnak a sajátérték-számítás módszereihez (lásd a 4.7. szakaszt), az SVD kiszámítására szolgáló szoftvereket a sajátértékekre és sajátvektorokra vonatkozó szoftverekkel együtt a 4.2. táblázat sorolja fel. A teljes legkisebb négyzetes feladatok megoldására – ahol az összes változó véletlen hibával terhelt – a `dtls` rutin elérhető a Netlibről.

Az $Ax \cong b$ lineáris legkisebb négyzetes feladatok megoldására szolgáló hagyományos szoftver olykor egyetlen rutinként van megvalósítva, de felosztható két rutinra is: az egyik a felbontás kiszámítására, a másik a keletkező háromszögű rendszer megoldására szolgál. A tipikusan megkövetelt bemenet a következőket tartalmazza: egy kétdimenziós tömb az A mátrixszal, egy egydimenziós tömb a b jobb oldali vektorral (vagy egy kétdimenziós tömb több jobb oldali vektorra), a mátrix m sorainak és n oszlopainak száma, az A-t tartalmazó tömb vezető dimenziója (hogy a szubrutin helyesen tudja értelmezni a tömbindexeket), valamint esetenként némi munkaterület és egy zászló az elvégzendő konkrét feladat jelzésére.

Forrás	Felbontás	Megoldás	Ranghiányos
FMM [152]	`svd`		`svd`
GSL	`gsl_linalg_QR_decomp`	`gsl_linalg_QR_solve`	`gsl_linalg_QRPT_decomp`
IMSL	`lqrrr`	`lqrsl`	`lsqrr`
KMN [262]	`sqrls`	`sqrls`	`ssvdc`
LAPACK [9]	`sgeqrf`	`sormqr` / `strtrs`	`sgeqpf` / `stzrqf`

Forrás	Felbontás	Megoldás	Ranghiányos
Lawson & Hanson [299]	`hft`	`hs1`	`hfti`
LINPACK [116]	`sqrdc`	`sqrsl`	`sqrst`
MATLAB	`qr`	`\`	`svd`
NAG	`f08aef`	`f08agf` / `f07tef`	`f04jgf`
NAPACK [220]	`qr`	`over`	`sing` / `rsolve`
NR [377]	`qrdcmp`	`qrsolv`	`svdcmp` / `svbksb`
NUMAL [297]	`lsqortdec`	`lsqsol`	`solovr`
SciPy	`linalg.qr`	`linalg.solve_triangular`	`linalg.qr`
SLATEC	`sqrdc`	`sqrsl`	`llsia` / `sglss` / `minfit`
SOL [509]	`hredl`	`qrvslv`	`mnlnls`

A megjelent formájában a `qrdcmp` és a `qrsolv` csak négyzetes mátrixokat kezel, de könnyen módosíthatók téglalap alakú mátrixok kezelésére.

3.1. táblázat: Szoftverek lineáris legkisebb négyzetes feladatokhoz.

A felhasználónak adott esetben egy toleranciát is meg kell adnia, ha oszloponkénti főelemkiválasztás vagy más rang-meghatározási módszer alkalmazására kerül sor. Visszatéréskor az x megoldás rendszerint felülírja a b memóriáját, a felbontás pedig az A memóriáját.

A MATLAB-ban a négyzetes lineáris egyenletrendszerek megoldására használt bal oldali osztás operátor téglalap alakú rendszerekre is kiterjesztésre került. Így az $Ax \cong b$ túlhatározott rendszer legkisebb négyzetek megoldását az `x = A \ b` utasítás adja. A megoldást belsőleg QR-felbontással számítja, de a felhasználónak erről nem kell tudnia. A QR-felbontás kifejezetten is kiszámítható, ha szükséges, a MATLAB `qr` függvényével: `[Q, R] = qr(A)`. A szingulárisérték-felbontást kiszámító MATLAB-függvény alakja `[U, S, V] = svd(A)`.

A táblázatban felsoroltakhoz hasonló matematikai szoftverkönyvtárakon kívül számos statisztikai csomag terjedelmes szoftverrel rendelkezik a legkisebb négyzetes feladatok különféle kontextusban történő megoldására, és ezek gyakran számos diagnosztikai lehetőséget is tartalmaznak az eredmények minőségének értékelésére. Ebbe a kategóriába tartozó ismert csomagok a BMDP, a JMP, a Minitab, az R, az S, a SAS, az SPSS, a Stata és a Statistica. Elérhető egy statisztikai eszköztár (*toolbox*) MATLAB-hoz, valamint könyvtárak a Pythonhoz, például a pandas és a statsmodels. További szoftver is rendelkezésre áll olyan adatillesztéshez, amely nem a legkisebb négyzetek, hanem más kritériumok alapján történik – különösen az 1-norma és a ∞-norma alapján –, amelyek bizonyos kontextusokban kedvezőbbek.

3.9 Történeti jegyzetek és további olvasnivaló

A legkisebb négyzetek módszerét, amely a normálegyenleteken alapul, Gauss fogalmazta meg és használta 1795-ben, először azonban Legendre publikálta 1805-ben, ami elsőbbségi vitához vezetett (lásd [374]-et). A Gram–Schmidt-ortogonalizációt Gram fogalmazta meg 1883-ban, majd modern algoritmikus formában Schmidt adta meg 1907-ben. A Gram–Schmidt „módosított” változata valójában idősebb a „klasszikus” változatnál: Laplace vezette le 1816-ban, numerikus fölényét azonban csak 1966-ban ismerte fel Rice. A QR-felbontás kiszámításának Householder-féle módszerét

1958-ban publikálták, bár elemi reflektorokat (amelyeket ma Householder-transzformációknak nevezünk) Turnbull és Aitken már 1932-ben használt, egy másik célból. A QR-felbontás kiszámításának Givens-féle módszerét szintén 1958-ban publikálták, bár síkbeli forgatásokat Jacobi már egy évszázaddal korábban használt sajátértékek kiszámítására (lásd a 4.5.8. szakaszt). A QR-felbontás – és különösen a Householder-módszer – legkisebb négyzetes feladatok megoldására való felhasználását Golub tette népszerűvé 1965-ben [194]. A legkisebb négyzetes feladat számításainak átfogó kézikönyvei közé tartoznak [39, 136, 229, 299]. A 2.8. szakaszban hivatkozott, mátrixszámításokkal foglalkozó könyvek szintén tárgyalják részletesen a lineáris legkisebb négyzetes feladatokat. A ranghiány kezelésére szolgáló technikák tárgya [226, 228]. A teljes legkisebb négyzetek alapos tárgyalása – amely akkor megfelelő, ha minden változó véletlen hibával terhelt – megtalálható [477, 478]-ban. A legkisebb négyzetes feladatok számításainak statisztikai nézőpontú tárgyalásához lásd [178, 179, 273, 335, 452]-t.

A legkisebb négyzetes feladatok legegyszerűbb típusával foglalkoztunk, amelyben a modellfüggvény lineáris és minden adatpont egyenlő súllyal szerepel. A nemlineáris legkisebb négyzetes feladatokat a 6.6. szakaszban tárgyaljuk. Az adatpontok változó súlyainak vagy a változók közötti általánosabb keresztkorrelációknak a figyelembevétele a tárgyalt keretben viszonylag egyszerű. Az adatpontok változó súlyainak engedélyezése például mindössze annyit jelent, hogy a legkisebb négyzetek rendszer mindkét oldalát megszorozzuk egy megfelelő diagonális mátrixszal.

A szingulárisérték-felbontást egymástól függetlenül Beltrami fogalmazta meg 1873-ban és Jordan 1874-ben, mindketten kvadratikus alakok kapcsán. Az SVD mátrixokra vonatkozó definícióját az 1930-as években Eckart és Young dolgozta ki, akik a 3.6.1. szakaszban idézett alacsonyabb rangú közelítési tételt is bizonyították. A szingulárisérték-felbontás részletes történetéhez lásd [427]-et. A szingulárisérték-felbontásnak a törzsanyagban tárgyaltakon kívül az alkalmazások széles köre ismert, köztük a képfeldolgozás [11], a jelfeldolgozás [470], az irányítás [336], a geofizika [250], az információ-visszakeresés [36] és a kriptográfia [332]. A pszeudoinverzt – az itt adott definícióban – Moore fogalmazta meg 1920-ban, majd Penrose tette népszerűvé 1955-ben, hatalmas szakirodalmat indítva útjára.

Áttekintő kérdések

- **3.1.** Igaz vagy hamis: Egy lineáris legkisebb négyzetes feladatnak mindig van megoldása.
- **3.2.** Igaz vagy hamis: Egyenes illesztése adatpontok halmazához lineáris legkisebb négyzetes feladat, míg másodfokú polinom illesztése ugyanezen adatokhoz nemlineáris legkisebb négyzetes feladat.
- **3.3.** Igaz vagy hamis: Az $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldásában az $r = b - Ax$ reziduumvektor ortogonális a $\mathrm{span}(A)$ altérre.
- **3.4.** Igaz vagy hamis: Egy túlhatározott $Ax \cong b$ lineáris legkisebb négyzetes feladatnak mindig van olyan egyértelmű x megoldása, amely minimalizálja az $r = b - Ax$ reziduumvektor euklideszi normáját.
- **3.5.** Igaz vagy hamis: Egy $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldásakor, ha a b vektor a $\mathrm{span}(A)$-ban fekszik, akkor a reziduum 0.
- **3.6.** Igaz vagy hamis: Egy $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldásakor, ha a reziduum 0, akkor az x megoldás szükségképpen egyértelmű.
- **3.7.** Igaz vagy hamis: Egy Householder-transzformáció és egy Givens-forgatás szorzata mindig ortogonális mátrix.
- **3.8.** Igaz vagy hamis: Ha az $n \times n$-es Q mátrix egy Householder-transzformáció, és x egy tetszőleges n-dimenziós vektor, akkor a Qx vektor utolsó k komponense nulla valamely $k < n$-

re.

- **3.9.** Igaz vagy hamis: Az ortogonális felbontáson alapuló módszerek általában számítási szempontból költségesebbek, mint a normálegyenleteken alapuló módszerek a lineáris legkisebb négyzetes feladatok megoldására.
- **3.10.** (a) Egy adatillesztési feladatban, ahol m darab (t_i, y_i) adatpontot illesztünk egy $f(t, x)$ modellfüggvénnyel – ahol t a független változó, x pedig a meghatározandó paraméterek n-dimenziós vektora –, mit jelent az, hogy f lineáris az x komponenseiben? (b) Adj példát ilyen értelemben vett lineáris $f(t, x)$ modellfüggvényre. (c) Adj példát nemlineáris $f(t, x)$ modellfüggvényre.
- **3.11.** Egy $Ax \cong b$ lineáris legkisebb négyzetes feladatban, ahol A egy $m \times n$-es mátrix, ha $\text{rank}(A) < n$, akkor az alábbi helyzetek közül melyek lehetségesek? (a) Nincs megoldás. (b) Egyetlen megoldás van. (c) Van megoldás, de nem egyértelmű.
- **3.12.** Egy túlhatározott $Ax \cong b$ legkisebb négyzetes feladat megoldásakor melyik volna a súlyosabb nehézség: ha A sorai lineárisan összefüggők, vagy ha A oszlopai lineárisan összefüggők? Magyarázd meg.
- **3.13.** Egy túlhatározott lineáris legkisebb négyzetes feladatban, ahol a modellfüggvény $f(t, x) = x_1\varphi_1(t) + x_2\varphi_2(t) + x_3\varphi_3(t)$, mi lesz a kapott legkisebb négyzetes A mátrix rangja, ha $\varphi_1(t) = 1$, $\varphi_2(t) = t$ és $\varphi_3(t) = 1 - t$?
- **3.14.** Mi az $Ax \cong b$ lineáris legkisebb négyzetes feladat normálegyenleteinek rendszere?
- **3.15.** Sorolj fel két módot, amelyeken a normálegyenletek használata a lineáris legkisebb négyzetes feladatok megoldására a numerikus pontosság elvesztésétől szenvedhet.
- **3.16.** Legyen A egy $m \times n$-es mátrix. Milyen feltételek mellett lesz az $A^T A$ mátrix (a) szimmetrikus? (b) reguláris? (c) pozitív definit?
- **3.17.** Egy $m \times n$-es A mátrix $(m > n)$ alábbi tulajdonságai közül melyek jelzik, hogy az $Ax \cong b$ legkisebb négyzetes feladat minimális reziduumú megoldása nem egyértelmű? (a) A oszlopai lineárisan összefüggők. (b) A sorai lineárisan összefüggők. (c) Az $A^T A$ mátrix szinguláris.
- **3.18.** (a) Használható-e a főelemkiválasztással végzett Gauss-elimináció arra, hogy egy téglalap alakú $m \times n$-es A mátrix LU-felbontását kiszámítsuk, ahol L egy $m \times k$-s mátrix, amelynek a főátló feletti összes eleme nulla, U egy $k \times n$-es mátrix, amelynek a főátló alatti összes eleme nulla, és $k = \min\{m, n\}$? (b) Ha ez lehetséges volna, megoldási módot adna-e egy $Ax \cong b$ túlhatározott legkisebb négyzetes feladatra, ahol $m > n$? Miért?
- **3.19.** (a) Mit jelent az, hogy két x és y vektor ortogonális egymásra? (b) Bizonyítsd be, hogy ha két nem nulla vektor ortogonális egymásra, akkor szükségképpen lineárisan függetlenek is. (c) Adj példát $\mathbb{R}^2$-ben két olyan nem nulla vektorra, amelyek ortogonálisak egymásra. (d) Adj példát $\mathbb{R}^2$-ben két olyan nem nulla vektorra, amelyek nem ortogonálisak egymásra. (e) Sorolj fel két módot, ahogyan az ortogonalitás fontos a lineáris legkisebb négyzetes feladatok kontextusában.
- **3.20.** Az euklideszi n-dimenziós térben tranzitív reláció-e az ortogonalitás? Azaz ha x ortogonális y-ra, és y ortogonális z-re, akkor x szükségképpen ortogonális-e z-re?
- **3.21.** Mit értünk ortogonális projektor alatt? Miért releváns ez a fogalom a lineáris legkisebb négyzetek szempontjából?
- **3.22.** (a) Miért használnak gyakran ortogonális transzformációkat – például Householder- vagy Givens-típusúakat – a legkisebb négyzetes feladatok megoldására? (b) Miért nem használják gyakran az ilyen módszereket négyzetes lineáris egyenletrendszerek megoldására? (c) Van-e valamilyen előnye az ortogonális transzformációknak a Gauss-eliminációval szemben a négyzetes lineáris egyenletrendszerek megoldásában? Ha igen, nevezz meg egyet.

- **3.23.** Az alábbi mátrixok közül melyek ortogonálisak? (a) $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ (b) $\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ (c) $\begin{bmatrix} 2 & 0 \\ 0 & 1/2 \end{bmatrix}$ (d) $\begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \\ -\sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}$
- **3.24.** Egy $n \times n$-es ortogonális mátrix szükségképpen mely tulajdonságokkal rendelkezik az alábbiak közül? (a) Nemszinguláris. (b) Megőrzi egy vektor euklideszi normáját, amikor a vektorral szorozzák. (c) A transzponáltja az inverze. (d) Az oszlopai ortonormáltak. (e) Szimmetrikus. (f) Diagonális. (g) Az euklideszi mátrixnormája 1. (h) Az euklideszi kondíciószáma 1.
- **3.25.** Az alábbi mátrixtípusok közül melyek szükségképpen ortogonálisak? (a) Permutáció. (b) Szimmetrikus pozitív definit. (c) Householder-transzformáció. (d) Givens-forgatás. (e) Nemszinguláris. (f) Diagonális.
- **3.26.** Mutasd meg, hogy egy ortogonális mátrixszal való szorzás megőrzi egy vektor euklideszi normáját.
- **3.27.** Milyen feltételt kell teljesítenie egy nem nulla n-dimenziós w vektornak ahhoz, hogy a $H = I - 2ww^T$ mátrix ortogonális legyen?
- **3.28.** Ha Q egy olyan 2×2-es ortogonális mátrix, amelyre

$$Q \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha \\ 0 \end{bmatrix},$$

akkor mi α értéke?

- **3.29.** Hány skalárszorzásra van szükség ahhoz, hogy egy tetszőleges n-dimenziós vektort megszorozzunk egy $n \times n$-es $H = I - 2ww^T$ Householder-transzformációs mátrixszal, ahol w egy n-dimenziós vektor $\|w\|_2 = 1$-gyel?
- **3.30.** Adott egy a vektor; egy olyan H Householder-transzformáció tervezésekor, amelyre $Ha = \alpha e_1$, tudjuk, hogy $\alpha = \pm\|a\|_2$. Milyen alapon kell az előjelet megválasztani?
- **3.31.** Sorolj fel egy előnyt és egy hátrányt, amelyeket a Givens-forgatások nyújtanak a QR-felbontásban a Householder-transzformációkkal szemben.
- **3.32.** Amikor egy 2-dimenziós vektor második komponensének nullázására használjuk, mindig ugyanazt az eredményt adja-e egy Householder-transzformáció, mint egy Givens-forgatás?
- **3.33.** Az A mátrixot tartalmazó – felülírható – bemeneti tömbön túl mennyi további kisegítő tömbmemória szükséges az alábbiak kiszámításához és tárolásához? (a) A LU-felbontása részleges főelemkiválasztással végzett Gauss-eliminációval, ahol A egy $n \times n$-es mátrix. (b) A QR-felbontása Householder-transzformációkkal, ahol A egy $m \times n$-es mátrix.
- **3.34.** Egy $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldásakor – ahol A egy $m \times n$-es mátrix, $m \geq n$ és $\operatorname{rank}(A) < n$ – a legkisebb négyzetes megoldási folyamat melyik pontján fog megakadni (egzakt aritmetikát feltételezve)? (a) A normálegyenletek Cholesky-felbontással történő megoldása esetén. (b) Householder-transzformációkkal végzett QR-felbontás esetén.
- **3.35.** A klasszikus Gram–Schmidt-eljáráshoz képest az alábbiak közül melyek a módosított Gram–Schmidt-ortogonalizáció előnyei? (a) Kevesebb memóriát igényel. (b) Kevesebb munkát igényel. (c) Numerikusan stabilabb.
- **3.36.** Egy $m \times n$-es mátrix ($m \geq n$) QR-felbontásához n-nek milyen nagynak kell lennie, mielőtt a klasszikus és a módosított Gram–Schmidt-eljárás között különbség mutatkozna?
- **3.37.** Magyarázd meg, miért igényel kevesebb memóriát a Householder-módszer az A mátrix QR-felbontásának kiszámítására, mint a módosított Gram–Schmidt-módszer.

- **3.38.** Magyarázd meg, hogyan használható az oszloponkénti főelemkiválasztással végzett QR-felbontás egy mátrix rangjának meghatározására.
- **3.39.** Magyarázd meg, hogy az oszloponkénti főelemkiválasztás miért használható a módosított Gram–Schmidt-ortogonalizációs eljárással, a klasszikus Gram–Schmidt-eljárással azonban nem.
- **3.40.** Az A mátrix kondíciószámának függvényében hasonlítsd össze a normálegyenletek módszerének és a Householder-féle QR-módszernek az alkalmazhatósági tartományát az $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldására [azaz $\mathrm{cond}(A)$ mely értékeire várható, hogy az egyes módszerek megakadnak?].
- **3.41.** Legyen A egy $m \times n$-es mátrix. (a) Mi a legnagyobb száma azoknak a nem nulla szinguláris értékeknek, amelyek A-nak lehetnek? (b) Ha $\mathrm{rank}(A) = k$, hány nem nulla szinguláris értéke van A-nak?
- **3.42.** Legyen a egy nem nulla oszlopvektor. $n \times 1$-es mátrixnak tekintve a-nak csak egyetlen pozitív szinguláris értéke van. Mennyi ez az érték?
- **3.43.** Fejezd ki egy mátrix euklideszi kondíciószámát a szinguláris értékeivel.
- **3.44.** Sorolj fel két megbízható módszert egy téglalap alakú mátrix rangjának numerikus meghatározására.
- **3.45.** Ha A egy $2n \times n$-es mátrix, rangsorold az alábbi módszereket az $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldásához szükséges munka mennyisége szerint. (a) Householder-transzformációkkal végzett QR-felbontás. (b) Normálegyenletek. (c) Szingulárisérték-felbontás.
- **3.46.** Sorolj fel legalább két alkalmazást egy mátrix szingulárisérték-felbontására (SVD) a legkisebb négyzetes feladatok megoldásán kívül.

Feladatok

- **3.1.** Ha egy függőleges tartóra a rúd alsó végén lefelé ható erő nehezedik, akkor a tartó megnyúlásának mértéke arányos lesz az erő nagyságával. Így a tartó teljes y hosszát az

$$y = x_1 + x_2 t$$

egyenlet adja, ahol x_1 az eredeti hossza, t a ható erő, x_2 pedig az arányossági állandó. Tegyük fel, hogy az alábbi méréseket végezzük:

t	10	15	20
y	11,60	11,85	12,25

- (a) Írd fel a gyűjtött adatoknak megfelelő 3×2-es túlhatározott lineáris egyenletrendszert!
- (b) Konzisztens-e ez a rendszer? Ha nem, számítsd ki (x_1, x_2) minden lehetséges értékpárját, amelyet a rendszerből bármely két egyenlet kiválasztásával kapunk! Van-e bármilyen ok, amiért ezen eredmények közül bármelyiket előnyben részesítenénk?
- (c) Írd fel a normálegyenletek rendszerét, és oldd meg, hogy megkapd a túlhatározott rendszer legkisebb négyzetes megoldását! Hasonlítsd össze az eredményed a (b) részben kapottakkal!
- **3.2.** Tegyük fel, hogy egy egyenest illesztesz a $(0, 1)$, $(1, 2)$, $(3, 3)$ három adatponthoz.
- (a) Írd fel a legkisebb négyzetes feladat túlhatározott lineáris egyenletrendszerét!

- (b) Írd fel a hozzá tartozó normálegyenleteket!
- (c) Számítsd ki a legkisebb négyzetes megoldást Cholesky-felbontással!
- **3.3.** Írd fel az $Ax \cong b$ lineáris legkisebb négyzetes rendszert az $f(t,x) = x_1 t + x_2 e^t$ modellfüggvénynek az $(1,2)$, $(2,3)$, $(3,5)$ három adatponthoz való illesztéséhez!
- **3.4.** Egy $y = x_0 + x_1 t$ egyenesnek a $(t_i, y_i) = (0,0), (1,0), (1,1)$ három adatponthoz való illesztésekor egyértelmű-e a legkisebb négyzetes megoldás? Miért?
- **3.5.** Legyen x az $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldása, ahol

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}.$$

Legyen $r = b - Ax$ a hozzá tartozó reziduumvektor. Az alábbi három vektor közül melyik lehet r lehetséges értéke? Miért?

$$(a) \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \qquad (b) \begin{bmatrix} -1 \\ -1 \\ 1 \\ 1 \end{bmatrix} \qquad (c) \begin{bmatrix} -1 \\ 1 \\ 1 \\ -1 \end{bmatrix}$$

- **3.6.** (a) Mi a minimális reziduumvektor euklideszi normája az alábbi lineáris legkisebb négyzetes feladat esetén?

$$\begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \cong \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix}$$

(b) Mi ennek a feladatnak az x megoldásvektora?

- **3.7.** Legyen A egy $m \times n$-es mátrix és b egy m-dimenziós vektor. (a) Bizonyítsd be, hogy az $Ax \cong b$ legkisebb négyzetes feladatnak mindig van megoldása! (b) Bizonyítsd be, hogy az ilyen megoldás akkor és csak akkor egyértelmű, ha $\operatorname{rank}(A) = n$!
- **3.8.** Tegyük fel, hogy A egy n rangú $m \times n$-es mátrix. Bizonyítsd be, hogy az $A^T A$ mátrix pozitív definit!
- **3.9.** Bizonyítsd be, hogy a 3.4.2. szakaszban szereplő bővített rendszer mátrixa *nem* lehet pozitív definit!
- **3.10.** Legyen B egy $n \times n$-es mátrix, és tegyük fel, hogy B egyszerre ortogonális és háromszögmátrix.
- (a) Bizonyítsd be, hogy B-nek diagonálisnak kell lennie!
- (b) Melyek B főátlóbeli elemei?
- (c) Legyen A egy $n \times n$-es reguláris mátrix. Az (a) és (b) részek felhasználásával bizonyítsd be, hogy A QR-felbontása egyértelmű az R főátlóbeli elemeinek előjelétől eltekintve!

Konkrétabban, léteznek olyan egyértelmű Q és R mátrixok, amelyekre Q ortogonális, R felső háromszögmátrix pozitív elemekkel a főátlóban, és $A = QR$.

- **3.11.** Tegyük fel, hogy a

$$\begin{bmatrix} A & B \\ O & C \end{bmatrix}$$

particionált mátrix ortogonális, ahol az A és C almátrixok négyzetesek. Bizonyítsd be, hogy A és C szükségképpen ortogonálisak, és $B = O$!

- **3.12.** (a) Legyen A egy $n \times n$-es mátrix. Mutasd meg, hogy az alábbi feltételek közül bármely kettőből következik a harmadik:
- 1. $A^T = A$
- 2. $A^T A = I$
- 3. $A^2 = I$
- (b) Adj konkrét példát – az I egységmátrixon vagy annak permutációján kívül – egy olyan 3×3-as mátrixra, amely mindhárom tulajdonsággal rendelkezik!
- (c) Nevezz meg egy nemtriviális mátrixosztályt, amelynek elemei mindhárom tulajdonsággal rendelkeznek!
- **3.13.** Ha A egyszerre ortogonális mátrix és ortogonális projektor, mit tudsz mondani A-ról?
- **3.14.** Mutasd meg, hogy ha a $v \neq 0$ vektor, akkor a

$$H = I - 2\,\frac{vv^T}{v^T v}$$

mátrix ortogonális és szimmetrikus!

- **3.15.** Legyen a tetszőleges nem nulla vektor. Ha $v = a - \alpha e_1$, ahol $\alpha = \pm\|a\|_2$, és

$$H = I - 2\,\frac{vv^T}{v^T v},$$

mutasd meg, hogy $Ha = \alpha e_1$!

- **3.16.** Tekintsd az a vektort $n \times 1$-es mátrixként.
- (a) Írd fel a redukált QR-felbontását, és mutasd be explicit módon a Q és R mátrixokat!
- (b) Mi az $ax \cong b$ lineáris legkisebb négyzetes feladat megoldása, ahol b egy adott n-dimenziós vektor?
- **3.17.** Határozd meg azt a Householder-transzformációt, amely az $\begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix}^T$ vektor első elemén kívül minden elemét nullázza! Konkrétabban, ha

$$\left(I - 2\,\frac{vv^T}{v^T v}\right) \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \alpha \\ 0 \\ 0 \\ 0 \end{bmatrix},$$

melyek az α és v értékei?

- **3.18.** Tegyük fel, hogy az

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \end{bmatrix}$$

mátrix QR-felbontását Householder-transzformációkkal számítod. - (a) Hány Householder-transzformációra van szükség? - (b) Mivé válik A első oszlopa az első Householder-transzformáció alkalmazásának eredményeként? - (c) Mivé válik ezután az első oszlop a második Householder-transzformáció alkalmazásának eredményeként? - (d) Hány Givens-forgatásra lenne szükség A QR-felbontásának kiszámításához?

- **3.19.** Tekintsd az

$$a = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}$$

vektort. - (a) Adj meg egy elemi eliminációs mátrixot, amely a harmadik komponensét nullázza! - (b) Adj meg egy Householder-transzformációt, amely a harmadik komponensét nullázza! - (c) Adj meg egy Givens-forgatást, amely a harmadik komponensét nullázza! - (d) Egy tetszőleges vektor adott nem nulla komponensének nullázásakor lehetséges-e valaha, hogy a megfelelő elemi eliminációs mátrix és Householder-transzformáció azonos? Miért? - (e) Egy tetszőleges vektor adott nem nulla komponensének nullázásakor lehetséges-e valaha, hogy a megfelelő Householder-transzformáció és Givens-forgatás azonos? Miért?

- **3.20.** Tegyük fel, hogy egy

$$a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}$$

vektor második komponensét szeretnéd nullázni egy Givens-forgatással, de a_1 már eleve nulla. - (a) Lehetséges-e még mindig nullázni a_2-t egy Givens-forgatással? Ha igen, adj meg egy megfelelő Givens-forgatást; ha nem, magyarázd meg, miért! - (b) Ilyen körülmények között nullázható-e a_2 elemi eliminációs mátrixszal? Ha igen, hogyan? Ha nem, miért?

- **3.21.** Egy Givens-forgatást két paraméter, c és s határoz meg, és így egy számítógépes implementációban látszólag két tárolóhelyet igényelne. A két paraméter azonban egyetlen forgatási szögtől függ, így elvileg lehetséges volna a forgatás csupán egyetlen szám tárolásával történő feljegyzése. Dolgozz ki egy sémát a Givens-forgatások tárolására és visszaállítására, amely forgatásonként mindössze egy tárolóhelyet használ!

- **3.22.** Legyen A egy n rangú $m \times n$-es mátrix. Legyen

$$A = Q \begin{bmatrix} R \\ O \end{bmatrix}$$

A QR-felbontása, ahol Q ortogonális és R egy $n \times n$-es felső háromszögmátrix. Legyen $A^T A = LL^T$ az $A^T A$ Cholesky-felbontása. - (a) Mutasd meg, hogy $R^T R = LL^T$! - (b) Következtethetjük-e, hogy $R = L^T$? Miért?

- **3.23.** A 3.4.1. szakaszban megfigyeltük, hogy az $A^T A$ keresztszorzat-mátrix lebegőpontos aritmetikában egzaktul szinguláris, ha

$$A = \begin{bmatrix} 1 & 1 \\ \epsilon & 0 \\ 0 & \epsilon \end{bmatrix},$$

ahol ϵ egy olyan pozitív szám, amely kisebb, mint $\sqrt{\epsilon_{\text{mach}}}$ egy adott lebegőpontos rendszerben. Mutasd meg, hogy ha $A = QR$ ennek az A mátrixnak a redukált QR-felbontása, akkor R nem szinguláris, még lebegőpontos aritmetikában sem!

- **3.24.** Ellenőrizd, hogy egy $m \times n$-es lineáris legkisebb négyzetes feladat normálegyenletekkel és Cholesky-felbontással történő megoldásának műveletszámában (szorzások vagy összeadások számában) a domináns tag $mn^2/2 + n^3/6$!

- **3.25.** Ellenőrizd, hogy egy $m \times n$-es mátrix Householder-transzformációkkal végzett QR-felbontásának műveletszámában (szorzások vagy összeadások számában) a domináns tag $mn^2 - n^3/3$!

- **3.26.** Legyen $c = \cos(\theta)$ és $s = \sin(\theta)$ valamilyen θ szögre. Adj részletes geometriai leírást az alábbi 2×2-es ortogonális mátrixok mindegyikének $\mathbb{R}^2$ euklideszi síkbeli vektorokra gyakorolt hatásairól!

$$(a)\ G = \begin{bmatrix} c & s \\ -s & c \end{bmatrix} \qquad (b)\ H = \begin{bmatrix} -c & s \\ s & c \end{bmatrix}$$

- **3.27.** (a) Tegyük fel, hogy Q egy olyan $n \times k$-s mátrix, amelynek oszlopai ortonormált bázist alkotnak $\mathbb{R}^n$ egy S alterének. Mutasd meg, hogy QQ^T ortogonális projektor S-re!
- (b) Ha A lineárisan független oszlopokkal rendelkező mátrix, mutasd meg, hogy $A(A^T A)^{-1} A^T$ ortogonális projektor a span(A)-ra! Hogyan kapcsolódik ez az eredmény a lineáris legkisebb négyzetes feladathoz?
- (c) Ha P ortogonális projektor egy S altérre, mutasd meg, hogy $I - P$ ortogonális projektor S ortogonális komplementumára!
- (d) Legyen v egy tetszőleges nem nulla n-dimenziós vektor. Mi a v által kifeszített altérre vett ortogonális projektor?
- **3.28.** (a) A 3.5.3. szakasz Gram–Schmidt-eljárásában, ha a $P_k = q_k q_k^T$ $(k = 1, \dots, n)$ ortogonális projektorokat definiáljuk – ahol q_k a kapott QR-felbontásbeli Q k-adik oszlopa –, mutasd meg, hogy

$$(I - P_k)(I - P_{k-1}) \cdots (I - P_1) = I - P_k - P_{k-1} - \cdots - P_1!$$

(b) Mutasd meg, hogy a klasszikus Gram–Schmidt-eljárás ekvivalens a

$$q_k = (I - (P_1 + \cdots + P_{k-1}))a_k$$

formulával!

(c) Mutasd meg, hogy a módosított Gram–Schmidt-eljárás ekvivalens a

$$q_k = (I - P_{k-1}) \cdots (I - P_1) a_k$$

formulával!

(d) A klasszikus eljárás stabilizálásának egy másik módja, hogy többször alkalmazzuk (azaz iteratív finomítás), ami azt jelenti, hogy

$$q_k = (I - (P_1 + \cdots + P_{k-1}))^m a_k,$$

ahol $m = 2$ tipikusan elegendő. Mutasd meg, hogy mindhárom változat matematikailag ekvivalens (bár véges precíziós aritmetikában jelentősen eltérhetnek)!

- **3.29.** Legyen v egy nem nulla n-dimenziós vektor. A v-re merőleges hipersík azoknak a z vektoroknak az $(n-1)$-dimenziós altere, amelyekre $v^T z = 0$. Egy R reflektor olyan lineáris transzformáció, amelyre $Rx = -x$, ha x a v skalárszorosa, és $Rx = x$, ha $v^T x = 0$. Így a hipersík tükörként viselkedik: tetszőleges vektor hipersíkon belüli komponense változatlan marad, míg a hipersíkra ortogonális komponense előjelet vált.
- (a) Mutasd meg, hogy $R = 2P - I$, ahol P a v-re merőleges hipersíkra vett ortogonális projektor! Rajzolj ábrát az eredmény szemléltetésére!
- (b) Mutasd meg, hogy R szimmetrikus és ortogonális!
- (c) Mutasd meg, hogy a

$$H = I - 2\,\frac{vv^T}{v^T v}$$

Householder-transzformáció reflektor! - (d) Mutasd meg, hogy bármely két s és t vektorra, amelyekre $s \neq t$ és $\|s\|_2 = \|t\|_2$, létezik olyan R reflektor, amelyre $Rs = t$! - (e) Mutasd meg, hogy bármely Q ortogonális mátrix reflektorok szorzata! - (f) Szemléltesd az előző eredményt azzal, hogy a

$$\begin{bmatrix} c & s \\ -s & c \end{bmatrix}$$

síkbeli forgatást – ahol $c^2 + s^2 = 1$ – két reflektor szorzataként fejezed ki! Konkrét forgatási szögre rajzolj ábrát a tükrök bemutatására!

- **3.30.** (a) Tekintsd az a oszlopvektort $n \times 1$-es mátrixként. Írd fel a redukált szingulárisérték-felbontását, és mutasd be explicit módon az U, Σ és V mátrixokat!
- (b) Tekintsd az a^T sorvektort $1 \times n$-es mátrixként. Írd fel a redukált SVD-jét, és mutasd be explicit módon az U, Σ és V mátrixokat!
- **3.31.** Ha A egy $m \times n$-es mátrix és b egy m-dimenziós vektor, bizonyítsd be, hogy az $Ax \cong b$ legkisebb négyzetes feladat minimális euklideszi normájú x megoldását a

$$x = \sum_{\sigma_i \neq 0} \frac{u_i^T b}{\sigma_i}\, v_i$$

képlet adja, ahol a σ_i, u_i és v_i az A szinguláris értékei és a megfelelő szinguláris vektorai!

- **3.32.** Bizonyítsd be, hogy egy $m \times n$-es A mátrix A^+ pszeudoinverze – ahogyan azt a 3.6.1. szakaszban az SVD segítségével definiáltuk – teljesíti az alábbi négy tulajdonságot, amelyeket Moore–Penrose-feltételeknek nevezünk.
- (a) $AA^+A = A$.
- (b) $A^+AA^+ = A^+$.
- (c) $(AA^+)^T = AA^+$.
- (d) $(A^+A)^T = A^+A$.
- **3.33.** Bizonyítsd be, hogy egy $m \times n$-es A mátrix A^+ pszeudoinverze – ahogyan azt a 3.6.1. szakaszban az SVD segítségével definiáltuk – az alábbi speciális esetek mindegyikében a megadott értéket veszi fel.
- (a) Ha $m = n$ és A reguláris, akkor $A^+ = A^{-1}$.
- (b) Ha $m > n$ és A rangja n, akkor $A^+ = (A^TA)^{-1}A^T$.
- (c) Ha $m < n$ és A rangja m, akkor $A^+ = A^T(AA^T)^{-1}$.
- **3.34.** (a) Mi az alábbi mátrix pszeudoinverze?

$$A_0 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

(b) Ha $\epsilon > 0$, mi az alábbi mátrix pszeudoinverze?

$$A_\epsilon = \begin{bmatrix} 1 & 0 \\ 0 & \epsilon \end{bmatrix}$$

(c) Mit implikálnak ezek az eredmények egy adott mátrix pszeudoinverzének kiszámítási feladatának kondicionáltságára?

Számítógépes feladatok

- **3.1.** $n = 0, 1, \ldots, 5$ esetén illessz legkisebb négyzetek módszerével n-edfokú polinomot az alábbi adatokra:

t	−1,0	−0,5	0,0	0,5	1,0	1,5	2,0	2,5	3,0	3,5	4,0
y	1,0	0,5	0,0	0,5	2,0	3,5	3,0	2,5	2,5	3,0	3,5

Készíts ábrát az eredeti adatpontokról és mindegyik kapott polinomgörbéről (készíthetsz külön grafikont minden görbéhez, vagy egyetlen, az összes görbét tartalmazó grafikont). Melyik polinomot mondanád olyannak, amely jobban megragadja az adatok általános trendjét? Nyilvánvalóan ez szubjektív kérdés, és a válasza egyaránt függ az adott adatok természetétől (pl. az adatértékek bizonytalanságától) és az illesztés céljától. Magyarázd meg a válaszadáshoz tett feltételezéseidet!

- **3.2.** A földmérésben gyakori feladat egy sor pont magasságának meghatározása egy referenciaponthoz képest. A mérések hibával terheltek, ezért több megfigyelést végzünk, mint amennyi a magasságok meghatározásához szigorú értelemben szükséges volna, és a kapott túlhatározott rendszert legkisebb négyzetes értelemben oldjuk meg a hibák kisimítására. Tegyük fel, hogy négy pont van, amelyek x_1, x_2, x_3, x_4 magasságát kell meghatározni. Az egyes x_i-k referenciaponthoz viszonyított közvetlen mérésein túl méréseket végzünk az egyes pontokra a többi pont mindegyikéhez viszonyítva is. A kapott mérések:

$$
\begin{aligned}
x_1 &= 2{,}95, & x_2 &= 1{,}74, & x_3 &= -1{,}45, & x_4 &= 1{,}32,\\
x_1 - x_2 &= 1{,}23, & x_1 - x_3 &= 4{,}45, & x_1 - x_4 &= 1{,}61,\\
x_2 - x_3 &= 3{,}21, & x_2 - x_4 &= 0{,}45, & x_3 - x_4 &= -2{,}75.
\end{aligned}
$$

Írd fel a hozzá tartozó $Ax \cong b$ legkisebb négyzetes rendszert, és egy könyvtári rutinnal – vagy egy saját tervezésűvel – oldd meg, hogy a magasságok legjobb értékeit megkapd! Hogyan viszonyulnak a számított értékek a közvetlen mérésekhez?

- **3.3.** (a) Egy sor n-ed rendű A mátrixra jegyezd fel egy könyvtári rutin A LU-felbontásának kiszámításához szükséges futási idejét! Egy lineáris legkisebb négyzetes rutin – vagy egy saját tervezésű – használatával illessz harmadfokú polinomot a futási időkre n függvényében! Megbízható eredmények elérése érdekében használj meglehetősen széles n-tartományt, mondjuk 100-tól kezdve több százig, 100-as lépésekben, az általad használt számítógép sebességétől és rendelkezésre álló memóriájától függően. Pontosabb időmérést kaphatsz, ha adott mátrixméretnél több futást átlagolsz. A kapott harmadfokú polinom felhasználható lenne más, ki nem próbált n-értékekre – például nagyon nagy n-értékekre – való futási idő előrejelzésére. Mi az előrejelzett futási idő egy 10 000-ed rendű mátrixra?
- (b) Próbáld meg meghatározni a számítógéped alapvető végrehajtási sebességét (lebegőpontos műveletek másodpercenkénti számában, azaz FLOP-okban) egy ismert számítás – például mátrixszorzás – időmérésével! Ezután ezt az információt felhasználhatod arra, hogy a futási időkre illesztett polinom alapján meghatározd az LU-felbontás komplexitását. Lebegőpontos műveletekre átváltva hogyan viszonyul a domináns tag a $4n^3/3$ elméletileg várt értékhez (mind az összeadásokat, mind a szorzásokat számolva)? Próbáld megmagyarázni az eltérést! Ha olyan rendszert használsz, amely automatikusan szolgáltat műveletszámokat, próbáld ki ugyanezt a kísérletet úgy is, hogy közvetlenül a műveletszámokra illesztesz!
- **3.4.** (a) Oldd meg az alábbi legkisebb négyzetes feladatot tetszőleges módszerrel!

$$
\begin{bmatrix} 0{,}16 & 0{,}10 \\ 0{,}17 & 0{,}11 \\ 2{,}02 & 1{,}29 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \cong \begin{bmatrix} 0{,}26 \\ 0{,}28 \\ 3{,}31 \end{bmatrix}.
$$

(b) Most oldd meg ugyanazt a legkisebb négyzetes feladatot újra, de ezúttal használd az enyhén perturbált

$$
b = \begin{bmatrix} 0{,}27 \\ 0{,}25 \\ 3{,}33 \end{bmatrix}
$$

jobb oldali vektort!

(c) Hasonlítsd össze az (a) és (b) részekből származó eredményeidet! Meg tudod-e magyarázni ezt a különbséget?

- **3.5.** Egy bolygó ellipszispályán mozog, amely egy (x, y) derékszögű koordináta-rendszerben az

$$
ay^2 + bxy + cx + dy + e = x^2
$$

egyenlettel ábrázolható.

(a) Egy lineáris legkisebb négyzetes könyvtári rutinnal – vagy egy saját tervezésűvel – határozd meg az a, b, c, d, e pályaparamétereket a bolygó helyzetének alábbi megfigyelései alapján:

x	1,02	0,95	0,87	0,77	0,67	0,56	0,44	0,30	0,16	0,01
y	0,39	0,32	0,27	0,22	0,18	0,15	0,13	0,12	0,13	0,15

A pályaparaméterek értékeinek kinyomtatása mellett ábrázold a kapott pályát és a megadott adatpontokat is az (x, y) síkon.

- (b) Ez a legkisebb négyzetes feladat majdnem ranghiányos. Hogy lásd, ennek milyen hatása van a megoldásra, perturbáld az input adatokat enyhén úgy, hogy minden adatpont minden koordinátájához adsz egy $[-0{,}005, 0{,}005]$ intervallumon egyenletes eloszlású véletlen számot (lásd a 13.5. szakaszt), és oldd meg a legkisebb négyzetes feladatot a perturbált adatokkal! Hasonlítsd össze a paraméterek új értékeit a korábban kiszámítottakkal! Milyen hatással van ez a különbség a pálya ábrájára? Meg tudod-e magyarázni ezt a viselkedést?

- (c) Oldd meg ugyanazt a legkisebb négyzetes feladatot újra, mind az eredeti, mind a perturbált adatokra, ezúttal olyan könyvtári rutinnal (vagy egy saját tervezésűvel), amelyet kifejezetten ranghiány kezelésére terveztek (például oszloponkénti főelemkiválasztással)! Egy ilyen rutin általában bemeneti paraméterként tartalmaz egy toleranciát a mátrix numerikus rangjának meghatározásához. Kísérletezz különböző toleranciaértékekkel, mondjuk 10^{-k}-val, $k = 1, \dots, 5$ mellett. Mi a mátrix kapott rangja az egyes toleranciaértékekre? Hasonlítsd össze a két megoldás (az eredeti és a perturbált adatokra vonatkozó) viselkedését egymással, ahogy a tolerancia és a kapott rang változik! Mennyire jól illeszkednek a kapott pályák az adatpontokra, ahogy a tolerancia és a rang változik? Melyik megoldást tartanád jobbnak: azt, amelyik szorosabban illeszkedik az adatokra, vagy azt, amelyik kevésbé érzékeny az adatok kis perturbációira? Miért?

- (d) Egy könyvtári rutinnal számítsd ki a 10×5-ös legkisebb négyzetes mátrix szingulárisérték-felbontását!

- (e) A szingulárisérték-felbontás segítségével számítsd ki a legkisebb négyzetes feladat megoldását! A szinguláris értékeket nagyságuk szerinti csökkenő sorrendbe rendezve számítsd ki a megoldásokat az első k szinguláris érték használatával, $k = 1, \dots, 5$ mellett. A kapott öt megoldás mindegyikére nyomtasd ki a pályaparaméterek értékeit, és ábrázold is a kapott pályákat a megadott adatpontokkal együtt az (x, y) síkon!

- (f) Perturbáld az input adatokat enyhén úgy, hogy minden adatpont minden koordinátájához adsz egy $[-0{,}005, 0{,}005]$ intervallumon egyenletes eloszlású véletlen számot (lásd a 13.5. szakaszt)! Számítsd ki az új legkisebb négyzetes mátrix szingulárisérték-felbontását, és oldd meg a legkisebb négyzetes feladatot a perturbált adatokkal az (e) résznek megfelelően! Hasonlítsd össze a paraméterek új értékeit a korábban kiszámítottakkal minden k-ra! Milyen hatással van ez a különbség a pályák ábrájára? Meg tudod-e magyarázni ezt a viselkedést? Melyik megoldást tartanád jobbnak: azt, amelyik szorosabban illeszkedik az adatokra, vagy azt, amelyik kevésbé érzékeny az adatok kis perturbációira? Miért?

- (g) Az egyszerűség kedvéért közönséges legkisebb négyzeteket használtunk ebben a feladatban, valójában azonban minden adat ugyanúgy ki van téve a megfigyelési hibáknak (valóban, x az egyenlet mindkét oldalán megjelenik), ami kérdésessé teszi a közönséges legkisebb négyzetek alkalmazhatóságát. Fogalmazd át ezt a feladatot teljes legkisebb négyzetes feladattá, és oldd meg az utóbbit a szingulárisérték-felbontással, ahogy a 3.6.1. szakaszban leírtuk!

- **3.6.** Írj rutint egy tetszőleges $m \times n$-es mátrix pszeudoinverzének kiszámítására! Hívhatsz könyvtári rutint a szingulárisérték-felbontás kiszámítására, majd a kimenete alapján számítsd ki a pszeudoinverzet (lásd a 3.6.1. szakaszt)! Vedd figyelembe a viszonylag kis szinguláris értékek nullának nyilvánításához használt tolerancia alkalmazását. Teszteld a rutinodat szinguláris és reguláris mátrixokon egyaránt! Az utóbbi esetben természetesen az eredményeidnek egyezniük kell a standard mátrixinvertálás eredményeivel. Mi történik, ha a mátrix reguláris, de súlyosan rosszul kondicionált (pl. egy Hilbert-mátrix)?

- **3.7.** Írj rutint egy tetszőleges, esetlegesen ranghiányos $Ax \cong b$ lineáris legkisebb négyzetes feladat megoldására a szingulárisérték-felbontás segítségével! Hívhatsz könyvtári rutint az SVD kiszámítására, majd a kimenete alapján számítsd ki a legkisebb négyzetes megoldást (lásd a 3.6. szakaszt)! A rutinod bemenetének tartalmaznia kell az A mátrixot, a b jobb oldali vektort és egy toleranciát az A numerikus rangjának meghatározásához. Teszteld a rutinodat a fejezet egyéb számítógépes feladataiban szereplő lineáris legkisebb négyzetes feladatok némelyikén!

- **3.8.** Annak bemutatására, hogy a normálegyenletek módszere és a QR-felbontás eredményei numerikusan hogyan térhetnek el, olyan legkisebb négyzetes feladatra van szükségünk, amely rosszul kondicionált és emellett kis reziduummal rendelkezik. Ilyen feladatot a következőképpen generálhatunk. $n-1$-edfokú polinomot,

$$p_{n-1}(t) = x_1 + x_2 t + x_3 t^2 + \cdots + x_n t^{n-1},$$

illesztünk m darab (t_i, y_i) adatpontra, ahol $m > n$. A $t_i = (i-1)/(m-1)$, $i = 1, \ldots, m$ választással az adatpontok egyenletesen oszlanak el a $[0, 1]$ intervallumon. A hozzájuk tartozó y_i értékeket úgy generáljuk, hogy először értékeket választunk az x_j-kre, mondjuk $x_j = 1$, $j = 1, \ldots, n$, és a kapott polinomot kiértékeljük, hogy megkapjuk az $y_i = p_{n-1}(t_i)$, $i = 1, \ldots, m$ értékeket. Most megnézhetnénk, vissza tudjuk-e nyerni azokat az x_j-ket, amelyeket az y_i-k generálására használtunk, de hogy érdekesebbé tegyük, először véletlenszerűen perturbáljuk az y_i értékeket, hogy a legkisebb négyzetes feladatokra jellemző adathibát szimuláljuk. Konkrétan az $y_i = y_i + (2u_i - 1) * \epsilon$, $i = 1, \ldots, m$ értékeket vesszük, ahol minden u_i egy $[0, 1)$ intervallumon egyenletes eloszlású véletlen szám (lásd a 13.5. szakaszt), és ϵ egy kicsi pozitív szám, amely a maximális perturbációt határozza meg. Ha IEEE dupla precíziót használsz, ehhez a feladathoz ésszerű paraméterek az $m = 21$, $n = 12$ és $\epsilon = 10^{-10}$.

Miután a fent vázolt módon generáltad a (t_i, y_i) adathalmazt, most összehasonlítjuk a két módszert a legkisebb négyzetes megoldás kiszámítására ehhez a polinomillesztési feladathoz. Először írd fel a feladathoz tartozó normálegyenletek rendszerét, és oldd meg egy Cholesky-felbontást végző könyvtári rutinnal! Ezután oldd meg a legkisebb négyzetes rendszert egy QR-felbontást végző könyvtári rutinnal! Hasonlítsd össze a két kapott x megoldásvektort! Melyik módszernél érzékenyebb a megoldás az adatokba bevitt perturbációra? Melyik módszer közelíti meg jobban azt az x-et, amelyet az adatok generálására használtunk? Az, hogy a megoldások eltérnek,

befolyásolja-e azt, hogy a (t_i, y_i) adatpontokat közel tudjuk-e illeszteni a polinommal? Miért?

- **3.9.** Használd a 3.4.2. szakasz bővített rendszer módszerét az előző feladatban levezetett legkisebb négyzetes feladat megoldására! A bővített rendszer szimmetrikus, de nem pozitív definit, ezért a Cholesky-felbontás nem alkalmazható, de használhatsz szimmetrikus indefinit vagy LU-felbontást. Kísérletezz az α skálázási paraméter különféle értékeivel! Hogyan viszonyul ennek a módszernek a pontossága és futási ideje a normálegyenletek és a QR-felbontás módszereinek pontosságához és futási idejéhez?

- **3.10.** Az $m \times n$-es $Ax \cong b$ legkisebb négyzetes feladat kovarianciamátrixát $\sigma^2(A^TA)^{-1}$ adja, ahol $\sigma^2 = \|b - Ax\|_2^2/(m-n)$ a legkisebb négyzetes x megoldásnál. E mátrix elemei fontos információt tartalmaznak az illesztés jóságáról és az illesztett paraméterek közötti keresztkorrelációkról. A kovarianciamátrix kivételt képez azon általános szabály alól, hogy mátrixok inverzét nem szabad explicit módon kiszámítani. Ha a legkisebb négyzetes feladat megoldására ortogonalizációs módszert használunk, akkor az A^TA keresztszorzat-mátrix sosem képződik, tehát alternatív módszerre van szükségünk a kovarianciamátrix kiszámítására.

- (a) Mutasd meg, hogy $(A^TA)^{-1} = (R^TR)^{-1}$, ahol R az A QR-felbontásával kapott felső háromszögű tényező!

- (b) Erre a tényre alapozva valósíts meg egy rutint, amely a kovarianciamátrixot csak a már kiszámított R segítségével számítja ki! (E feladat céljaira figyelmen kívül hagyhatod a σ^2 skalártényezőt.) Teszteld a rutinodat néhány példamátrixon, hogy megerősítsd: ugyanazt az eredményt adja, mint $(A^TA)^{-1}$ kiszámítása!

- **3.11.** Az $m \times n$-es A mátrix QR-felbontásának kiszámítására szolgáló legtöbb könyvtári rutin az R mátrixot az A tárolási területének felső háromszögében, a Householder-vektorokat pedig A alsó háromszögében adja vissza, egy további vektorral a főátló menti átfedés kezelésére. Írj egy rutint, amely ezt a kimeneti tömböt és kisegítő vektort fogadja, és explicit módon előállítja a Q ortogonális mátrixot úgy, hogy a Householder-transzformációk megfelelő sorozatával megszoroz egy $m \times m$-es mátrixot, amelyet az I egységmátrixra inicializáltunk. Természetesen ehhez külön tömbre lesz szükség. Teszteld a programodat több mátrixon, és erősítsd meg, hogy a számított Q valóban ortogonális, és hogy a

$$Q \begin{bmatrix} R \\ O \end{bmatrix}$$

szorzat visszaadja A-t!

- **3.12.** (a) Valósítsd meg mind a klasszikus, mind a módosított Gram–Schmidt-eljárást, és mindkettővel generálj olyan Q ortogonális mátrixot, amelynek oszlopai ortonormált bázist alkotnak a H Hilbert-mátrix oszlopterére, ahol $h_{ij} = 1/(i+j-1)$, $n = 2, \ldots, 12$ esetén (lásd a 2.6. számítógépes feladatot). Az eredmények minőségének mérésére (konkrétabban az ortogonalitás esetleges elvesztésének) ábrázold a $-\log_{10}(\|I - Q^TQ\|)$ mennyiséget – amelyet „pontosságjegyek” értelmében lehet értelmezni – minden módszernél n függvényében! Emellett próbáld meg a klasszikus eljárást kétszer alkalmazni (azaz alkalmazd a klasszikus Gram–Schmidt-rutinodat a saját Q kimenetére, hogy új Q-t kapj), és megint ábrázold a kapott ortogonalitástól való eltérést! Hogyan viszonyul a három módszer sebességben, memóriában és pontosságban?

- (b) Ismételd meg az előző kísérletet, de ezúttal használd a Householder-módszert, azaz az explicit módon kiszámított Q ortogonális mátrixot, amely a Hilbert-mátrix Householder-féle QR-felbontásából származik! Ne feledd, hogy ha a Householder-féle QR-felbontáshoz használt rutin nem állítja elő explicit módon a Q-t, akkor a Q-t úgy kaphatod meg, hogy a Householder-transzformációk sorozatát megszorzod egy I egységmátrixra inicializált mátrixszal (lásd az előző feladatot). Megint ábrázold ennek a módszernek az ortogonalitástól való eltérését, és hasonlítsd össze a korábbi módszerekével!
- (c) Ismételd meg az előző kísérletet, de ezúttal az SVD-t használd az ortonormált bázis megszerzésére (lásd a 3.6.1. szakaszt)!
- (d) Ortonormált bázis kiszámításának még egy módja a normálegyenletek használata. Ha képezzük a keresztszorzat-mátrixot, és kiszámítjuk az $A^T A = LL^T$ Cholesky-felbontását, akkor

$$I = L^{-1}(A^T A)L^{-T} = (AL^{-T})^T(AL^{-T}),$$

ami azt jelenti, hogy a $Q = AL^{-T}$ ortogonális, és az oszloptere nyilvánvalóan ugyanaz, mint A-é. Ismételd meg az előző kísérletet megint Hilbert-mátrixokkal, ezúttal az így a normálegyenletekből kapott Q-t használva (a szükséges háromszögű megoldás kiszámítása az általad használt szoftvertől függően kissé trükkös lehet)! Megint ábrázold a kapott ortogonalitástól való eltérést, és hasonlítsd össze a korábbi módszerekével! - (e) Meg tudod-e magyarázni az ezekben a kísérletekben a különféle módszerekkel kapott eredmények relatív minőségét?

- **3.13.** Mi az egzakt x megoldása az

$$\begin{bmatrix} 1 & 1 & 1 \\ \epsilon & 0 & 0 \\ 0 & \epsilon & 0 \\ 0 & 0 & \epsilon \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \cong \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

lineáris legkisebb négyzetes feladatnak ϵ függvényében?

Oldd meg ezt a legkisebb négyzetes feladatot az alábbi módszerek mindegyikével! Minden módszernél kísérletezz az ϵ paraméter értékével, hogy lásd, milyen kicsire veheted, és még mindig pontos megoldást kapj! Különös figyelmet fordíts az $\epsilon \approx \sqrt{\epsilon_{\text{mach}}}$ és $\epsilon \approx \epsilon_{\text{mach}}$ körüli értékekre.

- (a) Normálegyenletek.
- (b) Bővített rendszer.
- (c) Householder-féle QR.
- (d) Givens-féle QR.
- (e) Klasszikus Gram–Schmidt-ortogonalizáció.
- (f) Módosított Gram–Schmidt-ortogonalizáció.
- (g) Klasszikus Gram–Schmidt iteratív finomítással (azaz kétszer alkalmazott CGS).